

# Dissertação de Mestrado

Análise Bayesiana aplicada à modelagem dos processos de interceptação e de chuva-vazão em duas bacias florestais

Debora Yumi de Oliveira



Universidade Federal de Santa Catarina  
Programa de Pós-graduação em  
Engenharia Ambiental



Debora Yumi de Oliveira

**ANÁLISE BAYESIANA APLICADA À MODELAGEM DOS  
PROCESSOS DE INTERCEPTAÇÃO E CHUVA-VAZÃO EM  
DUAS BACIAS FLORESTAIS**

Dissertação submetida ao Programa de Pós-graduação em Engenharia Ambiental da Universidade Federal de Santa Catarina como parte dos requisitos para a obtenção do Grau de Mestre em Engenharia Ambiental. Orientador: Prof. Dr. Pedro Luiz Borges Chaffe

Florianópolis  
2018

Ficha de identificação da obra elaborada pelo autor,  
através do Programa de Geração Automática da Biblioteca Universitária da UFSC.

Oliveira, Debora Yumi de Oliveira  
Análise Bayesiana aplicada à modelagem dos  
processos de interceptação e chuva-vazão em duas  
bacias florestais / Debora Yumi de Oliveira  
Oliveira ; orientador, Pedro Luiz Borges Chaffé  
Chaffé, 2018.  
305 p.

Dissertação (mestrado) - Universidade Federal de  
Santa Catarina, Centro Tecnológico, Programa de Pós  
Graduação em Engenharia Ambiental, Florianópolis,  
2018.

Inclui referências.

1. Engenharia Ambiental. 2. inferência  
Bayesiana. 3. interceptação. 4. chuva-vazão. 5.  
análise de incerteza. I. Chaffé, Pedro Luiz Borges  
Chaffé. II. Universidade Federal de Santa Catarina.  
Programa de Pós-Graduação em Engenharia Ambiental.  
III. Título.



UNIVERSIDADE FEDERAL DE SANTA CATARINA  
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA AMBIENTAL  
CENTRO TECNOLÓGICO



**"ANÁLISE BAYESIANA APLICADA À MODELAGEM DOS PROCESSOS DE  
INTERCEPTAÇÃO E DE CHUVA-VAZÃO EM DUAS BACIAS FLORESTAIS"**

**DEBORA YUMI DE OLIVEIRA**

Dissertação submetida ao corpo docente do Programa de Pós-Graduação em Engenharia Ambiental da Universidade Federal de Santa Catarina como parte dos requisitos necessários para obtenção do grau de

**MESTRE EM ENGENHARIA AMBIENTAL**

na Área de Engenharia Ambiental.

Aprovado por:

Prof. Dr. Pedro Luiz Borges Chalé  
(Orientador)

Prof. Dr. Davide Franco

Prof.ª Dr.ª Nadia Bernardi Bonumá

Prof. Dr. Roberto Valmir da Silva

Prof.ª Dr.ª Mânia Eliza Nagel Hassemer  
(Coordenadora)

FLORIANÓPOLIS, SC – BRASIL  
MARÇO/2018



## **AGRADECIMENTOS**

Ao Prof. Pedro, por estar sempre nos apresentando o que existe de melhor na pesquisa científica ao redor do mundo, pelo esforço contínuo em promover um ambiente de trabalho agradável, pelo incentivo constante e pela confiança depositada em mim.

À Aline, ao João e ao Prof. Pedro, pela disponibilização dos valiosos dados necessários para elaboração deste trabalho.

A todos do LabHidro que me acompanharam durante estes dois anos de mestrado. Ao Daniel e à Ana, pelos bons momentos de discussão que me fizeram aprender muito. Agradeço em especial à Paula, que teve um papel fundamental na execução deste trabalho, iniciando todo o trabalho com o SUPERFLEX e tornando a busca pela likelihood perfeita mais divertida e menos desafiadora.

Aos professores Nadia Bernardi Bonumá, Davide Franco e Roberto Valmir da Silva por todo o tempo dedicado em contribuir para a melhoria deste trabalho.

Aos meus amigos e minha família, por estarem sempre torcendo pelo meu sucesso e, sobretudo, pela minha felicidade.

Ao Programa de Pós-graduação em Engenharia Ambiental (PPGEA) da Universidade Federal de Santa Catarina por todo o apoio.

Ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPQ) pelo auxílio financeiro.

Muito obrigada!



## RESUMO

Modelos são representações simplificadas da realidade. Devido a simplificações dos modelos de sistemas ambientais, assim como a existência de diversos erros envolvidos no processo de modelagem, todo estudo de modelagem está necessariamente sujeito a incertezas. A inferência Bayesiana permite a estimativa conjunta dos valores dos parâmetros do modelo e da incerteza associada às simulações. A principal dificuldade na utilização da inferência Bayesiana nesse processo reside na formulação de uma função de verossimilhança que represente os resíduos de maneira adequada. Nesta dissertação buscou-se identificar funções de verossimilhança que se adequem à representação dos resíduos de modelos de interceptação e chuva-vazão. Os modelos foram aplicados a duas bacias florestais: a bacia do rio Saci, coberta majoritariamente por reflorestamento de pinus; e a bacia do rio Araponga, com vegetação nativa. A partir da escolha de uma função de verossimilhança adequada, foram investigados (1) o uso de diferentes formulações para representar o processo de interceptação e chuva-vazão e (2) a influência do processo de interceptação na simulação do processo chuva-vazão. A seleção entre os diferentes modelos testados foi realizada com base na qualidade da faixa de incerteza associada aos resultados das simulações e nos valores dos critérios de informação de Akaike e de Bayes. A escolha da função de verossimilhança impactou a qualidade da faixa de incerteza, os valores dos parâmetros obtidos na inferência e os valores de critério de informação. Este resultado indica que a escolha da função de verossimilhança é uma etapa fundamental do processo de modelagem. O processo de interceptação foi melhor descrito por formulações que separam o armazenamento e transferência da água na vegetação da parte da água da chuva que atinge o solo diretamente passando pelos vazios da copa. A geração de escoamento nas duas bacias foi melhor representada por modelos que incluem um reservatório da zona não saturada seguido por dois reservatórios conectados em paralelo, um representando o movimento rápido da água por meio de caminhos preferenciais, e outro representando a resposta mais lenta da bacia. A consideração explícita do processo de interceptação na modelagem chuva-vazão resultou em maiores valores para o valor máximo da função de verossimilhança; porém, sem afetar de maneira significativa a qualidade da faixa de incerteza.

**Palavras-chave:** modelagem, interceptação, chuva-vazão, análise de incerteza, inferência Bayesiana



## ABSTRACT

Models are simplifications of the system being modeled. Therefore, they are not intended to represent exactly all the processes that occur in nature and their interactions. Due to this intrinsic simplification, as well as many sources of errors in the modeling process, every modeling exercise is subject to uncertainty. Bayesian inference allows the joint inference of model parameters and the uncertainty in model predictions. The main difficulty associated with the use of Bayesian inference for that purpose is the formulation of a likelihood function that correctly represents model residuals. In this study, different likelihood functions were tested in terms of their ability to represent the residuals from interception and rainfall-runoff models. These models were applied to two forested catchments: the Saci river catchment, mainly covered by pine plantation; and the Araponga river catchment, covered by native forest. Once the likelihood function was identified, the following investigations were conducted: (1) the comparison of different formulations used to represent the interception and the rainfall-runoff processes; and (2) the influence of explicitly considering the interception process in rainfall-runoff modeling. The selection between competing models with different complexity levels was carried out by analyzing the quality of the predictive uncertainty and by using the Akaike and the Bayes information criteria. The choice of the likelihood function impacted the quality of the predictive uncertainty, the posterior parameter distribution and the values of the information criteria. This result indicates that the choice of the likelihood function is an extremely important step of the modeling process. The interception process was better described by formulations that separate the routing of water through the vegetation from the portion of rainfall that reaches directly the forest floor by passing through the gaps in the canopy. The runoff generation in the two basins were better represented by formulations that include an unsaturated soil reservoir followed by two reservoirs connected in parallel, one representing the fast movement of water through preferential flowpaths and the other representing a slower response of the watersheds. The explicit consideration of the interception process in rainfall-runoff modeling always resulted in higher maximum likelihood values; however, without a significant impact in the quality of the predictive uncertainty.

**Keywords:** modeling, interception, rainfall-runoff, uncertainty analysis, Bayesian inference



## LISTA DE FIGURAS

<b>Figura 1.</b> Representação esquemática da calibração de um modelo. Os parâmetros do modelo são ajustados iterativamente a fim de que os resultados simulados (linha sólida) se aproximem ao máximo da resposta observada (linha pontilhada) (adaptado de Vrugt et al., 2008). ....	37
<b>Figura 2.</b> Fontes de incerteza envolvidas no processo de modelagem (traduzido de Sadegh e Vrugt, 2013).....	38
<b>Figura 3.</b> Faixa de incerteza (intervalo de credibilidade) construída considerando homoscedasticidade (esquerda) ou heteroscedasticidade (direita) dos resíduos. ....	40
<b>Figura 4.</b> Influência do parâmetro de curtose ( $\beta$ ) e de assimetria ( $\zeta$ ) na distribuição <i>skewed exponential power</i> (SCHOUPS; VRUGT, 2010)..	41
<b>Figura 5.</b> Representação esquemática do balanço de massa realizado para a água na vegetação. $P$ é a chuva total, $I_L$ são as perdas por interceptação, $T_f$ é a chuva interna, $S_f$ é o escoamento pelos troncos e $S$ é o armazenamento na vegetação. A linha pontilhada delimita o volume de controle considerado. ....	49
<b>Figura 6.</b> Fluxograma do modelo de Rutter (traduzido de Gash e Morton, 1978). ....	54
<b>Figura 7.</b> Fluxograma do modelo de Rutter modificado (traduzido de Valente, David e Gash, 1997). ....	59
<b>Figura 8.</b> Exemplos de estruturas construídas a partir do método SUPERFLEX (traduzido de Fenicia et al., 2014).....	62
<b>Figura 9.</b> Relação entre complexidade e resíduos associados aos resultados de um modelo (resíduo é diferença entre o valor observado e o valor simulado) (traduzido de Massoud, 2017).....	64
<b>Figura 10.</b> Fluxograma geral do trabalho. ....	65
<b>Figura 11.</b> Localização das bacias experimentais consideradas neste estudo. ....	66
<b>Figura 12.</b> Pontos de monitoramento. (a) Medição de chuva interna e escoamento pelos troncos na bacia do rio Saci (CHAFFE, 2009). (b) Medição de vazão na bacia do rio Saci (CHAFFE, 2009). Medição de (c) chuva total, (d) chuva interna, e (e) escoamento pelos troncos na bacia do rio Araponga (SÁ, 2015). (f) Medição de vazão na bacia do rio Araponga (MOTA, 2017). ....	70
<b>Figura 13.</b> Estruturas consideradas para representar o processo de interceptação. ....	77
<b>Figura 14.</b> Variação das funções auxiliares $f_m$ e $f_h$ com $x$ , para $m = 0,01$ . ....	78

<b>Figura 15.</b> Séries de dados da bacia do rio Saci (esquerda), de reflorestamento de pinus, e da bacia do rio Araponga (direita), de floresta nativa secundária, separadas em eventos de chuva. No painel superior os eventos são apresentados em ordem de ocorrência. No painel central os eventos são apresentados em ordem crescente de volume de chuva total, sendo separados em eventos para obtenção dos parâmetros (calibração, em vermelho) e para avaliação de desempenho dos modelos (validação, em branco). No painel inferior são apresentadas as séries resultantes de calibração e validação para cada uma das bacias.....	80
<b>Figura 16.</b> Modelos chuva-vazão considerados neste estudo (adaptado de Fenicia et al., 2014). Em vermelho estão os parâmetros.....	83
<b>Figura 17.</b> Variação das funções auxiliares $f_h$ , $f_m$ e $f_e$ com $x$ , para $m = 0,01$ . ....	85
<b>Figura 18.</b> Série de dados de chuva total (painel superior) e de vazão (painel inferior) para a bacia do rio Saci, com resolução temporal de 10 min. ....	87
<b>Figura 19.</b> Série de dados de chuva total (painel superior) e de vazão (painel inferior) para a bacia do rio Araponga, com resolução temporal de 5 min. ....	88
<b>Figura 20.</b> Interpretação do gráfico quantil-quantil para avaliar a confiabilidade da faixa de incerteza (traduzido de Thyer et al., 2009). U[0,1] indica uma distribuição uniforme com limite inferior igual a 0 e limite superior igual a 1. ....	101
<b>Figura 21.</b> Frequência do número de eventos, classificados de acordo com a chuva total, em relação ao número total de eventos. Para a floresta nativa secundária, o evento de 352 mm não é mostrado para melhorar a visualização dos demais eventos.....	105
<b>Figura 22.</b> Totais por evento de chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) para o reflorestamento de pinus (na bacia do rio Saci). ....	107
<b>Figura 23.</b> Totais por evento de chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) para a floresta nativa secundária (na bacia do rio Araponga).....	108
<b>Figura 24.</b> Totais por evento de chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) para a floresta nativa secundária (na bacia do rio Araponga) para eventos com chuva total ( $P$ ) $< 80$ mm. ....	109
<b>Figura 25.</b> Exemplo da análise da variação da interceptação ao longo de um evento.....	113
<b>Figura 26.</b> Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo de interceptação.....	114

- Figura 27.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C). No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita)..... 120
- Figura 28.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C).  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita)..... 122
- Figura 29.** Métricas de desempenho obtidas para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL. As métricas foram calculadas para: (a) floresta nativa considerando a série inteira; (b) floresta nativa considerando apenas passos de tempo com resíduo diferente de zero; (c) reflorestamento de pinus considerando a série inteira; e (d) reflorestamento de pinus considerando apenas passos de tempo com resíduo diferente de zero. Para as três métricas, o valor de zero indica um desempenho perfeito..... 123
- Figura 30.** Métricas de desempenho obtidas para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . As métricas foram calculadas para: (a) floresta nativa considerando a série inteira; (b) floresta nativa considerando apenas passos de tempo com resíduo diferente de zero; (c) reflorestamento de pinus considerando a série inteira; e (d) reflorestamento de pinus considerando apenas passos de tempo com resíduo diferente de zero. Para as três métricas, o valor de zero indica um desempenho perfeito..... 124
- Figura 31.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL, para (a) floresta nativa e (b) reflorestamento de pinus. Os limites do eixo y foram fixados de acordo com a faixa inicial de cada um dos parâmetros..... 125
- Figura 32.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , para (a) floresta nativa e (b) reflorestamento de pinus. Os limites do eixo y foram fixados de acordo com a faixa inicial de cada um dos parâmetros..... 126

- Figura 33.** Diagnóstico dos resíduos para a floresta nativa (validação), para cada um dos modelos para resíduos (L1 a L5) considerando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C). Este diagnóstico foi realizado para os resíduos obtidos a partir da simulação que maximizou a função de verossimilhança. Da esquerda para a direita: histogramas dos resíduos transformados ( $a_t$ ), em que a linha vermelha indica a distribuição teórica;  $a_t$  em função do valor simulado de chuva interna ( $T_f$ ); e autocorrelação parcial dos resíduos, em que a linha vermelha indica o intervalo de confiança de 95%. Nos histogramas do método ZI-GL (C), a distribuição dos resíduos da categoria 2 é apresentada na esquerda e a distribuição dos resíduos da categoria 3 é apresentada na direita. A autocorrelação parcial foi calculada para a série inteira..... 128
- Figura 34.** Diagnóstico dos resíduos para a floresta nativa (validação), para cada um dos modelos para resíduos (L1 a L5) considerando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C), com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . Este diagnóstico foi realizado para os resíduos obtidos a partir da simulação que maximizou a função de verossimilhança. Da esquerda para a direita: histogramas dos resíduos transformados ( $a_t$ ), em que a linha vermelha indica a distribuição teórica;  $a_t$  em função do valor simulado de chuva interna ( $T_f$ ); e autocorrelação parcial dos resíduos, em que a linha vermelha indica o intervalo de confiança de 95%. Nos histogramas do método ZI-GL (C), a distribuição dos resíduos da categoria 2 é apresentada na esquerda e a distribuição dos resíduos da categoria 3 é apresentada na direita. A autocorrelação parcial foi calculada para a série inteira. .... 129
- Figura 35.** Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo de interceptação – e o resultado correspondente à escolha da função de verossimilhança. .... 130
- Figura 36.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para o reflorestamento de pinus considerando a evaporação potencial calculada pelo método de Penman (EO), igual a  $4 \text{ mm d}^{-1}$  e com variação senoidal ao longo do dia (E4S) e igual a  $4 \text{ mm d}^{-1}$  e distribuída uniformemente ao longo do dia (E4U). (a) Calibração com a série original de chuva interna. (b) Calibração com um aumento de 20% no valor da chuva interna. .... 132
- Figura 37.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para a floresta nativa considerando a evaporação potencial calculada pelo método de Penman (EO), igual a  $4 \text{ mm d}^{-1}$  e com variação senoidal ao longo do dia (E4S) e igual a  $4 \text{ mm d}^{-1}$  e distribuída uniformemente ao longo do dia (E4U). (a) Calibração com a série original de chuva interna. (b) Calibração com um aumento de 20% no valor da chuva interna. .... 132

- Figura 38.** Métricas de desempenho para o reflorestamento de pinus obtidas para cada um dos modelos de interceptação (S1 a S4D2) utilizando a ZI-GL, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . P é a precisão, V o viés, C a confiabilidade,  $C^{y<2}$  a confiabilidade para chuva interna  $< 2 \text{ mm h}^{-1}$ ,  $C^{y>2}$  a confiabilidade para chuva interna  $> 2 \text{ mm h}^{-1}$  ..... 133
- Figura 39.** Resultado para a estrutura 1 (S1). Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita)..... 135
- Figura 40.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 1. Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita)..... 136
- Figura 41.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 2. Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita)..... 137
- Figura 42.** Métricas de desempenho para a floresta nativa obtidas para cada um dos modelos de interceptação (S1 a S4D2) utilizando a ZI-GL, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . P é a precisão, V o viés, C a confiabilidade,  $C^{y<2}$  a confiabilidade para chuva interna  $< 2 \text{ mm h}^{-1}$ ,  $C^{y>2}$  a confiabilidade para chuva interna  $> 2 \text{ mm h}^{-1}$  ..... 138
- Figura 43.** Resultado para a estrutura 1 (S1). Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita)..... 139
- Figura 44.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 1. Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro)

- utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita). A calibração com a estrutura S2D1 não convergiu quando o modelo de resíduos L1 foi utilizado, e desta maneira este resultado não é apresentado. .... 140
- Figura 45.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 2. Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita). .... 141
- Figura 46.** Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo de interceptação – e o resultado correspondente à escolha do modelo de interceptação..... 142
- Figura 47.** Fluxograma geral do trabalho, com destaque para as etapas da segunda parte – modelagem do processo chuva-vazão. .... 143
- Figura 48.** Diagnóstico dos resíduos para a bacia do rio Saci. Calibração realizada com a L1 (painel superior) e L3 (painel inferior) utilizando dados de vazão da série completa com 10 min de resolução temporal. .... 144
- Figura 49.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.. 145
- Figura 50.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) e do modelo para resíduos ( $\sigma_0$ ,  $\sigma_1$ ,  $\beta$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L3. Calibração realizada com dados de vazão da série completa com decimação de 1, 6, 18 e 72 (10 min) e chuva total como entrada. .... 146
- Figura 51.** Diagnóstico dos resíduos para a bacia do rio Saci. Calibração realizada com a L3 utilizando dados de vazão da série completa com decimação de 1, 6, 18 e 72..... 147
- Figura 52.** Diagnóstico dos resíduos para a bacia do rio Araponga. Calibração realizada com a L1 (painel superior) e L3 (painel inferior) utilizando dados de vazão da série completa com decimação de 12 (um dado a cada hora). .... 148
- Figura 53.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão

da série completa com dados de 10 min e decimação de 12 (1 dado a cada hora), com chuva total como entrada. ....	148
<b>Figura 54.</b> Distribuição <i>a posteriori</i> para os parâmetros do modelo hidrológico ( $C_e$ , $S_{u,\max}$ , $k_f$ , $M_s$ , $k_s$ ) e do modelo para resíduos ( $\sigma_0$ , $\sigma_1$ , $\beta$ ) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação de 12 e 288 (5 min) e chuva total como entrada. Para decimação = 12, foi utilizado o modelo para resíduos L3. Para decimação = 288, foi utilizado o modelo para resíduos L5, com o parâmetro $\phi$ fixo em 0,40. ....	150
<b>Figura 55.</b> Diagnóstico dos resíduos para a bacia do rio Araponga. Calibração realizada utilizando dados de vazão da série completa com decimação de 12 (painel superior) e de 288 (painel inferior). Para decimação = 12, foi utilizado o modelo para resíduos L3. Para decimação = 288, foi utilizado o modelo para resíduos L5, com o parâmetro $\phi$ fixo em 0,40. ....	150
<b>Figura 56.</b> Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo chuva-vazão – e o resultado correspondente à escolha da função de verossimilhança. S: bacia do rio Saci. A: bacia do rio Araponga. ....	151
<b>Figura 57.</b> Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada. ....	152
<b>Figura 58.</b> Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 5 min, decimação igual a 12 e chuva total como entrada. ....	153
<b>Figura 59.</b> Fluxograma geral do trabalho, com destaque para as etapas da segunda parte – modelagem do processo chuva-vazão – e o resultado correspondente à escolha do modelo chuva-vazão para cada bacia estudada. S: bacia do rio Saci. A: bacia do rio Araponga. ....	157
<b>Figura 60.</b> Fluxograma geral do trabalho, com destaque para a terceira parte – análise da influência do processo de interceptação na modelagem chuva-vazão. ....	158
<b>Figura 61.</b> Diagnóstico dos resíduos para a bacia do rio Saci. Calibração realizada utilizando o modelo para resíduos L5, com o parâmetro $\phi$ fixo em 0,40, dados de vazão da série completa com decimação de 6 e M11	

sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M11 sem reservatório de interceptação e com chuva líquida como entrada ( $P_n$ ), M11 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M11 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ). ..... 160

**Figura 62.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $\gamma$ ,  $t_{lag}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L3. Calibração realizada com dados de vazão da série completa com decimação de 6 (um dado por hora) e M11 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M11 sem reservatório de interceptação e com chuva líquida como entrada ( $P_n$ ), M11 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M11 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ). ..... 161

**Figura 63.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada. ..... 162

**Figura 64.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva líquida** como entrada. ..... 163

**Figura 65.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (parâmetros de interceptação fixos)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada. ..... 164

**Figura 66.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (parâmetros de interceptação calibrados)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada. ..... 165

**Figura 67.** Diagnóstico dos resíduos para a bacia do rio Araponga. Calibração realizada utilizando o modelo para resíduos L5, com o

- parâmetro  $\phi$  fixo em 0,40, dados de vazão da série completa com decimação de 288 e M09 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ )..... 167
- Figura 68.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Araponga, utilizando o modelo para resíduos L3. Calibração realizada com dados de vazão da série completa com decimação de 288 (um dado a cada dia) e M09 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ )..... 168
- Figura 69.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 sem reservatório de interceptação e chuva total como entrada**. ... 170
- Figura 70.** Painel superior: série de chuva líquida ( $Pn$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 sem reservatório de interceptação e chuva líquida como entrada**. 171
- Figura 71.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 com reservatório de interceptação (parâmetros fixos) e chuva total como entrada** ..... 172
- Figura 72.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 com reservatório de interceptação (parâmetros fixos) e chuva total como entrada** .. 173

- Figura 73.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série A com decimação igual a 288 (um dado a cada dia) e chuva total como entrada..... 174
- Figura 74.** Painel superior: série de chuva líquida ( $Pn$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série A com decimação igual a 288 (um dado a cada dia) e chuva líquida como entrada..... 175
- Figura 75.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série B com decimação igual a 288 (um dado a cada dia) e chuva total como entrada..... 176
- Figura 76.** Painel superior: série de chuva líquida ( $Pn$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série B com decimação igual a 288 (um dado a cada dia) e chuva líquida como entrada..... 177

## LISTA DE TABELAS

<b>Tabela 1.</b> Funcionamento do algoritmo de calibração automática DREAM (traduzido de Massoud, 2016).....	47
<b>Tabela 2.</b> Descrição dos parâmetros do modelo de Rutter original e modificado.....	60
<b>Tabela 3.</b> Métodos de medição de chuva total, chuva interna e escoamento pelos troncos nas duas bacias experimentais.....	71
<b>Tabela 4.</b> Reservatórios de cada modelo chuva-vazão considerado neste estudo. ....	84
<b>Tabela 5.</b> Equações utilizadas em cada modelo. ....	84
<b>Tabela 6.</b> Funções auxiliares. ....	85
<b>Tabela 7.</b> Parâmetros de cada modelo considerado. ....	85
<b>Tabela 8.</b> Descrição dos parâmetros. ....	85
<b>Tabela 9.</b> Premissas de cada um dos modelos para resíduos considerados. ....	92
<b>Tabela 10.</b> Limites inferior e superior para cada um dos parâmetros considerados na calibração do modelo de interceptação.....	98
<b>Tabela 11.</b> Limites inferior e superior para cada um dos parâmetros considerados na calibração do modelo chuva-vazão.....	98
<b>Tabela 12.</b> Distribuição dos eventos monitorados na bacia do rio Saci (PIN) e na bacia do rio Araponga (ARA) em classes de chuva total. Os totais de chuva total ( $P$ ), chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) são apresentados para cada uma das classes. Valores entre parênteses se referem ao percentual da classe em relação ao valor total. ....	106
<b>Tabela 13.</b> Totais de chuva total ( $P$ ), chuva interna ( $T_f$ ) e escoamento pelos troncos ( $S_f$ ) durante o monitoramento na bacia do rio Saci (PIN) e na bacia do rio Araponga (ARA). ....	110
<b>Tabela 14.</b> Critérios de informação ( $I_k$ ) para as diferentes formulações do processo de interceptação. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes. Valores calculados para o reflorestamento de pinus para o período de calibração. $L$ indica o valor (máximo) da função de verossimilhança obtido na calibração, $k$ é o número de parâmetros, $n$ é o número de dados utilizado, $w_i$ é o peso de cada modelo e $L_{val}$ é o valor (máximo) da função de verossimilhança obtido na validação.....	134
<b>Tabela 15.</b> Critérios de informação ( $I_k$ ) para as diferentes formulações do processo de interceptação. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes. Valores calculados para a vegetação nativa para o período de calibração. $L$ indica o valor (máximo)	

da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado,  $w_i$  é o peso de cada modelo e  $L_{\text{val}}$  é o valor (máximo) da função de verossimilhança obtido na validação. A calibração com a estrutura S2D1 não convergiu quando o modelo de resíduos L1 foi utilizado, e desta maneira este resultado não é apresentado. .... 139

**Tabela 16.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada. Células em cinza indicam melhor desempenho..... 145

**Tabela 17.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação variando de 1 (um dado a cada 10 min) a 72 (um dado a cada 12 horas) e chuva total como entrada..... 146

**Tabela 18.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e decimação de 12 (1 dado a cada hora), com chuva total como entrada. Células em cinza indicam melhor desempenho. .... 149

**Tabela 19.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação variando de 12 (um dado a cada hora) a 288 (um dado a cada 24 horas) e chuva total como entrada. .... 149

**Tabela 20.** Critérios de informação ( $I_k$ ) para as diferentes modelos chuva-vazão considerados. Valores calculados para a bacia do rio Saci. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado e  $w_i$  é o peso de cada modelo. .... 155

**Tabela 21.** Critérios de informação ( $I_k$ ) para as diferentes modelos chuva-vazão considerados. Valores calculados para a bacia do rio Araponga. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado e  $w_i$  é o peso de cada modelo. .... 156

**Tabela 22.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e M11 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M11 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M11 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ )

e M11 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).....	159
<b>Tabela 23.</b> Critérios de informação ( $I_k$ ) para as diferentes considerações do processo de interceptação na modelagem chuva-vazão. Valores calculados para a bacia do rio Saci. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes. $L$ indica o valor (máximo) da função de verossimilhança obtido na calibração, $k$ é o número de parâmetros, $n$ é o número de dados utilizado e $w_i$ é o peso de cada modelo.....	161
<b>Tabela 24.</b> Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia) e M09 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).....	166
<b>Tabela 25.</b> Critérios de informação ( $I_k$ ) para as diferentes considerações do processo de interceptação na modelagem chuva-vazão. Valores calculados para a bacia do rio Araponga. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes. $L$ indica o valor (máximo) da função de verossimilhança obtido na calibração, $k$ é o número de parâmetros, $n$ é o número de dados utilizado e $w_i$ é o peso de cada modelo.....	168
<b>Tabela 26.</b> Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga. Calibração realizada com dados da série A e da série B com decimação igual a 288 (um dado a cada dia) e chuva total ( $P$ ) e chuva líquida ( $Pn$ ) como entrada. Células em cinza indicam melhor desempenho.....	169



## LISTA DE ABREVIATURAS E SIGLAS

AIC – Critério de informação de Akaike

BIC – Critério de informação de Bayes

EO – Evaporação potencial calculada com o método de Penman modificado

E4S – Evaporação potencial igual a 4 mm d<sup>-1</sup> e com variação senoidal ao longo do dia

E4U – Evaporação potencial igual a 4 mm d<sup>-1</sup> e distribuição uniforme ao longo do dia

FR – Reservatório rápido (do inglês, *fast reservoir*)

GL – *Generalized Likelihood function*

GL<sup>y>0</sup> – *Generalized Likelihood function* utilizada apenas com resíduos de observações iguais a zero

IR<sub>cal</sub> – Modelo chuva-vazão acoplado com modelo de interceptação com parâmetros calibrados

IR<sub>fix</sub> – Modelo chuva-vazão acoplado com modelo de interceptação com parâmetros fixos

MIT – Período seco entre um evento e outro (do inglês, *minimum inter-event time*)

NS – Coeficiente de Nash-Sutcliffe

RMSE – Raiz do erro quadrático médio (do inglês, *root mean square error*)

RR – Reservatório da zona ripária (do inglês, *riparian zone reservoir*)

SEP – *Skewed exponential power*

SR – Reservatório lento (do inglês, *slow reservoir*)

UR – Reservatório da zona não saturada (do inglês, *unsaturated soil reservoir*)

ZI-GL – *Zero-Inflated Generalized Likelihood function*



## LISTA DE SÍMBOLOS

<b>Símbolo</b>	<b>Descrição</b>	<b>Dimensão</b>
$a$	Amostra da distribuição assumida para os resíduos (resíduo transformado)	-
$a_{t, sim=0}$	Resíduo transformado de simulações iguais a zero	-
$a_{t, sim>0}$	Resíduo transformado de simulações diferente de zero	-
$A_{\text{parcela}}$	Área da parcela	$L^2$
$b$	Parâmetro empírico de drenagem da copa	$T^{-1}$
$C$	Capacidade de armazenamento da copa	$L$
$C_c$	Capacidade de armazenamento da copa por unidade de área coberta por vegetação	$L$
$C_e$	Parâmetro de eficiência de evaporação	-
$C_t$	Capacidade de armazenamento dos troncos	$L$
$C_{t,c}$	Capacidade de armazenamento dos troncos por unidade de área coberta por vegetação	$L$
$c$	Fator de cobertura (proporção de área coberta em relação à área total)	-
$D$	Taxa de drenagem da água da copa	$L T^{-1}$
$D_s$	Taxa de drenagem da copa quando $S = C$	$L T^{-1}$
$e$	Resíduo bruto	$L T^{-1}$
$e_1$	Resíduos iguais a zero de simulações iguais a zero	$L T^{-1}$
$e_2$	Resíduos iguais a zero de simulações diferente de zero	$L T^{-1}$
$e_3$	Resíduos diferente de zero de simulações diferente de zero	$L T^{-1}$
$E$	Taxa de evaporação da copa	$L T^{-1}$
$E_c$	Taxa de evaporação da copa por unidade de área coberta por vegetação	$L T^{-1}$
$E_p$	Taxa de evaporação potencial por unidade de área	$L T^{-1}$
$E_{t,c}$	Taxa de evaporação dos troncos por unidade de área coberta por vegetação	$L T^{-1}$
$F$	Fator de conversão utilizado para extrapolar para a parcela os dados de escoamento pelos troncos medidos	-
$F_{\hat{y}(t)}$	Função distribuição acumulada da distribuição probabilística no tempo $t$	-
$F_U$	Função distribuição acumulada de uma distribuição uniforme	-
$F_\Omega$	Função distribuição empírica	-

L: comprimento, T: tempo, NA: não aplicável

Símbolo	Descrição	Dimensão
$I$	Taxa de interceptação	$L T^{-1}$
$I_k$	Valor do critério de informação	-
$I_L$	Perdas por interceptação	$L$
$k$	Número de parâmetros	-
$k_f$	Coeficiente de recessão do reservatório rápido	$T^{-1}$
$k_r$	Coeficiente de recessão do reservatório da zona ripária	$T^{-1}$
$k_s$	Coeficiente de recessão do reservatório lento	$T^{-1}$
$\ell$	Logaritmo natural da função de verossimilhança	-
$L$	Valor da função de verossimilhança	-
$L^*$	Valor da função de verossimilhança para o conjunto ótimo de parâmetros (que maximiza o valor da função de verossimilhança)	-
$M_e$	Parâmetro de repartição da entrada entre reservatórios	-
$M_s$	Parâmetro de repartição do fluxo de saída do reservatório da zona não saturada	-
$n$	Número de dados	-
$n_1$	Número de simulações iguais a zero com resíduo zero	-
$n_2$	Número de simulações iguais a zero com resíduo diferente de zero	-
$n_3$	Número de simulações diferente de zero com resíduo diferente de zero	-
$N$	Número de cadeias de Markov	-
$P$	Chuva total	$L$
$Pn$	Chuva líquida	$L$
$p$	Proporção de água da chuva que chega ao solo sem colidir com elementos da vegetação	-
$p_d$	Proporção da drenagem da copa desviada para os troncos	-
$p_t$	Proporção de água da chuva que é interceptada pelos troncos	-
$Q$	Vazão	$L T^{-1}$
$Q_f$	Vazão de saída do reservatório rápido	$L T^{-1}$
$Q_q$	Vazão de saída do reservatório da zona não saturada	$L T^{-1}$
$Q_r$	Vazão de saída do reservatório da zona ripária	$L T^{-1}$
$Q_s$	Vazão de saída do reservatório lento	$L T^{-1}$
$R$	Intensidade da chuva	$L T^{-1}$

L: comprimento, T: tempo, NA: não aplicável

Símbolo	Descrição	Dimensão
$S$	Armazenamento de água na copa	L
$S_t$	Armazenamento de água nos troncos	L
$S_u$	Armazenamento no reservatório da zona não saturada	L
$S_{u,\max}$	Capacidade de armazenamento do reservatório da zona não saturada	L
$\bar{S}_u$	Coeficiente de saturação do reservatório da zona não saturada	-
$Sf$	Escoamento pelos troncos	L
$Sf_{\text{parcela}}$	Escoamento pelos troncos da parcela	L
$Sf_{\text{pluv}}$	Volume de escoamento pelos troncos medido no pluviógrafo	$L^3$
$T$	Número de gerações	-
$t$	Tempo	T
$Tf$	Chuva interna	L
$U(0,1)$	Distribuição uniforme com média 0 e variância 1	NA
$w_i$	Peso do modelo $i$ utilizado na avaliação dos critérios de informação	-
$\mathbf{y}$	Vetor com as observações	$L T^{-1}$
$\hat{\mathbf{y}}$	Vetor com as simulações	$L T^{-1}$
$y$	Variável observada	$L T^{-1}$
$\hat{y}$	Variável simulada	$L T^{-1}$
$\hat{y}_{t,\text{mean}}$	Mediana das simulações no passo de tempo $t$	$L T^{-1}$
$\alpha$	Parâmetro de não linearidade do reservatório R04	-
$\beta$	Parâmetro de curtose	-
$\gamma$	Parâmetro de não linearidade dos reservatórios R01 e R03	-
$\varepsilon$	Proporção de evaporação potencial dos troncos em relação à evaporação potencial da copa	-
$\eta$	Resíduo padronizado	-
$\Theta$	Conjunto de parâmetros	-
$\Theta_e$	Conjunto de parâmetros do modelo para resíduos	-
$\Theta_s$	Conjunto de parâmetros do modelo determinístico	-
$\mu$	Média	$L T^{-1}$
$\xi$	Parâmetro de assimetria	-
$\rho$	Probabilidade de resíduo igual a zero dado que o valor simulado é zero	-

L: comprimento, T: tempo, NA: não aplicável

Símbolo	Descrição	Dimensão
$\sigma$	Desvio padrão	$L T^{-1}$
$\sigma_e$	Desvio padrão dos resíduos brutos	$L T^{-1}$
$\sigma_0$	Coeficiente linear do modelo heteroscedástico	$L T^{-1}$
$\sigma_1$	Coeficiente angular do modelo heteroscedástico	-
$\phi$	Parâmetro do modelo autorregressivo	-
$\psi$	Termo que penaliza pela complexidade do problema	-

L: comprimento, T: tempo, NA: não aplicável

## SUMÁRIO

<b>1. INTRODUÇÃO .....</b>	<b>33</b>
1.1. OBJETIVOS.....	35
1.1.1. Objetivo geral .....	35
1.1.2. Objetivos específicos.....	35
<b>2. REVISÃO BIBLIOGRÁFICA .....</b>	<b>37</b>
2.1. MODELAGEM DE PROCESSOS HIDROLÓGICOS.....	37
2.1.1. Calibração de modelos utilizando a inferência Bayesiana	
38	
2.1.2. Métodos de amostragem da distribuição <i>a posteriori</i> .....	43
2.2. MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO	48
2.2.1. Regressão linear.....	50
2.2.2. Modelo de Rutter.....	51
2.3. MODELAGEM CHUVA-VAZÃO.....	60
2.3.1. Interceptação em modelos chuva-vazão .....	61
2.4. SELEÇÃO DE MODELOS.....	62
<b>3. MATERIAIS E MÉTODOS .....</b>	<b>65</b>
3.1. ÁREAS DE ESTUDO .....	66
3.2. DADOS HIDROMETEOROLÓGICOS .....	67
3.2.1. Bacia do rio Saci.....	67
3.2.2. Bacia do rio Araponga.....	68
3.3. ANÁLISE DOS DADOS .....	72
3.3.1. Estimativa da evaporação potencial.....	72
3.3.2. Transformação dos volumes de escoamento pelos troncos	
em altura de lâmina d'água correspondente .....	72
3.3.3. Separação em eventos de chuva .....	74
3.3.4. Análise da variação no tempo do processo de	
interceptação.....	75
3.4. MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO E	
DO PROCESSO CHUVA-VAZÃO.....	76

3.4.1.	Modelagem do processo de interceptação.....	76
3.4.2.	Modelagem do processo chuva-vazão.....	81
3.4.3.	Inferência dos parâmetros e análise de incerteza .....	89
3.4.4.	Avaliação do desempenho dos modelos.....	100
3.4.5.	Influência do processo de interceptação no processo chuva-vazão.....	103
<b>4.</b>	<b>RESULTADOS E DISCUSSÃO .....</b>	<b>105</b>
4.1.	ANÁLISE DOS DADOS DE INTERCEPTAÇÃO .....	105
4.1.1.	Análise da variação no tempo do processo de interceptação.....	111
4.2.	MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO 114	
4.2.1.	Escolha da função de verossimilhança.....	114
4.2.2.	Análise da influência da evaporação potencial .....	130
4.2.3.	Comparação entre diferentes formulações .....	133
4.3.	MODELAGEM DO PROCESSO CHUVA-VAZÃO.....	143
4.3.1.	Escolha da função de verossimilhança.....	143
4.3.2.	Comparação entre modelos chuva-vazão .....	154
4.3.3.	Influência do processo de interceptação na modelagem do processo chuva-vazão.....	158
<b>5.</b>	<b>CONCLUSÕES .....</b>	<b>179</b>
<b>REFERÊNCIAS BIBLIOGRÁFICAS .....</b>		<b>183</b>
<b>APÊNDICE A .....</b>		<b>194</b>
<b>APÊNDICE B .....</b>		<b>198</b>
<b>APÊNDICE C .....</b>		<b>216</b>
<b>APÊNDICE D .....</b>		<b>224</b>
<b>APÊNDICE E .....</b>		<b>244</b>
<b>APÊNDICE F .....</b>		<b>262</b>
<b>APÊNDICE G .....</b>		<b>280</b>
<b>APÊNDICE H .....</b>		<b>290</b>

## 1. INTRODUÇÃO

Modelos são uma das ferramentas que podemos utilizar para estudar o comportamento de sistemas ambientais. Pode-se também utilizá-los para realizar previsões sobre a resposta desses sistemas em condições futuras ou distintas das que se encontram. Os modelos são simplificações da realidade e, portanto, não representam (e não têm a intenção de representar) todos os processos que ocorrem na natureza. Todo estudo de modelagem está necessariamente sujeito a incertezas devido à essas simplificações. Além disso, existem várias outras fontes de incerteza envolvidas no processo de modelagem – como consequência do desconhecimento dos valores dos parâmetros, inacurácia nas entradas do modelo, desconhecimento das condições iniciais e de contorno. A análise de incerteza vem sendo reconhecida como uma etapa fundamental do processo de modelagem. O desenvolvimento e a avaliação de diferentes métodos de estimativa das incertezas associadas aos resultados de uma simulação vem sendo o tema de diversos estudos conduzidos nos últimos anos (BEVEN, 2006; BEVEN; BINLEY, 1992; KAVETSKI; KUCZERA; FRANKS, 2006; MCINERNEY et al., 2017; RENARD et al., 2010, 2011; SADEGH; VRUGT, 2013, 2014; THYER et al., 2009; VRUGT; SADEGH, 2013; VRUGT et al., 2008; e vários outros).

A correta estimativa das incertezas associadas aos resultados de uma simulação transmite maior confiabilidade às previsões e permite identificar componentes do modelo que precisam ser aprimorados. Uma forma de se obter esta faixa de incerteza é a partir da combinação das saídas do modelo (componente determinístico) com um modelo para os resíduos (componente probabilístico). Nesta abordagem, os diferentes erros envolvidos no processo de modelagem (e.g. erros nos dados monitorados, erros na estrutura dos modelos, erros nas forçantes do modelo) são agregados e representados por meio de uma distribuição de probabilidade.

A inferência Bayesiana permite a estimativa conjunta dos valores dos parâmetros do modelo e da incerteza associada às simulações. Segundo o teorema de Bayes, a distribuição *a posteriori* de um conjunto de parâmetros  $P(\boldsymbol{\theta}|\mathbf{y})$  – sendo  $\boldsymbol{\theta}$  o conjunto de parâmetros e  $\mathbf{y}$  as observações – pode ser obtida a partir da atualização da distribuição *a priori* dos parâmetros  $P(\boldsymbol{\theta})$  com a função de verossimilhança  $P(\mathbf{y}|\boldsymbol{\theta})$ , i.e.,  $P(\boldsymbol{\theta}|\mathbf{y}) \propto P(\boldsymbol{\theta})P(\mathbf{y}|\boldsymbol{\theta})$ . A função *a priori* sumariza o conhecimento sobre os valores dos parâmetros antes da obtenção de qualquer informação sobre os dados  $\mathbf{y}$ . A função de verossimilhança mede em

termos probabilísticos a distância entre as saídas do modelo e as observações. A distribuição *a posteriori* dos parâmetros é utilizada para determinação da incerteza associada aos parâmetros do modelo, e a faixa de incerteza total é obtida a partir da adição ao valor simulado de um valor amostrado da distribuição de probabilidade assumida para os resíduos.

Neste estudo, a análise Bayesiana foi empregada para inferência dos parâmetros e análise de incerteza de modelos de interceptação e chuva-vazão. O processo de interceptação da água da chuva pela vegetação altera a quantidade e a qualidade da água que chega ao solo, afetando sua distribuição no espaço e no tempo. Em bacias florestais, as perdas por interceptação variam geralmente de 10 a 30% da precipitação anual, dependendo das condições climáticas e do tipo de floresta. Uma vez que a quantidade de água da chuva que é interceptada e perdida por evaporação pode representar uma proporção considerável no balanço hídrico, a compreensão dos principais mecanismos que governam este processo é essencial. Um erro em sua estimativa ou então sua desconsideração pode causar erros na simulação dos processos subsequentes. Neste trabalho foram investigados (1) o uso de diferentes formulações para representar o processo de interceptação e chuva-vazão e (2) a influência do processo de interceptação na simulação do processo chuva-vazão. Utilizou-se dados de chuva total, chuva interna, escoamento pelos troncos e vazão de duas bacias experimentais com diferentes coberturas, uma de reflorestamento de pinus e outra coberta por vegetação nativa secundária, ambas localizadas no norte do estado de Santa Catarina.

A principal dificuldade da utilização da inferência Bayesiana para estimativa dos parâmetros e incerteza das simulações reside na formulação de uma função de verossimilhança que represente os resíduos de maneira adequada. A violação das premissas assumidas para os resíduos resulta em valores não confiáveis para os parâmetros e para os intervalos de incerteza (KAVETSKI; FENICIA; CLARK, 2011; SCHOUPS; VRUGT, 2010; SMITH; MARSHALL; SHARMA, 2015; SMITH et al., 2010; THYER et al., 2009). Desta maneira, nesta dissertação buscou-se identificar funções de verossimilhança que se adequem à representação dos resíduos de modelos de interceptação e chuva-vazão.

## 1.1.OBJETIVOS

### **1.1.1.Objetivo geral**

Avaliar a utilização da inferência Bayesiana na calibração e análise de incerteza de modelos de interceptação e chuva-vazão.

### **1.1.2.Objetivos específicos**

- Identificar funções de verossimilhança que representem de maneira adequada os resíduos de modelos de interceptação e chuva-vazão;
- Avaliar o desempenho de diferentes formulações do processo de interceptação;
- Avaliar o desempenho de diferentes estruturas de modelos chuva-vazão quando aplicados a duas bacias florestais;
- Avaliar a influência da interceptação na modelagem do processo chuva-vazão.

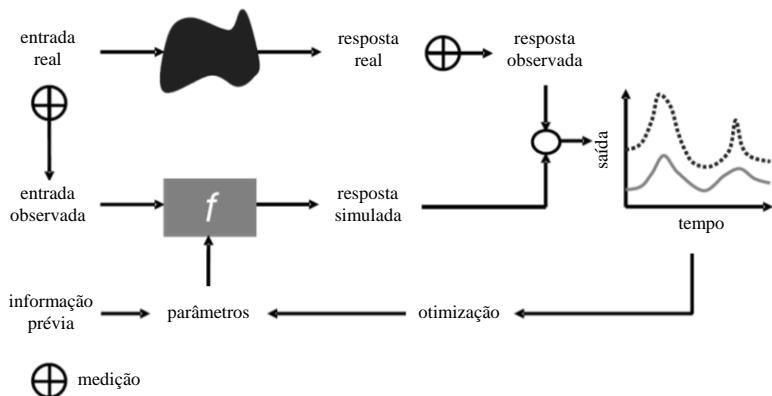


## 2. REVISÃO BIBLIOGRÁFICA

### 2.1. MODELAGEM DE PROCESSOS HIDROLÓGICOS

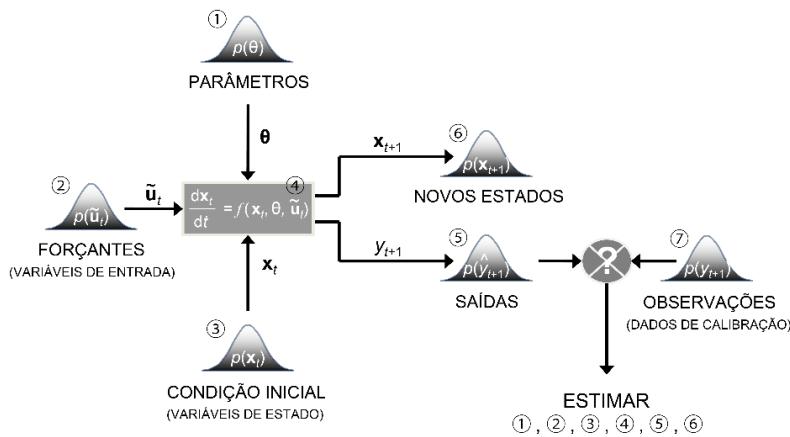
Para melhorar a compreensão sobre os processos hidrológicos, geralmente são combinadas atividades de monitoramento e de modelagem. Enquanto o monitoramento nos fornece dados que nos permitem quantificar os componentes do processo analisado, a utilização de modelos serve como uma ferramenta para testar nossas hipóteses sobre o funcionamento desse processo. Os modelos também podem ser utilizados para realizar previsões sobre a resposta do sistema estudado em condições futuras ou distintas das quais se encontra. Os modelos são simplificações da realidade e, portanto, não representam (e não têm a intenção de representar) todos os processos que ocorrem na natureza.

Uma vez que os modelos são apenas representações simplificadas do sistema considerado, dificilmente seus parâmetros podem ser obtidos a partir de medição direta. Desta maneira, os valores dos parâmetros do modelo devem ser inferidos a partir da calibração. O funcionamento do processo de calibração é apresentado na Figura 1: os valores dos parâmetros do modelo  $f$  são alterados iterativamente, e a cada iteração (para cada conjunto de parâmetros) a resposta do modelo é comparada à resposta observada. Na calibração tradicional, o objetivo é encontrar um conjunto de parâmetros que minimize o erro entre as simulações e as observações medido através de alguma função objetivo.



**Figura 1.** Representação esquemática da calibração de um modelo. Os parâmetros do modelo são ajustados iterativamente a fim de que os resultados simulados (linha sólida) se aproximem ao máximo da resposta observada (linha pontilhada) (adaptado de Vrugt et al., 2008).

Devido às diversas fontes de erro envolvidas no processo de modelagem (como erros de medição dos dados ou erro na estrutura do modelo), a inferência dos parâmetros deveria sempre ser acompanhada da estimativa de incerteza associada aos resultados da simulação. Nesse sentido, a calibração deve buscar uma faixa de valores plausíveis, e não um único conjunto de parâmetros como é feito na calibração tradicional. A desconsideração das incertezas envolvidas no processo de modelagem pode resultar em valores não representativos para os parâmetros do modelo, dificultando a sua transferência no espaço e no tempo. A estimativa da incerteza é, portanto, uma parte fundamental do processo de modelagem, transmite maior confiabilidade às simulações e deveria ser considerada prática comum em qualquer estudo de modelagem. Uma exemplificação das diversas fontes de incerteza envolvidas no processo de modelagem é apresentada na Figura 2.



**Figura 2.** Fontes de incerteza envolvidas no processo de modelagem (traduzido de Sadegh e Vrugt, 2013).

### 2.1.1. Calibração de modelos utilizando a inferência Bayesiana

A inferência Bayesiana é um método amplamente empregado para a estimativa conjunta dos valores dos parâmetros dos modelos e da incerteza associada aos resultados das simulações (KAVETSKI; KUCZERA; FRANKS, 2006; MCINERNEY et al., 2017; RENARD et al., 2010, 2011; SCHAEFLI; TALAMBA; MUSY, 2007; SMITH; MARSHALL; SHARMA, 2015; THYER et al., 2009; VRUGT et al., 2008; e muitos outros). Na abordagem Bayesiana, os parâmetros do

modelo são considerados como variáveis probabilísticas e o teorema de Bayes é utilizado para atualizar a probabilidade de uma hipótese – uma combinação de modelo e valores para os parâmetros – com a evidência disponível, ou seja,

$$P(\boldsymbol{\theta} | \mathbf{y}) \propto P(\boldsymbol{\theta})P(\mathbf{y} | \boldsymbol{\theta}) \quad (1)$$

em que  $P(\boldsymbol{\theta} | \mathbf{y})$  é a distribuição *a posteriori* de um conjunto de parâmetros  $\boldsymbol{\theta}$  após atualização com a informação das observações  $\mathbf{y}$ ,  $P(\boldsymbol{\theta})$  é a distribuição *a priori* dos parâmetros e  $P(\mathbf{y} | \boldsymbol{\theta})$  é a função de verossimilhança. A distribuição *a priori* sumariza o conhecimento sobre os valores dos parâmetros antes da obtenção de qualquer informação sobre os dados  $\mathbf{y}$ . A função de verossimilhança mede em termos probabilísticos a distância entre as saídas do modelo e as observações. A distribuição *a posteriori* dos parâmetros é utilizada para determinação da incerteza associada aos parâmetros do modelo.

A principal dificuldade da utilização da inferência Bayesiana para estimativa dos parâmetros e da incerteza das simulações reside na formulação de uma função de verossimilhança que represente os resíduos do modelo de maneira adequada. Assumindo que os resíduos seguem uma distribuição Gaussiana, a função de verossimilhança é

$$L(\boldsymbol{\theta} | \mathbf{y}) = \prod_{t=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2}\left(\frac{y_t - \hat{y}_t(\boldsymbol{\theta})}{\sigma}\right)^2\right], \quad (2)$$

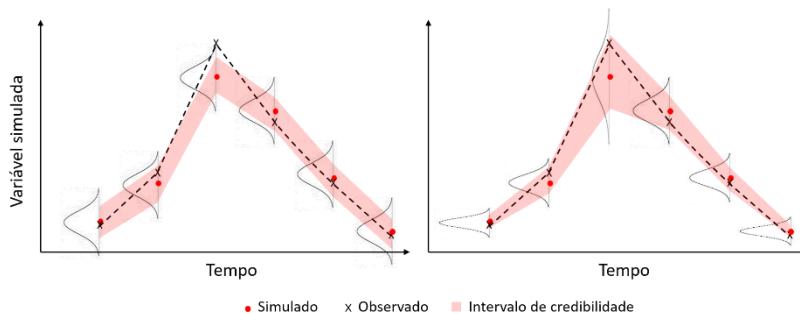
em que a diferença entre o valor observado ( $y_t$ ) e simulado ( $\hat{y}_t$ ) no tempo  $t$  representa os resíduos do modelo e  $\sigma$  é o desvio padrão dos resíduos. Esta função de verossimilhança considera que os resíduos são homoscedásticos (com variância constante) e independentes. Esta situação ocorreria, por exemplo, na hipótese do modelo representar exatamente a realidade e caso a única fonte de erro na modelagem fosse o erro de medição da variável utilizada na calibração (e este erro fosse um erro aleatório – *white noise*). No cálculo do valor da função de verossimilhança, é mais adequado trabalhar com o seu logaritmo, evitando assim a obtenção de valores extremamente pequenos quando o número de dados observados é elevado. A Eq. (2) ficaria, por exemplo,

$$\ell(\boldsymbol{\theta} | \mathbf{y}) = -\frac{1}{2}n \log(2\pi) - \frac{1}{2}n \log(\sigma^2) - \frac{1}{2}\sigma^{-2} \sum_{t=1}^n (y_t - \hat{y}_t(\boldsymbol{\theta}))^2 \quad (3)$$

A função de verossimilhança apresentada na Eq. (2) pode ser facilmente modificada para considerar a heteroscedasticidade dos resíduos,

$$L(\boldsymbol{\theta} | \mathbf{y}) = \prod_{t=1}^n \frac{1}{\sqrt{2\pi\sigma_t^2}} \exp\left[-\frac{1}{2}\left(\frac{y_t - \hat{y}_t(\boldsymbol{\theta})}{\sigma_t}\right)^2\right], \quad (4)$$

característica muito comum na modelagem hidrológica. Este seria o caso, por exemplo, dos resíduos representarem o erro de medição da vazão, que geralmente é maior conforme o valor medido (devido à utilização de uma curva-chave para transformação dos valores de níveis em valores de vazão). A Figura 3 ilustra o conceito de homoscedasticidade e heteroscedasticidade dos resíduos, sendo considerado, a título de ilustração, que a heteroscedasticidade é função do valor simulado (quanto maior o valor simulado, maior o valor do desvio padrão dos resíduos).



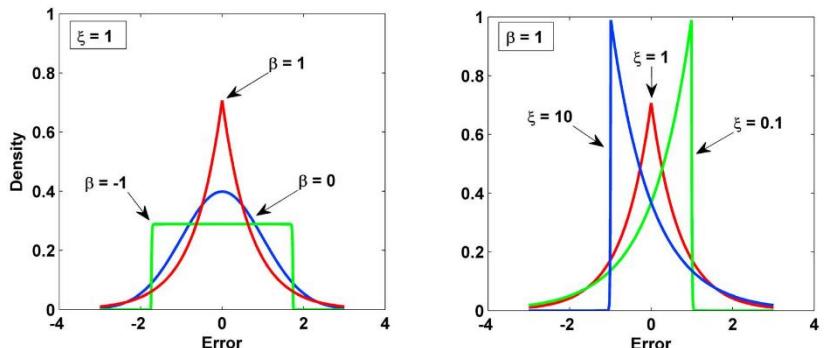
**Figura 3.** Faixa de incerteza (intervalo de credibilidade) construída considerando homoscedasticidade (esquerda) ou heteroscedasticidade (direita) dos resíduos.

Diferentes métodos vêm sendo utilizados para lidar com a heteroscedasticidade dos resíduos dos modelos. A heteroscedasticidade foi considerada utilizando uma mistura de duas distribuições Gaussianas, uma para vazões baixas e outra para vazões altas (SCHAELI; TALAMBA; MUSY, 2007); considerando que o desvio padrão dos erros varia linearmente em função dos valores simulados (EVIN et al., 2014; SCHOUPPS; VRUGT, 2010; WESTRA et al., 2014; e vários outros); e utilizando transformações Box-Cox dos dados (CHENG et al., 2014; SMITH; MARSHALL; SHARMA, 2015; SMITH et al., 2010). Uma comparação entre diferentes formulações para considerar a

heteroscedasticidade dos resíduos é apresentada em McInerney et al. (2017).

Além de heteroscedásticos, os resíduos da modelagem hidrológica geralmente também apresentam autocorrelação (SCHOUPS; VRUGT, 2010). Autocorrelação significa que existe correlação temporal na série de resíduos. Um modelo autorregressivo de primeira ordem é a formulação mais utilizada para lidar com a correlação temporal dos resíduos (EVIN et al., 2013, 2014; SCHAEFLI; TALAMBA; MUSY, 2007; e vários outros), sendo que formulações mais genéricas foram apresentadas em alguns estudos (e.g., Schoups e Vrugt, 2010).

Schoups e Vrugt (2010) apresentaram uma função de verossimilhança flexível, a *Generalized Likelihood function*, para lidar com resíduos heteroscedásticos, correlacionados e que não seguem uma distribuição Gaussiana. Nesta função de verossimilhança, os resíduos são modelados a partir de uma distribuição *Skewed Exponential Power* (SEP), que possui parâmetros de curtose ( $\beta$ ) e assimetria ( $\xi$ ). A influência do valor de curtose e de assimetria no formato da distribuição SEP é demonstrada na Figura 4. Caso o valor de curtose seja igual a 0 e o valor de assimetria seja igual a 1, esta função de verossimilhança assume o formato de uma distribuição Gaussiana, idêntica à apresentada na Eq. (2).



**Figura 4.** Influência do parâmetro de curtose ( $\beta$ ) e de assimetria ( $\xi$ ) na distribuição *skewed exponential power* (SCHOUPS; VRUGT, 2010).

O logaritmo da *Generalized Likelihood function* é

$$\ell(\boldsymbol{\theta} | \mathbf{y}) = n \log \frac{2\sigma_\xi \omega_\beta}{\xi + \xi^{-1}} - \sum_{t=1}^n \log \sigma_t - c_\beta \sum_{t=1}^n |a_{\xi,t}|^{2/(1+\beta)}, \quad (5)$$

em que  $\Theta = \{\Theta_s, \Theta_e\}$  é o conjunto de parâmetros (composto pelos parâmetros do modelo determinístico  $\Theta_s$  – neste caso o modelo de interceptação ou o modelo chuva-vazão – e pelos parâmetros do modelo para resíduos  $\Theta_e = \{\sigma_t, \xi, \beta, \phi\}$ ),  $y$  é um vetor com as observações (medidas da resposta observada do sistema em questão),  
 $a_{\xi,t} = \xi^{-\text{sign}(\mu_\xi + \sigma_\xi a_t)} (\mu_\xi + \sigma_\xi a_t)$  e  $\omega_\beta, c_\beta, \mu_\xi$  e  $\sigma_\xi$  são calculados a partir de  $\beta$  e  $\xi$  e são apresentados no Apêndice A de Schoups e Vrugt (2010) (equações (A2), (A3), (A5) e (A6), respectivamente) e  $n$  é o número de dados considerados na calibração. A aplicabilidade desta função de verossimilhança foi demonstrada em diversos estudos de modelagem hidrológica (e.g., Koskela et al., 2012; Schoups e Vrugt, 2010) e outros estudos sugeriram a sua aplicação (e.g., Li et al., 2012).

Na avaliação das incertezas associadas aos resultados de modelos hidrológicos utilizando a inferência Bayesiana, duas metodologias são comumente empregadas: (1) tratamento explícito de cada uma das fontes de incerteza (KAVETSKI; KUCZERA; FRANKS, 2006b; RENARD et al., 2010, 2011; THYER et al., 2009; VRUGT et al., 2008); e (2) agrupamento de todas as incertezas em um único termo, sendo que a faixa de incerteza total é obtida a partir da adição ao valor simulado de um valor amostrado da distribuição de probabilidade assumida para os resíduos (SCHOUPS; VRUGT, 2010; THYER et al., 2009). Independentemente do método utilizado para estimativa da incerteza associada aos resultados da simulação, a correta caracterização dos resíduos vem sendo reconhecida como prática essencial para garantir a obtenção de valores representativos para os parâmetros e de uma faixa de incerteza confiável (SCHOUPS; VRUGT, 2010; SMITH et al., 2010; THYER et al., 2009).

Como mencionado anteriormente, a grande dificuldade da utilização da inferência Bayesiana para estimativa dos parâmetros e da incerteza associada aos resultados das simulações reside na elaboração de uma função de verossimilhança que represente adequadamente os resíduos dos modelos. Devido às diversas fontes de incerteza envolvidas no processo de modelagem, como apresentado na Figura 2, alguns trabalhos questionam a existência de uma função de verossimilhança cujas premissas possam ser satisfeitas (e.g., Beven et al., 2012). Por este motivo, estes trabalhos defendem a utilização de funções de verossimilhança informais, ou seja, que não se baseiem na formulação de premissas para os resíduos que muito dificilmente conseguirão ser satisfeitas. Um dos métodos mais utilizados para a calibração e análise de incerteza segundo esta abordagem é o método *Generalized Likelihood Uncertainty Estimation* – GLUE (BEVEN; BINLEY, 1992, 2014). No

GLUE, os conjuntos de parâmetros que promovem uma simulação satisfatória são considerados *behavioral*; de maneira contrária, é atribuído um valor igual a zero para o valor de verossimilhança aos conjuntos de parâmetros que não resultam em uma simulação satisfatória. De maneira análoga à estimativa de incerteza utilizando a inferência Bayesiana, podem ser atribuídos pesos às simulações com base no valor de verossimilhança, o que permite o estabelecimento de uma função distribuição acumulada (cdf) e, portanto, a geração da faixa de incerteza associada aos resultados do modelo (BEVEN; BINLEY, 2014). O GLUE é criticado em alguns trabalhos (e.g., Clark, Kavetski e Fenicia, 2011) por estes considerarem que a definição do limiar para que a simulação seja considerada satisfatória ou não é subjetiva. Ou seja, para um mesmo modelo e mesmos dados de calibração, diferentes valores para os parâmetros e de faixa de incerteza podem ser obtidos, dependendo do critério utilizado para considerar a simulação como sendo satisfatória ou não. Além disso, as funções de verossimilhança informais, utilizada no método GLUE, apesar de não estabelecerem *a priori* nenhuma premissa sobre os resíduos, acabam fazendo isso de maneira implícita. Se as premissas são feitas implicitamente, o modelador não consegue verificar *a posteriori* o seu cumprimento, dificultando a verificação da validade das faixas de incerteza estimadas. Os defensores do GLUE, porém, atestam que a utilização de uma função de verossimilhança formal geralmente resulta em uma distribuição *a posteriori* para os parâmetros excessivamente restrita, eliminando partes do espaço dos parâmetros que também poderiam resultar em simulações em acordo com os valores observados. Uma discussão interessante sobre as vantagens e desvantagens da utilização de funções de verossimilhança formais e informais pode ser encontrada em Beven et al. (2012) e Clark, Kavetski e Fenicia (2011, 2012).

### **2.1.2. Métodos de amostragem da distribuição *a posteriori***

#### *Monte Carlo*

Uma das formas de se obter a distribuição *a posteriori* dos parâmetros é a partir do método de Monte Carlo. Neste método, um número elevado de amostragens é realizado de maneira aleatória dentro dos limites definidos para os parâmetros. O número de amostragens deve ser suficiente para que todas as regiões do espaço para os parâmetros sejam amostradas. Para cada conjunto de parâmetro (= uma amostra), são calculados o valor da distribuição *a priori* e o valor da função de

verossimilhança, cuja multiplicação resulta no valor da distribuição *a posteriori*. Caso a dimensão do problema (i.e., o número de parâmetros a serem inferidos) seja muito elevada, a utilização do método de Monte Carlo para amostragem da distribuição *a posteriori* dos parâmetros pode ser inviável, especialmente caso o modelo utilizado para avaliação da função de verossimilhança requeira uma elevada demanda computacional para ser executado. O método de Monte Carlo é visto, portanto, como um método ineficiente para amostragem da distribuição *a posteriori* dos parâmetros.

### *Latin hypercube*

Visando aumentar a eficiência do método Monte Carlo, o método *Latin Hypercube* primeiramente divide o espaço amostral dos parâmetros em regiões de mesmo tamanho, e então uma amostra é gerada de cada uma destas regiões. Este método garante que todo o espaço dos parâmetros seja explorado com um menor número de amostras quando comparado ao método de Monte Carlo.

### *Random Walk Metropolis (RWM)*

Outra forma para obtenção da distribuição *a posteriori* dos parâmetros é a partir da utilização do método *Random Walk Metropolis* (RWM). Este método utiliza cadeias de Markov – definidas como sendo uma sequência de valores em que determinado valor da cadeia depende exclusivamente do valor precedente – para geração de amostras da distribuição *a posteriori*. Neste caso, cada valor da cadeia corresponde a um conjunto de parâmetros. No método RWM, uma amostra aleatória é gerada para inicialização da cadeia de Markov. A evolução da cadeia depende da definição de uma distribuição proposta (distribuição de amostragem). Por exemplo, pode-se utilizar como distribuição proposta uma distribuição normal centrada no ponto atual da cadeia e com determinado valor de desvio padrão. O tamanho do salto que será dado na cadeia depende então do valor do desvio padrão escolhido. O ponto candidato (candidato a entrar na cadeia) é gerado a partir da amostragem de um elemento aleatório desta distribuição proposta. O valor da distribuição *a posteriori* é avaliado no ponto candidato, sendo que o aceite deste ponto depende da razão de Metropolis,

$$P_{\text{acc}}(\mathbf{x}_p) = \min[1, f(\mathbf{x}_p) / f(\mathbf{x}_{(i-1)})], \quad (6)$$

em que  $P_{\text{acc}}(\mathbf{x}_p)$  é a probabilidade de aceite do conjunto de parâmetros  $\mathbf{x}_p$ ,  $f(\mathbf{x}_p)$  é o valor da distribuição *a posteriori* para o conjunto de parâmetros proposto  $\mathbf{x}_p$ , e  $f(\mathbf{x}_{(i-1)})$  é o valor da distribuição *a posteriori* para o ponto atual da cadeia  $\mathbf{x}_{(i-1)}$ . Ou seja, conjuntos de parâmetros que resultam em um maior valor da distribuição *a posteriori* serão sempre aceitos, enquanto que conjuntos de parâmetros que resultam em um valor menor de distribuição *a posteriori* serão aceitos com probabilidade que depende da razão  $f(\mathbf{x}_p) / f(\mathbf{x}_{(i-1)})$  (quanto pior o conjunto de parâmetros, menor é a probabilidade deste ser aceito à cadeia de Markov). Caso o ponto candidato seja aceito, este é adicionado à cadeia de Markov; caso o ponto candidato seja rejeitado, o ponto atual da cadeia é repetido na cadeia de Markov. A utilização desta razão de Metropolis como probabilidade de aceite faz com que, após um número suficientemente grande de iterações, os elementos da cadeia formem a distribuição *a posteriori* dos parâmetros. A taxa de convergência do algoritmo RWM para a distribuição *a posteriori* depende do tamanho do salto que é dado na geração do ponto candidato. Um salto muito grande faz com que a taxa de aceite seja muito baixa, e então um número de iterações deve ser muito elevado para geração de um número suficiente de amostras da distribuição *a posteriori*. Um salto muito pequeno faz com que a taxa de aceite seja muito elevada; porém, um número muito elevado de iterações também é requerido para que todo o espaço amostral dos parâmetros seja percorrido.

### *MCMC com o algoritmo de calibração automática DREAM*

O algoritmo de calibração automática *differential evolution adaptive Metropolis* – DREAM (VRUGT, 2016) é um amostrador do tipo *Markov Chain Monte Carlo* (MCMC) que realiza a exploração do espaço amostral dos parâmetros de maneira eficiente e robusta, possibilitando a amostragem da distribuição *a posteriori* dos parâmetros com um número reduzido de simulações quando comparado a métodos Monte Carlo ou MCMC tradicionais (como o método RWM).

O DREAM é baseado no algoritmo *differential evolution Markov chain* – DE-MC (TER BRAAK, 2006). No algoritmo DE-MC, várias cadeias de Markov são inicializadas em paralelo, possibilitando a exploração simultânea de diferentes regiões do espaço dos parâmetros e o monitoramento da convergência do algoritmo a partir da comparação

da variância entre os elementos das cadeias e entre as diferentes cadeias. Visando aprimorar a taxa de convergência em relação ao algoritmo RWM, o tamanho do salto é adaptado a cada iteração. No método DE-MC, um ponto candidato em determinada cadeia  $j$  é gerado a partir da diferença entre elementos de duas cadeias amostradas aleatoriamente. Esta forma de determinação do tamanho do salto faz com que no início os saltos sejam grandes, já que os elementos das cadeias vão estar bem espaçados entre si, e à medida que o algoritmo converge o salto vai diminuindo. Neste algoritmo, o número recomendado de cadeias é  $N = \min(10, 2k)$ , em que  $k$  é o número de parâmetros considerados na calibração.

O algoritmo DREAM surgiu a partir de três modificações implementadas sobre o algoritmo DE-MC (VRUGT et al., 2008): (1) apenas um subconjunto  $A$  da dimensão total (i.e., do número de parâmetros inferidos) é atualizado a cada iteração, ou seja, a cada iteração, são sorteadas aleatoriamente as dimensões ( $k^*$ ) do conjunto de parâmetros que serão atualizadas; (2) um maior número de pares de cadeias é utilizado nos saltos, permitindo um aumento na diversidade da distribuição proposta; (3) cadeias consideradas como *outliers*, que prejudicam a convergência do algoritmo, são removidas. No DREAM, o tamanho do salto  $\Delta\mathbf{x}$  é calculado por

$$\begin{aligned}\Delta\mathbf{x}_{(i-1),A}^j &= \boldsymbol{\varsigma}_{k^*} + (\mathbf{1}_{k^*} + \boldsymbol{\lambda}_{k^*}) \gamma_{(\delta,k^*)} \sum_{m=1}^{\delta} (\mathbf{x}_{(i-1),A}^{\mathbf{a}_m} - \mathbf{x}_{(i-1),A}^{\mathbf{b}_m}) \\ \Delta\mathbf{x}_{(i-1),\neq A}^j &= 0\end{aligned}\quad (7)$$

em que  $j$  é o índice da cadeia sendo atualizada,  $(i-1)$  representa o índice do elemento da cadeia a partir do qual o salto é realizado,  $A$  é o subconjunto contendo os  $k^*$  elementos de  $\mathbf{x}$ ,  $\gamma_{(\delta,d^*)} = 2,38/\sqrt{2\delta k^*}$  é a *jump rate*,  $\delta$  é o número de pares de cadeias que são utilizadas no salto,  $\mathbf{a}$  e  $\mathbf{b}$  são vetores de dimensão  $\delta$  preenchidos com valores inteiros amostrados sem reposição de  $\{1, \dots, j-1, j+1, \dots, N\}$ ,  $\boldsymbol{\varsigma}$  é vetor com valores amostrados de uma distribuição uniforme  $U_{k^*}(-c, c)$  e  $\boldsymbol{\lambda}$  é um vetor com valores amostrados de uma distribuição normal  $N_{k^*}(0, c^*)$ , sendo sugeridos valores de  $c = 0,1$  e  $c^* = 10^{-6}$  (VRUGT, 2016). O ponto candidato é gerado então por

$$\mathbf{x}_p^j = \mathbf{x}_{(i-1)}^j + \Delta\mathbf{x}_{(i-1)}^j \quad (8)$$

Assim como no algoritmo RWM, a razão de Metropolis é utilizada para determinar a probabilidade de aceite do ponto candidato,

$$P_{\text{acc}}(\mathbf{x}_p^j) = \min[1, f(\mathbf{x}_p^j) / f(\mathbf{x}_{(i-1)}^j)], \quad (9)$$

em que o índice  $j$  corresponde à cadeia que está sendo evoluída. O funcionamento completo do DREAM é apresentado na Tabela 1.

Na versão DREAM<sub>(zs)</sub> os elementos utilizados para determinar o tamanho do salto são amostrados de estados passados das cadeias, possibilitando uma redução do número mínimo de cadeias requerido. No DREAM<sub>(zs)</sub>, a utilização de  $N = 3$  se mostrou suficiente para diferentes problemas. Mais detalhes sobre o funcionamento do DREAM e suas diferentes versões podem ser obtidos em Vrugt (2016).

**Tabela 1.** Funcionamento do algoritmo de calibração automática DREAM (traduzido de Massoud, 2016).

---

**Algoritmo** DiffeRential Evolution Adaptive Metropolis

---

```

1: Definição do número de cadeias  $N \geq k/2$ .
2: Definição das variáveis do algoritmo,  $r, c = 0,1$  e  $c_* = 10^{-6}$ .
3: Cálculo de  $r$  valores de cruzamento,  $\eta = \{\eta_1, \dots, \eta_r\}$  com  $\mathbf{p}_\eta = \{1/r, \dots, 1/r\}$ .
4: Atribuição de  $i = 2$ .
5: for  $j = 1, \dots, N$  do
6:   Amostragem aleatória de  $\mathbf{x}_{(1)}^j$ , os estados iniciais de cada cadeia  $j$ , e cálculo  $f(\mathbf{x}_{(1)}^j)$ .
7: end for
8: while as cadeias não convergiram do
9:   for  $j = 1, \dots, N$  do
10:    Amostragem de um valor de cruzamento,  $\eta$ , de  $F(\eta | \mathbf{p}_\eta)$ .
11:    Amostragem de um vetor com dimensão  $k$ ,  $\mathbf{z}$ , de  $U_k(0,1)$ .
12:    Armazenamento em um subconjunto  $A$  dos índices  $l$  de  $\mathbf{z}$  que satisfazem  $\mathbf{z}_l \leq \eta$ , em que  $l = \{1, \dots, k\}$ .
13:    Se  $A = \emptyset$  (conjunto vazio), preenchimento de  $A$  com valores aleatórios amostrados de  $\{1, \dots, k\}$ .
14:    Cálculo da cardinalidade de  $A$ , isso é  $k^* = |A|$ .
15:    Amostragem aleatória de um valor de  $\delta$  de  $\{1, 2, 3\}$ , ou seja,  $\delta \sim U\{1, 3\}$ .
16:    Amostragem de vetores  $\mathbf{a}$  e  $\mathbf{b}$  com dimensão  $\delta$  sem substituição de  $\{1, \dots, j-1, j+1, \dots, N\}$ .
17:    Amostragem de  $R \sim U(0,1)$ , se  $R \leq 0,8$  define  $\gamma_{(\delta, k^*)} = 2,38/\sqrt{2\delta k^*}$ , caso contrário  $\gamma_{(\delta, k^*)} = 1$ .
18:    Criação de um ponto candidato,  $\mathbf{x}_p^j$ , na cadeia  $j$  usando as equações (7) e (8).
19:    Cálculo do valor de densidade,  $f(\mathbf{x}_p^j)$ , em  $\mathbf{x}_p^j$ .
20:    Cálculo da razão de Metropolis,  $P_{\text{acc}}(\mathbf{x}_p^j) = \min(1, f(\mathbf{x}_p^j)/f(\mathbf{x}_{(i-1)}^j))$ .
21:    if  $Z \leq P_{\text{acc}}(\mathbf{x}_p^j)$  then
22:      Atribuição de  $\mathbf{x}_{(i)}^j = \mathbf{x}_p^j$  e  $f(\mathbf{x}_{(i)}^j) = f(\mathbf{x}_p^j)$ .
23:    else
24:      Permanecer no estado “antigo”,  $\mathbf{x}_{(i)}^j = \mathbf{x}_{(i-1)}^j$  e  $f(\mathbf{x}_{(i)}^j) = f(\mathbf{x}_{(i-1)}^j)$ .
25:    end if
26:  end for
27:  Cálculo dos índices de convergência.
28:  Fragmentação das cadeias outliers
29:  Atualização da iteração,  $i = i + 1$ .
30: end while

```

---

## 2.2. MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO

O processo de interceptação da água da chuva pela vegetação altera a quantidade e a qualidade da água que chega ao solo, afetando sua distribuição no espaço e no tempo. Em bacias florestais, as perdas por interceptação variam geralmente de 10 a 30% da precipitação anual, dependendo das condições climáticas e do tipo de floresta. Perdas por interceptação superiores a 40% foram observadas em clima tropical úmido em uma floresta em Porto Rico (SCATENA, 1990), sendo este elevado valor atribuído principalmente ao regime climático, com chuvas frequentes de baixa intensidade, e não às características da floresta. Uma vez que a quantidade de água da chuva que é interceptada e perdida por evaporação pode representar uma proporção considerável no balanço hídrico, a compreensão dos principais mecanismos que governam este processo é essencial. Além disso, a distribuição da água da chuva no espaço e no tempo altera os padrões de infiltração no solo (LEVIA; GERMER, 2015), influenciando os demais processos do ciclo hidrológico.

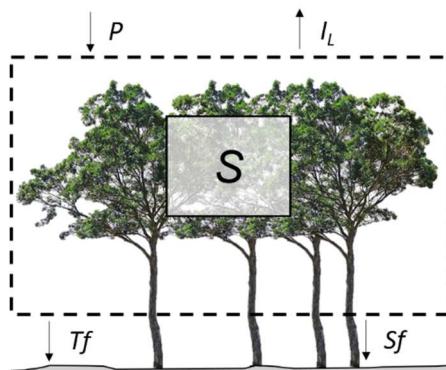
A parcela da água da chuva que é interceptada pelos elementos florestais fica retida temporariamente e então segue dois caminhos: parte evapora, voltando à atmosfera; e outra parte é direcionada para o chão florestal como gotejamento de folhas e galhos ou escoando pelos troncos das árvores. O contato da água da chuva com a vegetação faz com que a distância percorrida pelas gotas de água até chegarem ao solo seja maior do que se incidissem diretamente sem serem interceptadas, aumentando o tempo em que esta água está disponível para evaporação. Além da redução da quantidade de água que chega ao solo e a alteração de sua distribuição no tempo, a vegetação também redistribui a água da chuva no espaço (GERRITS; PFISTER; SAVENIJE, 2010; LLOYD; MARQUES, 1988). Esta redistribuição influencia os demais processos do ciclo hidrológico, como a infiltração e a geração de escoamento superficial. Em alguns pontos, o afunilamento pode fazer com que a intensidade de água que chega ao chão florestal supere as taxas de infiltração, e.g., próximos aos troncos das árvores e em pontos de concentração de gotejamento da copa. Por outro lado, as raízes das árvores podem criar caminhos preferenciais de água no solo, aumentando a capacidade de infiltração nesses locais.

Para a estimativa desta redistribuição da água da chuva pela vegetação, comumente os seguintes componentes do processo são monitorados: (1) chuva total ( $P$ ), ou seja, a chuva incidindo acima do dossel das árvores; (2) chuva interna ( $T_f$ , do inglês *throughfall*), a parte

da água da chuva que chega ao solo diretamente sem ser interceptada pela vegetação somada ao gotejamento de folhas e galhos; e (3) escoamento pelos troncos ( $S_f$ , do inglês *stemflow*), a água que chega ao chão florestal escoando pelos troncos. Por meio do monitoramento destes componentes, as perdas por interceptação ( $I_L$ , do inglês *interception loss*) durante um certo período de tempo podem ser estimadas indiretamente com um balanço de massa (Figura 5):

$$I_L = P - Tf - S_f \quad (10)$$

contanto que possa ser assumido que a variação de armazenamento de água na vegetação (copia e troncos) seja nula durante o período considerado.



**Figura 5.** Representação esquemática do balanço de massa realizado para a água na vegetação.  $P$  é a chuva total,  $I_L$  são as perdas por interceptação,  $Tf$  é a chuva interna,  $S_f$  é o escoamento pelos troncos e  $S$  é o armazenamento na vegetação. A linha pontilhada delimita o volume de controle considerado.

A partir de observação, monitoramento em campo e ensaios em laboratório, vários modelos de interceptação foram desenvolvidos para representar o processo (CALDER, 1986, 1996; GASH, 1979; GASH; LLOYD; LACHAUDB, 1995; LIU, 1997; RUTTER et al., 1971; RUTTER; MORTON; ROBINS, 1975). Segundo uma revisão sobre a modelagem do processo de interceptação (MUZYLO et al., 2009), os modelos mais utilizados são os modelos de Rutter (RUTTER et al., 1971; RUTTER; MORTON; ROBINS, 1975; VALENTE; DAVID; GASH, 1997) e o modelo de Gash (GASH, 1979; GASH; LLOYD; LACHAUDB, 1995; VALENTE; DAVID; GASH, 1997). Estes modelos

vêm sendo empregados em diversos tipos de florestas (MUZYLO et al., 2009), proporcionando boas estimativas de perdas por interceptação a longo prazo, isto é, em escala anual ou mensal (CARLYLE-MOSES; PRICE, 2007; HÖRMANN et al., 1996; LIU, 2001; RUTTER; MORTON; ROBINS, 1975). Porém, nem sempre boas estimativas de perdas por interceptação por evento foram obtidas (ASDAK; JARVIS; GARDINGEN, 1998; CARLYLE-MOSES; PRICE, 2007; MUZYLO et al., 2011). A variação da interceptação ao longo de um evento, i.e., com dados com elevada resolução temporal, raramente foi estudada (e.g. Schellekens et al., 1999). A falha dos modelos em simular adequadamente as perdas por interceptação em escalas temporais mais finas indica que (1) a concepção existente sobre o funcionamento do processo ainda precisa ser melhorada ou que (2) em escalas temporais menores o fenômeno não pode ser descrito com um modelo determinístico. Boas estimativas de perdas por interceptação a longo prazo podem ter sido obtidas como consequência da compensação de erros ao longo do tempo.

Muzylo et al. (2009) levanta como principais lacunas existentes na área: (1) o número limitado de estudos comparativos entre modelos; (2) a falta de validação dos modelos, sendo que em muitos estudos todos os dados disponíveis foram utilizados na obtenção dos parâmetros; (3) a falta de consideração das incertezas tanto nos dados observados quanto em relação aos parâmetros; e (4) a necessidade de se testar os modelos em diversos tipos de vegetação.

### **2.2.1. Regressão linear**

Uma das primeiras descrições do caminho que a água da chuva percorre após atingir a vegetação foi dada por Horton (1919), descreveu que: no início do evento, a maior parte das gotas de chuva que atingem a vegetação ficam retidas formando um filme sobre a folhagem; à medida que a chuva continua e a capacidade de armazenamento da folhagem é atingida, as gotas que são interceptadas promovem um acúmulo de água nas extremidades das folhas, acarretando em um aumento do tamanho das gotas; estas gotas são desprendidas da folhagem quando a força gravitacional supera a tensão superficial; o gotejamento é direcionado para o solo ou para partes inferiores da vegetação; o gotejamento também pode ocorrer devido à ação do vento ou pelo impacto das gotas com as folhas; uma vez que a capacidade de armazenamento da vegetação é atingida, a taxa de água que chega ao solo é a intensidade da chuva descontada da taxa de evaporação; após o fim do evento, a água retida na vegetação é evaporada. A partir desta descrição do processo, Horton

(1919) separou as perdas por interceptação em dois componentes: (1) evaporação durante o evento; (2) evaporação da água armazenada na vegetação após o fim do evento:

$$I_L = kEt + C_c \quad (11)$$

em que  $I_L$  são as perdas por interceptação,  $k$  é proporção da área da floresta a partir da qual ocorre evaporação,  $E$  é a taxa de evaporação durante o evento,  $t$  é a duração do evento e  $C_c$  é a capacidade de armazenamento da vegetação por unidade de área coberta por vegetação, que é a quantidade de água retida na vegetação após o fim da chuva em eventos em que a saturação foi atingida. As perdas por interceptação são então função da capacidade de armazenamento da vegetação, da duração do evento e da taxa de evaporação durante o evento (HORTON, 1919).

Devido à dificuldade de se quantificar os termos da Eq. (11), Horton (1919) relacionou as perdas por interceptação com a chuva total ( $P$ ), mais facilmente medida em campo quando comparada à medição de taxas de evaporação. A partir de experimentos em árvores isoladas, foi verificado que as perdas por interceptação ( $I_L$ ) se relacionam com a chuva total ( $P$ ) na forma de:

$$I_L = a + bP^n \quad (12)$$

em que  $a$ ,  $b$  e  $n$  são coeficientes de ajuste obtidos utilizando dados monitorados.

Desde Horton (1919), muitos trabalhos utilizaram regressão linear para estimar as perdas por interceptação. Um dos grandes problemas deste tipo de abordagem é que a equação obtida dificilmente pode ser extrapolada para outros locais ou condições diferentes daquelas a partir das quais foi desenvolvida. Além disso, mesmo que boas estimativas de perdas por interceptação possam ser obtidas, essas equações (modelo caixa preta) não fornecem informação sobre o funcionamento do processo.

## 2.2.2. Modelo de Rutter

Rutter et al. (1971) apresentaram um modelo de interceptação que buscou incorporar uma descrição física dos processos envolvidos. O modelo realiza um balanço de massa contínuo entre entradas e saídas da

copa para calcular a variação no armazenamento ao longo de um evento de chuva. A entrada na copa é igual a  $(1 - p)R$ , em que  $p$  é a proporção de água da chuva que chega ao solo sem colidir com elementos da vegetação e  $R$  é a intensidade da chuva. A saída pode ocorrer por evaporação ou por gotejamento da copa. Nessa primeira versão do modelo o escoamento pelos troncos foi desconsiderado, uma vez que as medições deste componente não resultaram em valores consideráveis em relação ao total precipitado (RUTTER et al., 1971).

O modelo foi elaborado a partir de observações de eventos extraídos de uma série de 8 meses contendo dados de chuva total e chuva interna com resolução temporal de 5 minutos. Estes dados foram coletados em uma floresta de coníferas em clima temperado. O modelo foi validado a partir da comparação entre os totais mensais de perdas por interceptação simulados e observados, tendo sido verificado bom ajuste da série observada e simulada durante este período. Os totais mensais de perdas por interceptação foram calculados a partir de dados de chuva total e chuva interna coletados diariamente durante 18 meses na mesma floresta a partir do qual o modelo foi desenvolvido. Os valores simulados foram obtidos com a utilização de uma série de dados horários de chuva total de uma estação próxima à floresta, considerando um passo de tempo da simulação igual a 0,1 h e assumindo intensidade constante durante cada hora.

Em Rutter, Morton e Robins (1975) esta versão preliminar do modelo foi generalizada. A principal modificação foi a inclusão de um compartimento representando os troncos das árvores, para o qual um balanço entre entradas e saídas, similar ao realizado para a copa, é calculado. A entrada nesse compartimento é  $p_t R$ , em que  $p_t$  é a proporção de água da chuva que é interceptada pelos troncos, e, consequentemente, a entrada na copa foi reduzida a  $(1 - p - p_t)R$ . O modelo foi testado com a utilização de dados mensais de três florestas de coníferas e três florestas decíduas, apresentando ou não escoamento pelos troncos, e com frações de cobertura distintas, todas localizadas em clima temperado. Para as florestas que apresentaram volumes consideráveis de escoamento pelos troncos, as simulações foram realizadas com e sem a consideração explícita de um compartimento para os troncos. Devido à melhora pouco expressiva das simulações quando os troncos foram tratados em separado, e à incerteza quanto às equações utilizadas para descrever o processo nesse compartimento, os autores não conseguiram afirmar se o aumento de complexidade, que resultou na incorporação de três novos parâmetros ao modelo, é justificado. Rutter, Morton e Robins (1975) também testaram diferentes resoluções temporais das entradas do modelo, tendo

sido verificada a necessidade de dados horários de chuva total e demais dados meteorológicos com no mínimo 3h de resolução temporal para que os totais mensais de perdas por interceptação fossem simulados adequadamente.

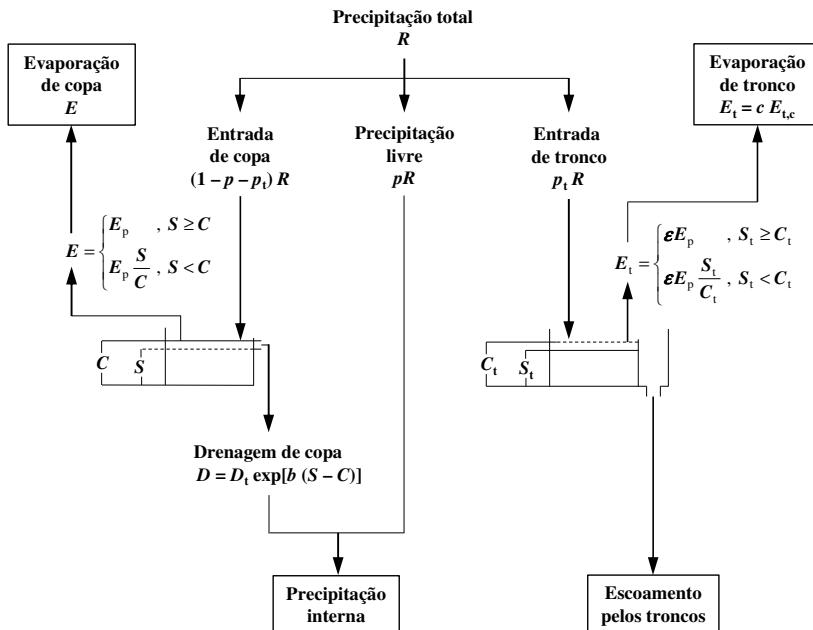
No modelo de Rutter, a chuva incidente acima do dossel das árvores ( $R$ ) é dividida entre: (1) chuva interna livre,  $pR$ , que é a parcela da água da chuva que chega ao solo sem colidir com a vegetação; (2) entrada nos troncos,  $p_t R$ ; e (3) entrada na copa,  $(1 - p - p_t)R$  (Figura 6). O modelo considera que a árvore é constituída de dois tanques de armazenamento: um representando a copa das árvores, com capacidade de armazenamento  $C$ , e outro representando os troncos, com capacidade de armazenamento  $C_t$ . Esta capacidade de armazenamento foi definida em Rutter et al. (1971) como a quantidade de água necessária para molhamento de toda a vegetação. Quando esta situação é atingida, a taxa de evaporação corresponde à taxa de evaporação potencial, e à medida que o armazenamento é reduzido, a área molhada também diminui, sendo considerado que a taxa de evaporação é reduzida proporcionalmente (RUTTER et al., 1971). Segundo este modelo, a capacidade de armazenamento  $C$  também é o valor de água que permanece na copa após o fim do gotejamento. De acordo com este conceito de capacidade de armazenamento, o armazenamento de água na copa em certos momentos durante o evento pode ser superior à  $C$ , o excedente sendo em seguida convertido em chuva interna. A saída de água da copa se dá de forma exponencial em função da quantidade armazenada  $S$ :

$$D = D_s \exp[b(S - C)] \quad (13)$$

em que  $b$  é um parâmetro empírico de drenagem da copa, e  $D_s$  é a taxa de drenagem quando  $S = C$  (em Rutter et al. (1971) foi considerado um valor de 0,002 mm/min para  $D_s$ ). Cabe destacar que, conforme exposto por Calder (1977), a utilização desta equação resulta em um valor (pequeno) de drenagem da copa mesmo com a copa seca. Desta forma, conforme sugerido em Gash e Morton (1978), muitos estudos ao utilizarem o modelo de Rutter assumem que a drenagem da copa é zero quando  $S < C$  (ABOAL et al., 1999; SCHELLEKENS et al., 1999; VALENTE; DAVID; GASH, 1997):

$$D = \begin{cases} D_s \exp[b(S - C)] & \text{se } S \geq C \\ 0 & \text{se } S < C \end{cases} \quad (14)$$

em que  $D$  é a taxa de drenagem da água armazenada na vegetação,  $S$  é o armazenamento,  $C$  é a capacidade de armazenamento e  $b$  é um parâmetro de drenagem da copa.



**Figura 6.** Fluxograma do modelo de Rutter (traduzido de Gash e Morton, 1978).

O excedente de água nos troncos é convertido diretamente em escoamento pelos troncos, ou seja:

$$Sf = \begin{cases} S_t - C_t & \text{se } S_t \geq C_t \\ 0 & \text{se } S_t < C_t \end{cases} \quad (15)$$

em que  $Sf$  é o escoamento pelos troncos,  $S_t$  é o armazenamento nos troncos e  $C_t$  é a capacidade de armazenamento dos troncos. Rutter e Morton (1977) destacam que existe uma inconsistência conceitual entre esta formulação e a forma como é calculada a drenagem de água na copa, que continua por um longo período após o impulso de chuva. Porém, esta formulação para drenagem da água nos troncos foi assumida uma vez que apenas totais mensais de escoamento pelos troncos foram utilizados na

verificação dos valores simulados desta variável (RUTTER; MORTON; ROBINS, 1975). Conforme apontado em Rutter Morton e Robins (1975), uma forma mais complexa de se tratar a geração de escoamento pelos troncos não é justificada a não ser que previsões com alta resolução temporal sejam requeridas.

A evaporação ocorre a partir dos dois tanques e, como já foi mencionado anteriormente, é proporcional à quantidade de água armazenada, possuindo um valor máximo e igual a evaporação potencial quando toda superfície está molhada, ou seja, quando a capacidade de armazenamento é atingida:

$$E = \begin{cases} E_p & \text{se } S \geq C \\ E_p \frac{S}{C} & \text{se } S < C \end{cases} \quad (16)$$

em que  $E$  é a evaporação da copa e  $E_p$  é a taxa de evaporação potencial por unidade de área. A taxa de evaporação dos troncos por unidade de área quando saturados é relacionada à taxa de evaporação da copa saturada por um fator  $\varepsilon$ :

$$E_t = \begin{cases} \varepsilon E_p & \text{se } S_t \geq C_t \\ \varepsilon E_p \frac{S_t}{C_t} & \text{se } S_t < C_t \end{cases} \quad (17)$$

Rutter, Morton e Robins (1975) afirmam que é esperado que  $\varepsilon$  assuma valores inferiores a 10%, e, portanto, a contribuição da evaporação dos troncos para as perdas por interceptação se dá principalmente pela evaporação após o fim do evento da água armazenada nesse compartimento.

O balanço de água na copa pode ser calculado pela equação (18),

$$(1 - p - p_t) \int R dt = \int D dt + \int E dt + \Delta C, \quad (18)$$

e nos troncos é

$$p_t \int R dt = Sf + \int E_t dt + \Delta C_t. \quad (19)$$

A utilização do modelo de Rutter sem a consideração de um comportamento exclusivo para os troncos pode ser efetuada desconsiderando esta parte do modelo, o que equivale a atribuir um valor igual a zero para o parâmetro  $p_t$ . Nesse caso, o parâmetro de capacidade de armazenamento da copa passa a representar o armazenamento na copa e nos troncos.

O modelo de Rutter já foi aplicado em diferentes formações florestais, apresentando bons resultados a longo prazo (em termos de valores acumulados durante alguns meses) (florestas de coníferas e decíduas em clima temperado (RUTTER; MORTON; ROBINS, 1975); floresta tropical em clima tropical de monções (ASDAK; JARVIS; GARDINGEN, 1998); floresta tropical úmida em clima mediterrâneo (ABOAL et al., 1999)). Porém, Schellekens et al. (1999) obtiveram uma subestimativa de quase 100% da chuva interna acumulada monitorada durante 2 meses em uma floresta nativa em Porto Rico sob clima tropical utilizando a equação de Penman-Monteith para a estimativa da evaporação potencial, conforme sugerido em Rutter et al. (1971) e Rutter, Morton e Robins (1975). Para melhorar a estimativa das perdas por interceptação a longo prazo, foi necessário aumentar o valor de evaporação potencial em mais de uma ordem de grandeza (SCHELLEKENS et al., 1999).

Uma menor quantidade de estudos avaliou o desempenho do modelo de Rutter em períodos mais curtos. Aboal et al. (1999) analisaram os totais semanais de perdas por interceptação, obtendo uma relação entre valores observados e simulados que se aproximou da linha 1:1, porém com certa dispersão dos dados. Asdak, Jarvis e Gardingen (1998) não obtiveram um bom ajuste das perdas por interceptação simuladas e observadas por evento, apesar do bom desempenho quanto à simulação de chuva interna por evento. Os autores atribuem este pior desempenho para as perdas por interceptação devido a sua menor contribuição no balanço de massa da água na vegetação, fazendo com que os erros de medições possuam maior influência sobre este componente.

O desempenho do modelo de Rutter em simular a variação do processo ao longo de um evento foi raramente avaliado. Schellekens et al. (1999) analisaram o ajuste das simulações de chuva interna a dados observados a cada 5 min de eventos selecionados da série de dados. Este ajuste foi quantificado com a utilização do coeficiente de Nash-Sutcliffe (NS), tendo sido obtidos melhores resultados (NS variando de 0,50 a 0,74) após calibração do modelo. A calibração foi realizada a partir do ajuste por tentativa-e-erro do valor de evaporação potencial verificando o total de chuva interna simulado para todo o período de monitoramento.

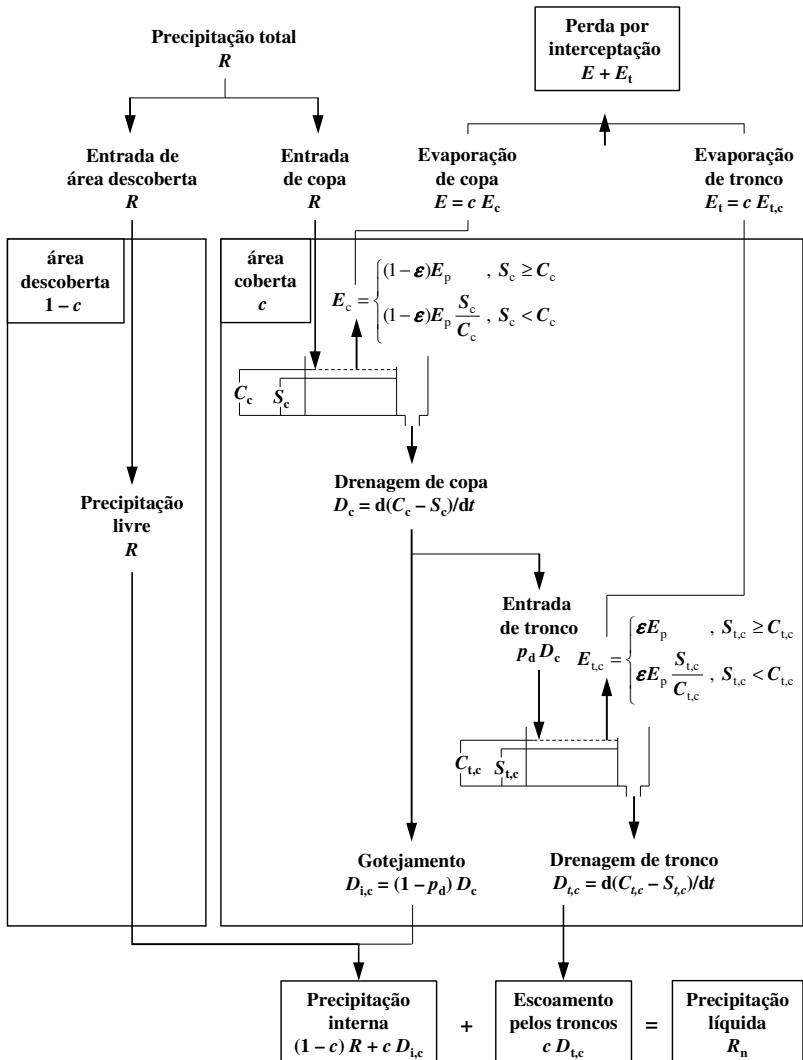
O modelo de Rutter deu origem a outros modelos de interceptação, como o modelo de Massman (MASSMAN, 1983), que incluiu a influência da intensidade da chuva no cálculo da drenagem da copa, e o modelo de Gash (GASH, 1979), que é essencialmente uma versão analítica do modelo de Rutter e será descrito com maiores detalhes no item 2.2.2. No modelo de Rutter, apenas a evaporação durante o início do evento depende da intensidade da chuva, uma vez que a taxa de evaporação antes da saturação da vegetação é proporcional ao armazenamento da copa. Uma vez que a vegetação atinge a sua capacidade de armazenamento, a evaporação da água interceptada não depende da intensidade da chuva (MURAKAMI, 2006).

Uma nova versão do modelo de Rutter foi apresentada em Valente, David e Gash (1997) (Figura 7), que verificaram que o modelo original poderia apresentar baixo desempenho em caso de florestas esparsas. Foi levantado como motivo de simulação insatisfatória a forma com que a taxa de evaporação era calculada, em relação a toda área e não apenas a parte coberta pela vegetação, ou seja, à medida que a fração coberta por vegetação diminui, a taxa de evaporação a partir da superfície molhada aumenta, atingindo valores muito altos e sem sentido físico quando a floresta é muito esparsa (VALENTE; DAVID; GASH, 1997). Para contornar este problema, a versão modificada do modelo divide a área total em dois componentes: uma área descoberta, em que a água da chuva atinge o solo diretamente; e uma área coberta, para a qual o balanço de massa é realizado separadamente, considerando a totalidade da intensidade da chuva como entrada. As saídas destes dois compartimentos são ponderadas de acordo com a proporção relativa de cada área, dando origem a um novo parâmetro que representa a cobertura da copa (fator de cobertura  $c$ ). Da mesma forma em que foi aplicada a correção em relação à taxa de evaporação, os parâmetros referentes à capacidade de armazenamento de copa e troncos passam a ser  $C_c (= C / c)$  e  $C_{t,c} (= C_t / c)$  respectivamente. Nesta nova versão do modelo a drenagem da copa foi simplificada, sendo considerado que todo o excedente é drenado instantaneamente. Esta formulação para drenagem da copa também foi utilizada em aplicações do modelo de Rutter original (e.g. Asdak, Jarvis e Gardingen, 1998). Além disso, considerou-se que a entrada de tronco é uma proporção  $p_d$  da drenagem da copa, ao invés da chuva incidindo diretamente sobre os troncos. Esta formulação de entrada para os troncos já havia sido mencionada em Rutter, Morton e Robins (1975), porém não havia sido incorporado desta forma no modelo original. Esta modificação implica que a forma com que a drenagem da copa é calculada possui grande influência na simulação dos troncos, já que a entrada nesse

compartimento é uma proporção da drenagem da copa. Outra modificação foi a multiplicação da evaporação da copa por  $(1 - \varepsilon)$ , já que na versão anterior do modelo a soma de evaporação de copa e dos troncos resultava em  $(1 + \varepsilon) E_p$ .

Valente, David e Gash (1997) compararam o desempenho desta nova versão do modelo em relação ao modelo original (RUTTER et al., 1971; RUTTER; MORTON; ROBINS, 1975) utilizando dados de uma floresta de eucalipto e outra de pinus, ambas em clima mediterrâneo. As simulações foram realizadas utilizando dados de entrada com resolução temporal de 10 min. A comparação dos resultados das simulações com dados observados de chuva interna e escoamento pelos troncos foi realizada para os totais acumulados por evento, por mês e para todo o período de validação. Em todas as escalas temporais consideradas, a versão modificada do modelo resultou em um melhor ajuste aos dados observados quando comparado ao modelo original (VALENTE; DAVID; GASH, 1997). Apesar da verificação de melhor desempenho desta versão modificada do modelo de Rutter, existem poucos estudos com a sua utilização (e.g. Bigelow, 2001).

A Tabela 2 apresenta de forma sumarizada os parâmetros do modelo de Rutter, na sua forma original (RUTTER et al., 1971; RUTTER; MORTON; ROBINS, 1975) e modificada (VALENTE; DAVID; GASH, 1997).



**Figura 7.** Fluxograma do modelo de Rutter modificado (traduzido de Valente, David e Gash, 1997).

**Tabela 2.** Descrição dos parâmetros do modelo de Rutter original e modificado.

<b>MODELO DE RUTTER ORIGINAL</b>		
<b>Parâmetro</b>	<b>Descrição</b>	<b>Dimensão</b>
$p$	Coeficiente de chuva interna livre (proporção da chuva que chega ao solo sem ser interceptada pela copa das árvores)	-
$p_t$	Proporção da chuva que é interceptada pelos troncos	-
$C$	Capacidade de armazenamento da copa	L
$C_t$	Capacidade de armazenamento dos troncos	L
$b$	Coeficiente de drenagem da copa	$T^{-1}$
$D_s$	Taxa de drenagem quando $S = C$	$L T^{-1}$
$\varepsilon$	Proporção de evaporação potencial dos troncos em relação à evaporação potencial da copa	-

<b>MODELO DE RUTTER MODIFICADO</b>		
<b>Parâmetro</b>	<b>Descrição</b>	<b>Dimensão</b>
$c$	Fator de cobertura (proporção de área coberta em relação à área total)	-
$C_c$	Capacidade de armazenamento da copa por unidade de área coberta	L
$C_{t,c}$	Capacidade de armazenamento dos troncos por unidade de área coberta	L
$p_d$	Proporção da drenagem da copa desviada para os troncos	-
$\varepsilon$	Proporção de evaporação potencial dos troncos em relação à evaporação potencial da copa	-

### 2.3. MODELAGEM CHUVA-VAZÃO

Existem inúmeros modelos utilizados para representar o processo de transformação da chuva em vazão. A escolha de qual modelo utilizar depende do objetivo do estudo considerado, da disponibilidade de dados, da disponibilidade computacional, entre outros fatores.

Os modelos hidrológicos podem ser classificados conforme a sua discretização espacial em distribuídos, semi-distribuídos e concentrados. Os modelos distribuídos dividem a bacia hidrográfica em células, sendo que os cálculos são realizados para cada elemento de área individualmente. Desta maneira, este tipo de modelo considera a variação espacial das entradas e das características das bacias hidrográficas (representadas pelos parâmetros do modelo) e as saídas também são apresentadas para cada elemento de área. Os modelos semi-distribuídos agrupam células com características semelhantes. Os modelos concentrados tratam a bacia como uma única unidade, não considerando a variabilidade espacial das entradas, saídas e parâmetros do modelo.

Os modelos também podem ser classificados conforme a sua formulação: modelos empíricos (caixa preta), obtidos a partir da relação direta entre dados observados; modelos conceituais (caixa cinza), que partem de uma concepção dos processos envolvidos; e fisicamente baseados (caixa branca), em que são utilizadas equações matemáticas para descrever os processos que ocorrem na bacia. Nos modelos fisicamente baseados, os parâmetros possuem sentido físico e podem (teoricamente) serem medidos individualmente. Porém, devido à grande heterogeneidade das características da bacia e combinação de diversos processos em um número limitado de representações, todo modelo fica sujeito à calibração. Na tentativa de representar com rigor os processos envolvidos, os modelos fisicamente baseados podem passar a ideia de precisão dos resultados que na verdade não existe (GRAYSON; MOORE; MCMAHON, 1992). Por mais fiel que seja a representação de um sistema por um modelo, todo modelo hidrológico é uma versão simplificada da realidade.

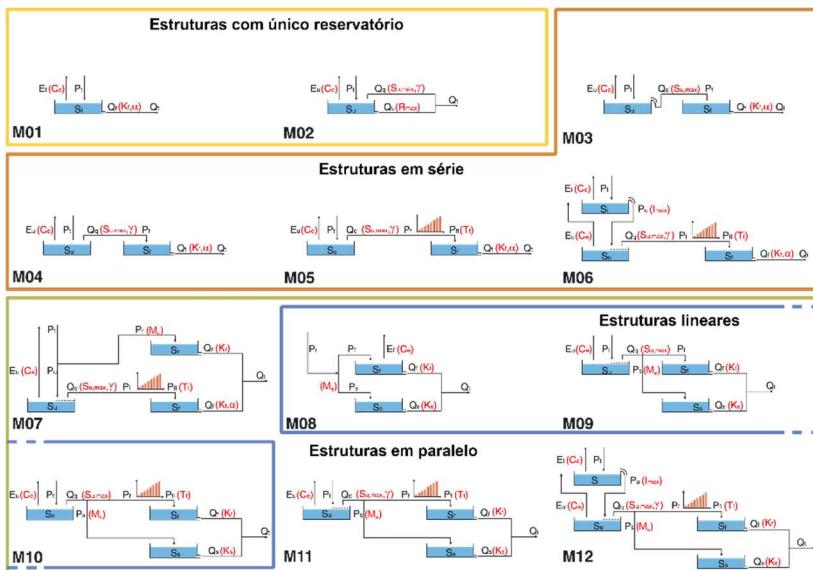
A diversidade de modelos hidrológicos existentes demonstra a inexistência de uma estrutura de modelo genérica que possa ser aplicada em bacias hidrográficas com diferentes características e sob diferentes condições climáticas (CLARK; KAVETSKI; FENICIA, 2011).

Fenicia, Kavetski e Savenije (2011) e Kavetski e Fenicia (2011) introduziram a metodologia SUPERFLEX, a partir da qual diferentes modelos conceituais podem ser construídos com a combinação de três elementos principais: reservatórios, junções e funções de transferência. A utilização desta estrutura flexível para modelagem do processo chuva-vazão permite que complexidade seja acrescentada de maneira incremental, possibilitando a identificação de elementos que melhoram a representação do processo de geração de vazão na bacia estudada. Um exemplo de modelos construídos com a utilização desta metodologia é apresentada na Figura 8. Metodologias semelhantes ao SUPERFLEX incluem o *Framework for Understanding Structural Errors* – FUSE (CLARK et al., 2008) e o DYNAMIT (HRACHOWITZ et al., 2013).

### **2.3.1. Interceptação em modelos chuva-vazão**

Nos modelos chuva-vazão, a interceptação geralmente é considerada como um reservatório, que tem como entrada a chuva total e as saídas ocorrem por evaporação e drenagem para o solo do que excede uma determinada capacidade de armazenamento (e.g. Euser et al., 2013; Fenicia et al., 2014, 2008; Gharari et al., 2014; Schoups e Vrugt, 2010). Apesar de demonstrada a importância da processo de interceptação na

modelagem chuva-vazão (CHAFFE et al., 2010; FENICIA et al., 2008), alguns estudos ainda desconsideram este processo na formulação do modelo. A ausência de consideração de explícita do processo de interceptação acaba sendo compensada nos demais processos incluídos no modelo chuva-vazão.



**Figura 8.** Exemplos de estruturas construídas a partir do método SUPERFLEX (traduzido de Fenicia et al., 2014).

## 2.4. SELEÇÃO DE MODELOS

Quando diferentes modelos são utilizados para representar um processo, é importante que seja considerada a complexidade do modelo na avaliação dos resultados obtidos. De maneira geral, um aumento de complexidade implica em uma maior habilidade do modelo em se ajustar à série utilizada em sua calibração. Desta maneira, medidas de controle de complexidade devem ser consideradas para evitar a escolha de um modelo que tenha sido superajustado à série de calibração e que resultaria em um elevado erro na simulação em um período independente (SCHOUPPS; VAN DE GIESEN; SAVENIJIE, 2008).

Uma das formas de controle de complexidade é a partir da separação da série de dados disponíveis em um período para calibração e um período para validação. A comparação entre os modelos pode ser

então realizada a partir da avaliação de desempenho dos modelos no período de validação. O problema relacionado a este método é que os resultados ficam dependentes do período de validação utilizado. Uma forma de lidar com esse problema é a partir da validação cruzada, que porém pode ser inviável quando a demanda computacional para rodar o modelo é muito elevada.

Outra forma de se selecionar um modelo é a partir de critérios de informação, utilizados para identificar o modelo com maior suporte pelos dados observados. Os critérios de informação medem a informação que é perdida se dado modelo é utilizado para descrever uma série de dados (VOLPI et al., 2017),

$$I_k = -2 \ln(L^*) + \psi \quad (20)$$

em que  $I_k$  representa o valor do critério de informação,  $L^*$  é o valor da função de verossimilhança para o conjunto ótimo de parâmetros (que maximiza o valor da função de verossimilhança) e  $\psi$  é um termo que penaliza pela complexidade do problema. Desta maneira, o aumento de complexidade de um modelo é justificado quando a melhoria no desempenho do modelo (em termos do ajuste da série simulada à série observada – primeiro termo da Eq. (20)) supera o incremento no termo que penaliza a complexidade (VOLPI et al., 2017). Existem diferentes formulações para o termo de complexidade  $\psi$ . No critério de informação de Akaike (AIC), o número de parâmetros do modelo ( $k$ ) é considerado no cálculo do termo  $\psi$ ,

$$\psi = 2k \quad (21)$$

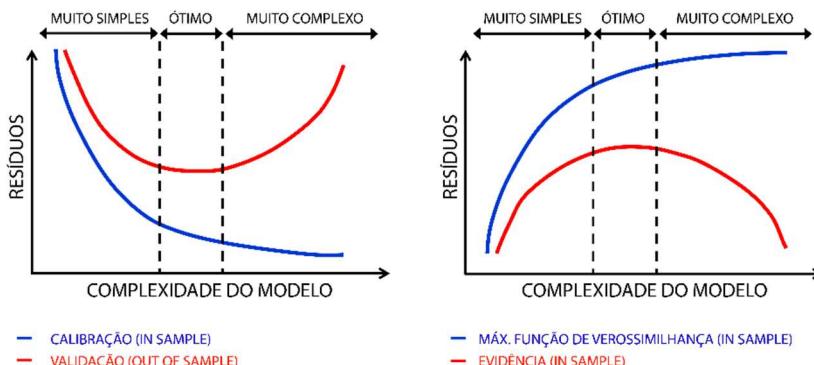
O critério de informação de Bayes (BIC), além do número de parâmetros do modelo, também leva em consideração o número de dados ( $n$ ) utilizados para avaliar o modelo,

$$\psi = k \ln n \quad (22)$$

Na modelagem hidrológica, em que geralmente o número de dados disponível é elevado, o BIC tende a penalizar mais pela adição de complexidade do que o AIC. Os critérios de informação não fornecem um conhecimento absoluto sobre o suporte de um modelo pelos dados. Ou seja, a utilização de critérios de informação apenas fornece uma medida relativa de suporte do modelo pelos dados na comparação com outros

modelos. Alguns estudos mostraram que o AIC superestima a complexidade do modelo, ou seja, este critério de informação tende a favorecer um aumento de complexidade (WESTRA et al., 2014). Desta maneira, a utilização do critério de informação de AIC na seleção de modelos pode ir contra o critério da parcimônia, que atesta que dentre modelos com habilidade similar em simular um processo, o mais simples deve ser selecionado.

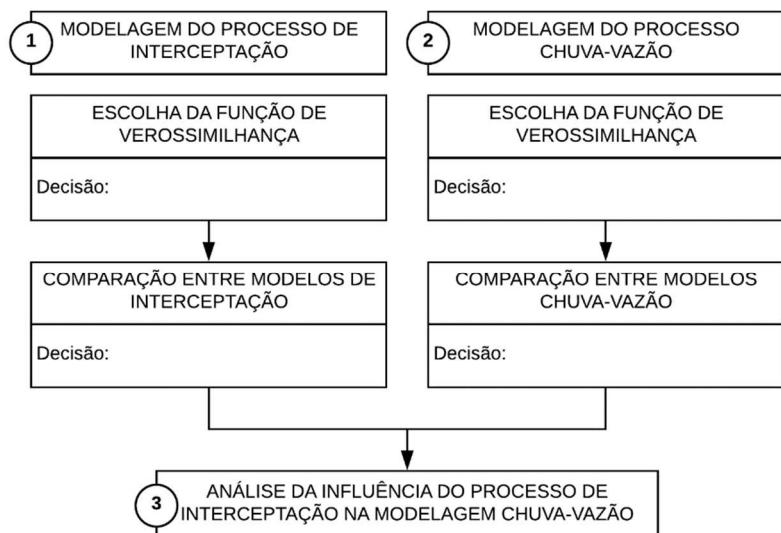
Dentro do contexto da inferência Bayesiana, a seleção de modelos pode ser realizada a partir da utilização do valor de evidência (denominador do teorema de Bayes). A evidência considera o valor médio da função de verossimilhança ao longo da distribuição *a priori*. Uma comparação entre a utilização de calibração e validação e da utilização da evidência do teorema de Bays para a avaliação de desempenho dos modelos é apresentada na Figura 9.



**Figura 9.** Relação entre complexidade e resíduos associados aos resultados de um modelo (resíduo é diferença entre o valor observado e o valor simulado) (traduzido de Massoud, 2017).

### 3. MATERIAIS E MÉTODOS

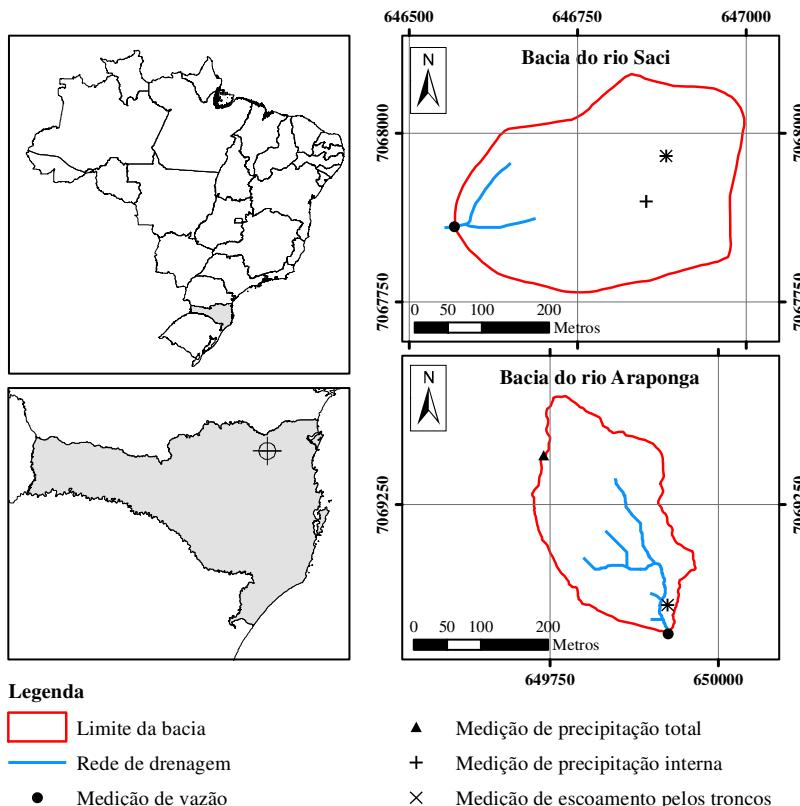
O fluxograma geral do trabalho é apresentado na Figura 10. Este trabalho consistiu de três partes principais: (1) a modelagem do processo de interceptação; (2) a modelagem do processo chuva-vazão; e (3) a análise da influência do processo de interceptação na modelagem chuva-vazão. A primeira etapa tanto da modelagem do processo de interceptação quanto da modelagem do processo chuva-vazão consistiu na identificação de uma função de verossimilhança a ser utilizada na inferência Bayesiana. Nesta etapa, um único modelo de interceptação e um único modelo chuva-vazão foi utilizado, de forma a caracterizar, de maneira geral, os resíduos destes dois tipos de modelos. Com a utilização da função de verossimilhança selecionada, todos os modelos considerados foram calibrados e então foi realizada a comparação entre os diferentes modelos testados. Após a identificação de uma formulação para representar os processos de interceptação e chuva-vazão, foi conduzida uma análise da influência do processo de interceptação na modelagem chuva-vazão. Maiores detalhes sobre cada uma das etapas são apresentados nos itens a seguir. Os campos em branco deste fluxograma, correspondentes às decisões tomadas ao fim de cada etapa, serão preenchidos ao longo deste trabalho.



**Figura 10.** Fluxograma geral do trabalho.

### 3.1. ÁREAS DE ESTUDO

O trabalho foi realizado a partir de dados coletados em duas bacias experimentais: a bacia do rio Saci, coberta predominantemente com reflorestamento de pinus; e a bacia do rio Araponga, coberta por vegetação nativa secundária. As duas bacias estão localizadas na zona rural do município de Rio Negrinho, norte do estado de Santa Catarina e estão inseridas na bacia hidrográfica do Alto Rio Negro (Figura 11).



**Figura 11.** Localização das bacias experimentais consideradas neste estudo.

Segundo a classificação de Köppen, o clima na região é do tipo Cfb, ou seja, mesotérmico úmido, caracterizado por verões frescos e ausência de estação seca.

A bacia do rio Saci possui uma área de 10,2 ha (CHAFFE, 2009). Nesta bacia, o reflorestamento de pinus é homogêneo, com densidade aproximada de 673 pinus/ha, e vegetação nativa está presente principalmente como mata ciliar (CHAFFE, 2009).

A bacia do rio Araponga possui uma área de 5,26 ha (MOTA et al., 2017). Na bacia do rio Araponga a floresta é heterogênea, caracterizada pela presença de vegetação secundária, em estado de regeneração, com poucas árvores mais desenvolvidas (GIGLIO, 2013).

Uma descrição mais detalhada da bacia do rio Saci pode ser encontrada em Chaffe (2009), Santos (2009) e Silva (2010) e da bacia do rio Araponga em Giglio (2013) e Mota (2012; 2017).

### 3.2.DADOS HIDROMETEOROLÓGICOS

Neste trabalho foram utilizados dados de chuva total, chuva interna, escoamento pelos troncos, vazão e dados meteorológicos. A coleta destes dados na bacia do rio Saci e na bacia do rio Araponga foi realizada em trabalhos anteriores do Laboratório de Hidrologia (LabHidro) da Universidade Federal de Santa Catarina e é descrita nos itens 3.2.1 e 3.2.2, respectivamente. A Tabela 3 sumariza os métodos utilizados para monitoramento da chuva total, chuva interna e escoamento pelos troncos nas duas bacias.

#### 3.2.1.Bacia do rio Saci

Os dados da bacia do rio Saci utilizados neste trabalho são provenientes do monitoramento realizado por Chaffe (2009) de 23/08/2008 a 17/11/2008, totalizando 86 dias de monitoramento. O registro de chuva total, chuva interna, escoamento pelos troncos e vazão foi realizado a cada 10 minutos (Figura 12a e Figura 12b). A chuva total foi monitorada em uma estação meteorológica situada a 1 km do exutório da bacia. A chuva interna foi coletada em dois pontos na bacia (Figura 11). Em cada ponto de monitoramento de chuva interna foi instalado um sistema composto por duas calhas (3 m x 0,1 m cada) conectadas a um pluviógrafo de báscula (resolução do sistema de 0,10 mm de chuva interna). Quatro troncos foram conectados a um pluviógrafo de báscula (resolução de 0,24 mm) para monitoramento de escoamento pelos troncos. A área de captação considerada foi de 24 m<sup>2</sup> (6 m<sup>2</sup> cada árvore). Desta forma, os volumes medidos pelo pluviógrafo foram divididos por esta área de captação para obtenção de valores de escoamento pelos troncos em mm. A vazão no exutório da bacia foi obtida a partir de dados

de nível, registrados em um *datalogger* a cada 10 min. A transformação de nível em vazão foi realizada a partir da utilização de uma curva-chave (CHAFFE, 2009).

A série de dados meteorológicos, utilizados na estimativa da evapotranspiração potencial, foram obtidos da estação meteorológica automática do Instituto Nacional de Meteorologia (INMET) situada a aproximadamente 28 km da bacia (estação RIO NEGRINHO-A862). Nesta estação, o registro de dados de temperatura, umidade, velocidade do vento e radiação foi realizado a cada hora.

Maiores detalhes do monitoramento nesta bacia podem ser obtidos em Chaffe (2009).

### **3.2.2.Bacia do rio Araponga**

Na bacia do rio Araponga foram coletados dados de chuva total (Figura 12c), chuva interna (Figura 12d), escoamento pelos troncos (Figura 12e) e vazão (Figura 12f). Os dados de chuva total, chuva interna e escoamento pelos troncos são provenientes do monitoramento realizado por Sá (2015) de 26/02/2014 a 06/10/2014, totalizando 223 dias de monitoramento. Para este mesmo período, a série de vazão foi obtida por Mota (2017).

A chuva total foi monitorada numa clareira localizada na cabeceira da bacia utilizando-se um pluviógrafo de báscula (Waterlog H-340, resolução de 0,24 mm, com correção automática conforme intensidade da chuva), com registro dos dados em um *datalogger* a cada 5 minutos.

As variáveis chuva interna e escoamento pelos troncos foram monitoradas de duas formas: (i) monitoramento automático; e (ii) coletores para armazenar o volume correspondente a um certo período. O monitoramento automático permitiu a obtenção de dados com elevada resolução temporal, enquanto que os coletores possibilitaram uma maior amostragem das variáveis em questão, que se mostrou necessária devido à elevada heterogeneidade da vegetação nesta bacia.

No monitoramento automático de chuva interna e escoamento pelos troncos o registro dos dados foi realizado a cada 5 minutos. A chuva interna foi monitorada com a utilização de uma calha (3 m x 0,2 m) conectada a um pluviógrafo de báscula. Um sistema composto por mangueiras conectando os troncos de 4 árvores a um pluviógrafo de báscula permitiram o monitoramento automático de escoamento pelos troncos. Os pluviógrafos utilizados no monitoramento de chuva interna e escoamento pelos troncos são semelhantes ao utilizado no monitoramento de chuva total. Falhas no registro automático de dados de chuva interna e

escoamento pelos troncos ocorreram de 08/05/2014 a 09/05/2014 e de 29/08/2014 a 09/09/2014. Estes períodos foram descartados da série de dados.

O monitoramento com coletores foi realizado em uma área circular de 3 m de raio centrada na posição da calha. A chuva interna foi monitorada com 28 pluviômetros (construídos a partir de garrafas de plástico de 5 L), e o escoamento pelos troncos de 5 árvores foi direcionado para coletores de plástico de 10 L. O volume armazenado pelos pluviômetros e por estes coletores foi medido a cada período com duração de 15 dias a um mês, dependendo da possibilidade de ida a campo.

Os dados de vazão foram obtidos de uma série de dados de níveis d'água registrados a cada 5 minutos no exutório da bacia. Os níveis foram convertidos em valores de vazão a partir da equação do vertedor, conforme apresentado em Mota (2012; 2017).

Os dados de temperatura, umidade relativa, velocidade do vento e radiação incidente e refletida foram obtidos da estação meteorológica Feio, localizada a aproximadamente 3 km de distância da bacia experimental. Nesta estação, o registro de dados é realizado a cada 10 minutos.

Maiores detalhes do monitoramento nesta bacia podem ser obtidos em Sá (2015) e Mota (2012; 2017).



**Figura 12.** Pontos de monitoramento. (a) Medição de chuva interna e escoamento pelos troncos na bacia do rio Saci (CHAFFE, 2009). (b) Medição de vazão na bacia do rio Saci (CHAFFE, 2009). Medição de (c) chuva total, (d) chuva interna, e (e) escoamento pelos troncos na bacia do rio Araponga (SÁ, 2015). (f) Medição de vazão na bacia do rio Araponga (MOTA, 2017).

**Tabela 3.** Métodos de medição de chuva total, chuva interna e escoamento pelos troncos nas duas bacias experimentais.

<b>BACIA DO RIO SACI (CHAFFE, 2009)</b>			
<b>Variável</b>	<b>Método de medição</b>	<b>Resolução temporal</b>	<b>Descrição</b>
Chuva total	Pluviógrafo de báscula	10 min	Pluviógrafo de báscula com resolução de 0,25 mm
Chuva interna	Calha conectada a um pluviógrafo de báscula	10 min	Dois sistemas compostos por duas calhas (3 m x 0,1 m) conectadas a um pluviógrafo de báscula (resolução do sistema de 0,10 mm)
Escoamento pelos troncos	Mangueira conectada a um pluviógrafo de báscula	10 min	Quatro troncos (área de captação de 24 m <sup>2</sup> ) conectados por mangueiras a um único pluviógrafo com resolução de 0,24 mm (resolução do sistema de 0,0003 mm)
<b>BACIA DO RIO ARAPONGA (SÁ, 2015)</b>			
<b>Variável</b>	<b>Método de medição</b>	<b>Resolução temporal</b>	<b>Descrição</b>
Chuva total	Pluviógrafo de báscula	5 min	Pluviógrafo de báscula com resolução de 0,24 mm
Chuva interna	Calha conectada a um pluviógrafo de báscula	5 min	Calha (3 m x 0,2 m) conectada a um pluviógrafo com resolução de 0,24 mm (resolução do sistema de 0,012 mm)
	Pluviômetro	~ 15 dias	Pluviômetro construído com garrafa de 5 L esvaziada manualmente
Escoamento pelos troncos	Mangueira conectada a um pluviógrafo de báscula	5 min	Quatro troncos conectados por mangueiras a um único pluviógrafo com resolução de 0,24 mm
	Mangueira conectada a coletores	~ 15 dias	Cinco troncos conectados por mangueiras a coletores de 10 L esvaziados manualmente

### 3.3. ANÁLISE DOS DADOS

#### 3.3.1. Estimativa da evaporação potencial

A evaporação potencial é uma das entradas de modelos de interceptação e chuva-vazão. A evaporação potencial foi estimada com o método de Penman modificado (DOORENBOS; PRUITT, 1977) a partir dos dados diários de radiação solar incidente, temperatura do ar, umidade relativa do ar e velocidade do vento. Os valores diários de evaporação potencial foram transformados em dados com resolução de 10 minutos considerando que 90% do valor diário é distribuído de 6h às 18h seguindo uma função senoidal e 10% é distribuído uniformemente durante a noite. Maiores detalhes deste cálculo podem ser obtidos em Chaffe (2009) e Oliveira (2015) para as bacias do rio Saci e Araponga, respectivamente. Este tipo de transformação de dados diários de evaporação potencial em dados subdiários utilizando uma senóide também foi empregada em outros trabalhos (e.g., FENICIA et al., 2006; VACHÉ; MCDONNELL, 2006).

#### 3.3.2. Transformação dos volumes de escoamento pelos troncos em altura de lâmina d'água correspondente

Os volumes de escoamento pelos troncos monitorados devem ser transformados em uma altura (valores em mm) para que possam ser comparados com os valores de chuva total e chuva interna.

Para o reflorestamento de pinus, em que a vegetação é mais homogênea, foi possível identificar uma área de influência uniforme de 6 m<sup>2</sup> para cada uma das árvores presentes na parcela. Desta maneira, o volume coletado pelos quatro troncos e direcionados para o pluviôgrafo foi dividido por uma área de 24 m<sup>2</sup> para obtenção de valores de escoamento pelos troncos em mm.

Para a floresta nativa, a heterogeneidade da vegetação, com a presença de árvores de diferentes portes e sobreposição entre as copas, dificultou a determinação de uma área de influência para cada árvore individualmente. Por este motivo, os valores medidos nas 9 árvores (5 com coletores e 4 no monitoramento automático) foram extrapolados para toda a parcela (total de 39 árvores), e então o volume obtido foi dividido pela área da parcela (área circular de 3 m de raio), ou seja,

$$Sf_{\text{parcela}} = \frac{F \times Sf_{\text{pluv}}}{A_{\text{parcela}}}, \quad (23)$$

em que  $Sf_{\text{parcela}}$  é a altura de escoamento pelos troncos para a parcela (mm),  $F$  é o fator de conversão utilizado para extrapolar os dados de escoamento pelos troncos medidos,  $Sf_{\text{pluv}}$  é o volume de escoamento pelos troncos medido no pluviógrafo (L) e  $A_{\text{parcela}}$  é a área da parcela ( $\text{m}^2$ ).

Para considerar a incerteza existente nesse processo, foi estabelecido um limiar inferior e um limiar superior para os valores de escoamento pelos troncos. Como limite inferior foi assumido que todo o escoamento pelos troncos da parcela teria sido gerado apenas pelas árvores monitoradas (total de 9 árvores, 4 de maior porte e 5 de menor porte). Como limite superior, a média dos volumes coletados em árvores de menor porte (5 das 9 monitoradas) foi utilizada na extração para as demais árvores não monitoradas (30 árvores), sendo este valor somado ao volume medido nas 4 árvores de maior porte. A partir da análise dos dados de escoamento pelos troncos disponíveis, foi verificado que a razão entre o volume total de escoamento pelos troncos da parcela e o volume de escoamento pelos troncos medido no pluviógrafo (correspondente ao fator de conversão de  $F$  da Eq. (23)) se relaciona linearmente com o volume de chuva total do período correspondente. Assim, os valores medidos no pluviógrafo foram extrapolados para a parcela de acordo com a chuva total de cada evento, conforme as Eq. (24) e (25), considerando o limiar inferior e superior, respectivamente, como definido anteriormente.

$$F_{\text{inf}} = 0,1645P(\text{mm}) + 5,4117 \quad (24)$$

$$F_{\text{sup}} = 0,1803P(\text{mm}) + 13,858 \quad (25)$$

Para obtenção destas equações foram utilizados apenas os períodos em que o volume de escoamento pelos troncos foi medido em todas as árvores monitoradas. Como em diversas idas a campo o volume de escoamento pelos troncos das árvores de maior porte foi superior à capacidade de armazenamento dos coletores, há uma incerteza quando à validade destas equações para eventos com maiores volumes de chuva total.

### **3.3.3.Separação em eventos de chuva**

Para análise do processo de interceptação, as séries de dados de chuva total, chuva interna e escoamento pelos troncos foi separada em eventos. A forma como é feita a separação da série de dados em eventos de chuva depende do objetivo do estudo em questão. Em estudos de interceptação, geralmente o objetivo é que se tenha eventos em que o balanço  $I_L = P - Tf - Sf$  seja válido, ou seja, a separação deve ser feita de forma que a variação do armazenamento de água na vegetação seja zero entre o início e fim do evento.

Um método comumente empregado em estudos de interceptação para a separação de eventos de chuva é a escolha de um valor fixo de período seco entre um evento e outro (MIT, do inglês *minimum inter-event time*), assumindo que este período é suficiente para evaporação de toda água presente na vegetação ao fim de um evento de chuva (DUNKERLEY, 2008). Diferentes valores de MIT foram utilizados em estudos de interceptação, como: 2h (KLAASEN; BOSVELD; DE WATER, 1998); 3h (HOLWERDA et al., 2012; SCHELLEKENS et al., 1999); 6h (CHAFFE et al., 2010; LINK; UNSWORTH; MARKS, 2004); 12h (CARLYLE-MOSES; PRICE, 2007); e 24h (VALENTE; DAVID; GASH, 1997).

Muzylo, Llorens e Domingo (2012), tendo observado condições meteorológicas distintas entre dia e noite, consideraram diferentes valores de MIT conforme a hora do fim do evento: 6h para eventos finalizados antes do pôr-do-sol; e 12h para eventos que acabaram durante a noite. Reid e Lewis (2009) utilizaram diferentes valores de MIT para separação de eventos dependendo do objetivo da análise: 3h para análise dos dados chuva interna, uma vez que constataram que após esse período praticamente todo o volume de chuva interna de um evento já havia sido coletado; e 48h para análise dos dados de escoamento pelos troncos, já que o registro de dados desta variável continuou por até esta duração após o fim da chuva.

Llorens et al. (2014) monitoraram a duração da presença de água na vegetação após o fim de eventos de chuva e verificaram que métodos comumente utilizados na separação de eventos, como a escolha de um valor fixo de MIT, não representam adequadamente o tempo necessário para secagem da vegetação.

Na ausência de dados que indiquem o estado de umidade da vegetação, foi adotado neste trabalho um MIT de 12 horas. Este valor corresponde à maior duração observada entre o último registro de chuva total e o último registro de chuva interna.

Após a separação das séries de dados de chuva total, chuva interna e escoamento pelos troncos em eventos, os eventos com as seguintes características foram descartados: (1) eventos com falha no monitoramento de alguma das variáveis; (2) eventos em que o total de chuva interna foi maior que o total de chuva total; e (3) eventos em que o total de chuva total foi de 0,24 mm (equivalente a uma basculada).

A série final de dados de interceptação da bacia do rio Saci (reflorestamento de pinus) contém um total de 35 eventos e da bacia do rio Araponga (floresta nativa) contém um total de 59 eventos.

### **3.3.4. Análise da variação no tempo do processo de interceptação**

Para auxiliar a interpretação dos resultados obtidos na modelagem do processo de interceptação, primeiramente foi realizada uma análise dos dados disponíveis. Para o estudo da variação do processo de interceptação ao longo de um evento, as seguintes análises foram realizadas:

- (1) análise da evolução da taxa de interceptação ( $I = P - Tf - Sf$ ) ao longo do tempo, ou seja, da variação da taxa de interceptação durante os eventos, considerando  $\Delta t$  igual a 1 hora;
- (2) análise da variação dos valores acumulados de  $Tf$ ,  $Sf$  e  $I$  ao longo do tempo, com  $\Delta t$  igual a 1 hora e considerando os volumes acumulados desde o início do evento até o tempo em questão;
- (3) análise da variação dos valores acumulados de  $Tf$ ,  $Sf$  e  $I$  em função ao acumulado de  $P$ , com  $\Delta t$  igual a 1 hora e considerando os volumes acumulados desde o início do evento até o tempo em questão; e
- (4) análise da variação de  $Tf/P$ ,  $Sf/P$  e  $I/P$  ao longo do tempo, com  $\Delta t$  igual a 1 hora e considerando os volumes acumulados desde o início do evento até o tempo em questão.

Eventos com as seguintes características foram selecionados para estas análises:

- (1) intensidade média (calculada considerando apenas os passos de tempo com registro de chuva total) maior que 0,5 mm/10 min, a fim de eliminar eventos em que o erro de medição devido à resolução do pluviógrafo é muito elevado;
- (2) tempo antecedente sem chuva de 24 horas, para garantir que a copa e os troncos estivessem secos no início de cada evento;
- (3) chuva total superior a 10 mm.

### 3.4. MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO E DO PROCESSO CHUVA-VAZÃO

Os processos de interceptação e chuva-vazão nas duas bacias experimentais já foram o foco de estudos de modelagem realizados pelo Laboratório de Hidrologia (LabHidro) da Universidade Federal de Santa Catarina. Chaffe (2009) estudou o processo chuva-vazão da bacia do rio Saci com a utilização do modelo hidrológico concentrado Tank Model, e o modelo de Rutter modificado foi utilizado para simular o processo de interceptação. Santos (2009) utilizou o modelo semi-distribuído TOPMODEL para simular o processo chuva-vazão na bacia do rio Saci. Silva (2010) desenvolveu um modelo hidrológico distribuído, o WADII-HM, aplicando este modelo na bacia do rio Saci em comparação com o modelo TOPMODEL. David (2017) utilizou 10 diferentes estruturas de modelos conceituais concentrados da metodologia SUPERFLEX para simular o processo chuva-vazão na bacia do rio Saci. O processo de interceptação da bacia do rio Araponga foi simulado com os modelos de Gash e de Rutter modificado (SÁ, 2015) e com o modelo de Rutter modificado (OLIVEIRA, 2015). Mota (2017) analisou os mecanismos de geração de vazão em três encostas da bacia do rio Araponga com o modelo HYDRUS-2D.

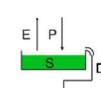
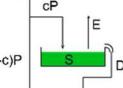
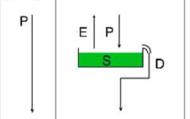
Neste trabalho, o processo de interceptação nas duas bacias foi investigado a partir da combinação de diferentes estruturas de modelo e de duas formulações de drenagem da água da copa (item 3.4.1). O processo de chuva-vazão foi modelado a partir da utilização de diferentes modelos conceituais concentrados construídos a partir da metodologia SUPERFLEX (item 3.4.2). A inferência Bayesiana foi utilizada para obtenção dos valores dos parâmetros dos modelos e para estimativa da incerteza associada aos resultados das simulações (item 3.4.3).

Parte deste item do trabalho – em especial os itens relacionados à escolha da função de verossimilhança para a modelagem do processo de interceptação – levou a produção do artigo intitulado “Extending the applicability of the Generalized Likelihood function for zero-inflated data series”, publicado na revista *Water Resources Research*.

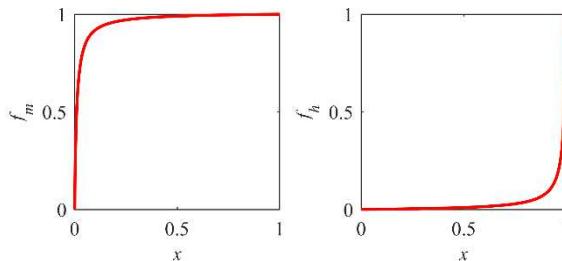
#### 3.4.1. Modelagem do processo de interceptação

Neste trabalho foi avaliado a utilização de sete modelos para representação do processo de interceptação. Estes modelos foram construídos a partir da combinação de quatro diferentes estruturas e de duas formulações de drenagem da água armazenada na copa. As quatro

estruturas, as equações correspondentes e as formulações de drenagem são apresentados na Figura 13. A Figura 14 apresenta o formato das funções constitutivas utilizadas no equacionamento dos modelos.

Representação de cada estrutura			
			
S01	S02	S03	S04
Balanço para cada estrutura			
S02	S03	S04	
$\frac{dS}{dt} = P - E - D$	$\frac{dS}{dt} = cP - E - D$	$\frac{dS}{dt} = P - E - D$	
$Pn = D$	$Pn = (1 - c) + D$	$Pn = (1 - c) + cD$	
Equações de drenagem			
D01		D02	
$D = Pf_h(\bar{S} \mid m_1)$	$D = Pf_h(\bar{S} \mid m_1)$	$D = b(S - C)$	
Evaporação			
		$E = C_e E_p f_m(\bar{S} \mid m_2)$	
Equações auxiliares			
$\bar{S} = \frac{S}{S_{\max}}$	$f_m(x \mid m) = \frac{x(1+m)}{x+m}$	$f_h(x \mid m) = 1 - \frac{(1-x)(1+m)}{1-x+m}$	

**Figura 13.** Estruturas consideradas para representar o processo de interceptação.



**Figura 14.** Variação das funções constitutivas  $f_m$  e  $f_h$  com  $x$ , para  $m = 0,01$ .

A primeira estrutura considerada (S01) é uma regressão linear simples, relacionando a variável predita (chuva interna ou chuva líquida) e a variável preditora (chuva total). Nesta estrutura é considerado que a chuva interna (ou chuva líquida) correspondem a uma fração constante da chuva total. Esta estrutura serviu de base de comparação com as demais. Qualquer outro modelo necessariamente precisa superar o desempenho deste modelo base.

A segunda estrutura (S02) é uma estrutura comumente encontrada em modelos chuva-vazão, constituída por um reservatório que tem como entrada a chuva total incidindo na bacia, e as saídas ocorrem por evaporação e drenagem.

A terceira estrutura (S03) é semelhante à estrutura S02, exceto que apenas uma fração da chuva total constitui a entrada do reservatório de interceptação. Essa fração pode ser interpretada como o fator de cobertura da vegetação (parâmetro  $c$ ). A parte da chuva total que colide com a vegetação é temporariamente retida, ficando disponível para evaporação ou sendo drenada para o solo. Esta estrutura é semelhante à estrutura do modelo de Rutter em sua formulação original, descrito no item 2.2.2.

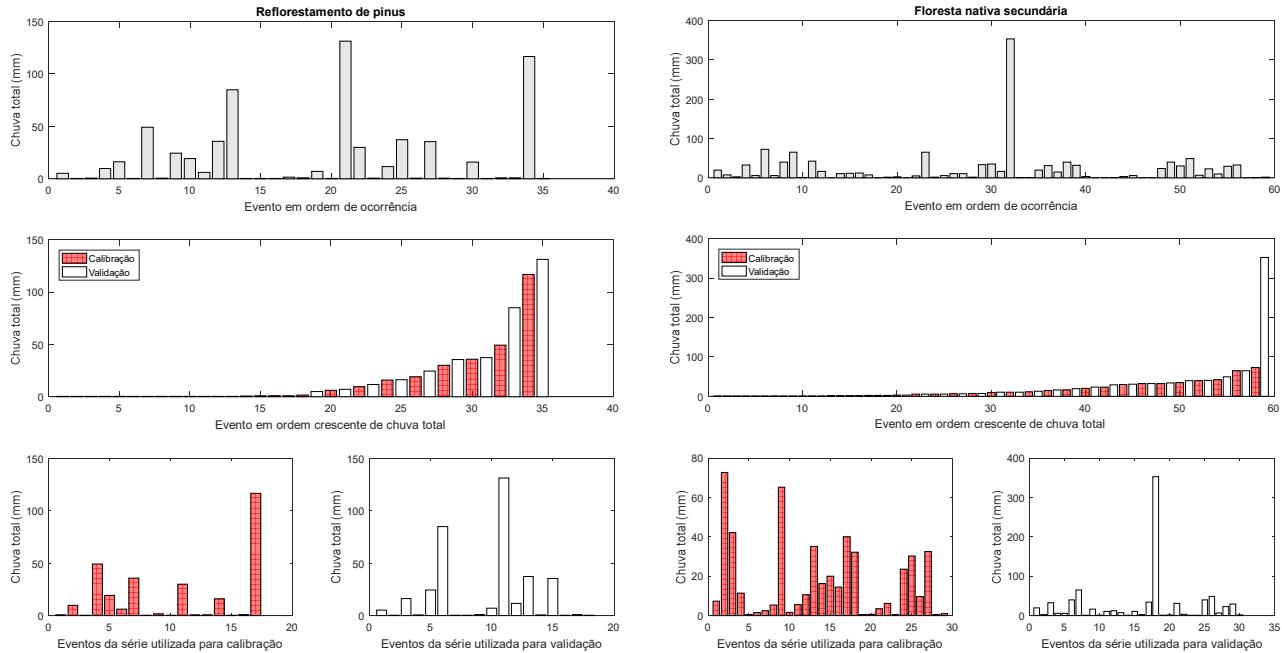
A quarta estrutura (S04) considera que a bacia é dividida em duas partes: uma parte descoberta, representando uma fração  $(1 - c)$  da área total; e uma parte coberta, representando uma fração  $c$  da área total. Esta estrutura corresponde à modificação proposta por Valente, David e Gash (1997) ao modelo de Rutter.

Estruturas mais complexas (com, por exemplo, a consideração explícita de um reservatório representando os troncos) não foram consideradas pois simulações preliminares demonstraram que os novos parâmetros adicionados não puderam ser identificados a partir da calibração automática com dados observados de chuva interna ou chuva líquida (chuva interna + escoamento pelos troncos).

As equações de drenagem descrevem a saída dos reservatórios das estruturas S02, S03 e S04 que é direcionada para o chão florestal. Na primeira equação de drenagem (D01), todo o volume que excede a capacidade de armazenamento do reservatório de interceptação é imediatamente direcionado para o solo. Na segunda equação de drenagem (D02), é considerado que a drenagem da água armazenada na copa se relaciona linearmente com o volume que excede a capacidade de armazenamento. Nesta formulação, o armazenamento de água na vegetação pode superar temporariamente a sua capacidade de armazenamento. A utilização de formulações de drenagem mais complexas inviabilizou a identificação de todos os parâmetros, sendo, portanto, não consideradas neste estudo.

Para a modelagem do processo de interceptação, as séries de dados de cada uma das florestas foram divididas em duas partes: uma parte para obtenção dos valores dos parâmetros (calibração); e outra parte para avaliação do desempenho dos modelos (validação). Para isso, os 35 eventos do reflorestamento de pinus e 59 eventos da floresta nativa foram ordenados em função do valor de chuva total, sendo utilizado os eventos ímpares resultantes desta classificação para composição da série de obtenção dos valores dos parâmetros (série A) e o restante utilizado para formação da série de avaliação de desempenho dos modelos (série B) (Figura 15). As séries A e B contêm 59 e 56% (reflorestamento de pinus) e 51 e 40% (floresta nativa) de observações iguais a zero, respectivamente. Sem consideração de observações iguais a zero, a proporção de dados com valor igual à resolução de monitoramento é de 44 e 29% (reflorestamento de pinus) e 7 e 4% (floresta nativa) para as séries A e B, respectivamente. Os dados foram acumulados para obtenção de uma série com resolução temporal de 1 hora.

Para avaliar a influência do valor da evaporação potencial na calibração dos modelos de interceptação, três situações foram consideradas: (1) evaporação potencial calculada com o método de Penman modificado; (2) evaporação potencial igual a  $4 \text{ mm d}^{-1}$  e com variação senoidal ao longo do dia; e (3) evaporação potencial igual a  $4 \text{ mm d}^{-1}$  e distribuição uniforme ao longo do dia.



**Figura 15.** Séries de dados da bacia do rio Saci (esquerda), de reflorestamento de pinus, e da bacia do rio Araponga (direita), de floresta nativa secundária, separadas em eventos de chuva. No painel superior os eventos são apresentados em ordem de ocorrência. No painel central os eventos são apresentados em ordem crescente de volume de chuva total, sendo separados em eventos para obtenção dos parâmetros (calibração, em vermelho) e para avaliação de desempenho dos modelos (validação, em branco). No painel inferior são apresentadas as séries resultantes de calibração e validação para cada uma das bacias.

### 3.4.2. Modelagem do processo chuva-vazão

Para a modelagem do processo chuva-vazão nas duas bacias experimentais foram utilizados oito modelos conceituais construídos a partir da metodologia SUPERFLEX (FENICIA; KAVETSKI; SAVENIJE, 2011; KAVETSKI; FENICIA, 2011). Esta metodologia permite que complexidade seja adicionada ao modelo de maneira incremental, possibilitando a identificação das modificações que são relevantes na representação do processo chuva-vazão de cada bacia estudada. Os modelos são construídos a partir da combinação de três elementos: reservatórios, junções e funções de transferência.

Fenia et al. (2014) apresentaram um total de 12 modelos (nomeados de M01 a M12) que foram aplicados a três bacias hidrográficas com área de 0,42 km<sup>2</sup>, 2,7 km<sup>2</sup> e 4,5 km<sup>2</sup>. Outros estudos utilizaram alguns destes modelos para simular o processo chuva-vazão de bacias com diferentes tamanhos, por exemplo: M01, M02, M03, M06, M07, M10, M12 em bacias com área de 0,04 km<sup>2</sup> e 4,6 km<sup>2</sup> (EUSER et al., 2013); M01, M02, M03, M04, M05, M10 e M11 em bacias com área de 0,04 km<sup>2</sup>, 4,6 km<sup>2</sup>, 250 km<sup>2</sup> e 385 km<sup>2</sup> (KAVETSKI; FENICIA, 2011); M04, M05, M06 e M12 em uma bacia com área de 1.607 km<sup>2</sup> (DE BOER-EUSER et al., 2017); e M12 em bacias com área de 2.924 km<sup>2</sup>, 5.526 km<sup>2</sup> e 10.009 km<sup>2</sup> (GAO et al., 2014).

Neste trabalho foram utilizados os modelos M01, M03, M04, M07, M08, M09, M10 e M11 apresentados em Fenicia et al. (2014) (Figura 16). O modelo M01 possui apenas um reservatório, os modelos M03 e M04 possuem dois reservatórios conectados em série, e os modelos M07, M08, M09, M10 e M11 são estruturas em paralelo.

Os modelos foram construídos a partir da utilização de quatro reservatórios, que representam o armazenamento e transferência de água na bacia de diferentes formas: reservatório rápido (FR, do inglês *fast reservoir*), com armazenamento  $S_f$ ; reservatório da zona não saturada (UR, do inglês *unsaturated soil reservoir*), com armazenamento  $S_u$ ; reservatório da zona ripária (RR, do inglês *riparian zone reservoir*), com armazenamento  $S_r$ ; e reservatório lento (SR, do inglês *slow reservoir*), com armazenamento  $S_s$ .

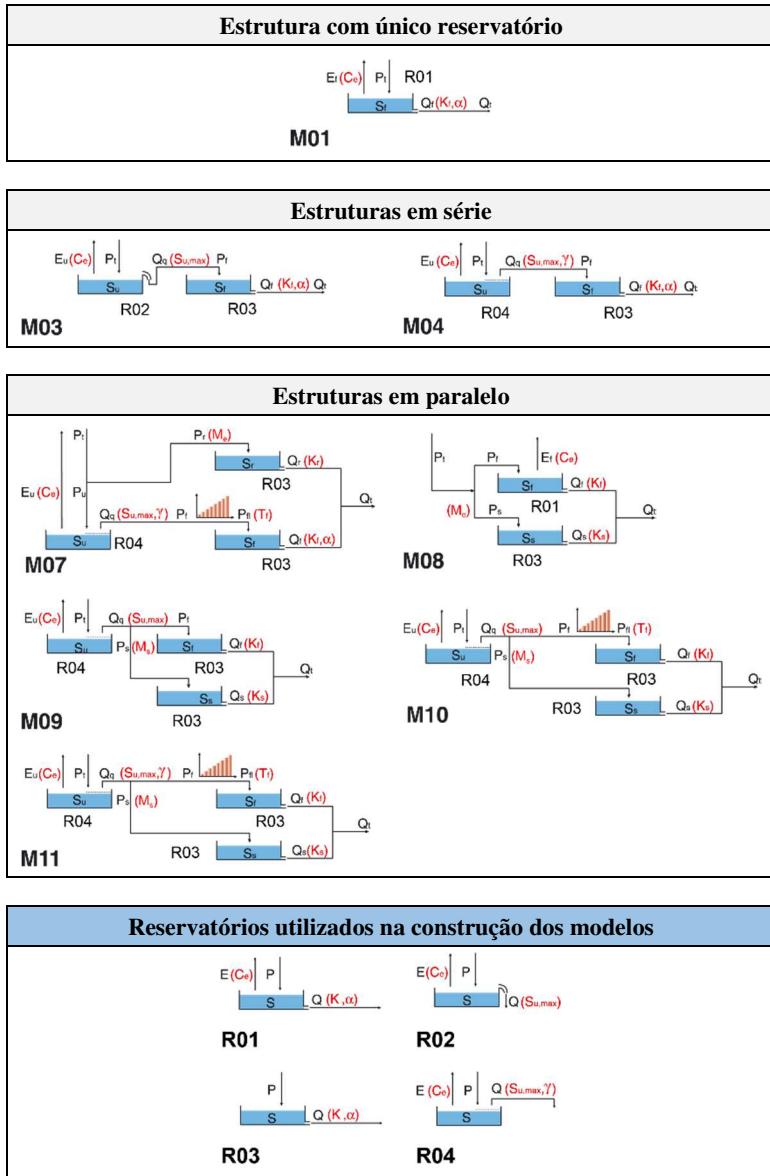
O modelo M01 é um modelo com um único reservatório rápido, não linear, sendo a formulação mais simples considerada (Figura 16). No modelo M03 é adicionado um reservatório da zona não saturada precedendo o reservatório rápido. Nesta formulação é considerado que o reservatório da zona não saturada possui uma capacidade máxima ( $S_{u,\max}$ ) a partir da qual se inicia o fluxo para o reservatório rápido. O modelo M04

apresenta a mesma estrutura que o M03, diferindo apenas no equacionamento de saída do reservatório da zona não saturada. No modelo M07 é adicionado um reservatório da zona ripária, linear, conectado em paralelo ao sistema de reservatórios em série do modelo M04. Nesse modelo, uma proporção  $(1 - M_e)$  da chuva total constitui a entrada do reservatório da zona não saturada, cujo fluxo é direcionado para o reservatório rápido, e uma proporção  $M_e$  da chuva total entra diretamente no reservatório da zona ripária. As saídas dos reservatórios da zona ripária e rápido compõem a vazão total. No modelo M08, a chuva total é dividida através de um parâmetro  $M_s$  entre dois reservatórios: um reservatório rápido e um reservatório lento, ambos lineares. No modelo M09 é adicionado um reservatório da zona não saturada, linear, precedendo o sistema de reservatórios do modelo M08. No modelo M10 é considerada uma função de transferência do fluxo do reservatório da zona não saturada para o reservatório rápido. O modelo M11 é semelhante ao modelo M10 exceto que o reservatório da zona não saturada é não linear.

Os reservatórios FR, UR, RR e SR são construídos a partir de quatro tipos distintos de reservatórios, que diferem em termos do tipo e equacionamento das entradas e saídas consideradas. Estes quatro tipos de reservatório (R01 a R04) são apresentados na Figura 16 e sua presença ou ausência em cada um dos modelos é listada na Tabela 4.

As equações dos modelos são apresentadas na Tabela 5. A Tabela 6 apresenta as funções auxiliares utilizadas, cujo formato é exemplificado na Figura 17. A listagem dos parâmetros presentes em cada modelo e sua descrição são apresentados nas Tabela 7 e Tabela 8, respectivamente.

Nos modelos M09, M10 e M11 os reservatórios rápido e lento são do mesmo tipo (reservatório do tipo R03) e são conectados em paralelo. Desta maneira, para garantir a correta interpretação dos resultados obtidos, é importante que seja atribuído o menor valor do coeficiente de recessão ao reservatório lento (que possui maior tempo de residência). Caso na calibração o menor valor do coeficiente de recessão tenha sido obtido para o reservatório rápido, os valores de  $k_s$  e  $k_f$  devem ser invertidos, e o valor do parâmetro  $M_s$  passa a ser igual a  $1 - M_s$ .



**Figura 16.** Modelos chuva-vazão considerados neste estudo (adaptado de Fenicia et al., 2014). Em vermelho estão os parâmetros.

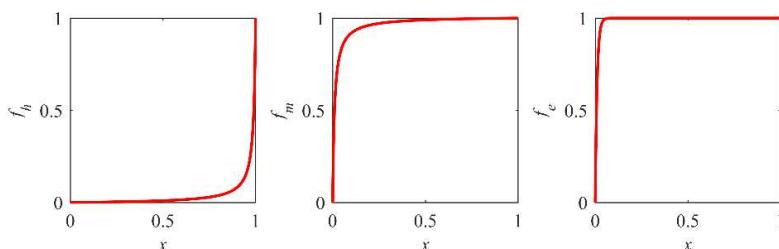
**Tabela 4.** Reservatórios de cada modelo chuva-vazão considerado neste estudo.

Modelo	N <sub>R</sub>	UR	FR	SR	RR
M01	1		R01		
M03	2	R02	R03		
M04	2	R04	R03		
M07	3	R04	R03		R03
M08	2		R01	R03	
M09	3	R04	R03	R03	
M10	3	R04	R03	R03	
M11	3	R04	R03	R03	

**Tabela 5.** Equações utilizadas em cada modelo.

Equação	M01	M03	M04	M07	M08	M09	M10	M11
$\bar{S}_u = \frac{S_u}{S_{u,\max}}$	X	X	X			X	X	X
$P_r = M_e P_t$					X			
$P_s = M_s Q_q$						X	X	X
$P_s = M_s P_t$						X		
$Q_q = P_u f_p(\bar{S}_u   \gamma)$					X	X		X
$Q_q = P_u f_h(\bar{S}_u   m_1)$	X							
$Q_r = k_r S_r$					X			
$Q_f = k_f S_f$						X	X	X
$Q_f = k_f S_f^\alpha$	X	X	X	X				
$Q_s = k_s S_s$						X	X	X
$E_u = C_e E_p f_m(\bar{S}_u   m_2)$	X	X	X	X		X	X	X
$E_f = C_e E_p f_e(S_f   m_3)$					X			

\* neste trabalho foi fixado  $m_1 = m_2 = m_3 = 0,01$ .

**Figura 17.** Variação das funções auxiliares  $f_h$ ,  $f_m$  e  $f_e$  com  $x$ , para  $m = 0,01$ .

**Tabela 6.** Funções auxiliares.

<b>Função</b>
$f_p(x   m) = x^m$
$f_h(x   m) = 1 - \frac{(1-x)(1+m)}{1-x+m}$
$f_m(x   m) = \frac{x(1+m)}{x+m}$
$f_e(x   m) = 1 - e^{-x/m}$

**Tabela 7.** Parâmetros de cada modelo considerado.

<b>Parâmetros</b>	<b>M01</b>	<b>M03</b>	<b>M04</b>	<b>M07</b>	<b>M08</b>	<b>M09</b>	<b>M10</b>	<b>M11</b>
$C_e$	X	X	X	X	X	X	X	X
$S_{u,\max}$		X	X	X		X	X	X
$\gamma$			X	X				X
$M_e$				X				
$k_r$					X			
$T_f$					X		X	X
$k_f$	X	X	X	X	X	X	X	X
$\alpha$	X	X	X	X				
$M_s$					X	X	X	X
$k_s$					X	X	X	X
Total	3	4	5	8	4	5	6	7

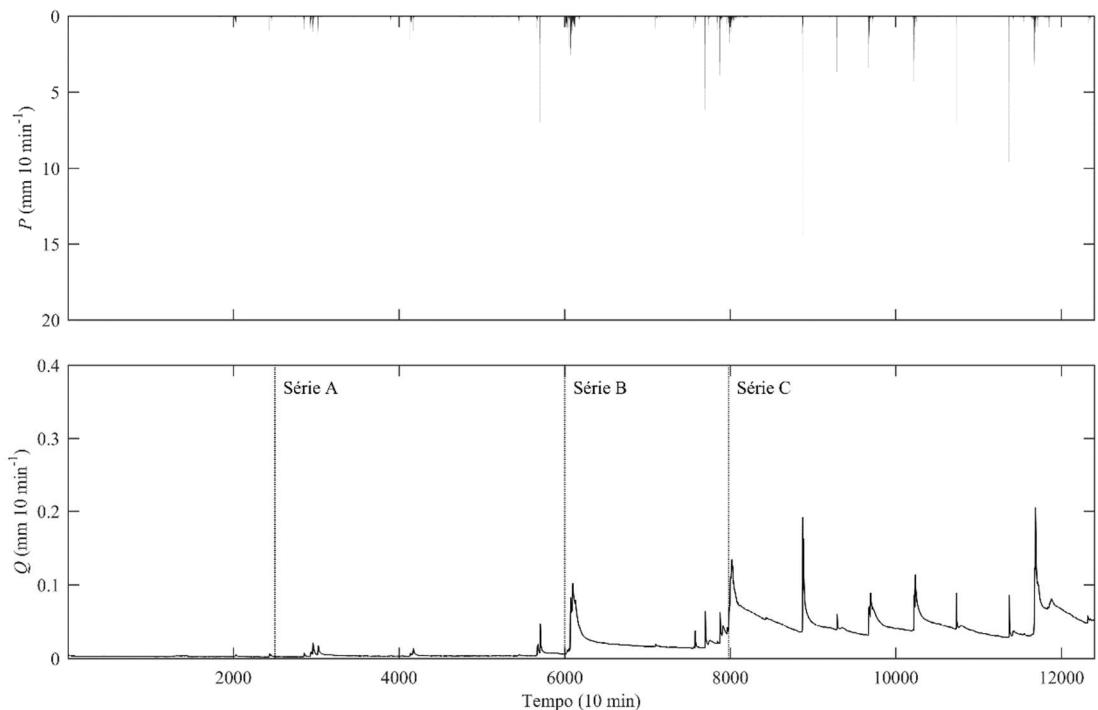
**Tabela 8.** Descrição dos parâmetros.

<b>Parâmetro</b>	<b>Descrição</b>	<b>Unidade</b>
$C_e$	Parâmetro de eficiência de evaporação	-
$S_{u,\max}$	Capacidade de armazenamento do reservatório UR	mm
$\gamma$	Parâmetro de não linearidade do reservatório R04	-
$M_e$	Parâmetro de repartição da entrada entre reservatórios	-
$k_r$	Coeficiente de recessão do reservatório da zona ripária	1/h
$T_f$	Tempo de atraso	h
$k_f$	Coeficiente de recessão do reservatório rápido	1/h
$\alpha$	Coeficiente de não linearidade dos reservatórios R01 e R03	-
$M_s$	Parâmetro de repartição do fluxo de saída do reservatório UR	-
$k_s$	Coeficiente de recessão do reservatório SR	1/h

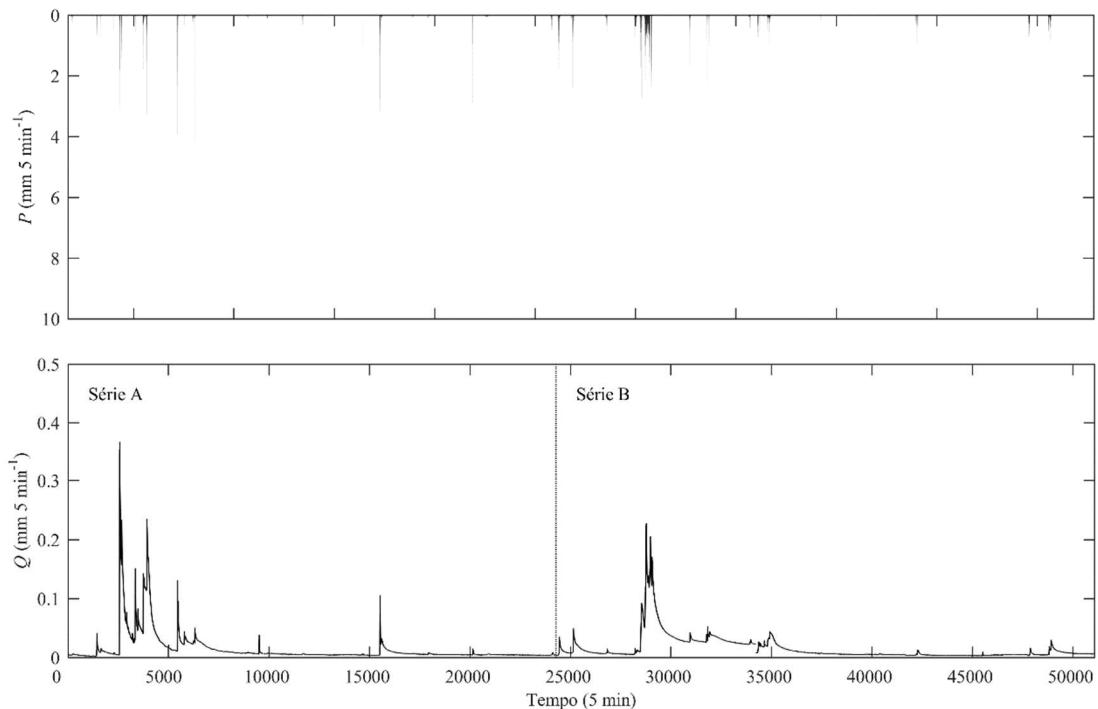
Para a bacia do rio Saci, a série disponível possui um total de 12.397 dados com resolução temporal de 10 min (CHAFFE, 2009). O armazenamento inicial dos reservatórios foi considerado como sendo zero, o que não deve prejudicar os resultados das simulações uma vez que a vazão no início do período de monitoramento era bem baixa (Figura 18). Porém, como no período compreendido entre os dados 1 e 2.500 não

houve nenhum evento de precipitação significativo, impedindo a “ativação” dos modelos (ou seja, neste período a vazão simulada permaneceu igual a zero), este período foi excluído da calibração. Para a análise de desempenho dos modelos em diferentes condições de umidade da bacia, a série de dados foi separada em três partes (Figura 18): série A (fase seca, do passo de tempo 2.501 ao passo de tempo 6.000); série B (fase de transição, do passo de tempo 6.001 ao passo de tempo 7.980); e série C (fase úmida, do passo de tempo 7.981 ao passo de tempo 12.397). Esta separação da série de dados foi sugerida em Chaffe (2009). Ressalta-se que a calibração dos modelos foi realizada com a totalidade da série (série A + série B + série C). Devido ao tamanho limitado da série de dados disponível, optou-se por não separar uma parte exclusiva da série de dados para validação dos modelos. Testes preliminares realizados com diferentes divisões da série para calibração e validação não promoveram resultados satisfatórios.

Seguindo o mesmo procedimento adotado para a bacia do rio Saci, para a bacia do rio Araponga a calibração dos modelos foi realizada com a totalidade da série de dados considerada neste estudo, ou seja, de 26/02/2014 a 06/10/2014 (período em que os dados de interceptação também foram medidos), totalizando 51.070 dados com resolução temporal de 5 min (Figura 19). O armazenamento inicial dos reservatórios foi considerado como sendo zero. Para reduzir a influência deste valor nos resultados das simulações foi considerado um período de aquecimento do modelo de 01/01/2013 a 25/02/2014. Como a série de dados da bacia do rio Araponga é muito mais longa do que no caso da bacia do rio Saci, também foi avaliada a divisão da série de dados em duas partes e realização de validação cruzada, isto é, utilização da série A para calibração e da série B para validação e vice-e-versa. A série A compreende os passos de tempo de 1 a 24.284 e a série B os passos de tempo de 24.285 a 51.070 (Figura 19). Esta divisão foi realizada de forma que duas séries de tamanho similar ficasse disponíveis, sendo evitado separar a série exatamente na metade para não cortar nenhum evento de precipitação.



**Figura 18.** Série de dados de chuva total (painel superior) e de vazão (painel inferior) para a bacia do rio Saci, com resolução temporal de 10 min.



**Figura 19.** Série de dados de chuva total (painel superior) e de vazão (painel inferior) para a bacia do rio Araponga, com resolução temporal de 5 min.

### 3.4.3. Inferência dos parâmetros e análise de incerteza

A calibração e análise de incerteza dos modelos de interceptação e chuva-vazão foram realizadas a partir da utilização do algoritmo de calibração automática *Differential Evolution Adaptive Metropolis* (DREAM) (VRUGT, 2016), implementado em MATLAB e disponibilizado pelo Dr. Jasper Vrugt. A versão 3.0 do algoritmo DREAM foi utilizada na modelagem do processo de interceptação devido à disponibilidade do código em formato .m, permitindo a inserção de diferentes funções de verossimilhança (mais detalhes sobre isso serão apresentados a seguir). Para a modelagem do processo chuva-vazão, a versão DREAM<sub>(zs)</sub> foi utilizada, que requer uma menor demanda computacional, porém os códigos estão em formato .p (protegido de modificações).

O DREAM utiliza a inferência Bayesiana para a estimativa conjunta dos valores dos parâmetros do modelo e da incerteza associada às simulações. Na inferência Bayesiana, a distribuição *a posteriori* dos parâmetros  $P(\boldsymbol{\theta} | \mathbf{y})$  é obtida a partir da aplicação do teorema de Bayes:

$$P(\boldsymbol{\theta} | \mathbf{y}) \propto P(\boldsymbol{\theta})P(\mathbf{y} | \boldsymbol{\theta}) \quad (26)$$

em que  $P(\boldsymbol{\theta})$  é a distribuição *a priori* dos parâmetros e  $P(\mathbf{y} | \boldsymbol{\theta})$  é a função de verossimilhança. Desta maneira, o usuário precisa definir uma distribuição *a priori*, que sumariza o conhecimento sobre os valores dos parâmetros antes da obtenção de qualquer informação sobre os dados  $\mathbf{y}$ , e uma função de verossimilhança, que mede em termos probabilísticos a distância entre as saídas do modelo e as observações.

Foi adotada como distribuição *a priori* uma distribuição uniforme, sendo definidos valores mínimos e máximos para cada um dos parâmetros dos modelos. A distribuição uniforme pode ser considerada como uma distribuição não informativa, no sentido de que não favorece *a priori* nenhum valor em específico para os parâmetros do modelo. Quando o número de dados utilizado na inferência é elevado, a distribuição *a priori* exerce pouca influência na distribuição *a posteriori* dos parâmetros.

Por outro lado, a escolha de uma função de verossimilhança que represente adequadamente os resíduos do modelo é fundamental para garantir a qualidade dos valores dos parâmetros e da faixa de incerteza associada aos resultados das simulações. A violação das premissas assumidas para os resíduos resulta em uma faixa de incerteza não confiável e de valores não representativos para os parâmetros

(SCHOUPS; VRUGT, 2010; THYER et al., 2009). Desta maneira, primeiramente foi avaliado o uso de diferentes funções de verossimilhança na calibração dos modelos. Nesta etapa foi empregado apenas um modelo de interceptação e um modelo chuva-vazão e analisada a influência da escolha da função de verossimilhança na estimativa dos parâmetros e da incerteza relacionada aos resultados das simulações. O objetivo desta etapa é selecionar uma função de verossimilhança adequada para a utilização na calibração dos diferentes modelos de interceptação e dos modelos chuva-vazão.

O modelo de interceptação utilizado para a escolha da função de verossimilhança é uma versão simplificada do modelo de Rutter (RUTTER et al., 1971), que considera um modelo linear para a drenagem da água armazenada na vegetação (VRUGT; DEKKER; BOUTEN, 2003). Este modelo considera que a vegetação se comporta como um tanque de armazenamento que tem como entrada a chuva interceptada pela vegetação ( $aP$ , em que  $a$  é um parâmetro relacionado à eficiência de interceptação) e as saídas ocorrem por drenagem ( $D$ ) e evaporação ( $I_L$ ). O modelo requer como entrada dados de chuva total e de evaporação potencial, e possui como saídas a variação no tempo das perdas por interceptação ( $I_L$ ) e da chuva interna ( $T_f$ ). O balanço de água na copa é calculado por

$$\frac{dS}{dt} = aP - D - I_L, \quad (27)$$

em que  $S$  (mm) é o armazenamento da água na vegetação,  $a$  (adimensional) é o parâmetro de eficiência de interceptação,  $P$  (mm h<sup>-1</sup>) é a intensidade de chuva total,  $D$  (mm h<sup>-1</sup>) é a taxa de drenagem da água armazenada na vegetação e  $I_L$  (mm h<sup>-1</sup>) é a taxa de perdas por interceptação. A drenagem da água armazenada na vegetação é calculada por

$$D = \begin{cases} b(S - c) & \text{se } S > c \\ 0 & \text{se } S < c \end{cases} \quad (28)$$

em que  $b$  (h<sup>-1</sup>) é um parâmetro de drenagem e  $c$  (mm) é a capacidade de armazenamento de água na vegetação. A intensidade de chuva interna é estimada como a soma da água drenada da copa e da proporção da chuva total que incide diretamente no solo sem ser interceptada, ou seja,

$$Tf = (1 - a)P + D, \quad (29)$$

e assume-se que a taxa de perdas por interceptação aumenta linearmente com o armazenamento de água na vegetação,

$$I_L = dE_p \frac{S}{c}, \quad (30)$$

em que  $d$  (adimensional) é um parâmetro de eficiência de evaporação e  $E_p$  ( $\text{mm h}^{-1}$ ) é a taxa de evaporação potencial. A evaporação da água armazenada na vegetação assume um valor máximo quando a copa está completamente molhada ( $S = c$ ). Este modelo de interceptação possui então quatro parâmetros ( $a, b, c$  and  $d$ ). O método de Euler implícito foi utilizado para resolução da Eq. (27) considerando um passo de integração de 1 min.

O modelo chuva-vazão considerado para a escolha da função de verossimilhança é o modelo M09 (descrito no item 3.4.2), tanto para a bacia do rio Saci quanto para a bacia do rio Araponga. Este modelo foi implementado utilizando o método de Euler explícito e um passo de integração de 5 min.

A função de verossimilhança é construída a partir das premissas assumidas para os resíduos (modelo para resíduos). A escolha dos modelos para resíduos considerados nesta análise foi realizada de uma maneira iterativa, em que o aumento de complexidade de um modelo para outro foi realizado apenas após verificação da inabilidade do modelo precedente em satisfazer uma ou mais premissas sobre os resíduos. Nesta parte do trabalho, foi analisado o uso de funções de verossimilhança com crescente complexidade do modelo para os resíduos. Os modelos para resíduos considerados são apresentados na Tabela 9. Todos os modelos para os resíduos foram construídos a partir da *Generalized Likelihood function* (SCHOUPS; VRUGT, 2010). A *Generalized Likelihood function* (GL) é uma função de verossimilhança flexível, que permite a adição de complexidade ao modelo para os resíduos com a inclusão de parâmetros no processo de calibração. Na GL, ao invés de assumir uma distribuição Gaussiana para os resíduos, estes são modelados por uma distribuição *skewed exponential power* (SEP), que possui parâmetros de curtose ( $\beta$ ) e de assimetria ( $\zeta$ ).

**Tabela 9.** Premissas de cada um dos modelos para resíduos considerados.

Formulação	Modelo para resíduo	Distribuição	Heteroscedasticidade	Correlação	Parâmetros fixos
<i>Generalized Likelihood function</i>	L1	Gaussiana	Homoscedástico	Independente	$\sigma_1 = 0, \beta = 0, \zeta = 1, \phi = 0$
	L2	Gaussiana	Heteroscedástico	Independente	$\beta = 0, \zeta = 1, \phi = 0$
	L3	<i>Skewed exponential power</i>	Heteroscedástico	Independente	$\zeta = 1, \phi = 0$
	L4 / L5 <sup>a</sup>	<i>Skewed exponential power</i>	Heteroscedástico	Correlacionados	$\zeta = 1$
<i>Zero-inflated Generalized Likelihood function<sup>b</sup></i>	L1	<i>Skewed exponential power</i>	Homoscedástico	Independente	$\sigma_1 = 0, \beta = 0, \phi = 0$
	L2	<i>Skewed exponential power</i>	Heteroscedástico	Independente	$\beta = 0, \phi = 0$
	L3	<i>Skewed exponential power</i>	Heteroscedástico	Independente	$\phi = 0$
	L4 / L5 <sup>a</sup>	<i>Skewed exponential power</i>	Heteroscedástico	Correlacionados	-

<sup>a</sup> Para L4 o modelo AR(1) é aplicado aos resíduos brutos ( $e_t$ ) e para L5 o modelo AR(1) é aplicado aos resíduos padronizados ( $\eta_t = e_t / \sigma_t$ ).

<sup>b</sup> Para ZI-GL, as premissas apresentadas correspondem aos resíduos da categoria 3. Os resíduos da categoria 2 são considerados como homoscedásticos e são modelados com a distribuição *Skewed exponential power* com parâmetros fixos  $\beta = 1$  and  $\zeta = 10$ .

Para garantir estabilidade numérica, é utilizado o logaritmo da função de verossimilhança. O logaritmo natural da GL é

$$\ell(\boldsymbol{\theta} | \mathbf{y}) = n \log \frac{2\sigma_\xi \omega_\beta}{\xi + \xi^{-1}} - \sum_{t=1}^n \log \sigma_t - c_\beta \sum_{t=1}^n \left| a_{\xi,t} \right|^{2/(1+\beta)}, \quad (31)$$

em que  $\boldsymbol{\theta} = \{\boldsymbol{\theta}_s, \boldsymbol{\theta}_e\}$  é o conjunto de parâmetros (composto pelos parâmetros do modelo determinístico  $\boldsymbol{\theta}_s$  – neste caso o modelo de interceptação ou o modelo chuva-vazão – e pelos parâmetros do modelo para resíduos  $\boldsymbol{\theta}_e = \{\sigma_t, \xi, \beta, \phi\}$ ),  $\mathbf{y}$  é um vetor com as observações (medidas da resposta observada do sistema em questão),  $a_{\xi,t} = \xi^{-sign(\mu_\xi + \sigma_\xi a_t)} (\mu_\xi + \sigma_\xi a_t)$  e  $\omega_\beta$ ,  $c_\beta$ ,  $\mu_\xi$  e  $\sigma_\xi$  são calculados a partir de  $\beta$  e  $\xi$  e são apresentados no Apêndice A de Schoups e Vrugt (2010) (equações (A2), (A3), (A5) e (A6), respectivamente) e  $n$  é o número de dados considerados na calibração.

O primeiro modelo para resíduos considerado (L1) é comumente empregado em estudos de modelagem hidrológica e foi utilizado como base para comparação com as demais. Este modelo considera que os resíduos seguem uma distribuição Gaussiana, são homoscedásticos (com variância constante) e independentes. A maximização da função de verossimilhança construída com este modelo para resíduos, em conjunto com a utilização de uma distribuição *a priori* uniforme, equivale à utilização de funções objetivos que minimizam a soma dos erros ao quadrado, como o coeficiente de Nash-Stutcliffe (NS) e a raiz do erro quadrático médio (RMSE). A partir de L1, as seguintes características foram consideradas sequencialmente: heteroscedasticidade (L2); curtoza da distribuição dos resíduos (L3) e autocorrelação (L4 e L5). A autocorrelação dos resíduos foi considerada com a inclusão de um modelo autorregressivo de primeira ordem, AR(1). Em L4, o modelo AR(1) é aplicado para os resíduos brutos, e em L5 o modelo AR(1) é aplicado para os resíduos padronizados. As premissas de cada um destes modelos para resíduos assim como a configuração da GL em cada caso (valores dos parâmetros da GL que precisam ser fixados) são apresentadas na Tabela 9.

A heteroscedasticidade dos resíduos foi considerada assumindo um modelo linear para o desvio padrão dos resíduos, i.e.,

$$\sigma_t = \sigma_0 + \sigma_1 \hat{y}_t, \quad (32)$$

em que  $\sigma_t$  é o desvio padrão no tempo  $t$ ,  $\sigma_0$  é coeficiente linear do modelo heteroscedástico e  $\sigma_1$  é o coeficiente angular do modelo heteroscedástico. O desvio padrão  $\sigma_t$  possui diferentes significados dependendo se heteroscedasticidade ou autocorrelação é considerada primeiramente. Se a autocorrelação é considerada antes da heteroscedasticidade, os resíduos brutos são modelados conforme (SCHOUPS; VRUGT, 2010)

$$e_t - \phi e_{t-1} = \sigma_t a_t \text{ com } a_t \sim \text{SEP}(\mu, 1, \xi, \beta), \quad (33)$$

em que  $\phi$  é o parâmetro do modelo autorregressivo de primeira ordem,  $\sigma_t$  é o desvio padrão dos resíduos no tempo  $t$  após aplicação do modelo AR(1) e  $a_t$  é uma amostra da distribuição assumida para os resíduos, neste caso a *skewed exponential power distribution* (SEP), com média  $\mu$ , variância unitária, parâmetro de assimetria  $\xi$  e parâmetro de curtose  $\beta$ . Evin et al. (2013) demonstraram que aplicando o modelo AR(1) aos resíduos padronizados,

$$\eta_t = \frac{e_t}{\sigma_t}, \quad (34)$$

evita a instabilidade que pode ocorrer quando o modelo AR(1) é aplicado aos resíduos (heteroscedásticos) brutos. Considerando a reparametrização deste método apresentado em Evin et al. (2014), a Eq. (33) fica

$$\eta_t - \phi \eta_{t-1} = a_t \text{ com } a_t \sim \text{SEP}(\mu, 1, \xi, \beta) \quad (35)$$

Neste caso, a variância dos resíduos padronizados é igual a  $1/(1-\phi^2)$  e o desvio padrão nas Eq. (32) e (34) corresponde a  $\sigma_t = \sqrt{1-\phi^2} \sigma_e$ , em que  $\sigma_e$  é o desvio padrão dos resíduos brutos.

Na modelagem do processo de interceptação, como a série de dados é composta por muitas observações iguais a zero (e que podem então ser modeladas com resíduo igual a zero), é esperado que a distribuição dos resíduos seja inflada com zeros. O uso da GL permite, até certo ponto, a consideração de série de dados com observações iguais a zero, a partir da consideração de curtose da distribuição. Porém, para períodos prolongados de observações iguais a zero, aumentar o valor do parâmetro  $\beta$  pode não ser suficiente para acomodar a inflação por zeros da distribuição dos resíduos (KOSKELA et al., 2012).

Desta maneira, na modelagem do processo de interceptação, além do método tradicional de calibração a partir da utilização da *Generalized Likelihood function* (GL), foram testados dois outros métodos com o objetivo de considerar a inflação da distribuição com zeros: desconsideração dos resíduos (zero e diferente de zero) correspondentes a observações iguais a zero no cálculo do valor da função de verossimilhança ( $GL^{y>0}$ ); e a utilização de uma versão modificada da *Generalized Likelihood function* considerando inflação com zeros (de agora em diante chamada de *Zero-Inflated Generalized Likelihood function*, ZI-GL). O uso dos três métodos na consideração de cada um dos modelos para os resíduos diverge do processo de escolha da função de verossimilhança apresentado por Smith, Marshall e Sharma (2015). Segundo esta abordagem, o potencial de inflação da distribuição dos resíduos por zeros deve ser verificado como um primeiro passo e muito provavelmente conduziria o processo de escolha da função de verossimilhança para uma função de verossimilhança com consideração de inflação com zeros, como a ZI-GL apresentada neste trabalho. Porém, mantendo os diferentes métodos (GL,  $GL^{y>0}$  e ZI-GL) permite que seja analisado de maneira separada os efeitos resultantes da adição de complexidade no modelo para os resíduos e de se considerar inflação da distribuição com zeros.

Na utilização do método  $GL^{y>0}$ , a formulação da função de verossimilhança permanece sendo a *Generalized Likelihood function*, exceto que são apenas considerados os resíduos de observações diferente de zero.

A formulação da ZI-GL apresentada nesta dissertação foi baseada no método de consideração de uma função de verossimilhança inflada com zeros proposto por Smith et al. (2010), exceto que a série de resíduos é dividida em termos dos valores simulados ao invés dos valores observados. Condicionando o modelo para resíduos nos valores simulados ao invés dos valores observados permite a sua utilização na previsão, situação em que as observações não estão disponíveis. Os resíduos brutos ( $e_t$ ), definidos como a diferença entre o valor observado ( $y_t$ ) e simulado ( $\hat{y}_t$ ) no tempo  $t$ ,

$$e_t = y_t - \hat{y}_t, \quad (36)$$

são divididos em três classes: resíduos iguais a zero de simulações iguais a zero ( $e_1$ ); resíduos diferentes de zero de simulações iguais a zero ( $e_2$ ); e resíduos diferentes de zero de simulações diferentes de zero ( $e_3$ ). Os

resíduos brutos são transformados para considerar heteroscedasticidade e autocorrelação ( $a$  se refere a esses resíduos transformados), como descrito anteriormente, e são modelados em duas etapas. Primeiramente, um modelo probabilístico binomial é utilizado para os resíduos de simulações iguais a zero ( $a_{t,sim=0}$ ), em que  $a_1$  são associados a uma probabilidade  $\rho$  e  $a_2$  são associados a uma probabilidade  $1-\rho$ . Os resíduos transformados da categoria 2 ( $a_2$ ) são então modelados a partir de uma SEP com média 1, variância unitária, parâmetro de assimetria  $\xi$  e parâmetro de curtose  $\beta$ . O modelo para resíduos de simulações iguais a zero é, portanto,

$$a_{t,sim=0} \sim \begin{cases} 0 & \text{com probabilidade } \rho \\ \text{SEP}(1,1,\xi,\beta) & \text{com probabilidade } 1-\rho \end{cases} \quad (37)$$

em que  $\rho = n_1/(n_1 + n_2)$  é a probabilidade de resíduo igual a zero dado que o valor simulado é zero e é calculado diretamente a partir do número de simulações iguais a zero com resíduo zero  $n_1$  e o número de simulações iguais a zero com resíduo diferente de zero  $n_2$ . Uma SEP padronizada (média igual a zero e variância unitária) é utilizada para modelar os resíduos transformados de simulações diferente de zero ( $a_{t,sim>0}$ ),

$$a_{t,sim>0} \sim \text{SEP}(0,1,\xi,\beta) \quad (38)$$

O logaritmo natural da *Generalized Likelihood function* modificada, que considera inflação da distribuição com zeros, heteroscedasticidade, autocorrelação e uma distribuição não Gaussiana para os resíduos, é

$$\begin{aligned} \ell(\boldsymbol{\theta} | \mathbf{y}) = & n_1 \log \rho + n_2 \log(1-\rho) + \\ & n_2 \log \frac{2\sigma_{\xi_2} \omega_{\beta_2}}{\xi_2 + \xi_2^{-1}} - \sum_{t_2=1}^{n_2} \log \sigma_{t_2} - c_{\beta_2} \sum_{t_2=1}^{n_2} |a_{\xi_2,t_2}|^{2/(1+\beta_2)} + \\ & n_3 \log \frac{2\sigma_{\xi_3} \omega_{\beta_3}}{\xi_3 + \xi_3^{-1}} - \sum_{t_3=1}^{n_3} \log \sigma_{t_3} - c_{\beta_3} \sum_{t_3=1}^{n_3} |a_{\xi_3,t_3}|^{2/(1+\beta_3)}, \end{aligned} \quad (39)$$

em que  $\boldsymbol{\theta} = \{\boldsymbol{\theta}_s, \boldsymbol{\theta}_e\}$  é o conjunto de parâmetros (composto pelos parâmetros do modelo determinístico  $\boldsymbol{\theta}_s$  e pelos parâmetros do modelo para resíduos  $\boldsymbol{\theta}_e = \{ \rho, \sigma_{t_2}, \sigma_{t_3}, \xi_2, \xi_3, \beta_2, \beta_3, \phi \}$ ),  $\mathbf{y}$  é um vetor com as observações (medições da resposta observada do sistema em questão),  $n_1$

é o número de simulações iguais a zero com resíduo igual a zero,  $n_2$  é o número de simulações iguais a zero com resíduo diferente de zero,  $n_3$  é o número de simulações diferentes de zero com resíduo diferente de zero,  $a_{\xi_i, t_i} = \xi_i^{-sign(\mu_{\xi_i} + \sigma_{\xi_i} a_{t_i})} (\mu_{\xi_i} + \sigma_{\xi_i} a_{t_i})$  e  $\omega_{\beta_i}$ ,  $c_{\beta_i}$ ,  $\mu_{\xi_i}$  e  $\sigma_{\xi_i}$  são calculados a partir de  $\beta_i$  e  $\xi_i$ , em que  $i$  é o índice da categoria de resíduos correspondente, e são apresentados no Apêndice A de Schoups e Vrugt (2010) (equações (A2), (A3), (A5) e (A6), respectivamente). A formulação ZI-GL é reduzida à GL conforme o número de simulações iguais a zero se aproxima de zero.

A formulação ZI-GL requer a especificação de duas SEP distintas. Para os resíduos da categoria 2 (resíduos diferentes de zero de simulações iguais a zero) o valor de  $\beta_2$  foi fixado em 1 e o valor de  $\xi_2$  foi fixado em 10. Para os resíduos da categoria 3 (resíduos diferentes de zero de simulações diferentes de zero) os valores dos parâmetros  $\beta_3$  e  $\xi_3$  foram calibrados junto com os parâmetros do modelo de interceptação e os demais parâmetros do modelo para resíduos. Quando ZI-GL foi utilizada, o modelo linear heteroscedástico foi aplicado apenas para os resíduos da categoria 3, e o modelo AR(1) foi aplicado para a série inteira. As premissas de cada dos modelos para resíduos considerados (L1 a L5) assim como a configuração da ZI-GL em cada caso (valores dos parâmetros da ZI-GL que precisam ser fixados) são apresentadas na Tabela 9.

Os parâmetros dos modelos para resíduos considerados foram calibrados em conjunto com os parâmetros do modelo determinístico (modelo de interceptação ou modelo chuva-vazão). Os limites da distribuição uniforme, utilizada como distribuição *a priori* para os parâmetros, são apresentados na Tabela 10 no caso da modelagem do processo de interceptação e na Tabela 11 no caso da modelagem do processo chuva-vazão.

**Tabela 10.** Limites inferior e superior para cada um dos parâmetros considerados na calibração do modelo de interceptação.

Parâmetro	Descrição	Mín.	Máx.	Unidade
<b>MODELO DE INTERCEPTAÇÃO</b>				
<i>a</i>	Eficiência de interceptação	0.1	1	-
<i>b</i>	Parâmetro de drenagem da copa	1.0	1000	$d^{-1}$
<i>c</i>	Capacidade de armazenamento	0.1	10	mm
<i>d</i>	Eficiência de evaporação	0.1	5	-
<b>GENERALIZED LIKELIHOOD FUNCTION</b>				
$\sigma_0$	Coeficiente linear do modelo heteroscedástico	0	50	$mm\ d^{-1}$
$\sigma_1$	Coeficiente angular do modelo heteroscedástico	0	1	-
$\beta$	Parâmetro de curtose	-1	1	-
$\phi$	Coeficiente de autocorrelação	0	1	-
<b>ZERO-INFLATED GENERALIZED LIKELIHOOD FUNCTION</b>				
$\sigma_{0,2}$	Desvio padrão para resíduos da categoria 2	0	50	$mm\ d^{-1}$
$\sigma_{0,3}$	Coeficiente linear do modelo heteroscedástico para resíduos da categoria 3	0	50	$mm\ d^{-1}$
$\sigma_{1,3}$	Coeficiente angular do modelo heteroscedástico para resíduos da categoria 3	0	1	-
$\beta_3$	Parâmetro de curtose para resíduos da categoria 3	-1	1	-
$\xi_3$	Parâmetro de assimetria para resíduos da categoria 3	0.1	10	-
$\phi$	Coeficiente de autocorrelação	0	1	-

**Tabela 11.** Limites inferior e superior para cada um dos parâmetros considerados na calibração do modelo chuva-vazão.

Parâmetro	Descrição	Mín.	Máx.	Unidade
<b>MODELO CHUVA-VAZÃO</b>				
$C_e$	Eficiência de evaporação	0,01	2	-
$S_{u,max}$	Capacidade de armazenamento da zona não saturada	1	500	mm
$\gamma$	Parâmetro de não linearidade do reservatório do tipo R04	0	20	-
$M_e$	Coeficiente de repartição da entrada entre reservatórios	0	1	-
$k_r$	Coeficiente de recessão do reservatório da zona ripária	0	1	$h^{-1}$
$T_f$	Tempo de atraso	0	100	h
$k_f$	Constante de recessão do reservatório rápido	0	1	$h^{-1}$
$M_s$	Proporção do fluxo direcionado para o reservatório lento	0,01	1	-
$k_s$	Constante de recessão do reservatório lento	0	0,5	$h^{-1}$
<b>GENERALIZED LIKELIHOOD FUNCTION</b>				
$\sigma_0$	Coeficiente linear do modelo heteroscedástico	0	1	$mm\ h^{-1}$
$\sigma_1$	Coeficiente angular do modelo heteroscedástico	0	1	-
$\beta$	Parâmetro de curtose	-1	1	-
$\phi$	Coeficiente de autocorrelação	0	1	-

Além da escolha da distribuição *a priori* e da função de verossimilhança, o DREAM possui alguns parâmetros cujos valores precisam ser definidos pelo usuário e dependem do estudo de caso: a dimensão do problema  $k$ , ou seja, o número de parâmetros a serem calibrados (parâmetros do modelo determinístico + parâmetros do modelo para resíduos); número de cadeias de Markov  $N$ ; e o número de gerações  $T$ , que é o número de amostras em cada uma das cadeias de Markov. Neste estudo, o valor de  $N$  foi fixado em  $N = \max(10; 2k)$  na calibração dos modelos de interceptação e em  $N = 3$  na calibração do modelo chuva-vazão. O número de cadeias utilizadas em cada caso difere já que para a inferência dos parâmetros dos modelos de interceptação foi utilizado a versão 3.0 do DREAM e para a inferência dos parâmetros dos modelos chuva-vazão foi utilizada versão DREAM<sub>(ZS)</sub>, como já mencionado no início deste item.  $T$  foi fixado inicialmente em 3.000. Quando necessário, o valor de  $T$  foi aumentado para garantir a convergência da distribuição *a posteriori* dos parâmetros para uma distribuição estacionária.

### *Geração da faixa de incerteza*

A distribuição *a posteriori* dos parâmetros é utilizada para construção da faixa de incerteza associada aos valores dos parâmetros, ou seja, amostras da distribuição *a posteriori* dos parâmetros são utilizadas para rodar o modelo determinístico e gerar a faixa de incerteza relacionada à incerteza dos parâmetros. A distribuição probabilística da variável simulada é gerada adicionando a cada simulação determinística, a cada passo de tempo, um erro amostrado do modelo para resíduos após “detransformação” para levar em consideração a heteroscedasticidade e autocorrelação, quando for o caso. A amostragem de erros da SEP foi realizada a partir do algoritmo apresentado em Schoups e Vrugt (2010). Quando a autocorrelação é considerada antes da heteroscedasticidade, os erros amostrados da SEP são multiplicados pelo desvio padrão  $\sigma_t$  e subsequentemente a Eq. (33) é utilizada para criar a série de resíduos final. Se a heteroscedasticidade dos resíduos é considerada antes da autocorrelação, os resíduos padronizados são obtidos a partir da Eq. (35) e em seguida a série de resíduos obtida é multiplicada pelo desvio padrão  $\sigma_t$ .

Quando ZI-GL é empregada, para os passos de tempo com simulação igual a zero, para cada simulação, o modelo binomial de probabilidade (Eq.(37)) é utilizado para determinar se a distribuição SEP com parâmetros  $\beta_2$  e  $\zeta_2$  deve ser utilizada. O valor de  $\rho$  calculado durante a calibração do modelo é utilizado tanto na calibração quanto na

validação, uma vez que na previsão as observações não estão disponíveis para o cálculo de  $n_1$  e  $n_2$ . Para os passos de tempo com simulação diferente de zero os erros são amostrados da SEP padronizada com parâmetros  $\beta_3$  e  $\zeta_3$ .

### 3.4.4. Avaliação do desempenho dos modelos

As últimas 3.000 amostras das cadeias de Markov, ou seja, os últimos 3.000 conjuntos de parâmetros amostrados com o algoritmo DREAM, foram utilizadas para representar a incerteza associada aos valores dos parâmetros e para criar as distribuições probabilísticas conforme descrito no item anterior.

O desempenho de cada modelo foi avaliado usando diferentes métricas. A confiabilidade da distribuição probabilística foi avaliada a partir da inspeção visual do gráfico quantil-quantil (THYER et al., 2009), que compara a função de densidade acumulada empírica (cdf) dos *p values*  $F_{\hat{y}(t)}(y_t)$  com a cdf de uma distribuição uniforme (Figura 20). Além disso, a confiabilidade da faixa de incerteza foi quantificada usando a métrica de confiabilidade (EVIN et al., 2014; MCINERNEY et al., 2017),

$$\text{Confiabilidade}[\hat{\mathbf{y}}, \mathbf{y}] = \frac{2}{n} \sum_{t=1}^n \left| F_U \left[ F_{\hat{y}(t)}(y_t) \right] - F_\Omega \left[ F_{\hat{y}(t)}(y_t) \right] \right|, \quad (40)$$

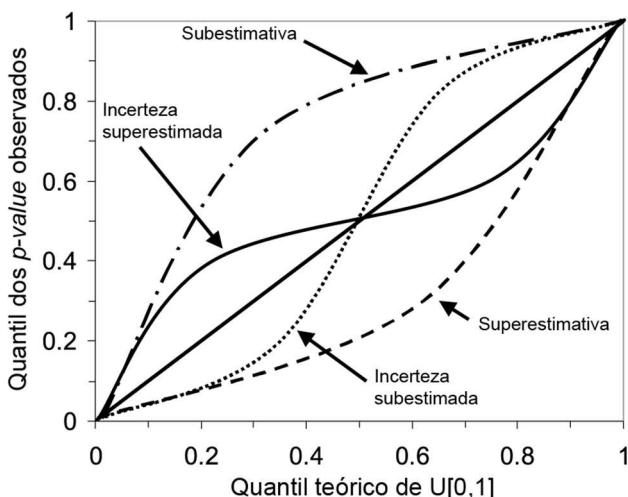
em que  $F_{\hat{y}(t)}$  é a cdf da distribuição probabilística no tempo  $t$  e  $y_t$  é o valor observado da variável simulada,  $F_U$  é a cdf da distribuição uniforme  $U(0,1)$ ,  $F_\Omega$  é a cdf empírica e  $n$  é o número de observações. A cdf da distribuição probabilística é descontínua em  $y_t = 0$ . Por este motivo, os *p values* correspondentes a observações iguais a zero foram considerados como sendo um valor aleatório entre o *p value* imediatamente antes  $y_t = 0$  e o *p value* imediatamente depois  $y_t = 0$ . Caso as observações sejam amostras da distribuição probabilística inferida, o gráfico quantil-quantil segue a linha 1:1 e o valor da métrica de confiabilidade é zero. A precisão está relacionada com a espessura da distribuição probabilística inferida e foi medida pela métrica de precisão (MCINERNEY et al., 2017),

$$\text{Precisão}[\hat{\mathbf{y}}, \mathbf{y}] = \frac{1}{n} \sum_{t=1}^n \text{sdev } \hat{y}_t \left/ \frac{1}{n} \sum_{t=1}^n y_t \right. \quad (41)$$

em que  $sdev \hat{y}_t$  é o desvio padrão da distribuição probabilística da variável simulada no passo de tempo  $t$ . A capacidade do modelo de simular o balanço hídrico (seja ele da vegetação ou da bacia hidrográfica) é quantificada pela métrica de viés volumétrico (MCINERNEY et al., 2017):

$$\text{Bias}[\hat{\mathbf{y}}, \mathbf{y}] = \left| \frac{\sum_{t=1}^n y_t - \sum_{t=1}^n \hat{y}_{t,\text{mean}}}{\sum_{t=1}^n y_t} \right| \quad (42)$$

em que  $\hat{y}_{t,\text{mean}}$  é a mediana das simulações no passo de tempo  $t$ . Para todas as métricas consideradas, o valor zero indica um desempenho perfeito. Para uma interpretação mais detalhada das métricas mencionadas, consultar as referências citadas. Métricas similares também foram utilizadas em outros estudos de modelagem hidrológica com quantificação das incertezas (e.g., Renard et al., 2010; Thyer et al., 2009).



**Figura 20.** Interpretação do gráfico quantil-quantil para avaliar a confiabilidade da faixa de incerteza (traduzido de Thyer et al., 2009).  $U[0,1]$  indica uma distribuição uniforme com limite inferior igual a 0 e limite superior igual a 1.

Como os modelos de interceptação e chuva-vazão possuem número diferente de parâmetros, os critérios de informação de Akaike (AIC) e de Bayes (BIC) foram utilizados para auxiliar a comparação de

desempenho dos modelos. Os critérios de informação são compostos de um termo que valoriza o ajuste da série simulada à série observada e um termo que penaliza pela complexidade do modelo,

$$I_k = -2 \ln(L^*) + \psi, \quad (43)$$

em que  $I_k$  representa o valor do critério de informação,  $L^*$  é o valor da função de verossimilhança para o conjunto ótimo de parâmetros (que maximiza o valor da função de verossimilhança) e  $\psi$  é um termo que penaliza pela complexidade do problema, sendo igual a

$$\psi = 2k \quad (44)$$

para o AIC, em que  $k$  é o número de parâmetros, e

$$\psi = k \ln n \quad (45)$$

para o BIC, em que  $n$  é o número de dados utilizados na calibração. O melhor modelo (entre os modelos considerados) é o que apresenta o menor valor de critério de informação. Cabe ressaltar que os valores de  $I_k$  são medidas relativas, utilizados na comparação de diferentes modelos, e então o valor absoluto de  $I_k$  por si só não possui nenhum significado.

O suporte relativo de um modelo em relação ao melhor modelo (o que presenta menor valor de critério de informação) é calculado a partir da diferença entre o valor de critério de informação para o modelo em questão,  $AIC_i$ , e o valor de critério de informação para o modelo com menor valor de AIC,  $AIC_{\min}$ , ou seja,

$$\Delta A_i = AIC_i - AIC_{\min} \quad (46)$$

A partir deste valor, pesos podem ser atribuídos a cada um dos modelos considerados,

$$w_i = \frac{\exp(-\frac{1}{2} \Delta A_i)}{\sum_{j=1}^{n_m} \exp(-\frac{1}{2} \Delta A_j)} \quad (47)$$

em que  $w_i$  é o peso para o modelo  $i$  e  $n_m$  é o número de modelos considerados. Os pesos para o critério de informação de Bayes são

calculados de maneira análoga. Os valores de  $w_i$  indicam a probabilidade do modelo  $i$  ser escolhido num período diferente do utilizado na calibração.

### **3.4.5. Influência do processo de interceptação no processo chuva-vazão**

Para avaliar a influência da consideração explícita do processo de interceptação na modelagem do processo chuva-vazão, quatro situações foram testadas: (1) calibração do modelo utilizando a série de chuva total como entrada; (2) calibração do modelo utilizando a série de chuva líquida (chuva interna + escoamento pelos troncos) como entrada; (3) modelo chuva-vazão acoplado com modelo de interceptação e parâmetros de interceptação fixos; e (4) modelo chuva-vazão acoplado com modelo de interceptação e parâmetros de interceptação calibrados. Para os itens (3) e (4), foram utilizados os modelos chuva-vazão e de interceptação selecionados após comparação entre os diferentes modelos considerados. Os resultados desta análise foram comparados em termos da faixa de incerteza obtida, avaliada a partir das métricas de desempenho (precisão, viés e confiabilidade), da distribuição *a posteriori* dos parâmetros e dos critérios de complexidade AIC e BIC.

Para a bacia do rio Araponga, as falhas na série de chuva líquida foram preenchidas com dados de chuva total, como é o caso de todo o período de aquecimento do modelo e alguns períodos pontuais na série utilizada na calibração (quando ocorreu falha do sistema de monitoramento automático de chuva interna e/ou escoamento pelos troncos).

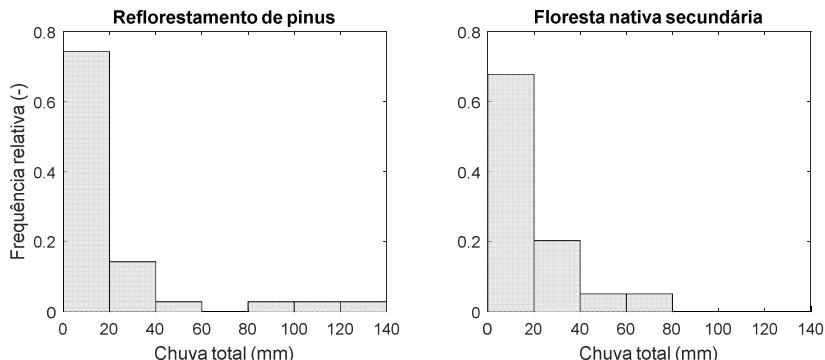


## 4. RESULTADOS E DISCUSSÃO

### 4.1. ANÁLISE DOS DADOS DE INTERCEPTAÇÃO

A separação das séries de dados em eventos (critérios descritos no item 3.3.3) resultou em 35 eventos para a parcela de reflorestamento de pinus (período de 23/08/2008 a 17/11/2008) e 59 eventos para a parcela de floresta nativa secundária (período de 26/02/2014 a 06/10/2014). Os totais de chuva total, chuva interna e escoamento pelos troncos de cada um dos eventos, assim como duração e período seco anterior ao início do evento, são apresentados no Apêndice A.

Eventos com chuva total abaixo de 20 mm foram os mais frequentes (~70% do número total de eventos), porém representam apenas 16 e 18% do total precipitado durante o período monitorado para o reflorestamento de pinus e a floresta nativa secundária, respectivamente (Figura 21). Estes eventos contribuem com aproximadamente um terço do total de perdas por interceptação observado para todo o período monitorado nas duas florestas. O evento com maior volume de chuva total foi de 131 mm no reflorestamento de pinus e de 352 mm na floresta nativa secundária.



**Figura 21.** Frequência do número de eventos, classificados de acordo com a chuva total, em relação ao número total de eventos. Para a floresta nativa secundária, o evento de 352 mm não é mostrado para melhorar a visualização dos demais eventos.

Os valores de chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) aumentam com o aumento da chuva total ( $P$ ) do evento (Figura 22 para o reflorestamento de pinus e Figura 23 para a floresta nativa secundária). O valor de chuva interna relativa (%P) é

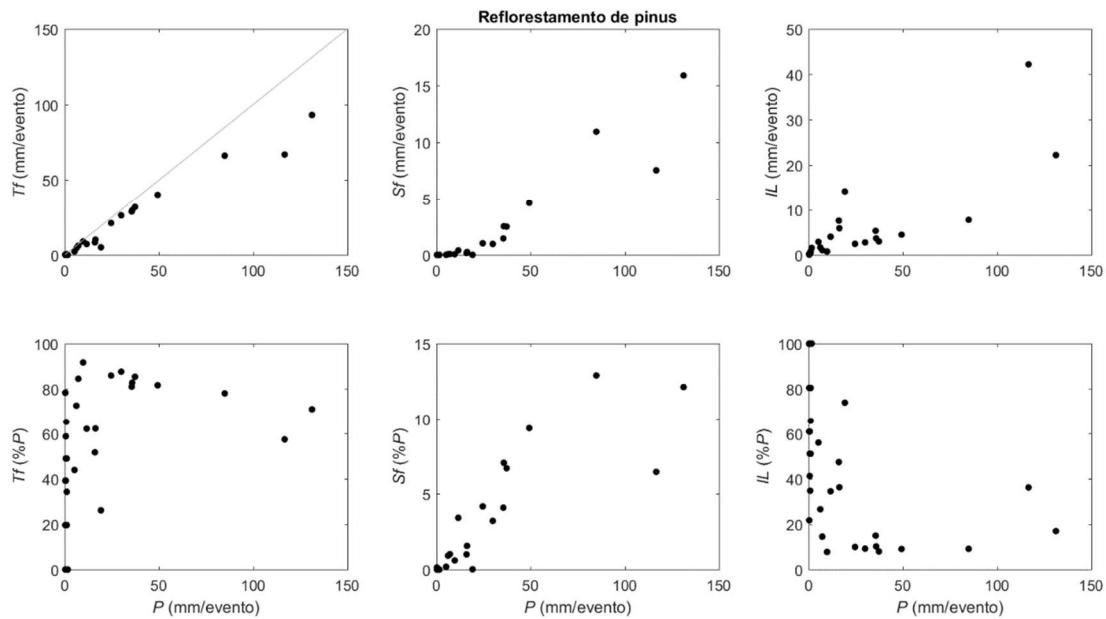
menor para eventos pequenos (porém bastante variável) e aumenta de acordo com  $P$ , estabilizando em torno de 80% para a floresta nativa secundária. Para o reflorestamento de pinus, a existência de apenas alguns eventos com  $P > 50$  mm dificulta a determinação deste valor “limite” para  $T_f$ . Já o escoamento pelos troncos relativo (% $P$ ) aumenta linearmente com  $P$  e não tende à estabilização.

**Tabela 12.** Distribuição dos eventos monitorados na bacia do rio Saci (PIN) e na bacia do rio Araponga (ARA) em classes de chuva total. Os totais de chuva total ( $P$ ), chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) são apresentados para cada uma das classes. Valores entre parênteses se referem ao percentual da classe em relação ao valor total.

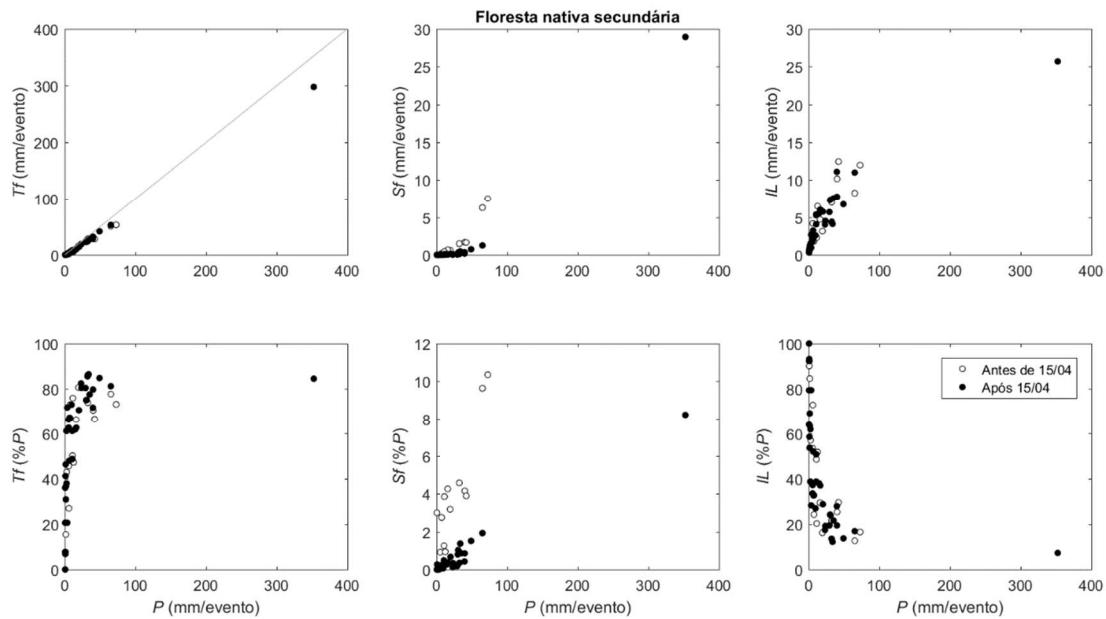
	Classe	# de eventos	$P$ mm	$T_f$ mm	% $P$	$S_f$ mm	% $P$	$I_L$ mm	% $P$
PIN	0-20	26	101 (16%)	55 (12%)	55	1 ( 2%)	1	45 (32%)	44
	20-40	5	163 (25%)	137 (30%)	84	8 (17%)	5	17 (12%)	10
	40-60	1	49 ( 7%)	40 ( 9%)	82	5 (10%)	9	4 ( 3%)	9
	60-80	0	0 ( 0%)	0 ( 0%)	0	0 ( 0%)	0	0 ( 0%)	0
	80-100	1	85 (13%)	66 (14%)	78	11 (22%)	13	8 ( 6%)	9
	100-120	1	117 (18%)	67 (15%)	57	8 (16%)	6	42 (30%)	36
	120-140	1	131 (20%)	93 (20%)	71	16 (33%)	12	22 (16%)	17
ARA	0-20	40	228 (18%)	136 (14%)	60	3 ( 5%)	1	89 (36%)	39
	20-40	12	382 (29%)	303 (31%)	79	4 ( 7%)	1	75 (30%)	20
	40-60	3	131 (10%)	98 (10%)	74	4 ( 7%)	3	29 (12%)	22
	60-80	3	203 (16%)	156 (16%)	77	15 (28%)	7	31 (12%)	15
	>80	1	352 (27%)	298 (30%)	84	29 (53%)	8	26 (10%)	7

Foi observado um comportamento distinto da relação de  $S_f$  e  $P$  ao longo do tempo para a floresta nativa secundária (Figura 23 e Figura 24). Supõe-se que esta mudança de comportamento ocorreu devido a alguma modificação nas árvores monitoradas. Por este motivo, a série de dados foi dividida em dois períodos: antes de 15/04 e após esta data.

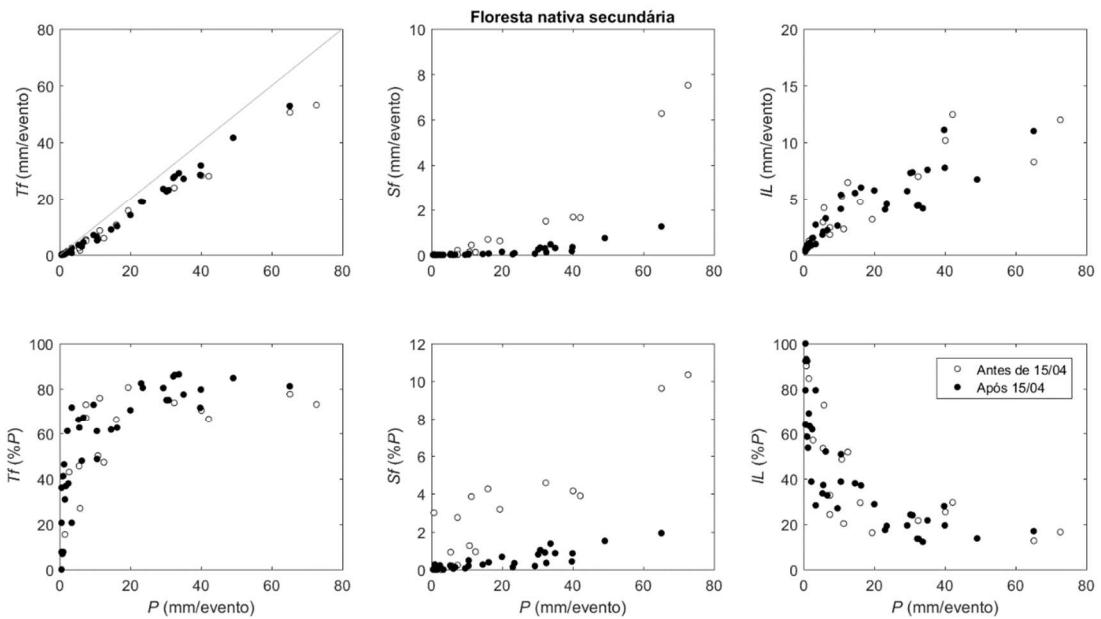
Os totais de chuva total, chuva interna e escoamento pelos troncos e a sua distribuição entre dia (considerado aqui de 06h00 às 18h00) e noite (de 18h00 às 06h00) são apresentados na Tabela 13. Para o reflorestamento de pinus, o total de chuva total foi de 646 mm, dos quais 302 mm (47%) precipitou durante o dia e 344 mm (53%) durante a noite. Para a floresta nativa secundária, o total de chuva total foi de 1.297 mm, 723 mm (56%) distribuídos durante o dia e 573 mm (44%) durante a noite.



**Figura 22.** Totais por evento de chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) para o reflorestamento de pinus (na bacia do rio Saci).



**Figura 23.** Totais por evento de chuva interna ( $Tf$ ), escoamento pelos troncos ( $Sf$ ) e perdas por interceptação ( $IL$ ) para a floresta nativa secundária (na bacia do rio Araponga).



**Figura 24.** Totais por evento de chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) e perdas por interceptação ( $I_L$ ) para a floresta nativa secundária (na bacia do rio Araponga) para eventos com chuva total ( $P$ ) < 80 mm.

**Tabela 13.** Totais de chuva total ( $P$ ), chuva interna ( $T_f$ ) e escoamento pelos troncos ( $S_f$ ) durante o monitoramento na bacia do rio Saci (PIN) e na bacia do rio Araponga (ARA).

	$P$ mm	$T_f$ mm	% $P$	$S_f$ mm	% $P$	$I$ mm	% $P$
PIN	Total	646	459	71	48	8	138
	Dia	302 (47%)	221 (48%)	73	26 (53%)	8	56 (40%)
	Noite	344 (53%)	238 (52%)	69	23 (47%)	7	82 (60%)
ARA	Total	1.297	992	76	54	4	250
	Dia	723 (56%)	560 (56%)	77	36 (67%)	5	127 (51%)
	Noite	573 (44%)	432 (44%)	75	18 (33%)	3	124 (49%)

### *Aumento linear de $S_f/P$ com $P$*

O aumento linear da relação  $S_f/P$  com  $P$  sugere que, para a faixa de eventos analisadas neste estudo, a capacidade de armazenamento dos troncos não chega a ser atingida. Supõe-se que novos caminhos vão sendo criados à medida que os inicialmente utilizados para escoar a água vão sendo saturados. Para a chuva interna, a partir do momento que a copa satura, sua capacidade de interceptação é praticamente nula, fazendo com que  $T_f/P$  também aumente com relação a  $P$ .

### *Elevada taxa de evaporação observada*

Como pode ser observado na Figura 22 a Figura 24, os valores de perdas por interceptação em muitos casos excedem os valores de evaporação potencial calculados (valor diário de  $E_p$  dificilmente excede 4 mm). Três hipóteses podem ser levantadas para justificar esses elevados valores de perdas por interceptação observados: (1) a capacidade de armazenamento da vegetação é muito elevada, fazendo com que grande parte das perdas por interceptação ocorra a partir da evaporação da água armazenada na vegetação ao final do evento; (2) a taxa de evaporação é maior do que a calculada a partir do método de Penman modificado; e (3) os valores elevados obtidos são consequência dos erros associados aos valores de chuva interna e escoamento pelos troncos, utilizados na estimativa indireta das perdas por interceptação.

Este mesmo resultado foi obtido em outros estudos de interceptação. Na modelagem do processo de interceptação realizada por Calder (1986), a capacidade de armazenamento foi aumentada para que os resultados se ajustassem aos valores de perdas por interceptação observados. Lloyd et al. (1988) criticou esta abordagem, uma vez que os elevados valores de capacidade de armazenamento obtidos perderam o

sentido físico. Schellekens et al. (1999) testaram as duas primeiras hipóteses e verificaram que os elevados valores de perdas por interceptação se devem principalmente às elevadas taxas de evaporação da água armazenada na copa, ao invés de uma grande capacidade de armazenamento da vegetação.

Alguns autores tentaram explicar estas elevadas taxas de evaporação necessárias para que os valores observados de perdas por interceptação pudessem ser obtidos. Pearce, Rowe e Stewart (1980) propuseram que a energia advectiva seria um componente mais importante do que a energia radiante no controle da evaporação da água armazenada na copa. O mesmo argumento é suportado em Schellekens et al. (2000), que encontraram valores similares para as taxas de evaporação durante o dia e durante a noite. David, Valente e Gash (2005) também suportam esta teoria, o que justificaria elevadas taxas de evaporação observadas em alguns estudos mesmo durante a noite, quando a energia radiativa é zero.

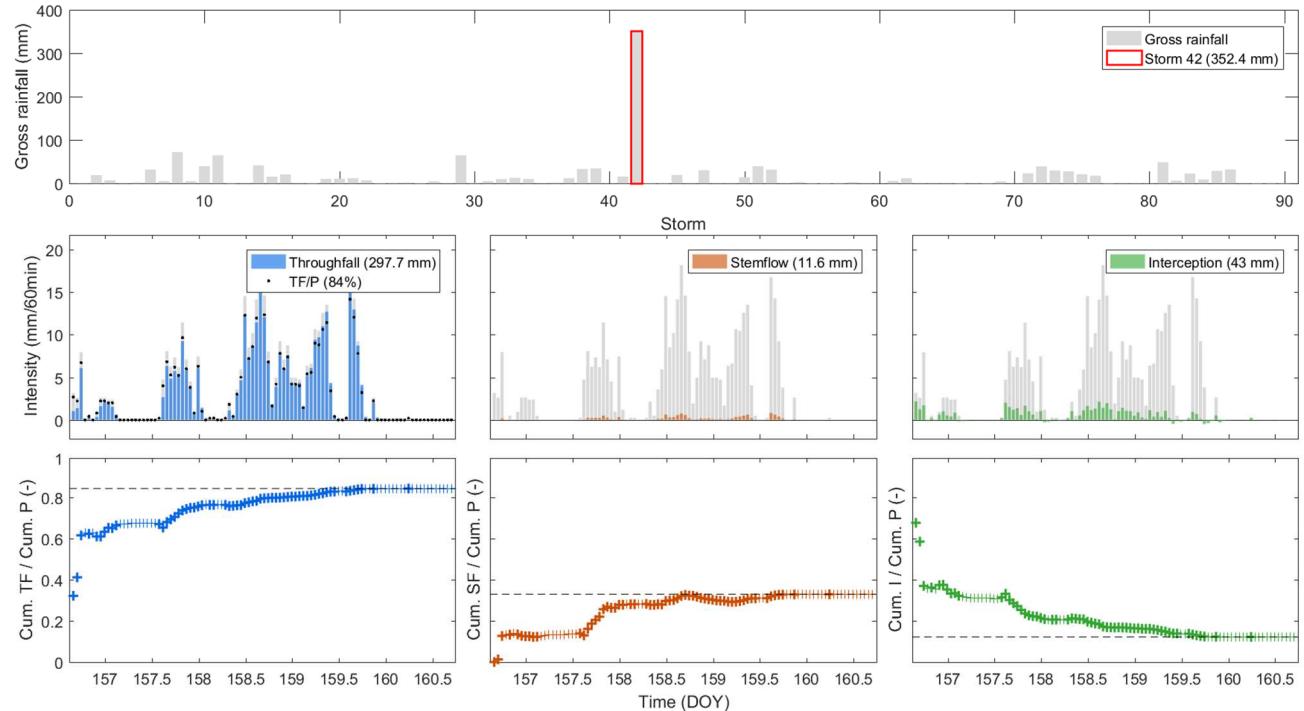
Uma análise mais aprofundada dos dados, em conjunto com a verificação dos resultados de modelagem realizados neste estudo, são necessários para determinação da causa destes valores de perdas por interceptação observados. A análise preliminar dos dados apresentados na Tabela 13 indicam que a segunda hipótese (taxa de evaporação é maior do que a calculada a partir do método de Penman) pode ser a que melhor explica os elevados valores de perdas por interceptação observados por evento nas duas florestas estudadas, uma vez que as perdas por interceptação não são superiores durante o dia.

#### **4.1.1. Análise da variação no tempo do processo de interceptação**

Para análise da variação da interceptação ao longo de um evento, os dados com resolução temporal de 5 min (para a floresta nativa) e 10 min (para o reflorestamento de pinus) foram acumulados para 60 minutos, visando amenizar o efeito da diferença entre resoluções de medição das variáveis. A existência de uma tendência de diminuição da interceptação *I* (interceptação calculada a cada passo de tempo horário, ou seja, não sendo necessariamente igual às perdas por interceptação) ao longo do evento devido à saturação da vegetação foi analisada com a variação da intensidade de *Tf*, *Sf* e *I*. Um exemplo desta análise é apresentado na Figura 25, para o maior evento (em termos de volume de chuva total) da série de dados da floresta nativa secundária. Pode ser observado que os valores de *Tf/P* e *Sf/P* são baixos na primeira hora do evento e aumentam ao longo do mesmo. Isso dá-se em função de que no início do evento a

vegetação está seca e uma maior quantidade de água da chuva pode ser retida na vegetação. À medida que a vegetação começa a saturar, uma maior quantidade de água é drenada para o solo. Outro ponto que pode ser observado é o rápido aumento da relação  $Tf/P$  após períodos secos dentro do evento (períodos sem chuva dentro do evento), o que indica que o espaço liberado a partir da evaporação ou da drenagem da água armazenada na vegetação durante estes períodos sem chuva é rapidamente preenchido.

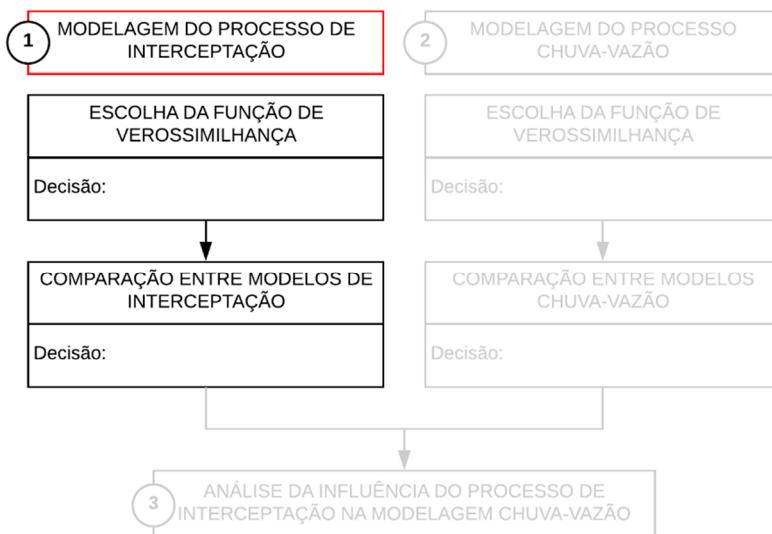
A verificação da redução do valor de  $Tf/P$  após apenas algumas horas sem ocorrência de chuva (Figura 25) suporta o argumento de que as taxas de evaporação podem ser elevadas durante os eventos, ocasionando o esvaziamento parcial da copa. Ressalta-se que a drenagem da água armazenada na vegetação em tempos anteriores também contribui para esse esvaziamento parcial da copa. Este fato é contrário ao observado em Iida et al. (2017), que verificaram que as taxas de interceptação diminuíram ao longo do evento, atingindo valores negativos na segunda metade do evento. Iida et al. (2017) também constataram que as perdas por interceptação por evento se aproximavam de um limite com o aumento de  $P$ , e que este limite correspondia à capacidade de armazenamento da vegetação.



**Figura 25.** Exemplo da análise da variação da interceptação ao longo de um evento.

## 4.2. MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO

A Figura 26 mostra a sequência das etapas apresentadas neste item do trabalho, referente à modelagem do processo de interceptação. A primeira etapa consiste na escolha da função de verossimilhança a ser utilizada para representar os resíduos do modelo. Em seguida, a função de verossimilhança escolhida é utilizada na inferência dos parâmetros de todos os modelos considerados, e os modelos são comparados em termos da qualidade da faixa de incerteza estimada e dos valores de critérios de informação.



**Figura 26.** Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo de interceptação.

### 4.2.1. Escolha da função de verossimilhança

Como mencionado no item 3.4.3, a distribuição *a posteriori* dos parâmetros é obtida a partir da distribuição *a priori* e da função de verossimilhança. A distribuição *a priori* sintetiza o conhecimento prévio sobre os parâmetros, antes da observação dos dados. Quando a série de dados é suficientemente longa, a distribuição *a priori* exerce pouca influência na estimativa da distribuição *a posteriori* e é geralmente assumida como sendo uniforme. Nesse caso, a inferência da distribuição

*a posteriori* dos parâmetros fica condicionada à escolha da função de verossimilhança, que mede em termos probabilísticos a distância entre as simulações e as observações. Portanto, a correta escolha da função de verossimilhança, construída a partir da distribuição assumida para os resíduos do modelo, é fundamental para a obtenção de uma distribuição *a posteriori* dos parâmetros representativa.

Na modelagem do processo de interceptação, como a série de dados é composta por muitas observações iguais a zero (e que podem então ser modeladas com resíduo igual a zero), é esperado que a distribuição dos resíduos seja inflada com zeros. Desta maneira, além do método tradicional de calibração a partir da utilização da *Generalized Likelihood function* (GL), foram testados dois outros métodos com o objetivo de considerar a inflação da distribuição com zeros: desconsideração dos resíduos (zero e diferente de zero) correspondentes a observações iguais a zero no cálculo do valor da função de verossimilhança ( $GL^{>0}$ ); e utilização de uma versão modificada da *Generalized Likelihood function* considerando inflação com zeros (de agora em diante chamada de *Zero-Inflated Generalized Likelihood function*, ZI-GL).

### *Análise da faixa de incerteza*

Comparado com a *Generalized Likelihood function* (GL), a *Zero-Inflated Generalized Likelihood function* (ZI-GL) melhorou a qualidade da faixa de incerteza estimada para todos os modelos para resíduos (L1 a L5) em termos das métricas de precisão, viés e confiabilidade (o que pode ser observado a partir análise da faixa de incerteza apresentada na Figura 27 e dos valores das métricas apresentados na Figura 29). O baixo desempenho para a GL é evidenciado pela inspeção visual das faixas de incerteza obtidas, que assume valores negativos em certos casos (sem sentido físico) (primeira coluna da Figura 27).

Outros estudos também encontraram este mesmo problema ao modelar o comportamento hidrológico de bacias secas (EVIN et al., 2013; SCHOUUPS; VRUGT, 2010). Considerar uma distribuição com assimetria (não simétrica) evitou a ocorrência desses valores negativos para a faixa de incerteza; porém, a faixa de incerteza continuou espessa e portanto sem sentido (resultados não apresentados). Omitir os resíduos de observações iguais a zero ( $GL^{>0}$ ) resultou em uma faixa de incerteza mais coerente comparada à GL (o que pode ser visualizado a partir da comparação das faixas de incerteza apresentadas nas primeira e segunda colunas da Figura 27). Quando o método  $GL^{>0}$  foi considerado, apenas o

modelo para resíduos L4 resultou em valores negativos significativos para a faixa de incerteza (painel L4B na coluna central da Figura 27). A faixa de incerteza espessa obtida com este modelo para resíduos (L4 utilizando  $GL^{y>0}$ ) foi o resultado de um valor inferido relativamente elevado para o parâmetro do modelo autoregressivo (valor que maximizou a função de verossimilhança de  $\phi$  foi de 0,36 para a floresta nativa) combinado com o uso de resíduos brutos no modelo AR(1). Como demonstrado por Evin et al. (2013), a remoção de autocorrelação dos resíduos brutos ao invés dos resíduos padronizados pode resultar em uma faixa de incerteza excessivamente larga e de baixa qualidade. A remoção de heteroscedasticidade dos resíduos antes de considerar autocorrelação (modelo para resíduos L5), como sugerido por aquele estudo, evitou a ocorrência de faixas de incerteza com valores negativos (como pode ser observado comparando as faixas de incerteza dos painéis L4B e L5B da coluna central na Figura 27). Para a floresta nativa (e reflorestamento de pinus), o uso do modelo para resíduos L5 com a GL ( $GL^{y>0}$ ) resultou na consideração da alta autocorrelação entre os resíduos padronizados, com um valor de  $\phi$  (do conjunto de parâmetros que maximizou a função de verossimilhança) superior a 0,30. Como consequência, uma maior diferença nas métricas de desempenho foram obtidas entre L4 e L5 nestes casos. Quando o valor inferido para o parâmetro do modelo autoregressivo não é muito elevado, a diferença de se aplicar o modelo AR(1) aos resíduos brutos (L4) ou aos resíduos padronizados (L5) é menos evidente.

A baixa qualidade da faixa de incerteza estimada com a formulação GL para os modelos para resíduos L2 a L5 pode ter sido uma consequência do impacto negativo dos resíduos de observações com valores próximos de zero na quantificação do valor da função de verossimilhança quando um modelo linear heteroscedástico é considerado. Este problema também foi constatado em outros estudos de modelagem hidrológica (e.g., Evin et al., 2013; Westra et al., 2014). A melhora na qualidade da faixa de incerteza obtida quando a formulação ZI-GL é utilizada demonstra a habilidade deste método em lidar, ao menos parcialmente, com este problema. Na formulação ZI-GL, os resíduos diferentes de zero de simulações iguais a zero são modelados separadamente e, portanto, estes resíduos são removidos da inferência do modelo linear heteroscedástico.

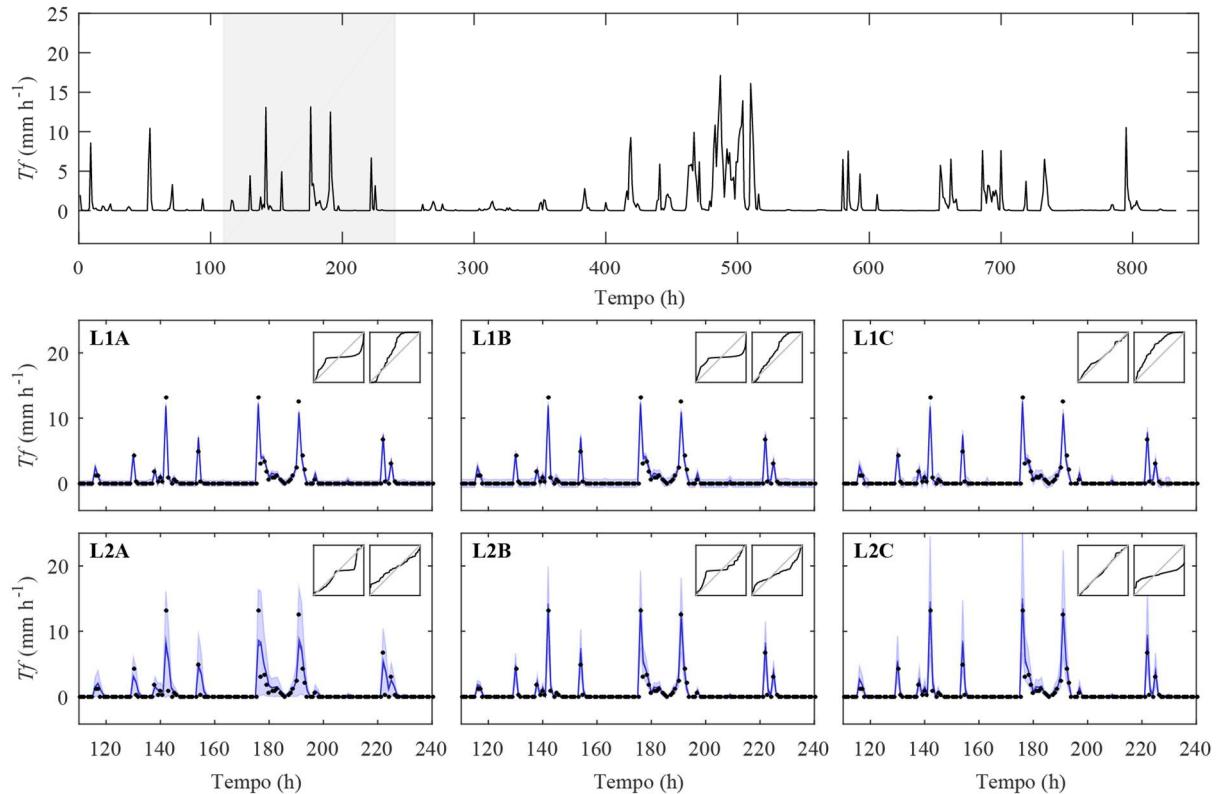
Uma vez que o método  $GL^{y>0}$  omite os resíduos (zero e não zero) de observações iguais a zero do cálculo do valor da função de verossimilhança, um menor número de resíduos de observações próximas a zero é considerada por este método. Como consequência, exceto para

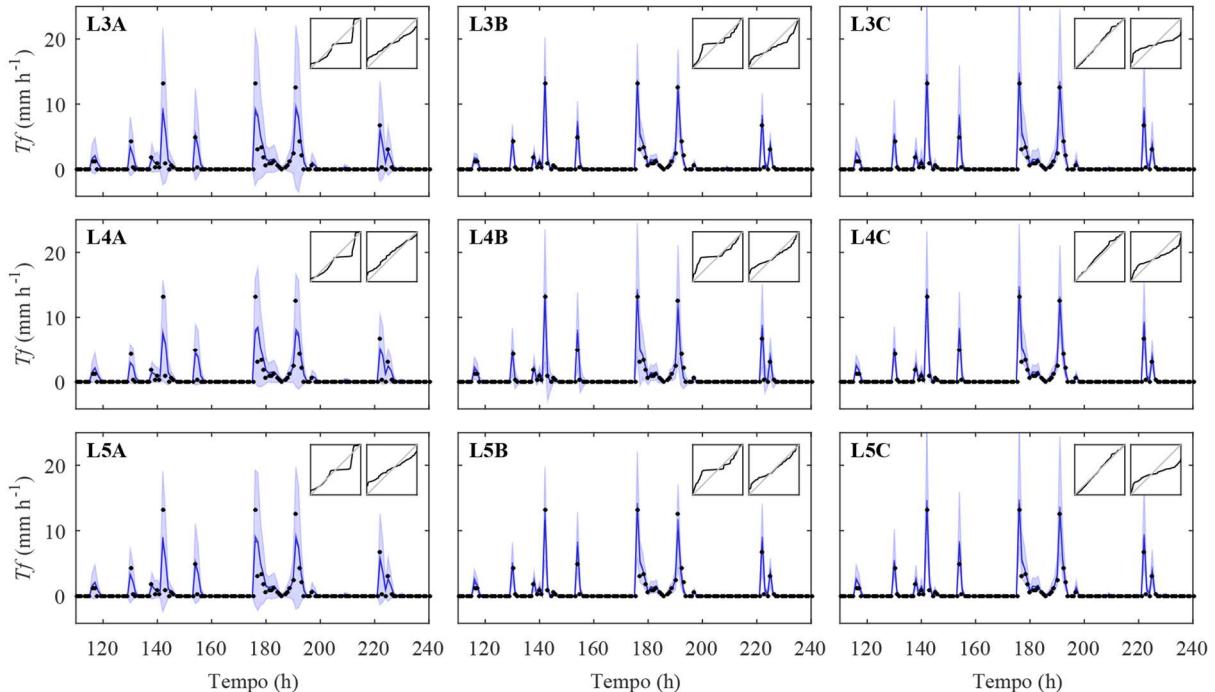
L4 em que a baixa qualidade da faixa de incerteza foi discutida anteriormente, os valores das métricas de precisão e de viés volumétrico obtidos com  $GL^{y>0}$  foram inferiores (melhores) do que para ZI-GL (Figura 29). Quando se evita o aumento na contribuição para o valor da função de verossimilhança de resíduos de observações próximas a zero (no caso da utilização do método  $GL^{y>0}$ ) um maior peso é dado aos resíduos de valores simulados elevados, que possuem maior impacto na quantificação das métricas de precisão e de viés. Os resíduos destas observações próximas a zero podem assumir valores exacerbadamente elevados após a padronização com o modelo linear heteroscedástico. A formulação ZI-GL promoveu melhores resultados do que  $GL^{y>0}$  considerando a métrica de confiabilidade (Figura 29a e Figura 29c), uma vez que a consideração da inflação da distribuição por zeros resultou em uma melhor faixa de incerteza para resíduos iguais a zero. Porém, quando apenas passos de tempo com resíduos diferente de zero são utilizados no cálculo das métricas, a métrica de confiabilidade é menor (melhor) para  $GL^{y>0}$  (Figura 29b e Figura 29d).

Com o objetivo de reduzir o impacto negativo de resíduos de observações iguais ou próximas de zero no cálculo da função de verossimilhança, o valor do coeficiente linear do modelo heteroscedástico foi fixado em  $0,12 \text{ mm h}^{-1}$  (ou  $3 \text{ mm d}^{-1}$ ) e as mesmas análises dos resultados realizadas até agora foram efetuadas (resultados apresentados na Figura 28 e na Figura 30). A escolha deste valor foi realizada após a comparação da utilização de diferentes valores, conforme apresentado no Apêndice B (Figura B5). Quando o coeficiente linear do modelo heteroscedástico foi fixado, os valores das métricas de desempenho para os três métodos, GL,  $GL^{y>0}$  e ZI-GL, foram bem mais próximos, como pode ser observado na Figura 30. Considerando a série toda no cálculo das métricas, menores (melhores) valores para a métrica de confiabilidade foram obtidos para a formulação ZI-GL, uma vez que este método é o único que não superestima a faixa de incerteza para resíduos iguais a zero (Figura 30a e Figura 30c). O valor da métrica de precisão também foi melhor para ZI-GL. Para GL e  $GL^{y>0}$  o desvio padrão para todos os resíduos de simulações iguais a zero é igual ao valor fixado do coeficiente linear do modelo heteroscedástico, o que resultou em uma faixa de incerteza superestimada para estes passos de tempo. O pior valor para a métrica de confiabilidade para ZI-GL quando apenas passos de tempo com resíduos de observações diferente de zero são considerados (Figura 30b e Figura 30d) é uma consequência da utilização da SEP inflada para resíduos de simulações iguais a zero, o que resulta em valores de *p values* maiores que  $\rho$  (probabilidade de um resíduo igual a zero dado que a

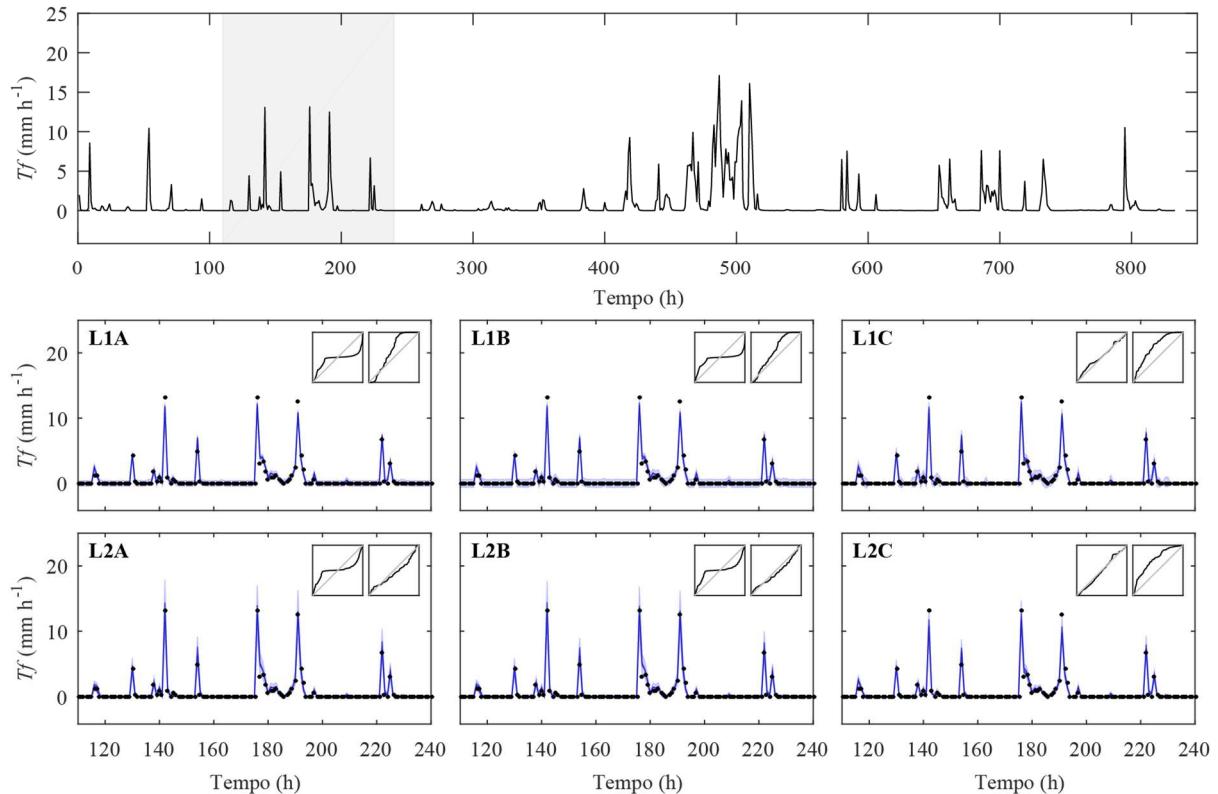
simulação é zero) para passos de tempo correspondentes aos resíduos da categoria 2 (resíduos diferentes de zero para simulações iguais a zero).

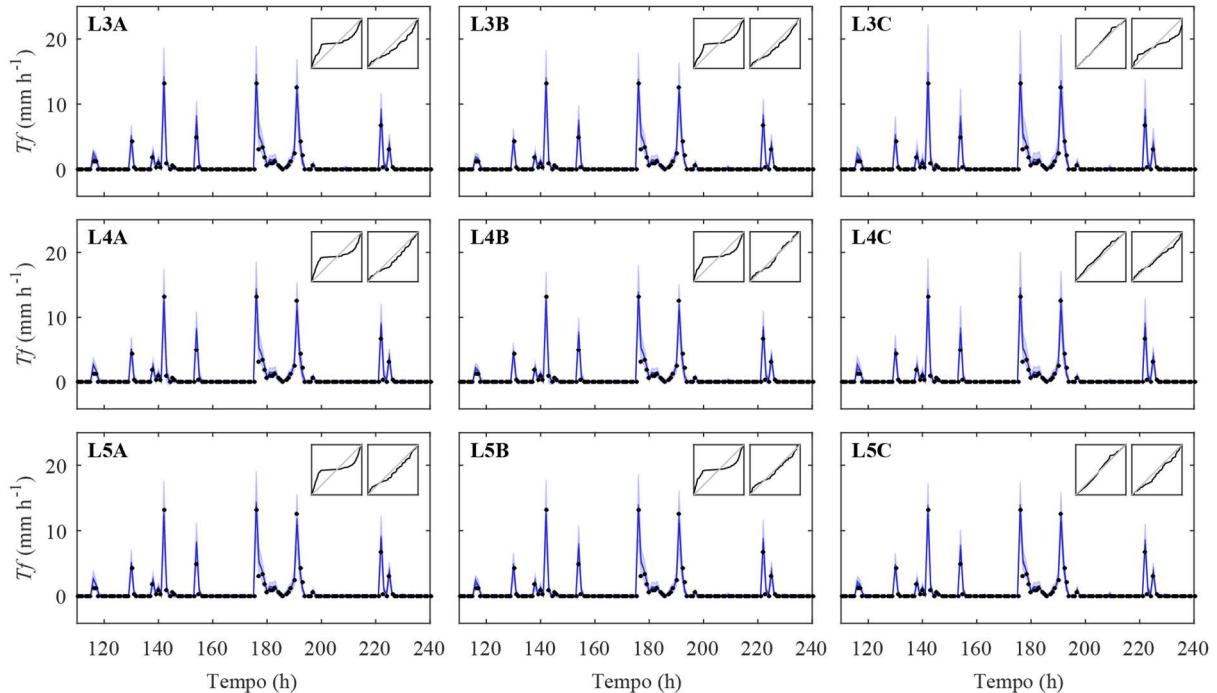
O modelo para resíduos que assume que os resíduos são homoscedásticos, gaussianos e independentes (L1) resultou em melhores estimativas do volume total simulado (menores valores para a métrica de viés volumétrico calculado para a simulação mediana de chuva interna) (Figura 29 e Figura 30). Modelos homoscedásticos dão peso igual para todos os resíduos brutos, que geralmente são maiores para valores simulados mais elevados. Uma vez que os picos correspondem a uma maior proporção do total simulado de chuva interna, é esperado que uma melhor simulação do volume total seja obtida quando um modelo para resíduos que produz um melhor ajuste aos valores mais elevados é utilizado. O mesmo resultado também ocorre em bacias hidrográficas que respondem rapidamente à precipitação. Por exemplo, na modelagem hidrológica de uma bacia hidrográfica semiárida na Austrália, em que uma grande proporção do volume escoado anual ocorre em um curto período do ano, Westra et al. (2014) obtiveram uma correspondência entre os modelos classificados de acordo com o coeficiente de Nash-Sutcliffe (que prioriza os picos de vazão) e com o erro volumétrico. Porém, este modelo para resíduos (L1) resultou em uma faixa de incerteza superestimada para valores baixos de chuva interna e sistemática subestimativa de valores elevados, como uma consequência da estreita faixa de incerteza obtida (painéis L1A, L1B e L1C na Figura 27 e na Figura 28).



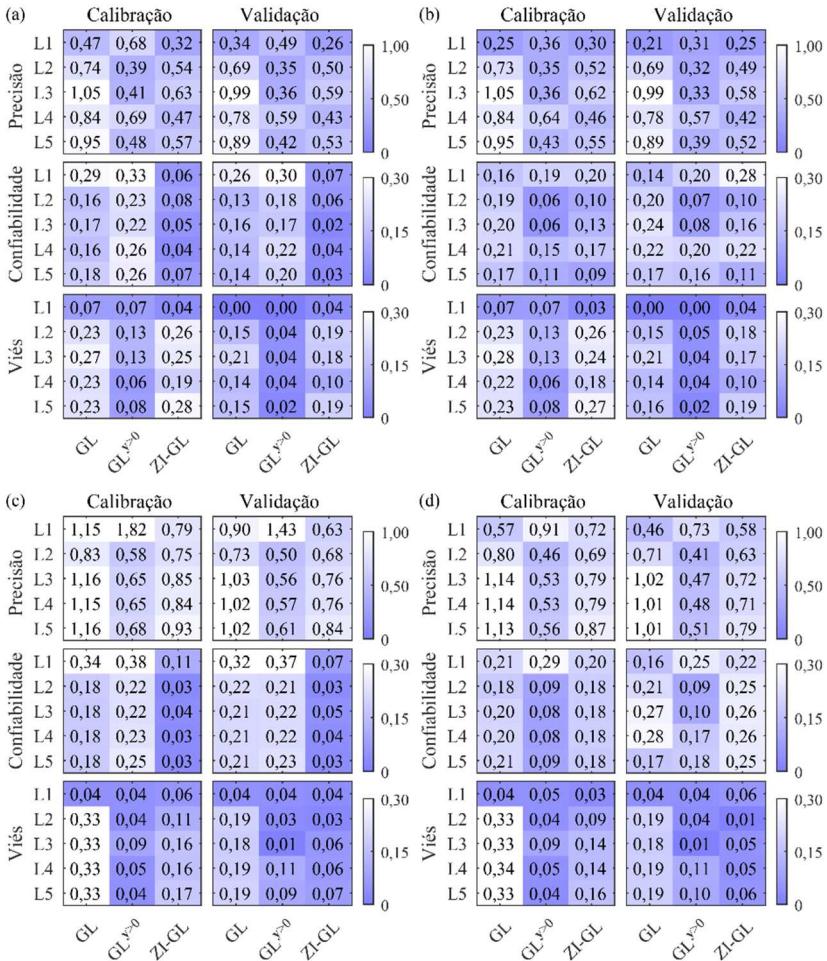


**Figura 27.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $\text{GL}^{y=0}$  (B) e ZI-GL (C). No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).

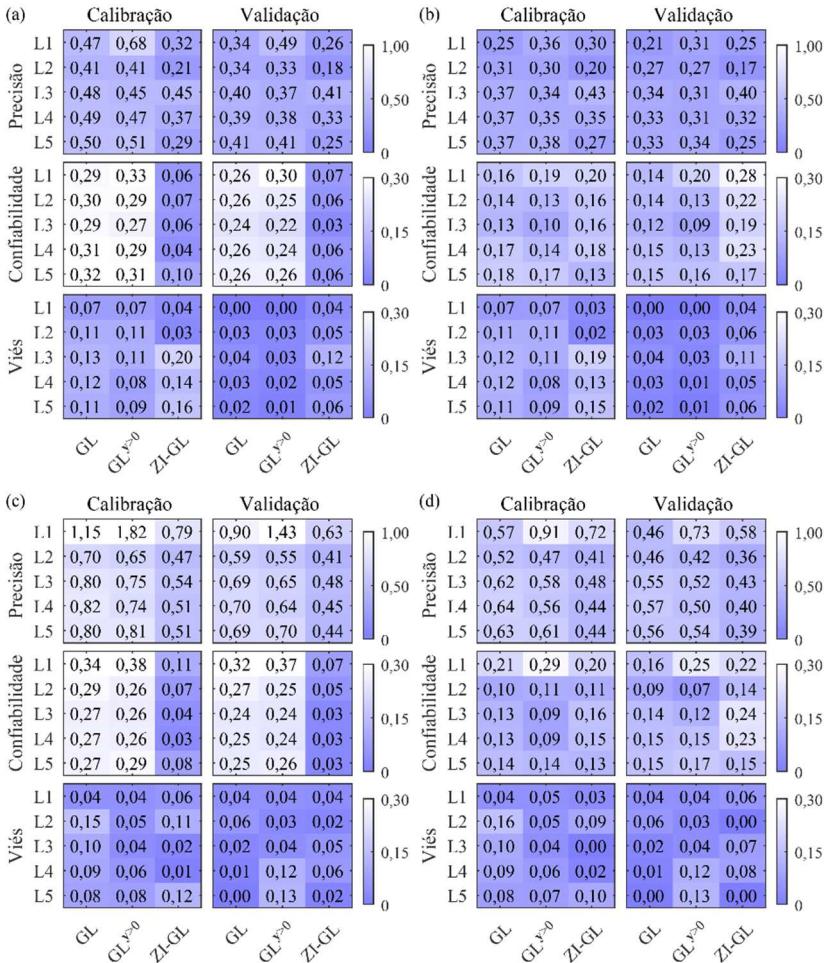




**Figura 28.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $\text{GL}^{y>0}$  (B) e ZI-GL (C).  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).



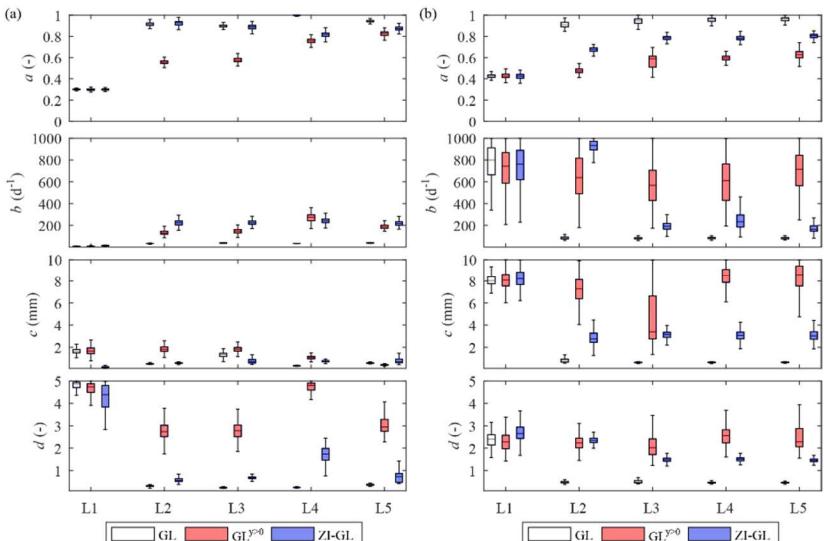
**Figura 29.** Métricas de desempenho obtidas para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL. As métricas foram calculadas para: (a) floresta nativa considerando a série inteira; (b) floresta nativa considerando apenas passos de tempo com resíduo diferente de zero; (c) reflorestamento de pinus considerando a série inteira; e (d) reflorestamento de pinus considerando apenas passos de tempo com resíduo diferente de zero. Para as três métricas, o valor de zero indica um desempenho perfeito.



**Figura 30.** Métricas de desempenho obtidas para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . As métricas foram calculadas para: (a) floresta nativa considerando a série inteira; (b) floresta nativa considerando apenas passos de tempo com resíduo diferente de zero; (c) reflorestamento de pinus considerando a série inteira; e (d) reflorestamento de pinus considerando apenas passos de tempo com resíduo diferente de zero. Para as três métricas, o valor de zero indica um desempenho perfeito.

### Análise da distribuição a posteriori dos parâmetros

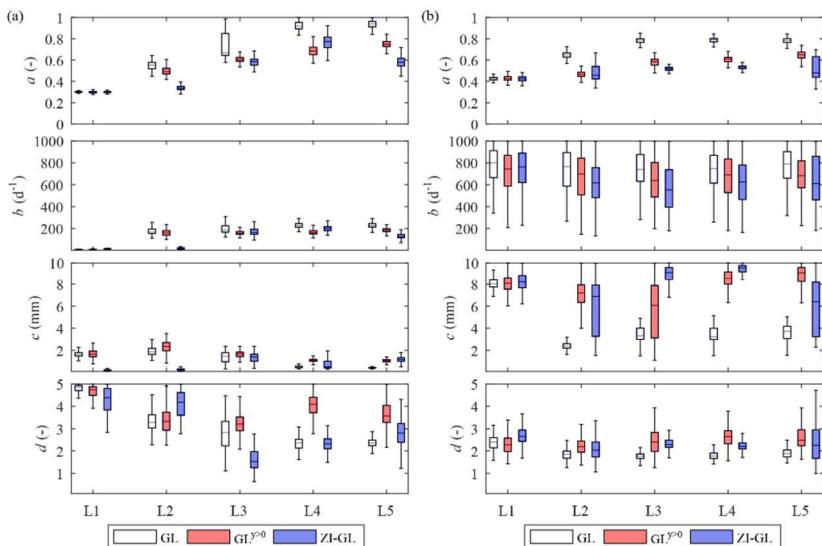
A escolha do modelo para resíduos resultou em uma grande influência na distribuição *a posteriori* dos parâmetros do modelo de interceptação (Figura 31). Para o primeiro modelo para resíduos considerado (L1), a distribuição *a posteriori* dos parâmetros foi similar entre GL,  $GL^{y>0}$  e ZI-GL. Duas maiores mudanças nos valores dos parâmetros podem ser observadas: (1) quando heteroscedasticidade é considerada (o que pode ser constatado comparando os diagramas de caixa para L1 com os obtidos para L2 a L5 na Figura 31); e (2) mudando de GL para  $GL^{y>0}$  e para ZI-GL quando a heteroscedasticidade dos resíduos é considerada (o que pode ser constatado pela diferença entre os diagramas de caixa brancos, vermelhos e azuis para os modelos para resíduos L2 a L5 na Figura 31). Estas duas mudanças na distribuição *a posteriori* dos parâmetros são causadas pela diferente contribuição relativa de resíduos de observações próximas a zero no cálculo do valor da função de verossimilhança. Como consequência, pesos diferenciados são dados para processos (e parâmetros correspondentes) relacionados a esses valores mais baixos dependendo da escolha do modelo para resíduos.



**Figura 31.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $GL^{y>0}$  e ZI-GL,

para (a) floresta nativa e (b) reflorestamento de pinus. Os limites do eixo y foram fixados de acordo com a faixa inicial de cada um dos parâmetros.

Quando o coeficiente linear do modelo heteroscedástico foi fixado em  $0,12 \text{ mm h}^{-1}$ , as diferenças entre as distribuições *a posteriori* dos parâmetros obtidas para GL,  $\text{GL}^{y>0}$  e ZI-GL foram bem menores (Figura 32).



**Figura 32.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para cada um dos modelos para resíduos (L1 a L5) utilizando GL,  $\text{GL}^{y>0}$  e ZI-GL, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , para (a) floresta nativa e (b) reflorestamento de pinus. Os limites do eixo y foram fixados de acordo com a faixa inicial de cada um dos parâmetros.

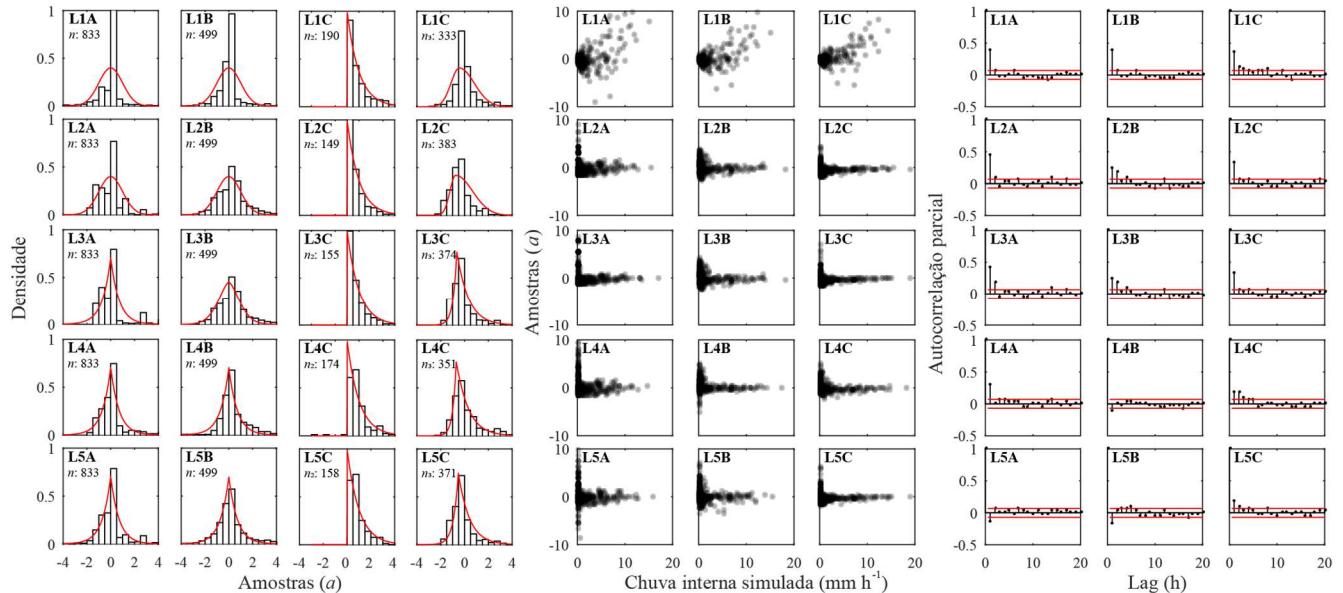
#### Análise dos resíduos

Os resíduos transformados foram melhor representados pela distribuição assumida com a consideração de uma distribuição SEP, autocorrelação dos resíduos e quando os resíduos zeros foram considerados separadamente (ou seja, L4 e L5 nos métodos  $\text{GL}^{y>0}$  e ZI-GL) (Figura 33). Para o reflorestamento de pinus, os resíduos transformados não se ajustaram tão bem à distribuição assumida. Isso pode ser uma limitação relacionada à resolução de monitoramento da chuva interna neste plot, que é 10 vezes maior do que a resolução de

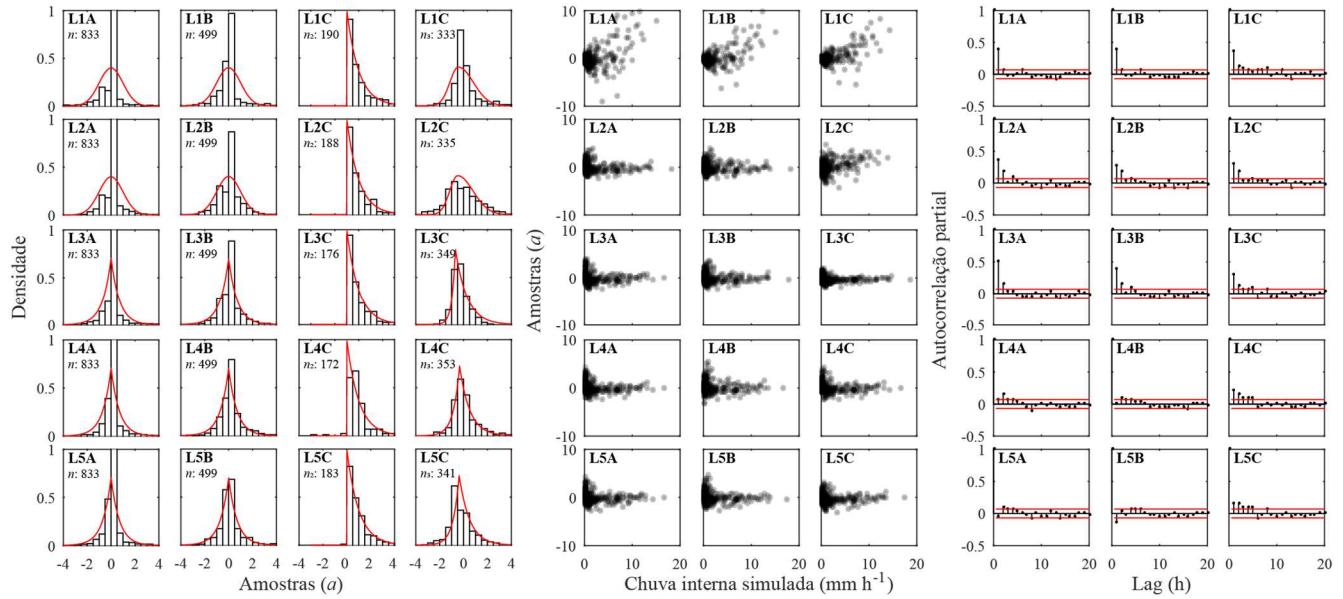
monitoramento do plot da floresta nativa. A série de dados coletada no reflorestamento de pinus possui uma maior proporção de dados iguais ao valor da resolução de monitoramento, dificultando a sua representação por uma função densidade de probabilidade.

A hipótese de homoscedasticidade dos resíduos foi claramente violada (Figura 33). Porém, a consideração de um modelo linear para o desvio padrão dos resíduos (L2 a L5) resultou em valores muito elevados para os resíduos transformados de simulações próximas a zero, o que pode ter impactado negativamente o cálculo do valor da função de verossimilhança (conforme discutido anteriormente). O uso de um modelo para resíduos ainda mais complexo, com a incorporação do modelo autoregressivo AR(1) (modelos para resíduos L4 e L5), exacerbou este problema. Além disso, apesar de reduzir a autocorrelação no lag 1 quando comparado com L2 e L3, a inclusão do modelo AR(1) não foi suficiente para remover completamente a correlação dos resíduos (Figura 33).

Fixando o valor do coeficiente linear do modelo heteroscedástico em  $0,12 \text{ mm h}^{-1}$  evitou a ocorrência de resíduos transformados com valores extremamente elevados para valores simulados próximos a zero, especialmente para as formulações GL e ZI-GL (Figura 34).



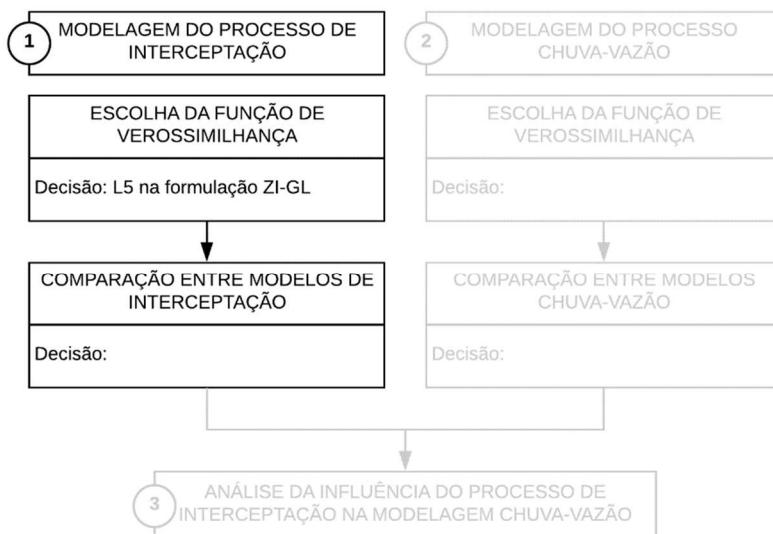
**Figura 33.** Diagnóstico dos resíduos para a floresta nativa (validação), para cada um dos modelos para resíduos (L1 a L5) considerando GL (A),  $GL^{>0}$  (B) e ZI-GL (C). Este diagnóstico foi realizado para os resíduos obtidos a partir da simulação que maximizou a função de verossimilhança. Da esquerda para a direita: histogramas dos resíduos transformados ( $a_i$ ), em que a linha vermelha indica a distribuição teórica;  $a_i$  em função do valor simulado de chuva interna ( $T_f$ ); e autocorrelação parcial dos resíduos, em que a linha vermelha indica o intervalo de confiança de 95%. Nos histogramas do método ZI-GL (C), a distribuição dos resíduos da categoria 2 é apresentada na esquerda e a distribuição dos resíduos da categoria 3 é apresentada na direita. A autocorrelação parcial foi calculada para a série inteira.



**Figura 34.** Diagnóstico dos resíduos para a floresta nativa (validação), para cada um dos modelos para resíduos (L1 a L5) considerando GL (A),  $GL^{x_0}$  (B) e ZI-GL (C), com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . Este diagnóstico foi realizado para os resíduos obtidos a partir da simulação que maximizou a função de verossimilhança. Da esquerda para a direita: histogramas dos resíduos transformados ( $a_t$ ), em que a linha vermelha indica a distribuição teórica;  $a_t$  em função do valor simulado de chuva interna ( $T_f$ ); e autocorrelação parcial dos resíduos, em que a linha vermelha indica o intervalo de confiança de 95%. Nos histogramas do método ZI-GL (C), a distribuição dos resíduos da categoria 2 é apresentada na esquerda e a distribuição dos resíduos da categoria 3 é apresentada na direita. A autocorrelação parcial foi calculada para a série inteira.

### *Conclusão – escolha da função de verossimilhança*

De acordo com os resultados apresentados neste item, optou-se por utilizar na calibração dos diferentes modelos de interceptação o modelo para resíduos L5 (que considera curtose da distribuição dos resíduos, heteroscedasticidade e autocorrelação) na formulação ZI-GL e com o coeficiente linear do modelo heteroscedástico fixado em  $0,12 \text{ mm h}^{-1}$  (Figura 35).



**Figura 35.** Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo de interceptação – e o resultado correspondente à escolha da função de verossimilhança.

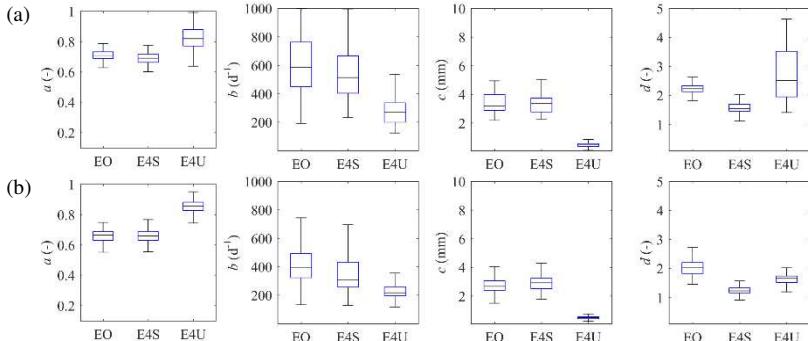
#### **4.2.2. Análise da influência da evaporação potencial**

Na análise do uso de diferentes funções de verossimilhança na calibração do modelo de interceptação o valor da evaporação potencial foi fixado em  $4 \text{ mm h}^{-1}$ , sendo considerada uma variação senoidal da taxa de evaporação potencial ao longo do dia. Esta consideração foi realizada uma vez que o método de Penman modificado resultou em valores muito baixos de evaporação potencial diária para a floresta nativa. Como mencionado no item 4.1, os valores de perdas por interceptação estimados indiretamente a partir do monitoramento de chuva total, chuva interna e

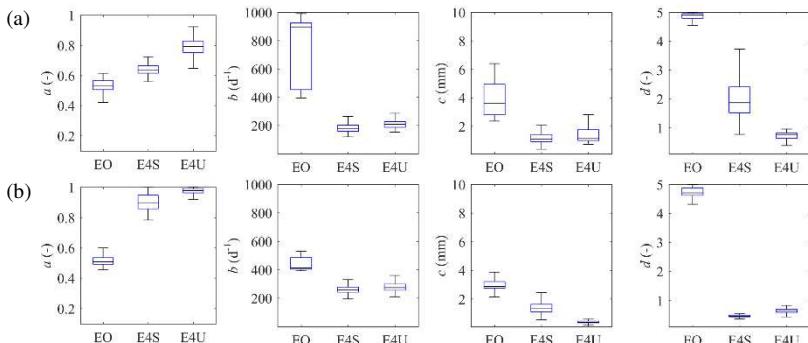
escoamento pelos troncos não condizem com os valores de evaporação potencial calculados.

Para avaliar a influência do valor da evaporação potencial na distribuição *a posteriori* dos parâmetros, três situações foram consideradas: (1) evaporação potencial calculada com o método de Penman modificado (EO); (2) evaporação potencial igual a 4 mm d<sup>-1</sup> e com variação senoidal ao longo do dia (como considerado no item anterior) (E4S); e (3) evaporação potencial igual a 4 mm d<sup>-1</sup> e distribuição uniforme ao longo do dia (E4U). Os resultados desta análise são apresentados na Figura 36a para o reflorestamento de pinus e na Figura 37a para a floresta nativa. Como pode ser observado, a utilização dos valores originais de evaporação potencial (estimados pelo método de Penman modificado) faz com que o parâmetro de eficiência de evaporação (parâmetro *d* do modelo de interceptação) atinja o limite superior (igual a 5) no caso da floresta nativa. Para o reflorestamento de pinus, as distribuições *a posteriori* dos parâmetros obtidas para EO e E4S são bem similares, uma vez que os valores estimados para este estudo de caso não variam tanto em relação ao valor assumido de 4 mm d<sup>-1</sup>.

Erros na representatividade dos valores observados de chuva interna também poderiam justificar a discordância entre os valores de perdas por interceptação monitorados e as taxas de evaporação potencial diária calculadas. Como a chuva interna é um componente importante (em termos de magnitude no balanço realizado ( $I_L = P - T_f - S_f$ ), um pequeno erro em sua estimativa acarreta em um erro significativo na estimativa das perdas por interceptação. Para avaliar o impacto de erros no valor da chuva interna (utilizada na calibração dos modelos de interceptação), a série de dados desta variável foi multiplicada por um fator igual a 1,2, o que corresponde a um aumento de 20% no valor da chuva interna. A influência desta variação na distribuição *a posteriori* dos parâmetros é apresentada na Figura 36b para o reflorestamento de pinus e na Figura 37b para a floresta nativa. Como pode ser observado, mesmo com um valor mais elevado para a chuva interna (que implicaria em uma menor evaporação simulada pelo modelo), o valor do parâmetro *d* continua atingindo o limite superior no caso da floresta nativa. Desta maneira, optou-se por manter o valor da taxa de evaporação potencial em 4 mm d<sup>-1</sup> na comparação do uso de diferentes formulações para representar o processo de interceptação.



**Figura 36.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para o reflorestamento de pinus considerando a evaporação potencial calculada pelo método de Penman (EO), igual a 4 mm d<sup>-1</sup> e com variação senoidal ao longo do dia (E4S) e igual a 4 mm d<sup>-1</sup> e distribuída uniformemente ao longo do dia (E4U). (a) Calibração com a série original de chuva interna. (b) Calibração com um aumento de 20% no valor da chuva interna.



**Figura 37.** Distribuição *a posteriori* dos parâmetros do modelo de interceptação para a floresta nativa considerando a evaporação potencial calculada pelo método de Penman (EO), igual a 4 mm d<sup>-1</sup> e com variação senoidal ao longo do dia (E4S) e igual a 4 mm d<sup>-1</sup> e distribuída uniformemente ao longo do dia (E4U). (a) Calibração com a série original de chuva interna. (b) Calibração com um aumento de 20% no valor da chuva interna.

#### 4.2.3.Comparação entre diferentes formulações

Neste item são apresentados os resultados da utilização dos sete modelos de interceptação considerados neste estudo (apresentados no item 3.4.1). Os modelos foram avaliados em termos da qualidade da faixa de incerteza (a partir da quantificação das métricas de precisão, viés e confiabilidade) e em termos dos valores dos critérios de informação, conforme exposto no item 3.4.4. Para análise da influência a escolha da função de verossimilhança na seleção do modelo de interceptação, os critérios de informação foram calculados para a função de verossimilhança mais simples ( $L_1$  na formulação GL) e para a função de verossimilhança escolhida como sendo mais adequada ( $L_5$  na formulação ZI-GL).

##### *Reflorestamento de pinus (na bacia do rio Saci)*

Para o reflorestamento de pinus, a regressão linear (S1) nem sempre resultou em piores valores para as métricas (precisão, viés e confiabilidade) na calibração, porém teve desempenho inferior na validação (Figura 38). A estrutura S2 apresentou piores resultados quando comparado a S3 e S4, para as duas formulações de drenagem consideradas (Figura 38). A utilização de uma formulação de drenagem mais complexa (D2) resultou em um melhor valor para a métrica de confiabilidade, porém com um pior valor de viés (Figura 38).

	Calibração					Validação				
	P	V	C	$C^{y<2}$	$C^{y>2}$	P	V	C	$C^{y<2}$	$C^{y>2}$
S1	0,57	0,11	0,05	0,07	0,62	0,48	0,22	0,05	0,02	0,65
S2D1	-0,71	0,26	0,03	0,03	0,22	0,62	0,14	0,05	0,05	0,27
S3D1	-0,54	0,05	0,04	0,05	0,19	0,47	0,03	0,02	0,03	0,25
S4D1	-0,52	0,04	0,04	0,05	0,21	0,46	0,04	0,03	0,04	0,26
S2D2	-0,84	0,34	0,06	0,06	0,22	0,74	0,20	0,05	0,04	0,24
S3D2	-0,62	0,19	0,07	0,07	0,13	0,55	0,09	0,03	0,03	0,14
S4D2	-0,61	0,18	0,05	0,06	0,11	0,54	0,08	0,02	0,03	0,12

**Figura 38.** Métricas de desempenho para o reflorestamento de pinus obtidas para cada um dos modelos de interceptação (S1 a S4D2) utilizando a ZI-GL, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>. P é a precisão, V o viés, C a confiabilidade,  $C^{y<2}$  a confiabilidade para chuva interna < 2 mm h<sup>-1</sup>,  $C^{y>2}$  a confiabilidade para chuva interna > 2 mm h<sup>-1</sup>.

Comparando as diferentes formulações com base nos valores dos critérios de informação ( $I_k$ ), verifica-se que um aumento de complexidade

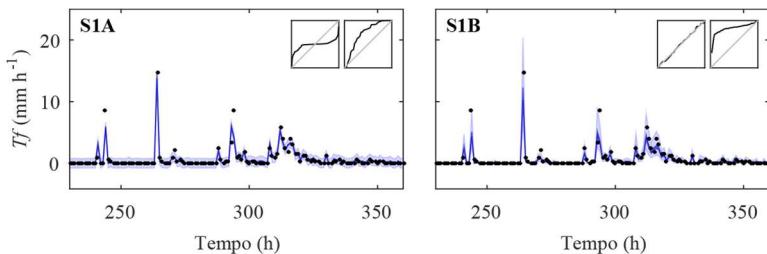
do modelo utilizado para representar o processo de interceptação é justificado pela melhoria de desempenho promovida (em termos do valor máximo da função de verossimilhança – utilizada no cálculo dos critérios de informação) (considerando os valores para L5 na Tabela 14). Segundo estes critérios de informação, os modelos S3D2 e S4D2 seriam preferíveis, pois apresentaram maior peso  $w_i$ . Os critérios de informação de Akaike (AIC) e de Bayes (BIC) resultaram em uma mesma classificação dos modelos. Verifica-se que a utilização dos critérios de informação para seleção de modelos é coerente com os valores de função de verossimilhança obtidos para a validação, mostrando que neste caso os critérios de informação conseguiram prever de maneira adequada o erro dos modelos quando utilizados em um período diferente do considerado para calibração. Verifica-se também que o uso do modelo para resíduos L1 na formulação GL resulta em uma classificação dos modelos diferente quando comparada à obtida com o modelo para resíduos L5 na formulação ZI-GL, mostrando a importância da escolha do modelo para resíduos no processo de seleção de modelos.

**Tabela 14.** Critérios de informação ( $I_k$ ) para as diferentes formulações do processo de interceptação. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes. Valores calculados para o reflorestamento de pinus para o período de calibração.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado,  $w_i$  é o peso de cada modelo e  $L_{\text{val}}$  é o valor (máximo) da função de verossimilhança obtido na validação.

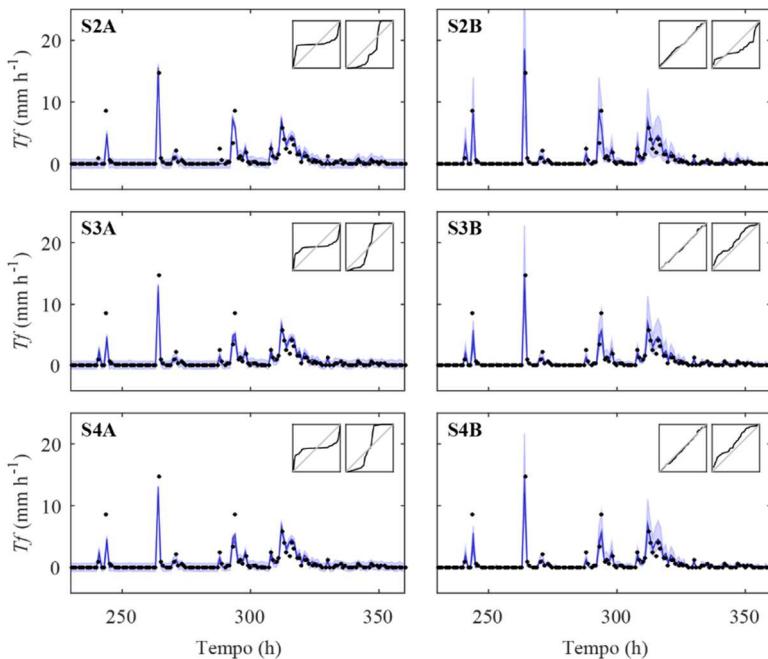
Formulação	$\ln L$	$k$	$n$	AIC		BIC		$\ln L_{\text{val}}$
				$I_k$	$w_i$	$I_k$	$w_i$	
<b>L1 na formulação GL</b>								
S1	-2045	3	533	4097	0,00	4099	0,00	-2146
S2D1	-2016	4	533	4040	0,00	4043	0,00	-2378
S3D1	-1956	5	533	3922	0,54	3926	0,54	-2217
S4D1	-1956	5	533	3923	0,46	3926	0,46	-2204
S2D2	-2045	4	533	4098	0,00	4101	0,00	-2259
S3D2	-1973	5	533	3955	0,00	3959	0,00	-2154
S4D2	-1973	5	533	3955	0,00	3959	0,00	-2147
<b>L5 na formulação ZI-GL</b>								
S1	-865	7	533	1744	0,00	1749	0,00	-1034
S2D1	-884	8	533	1784	0,00	1790	0,00	-1048
S3D1	-840	9	533	1697	0,01	1704	0,01	-1015
S4D1	-839	9	533	1697	0,01	1703	0,01	-1012
S2D2	-841	8	533	1697	0,01	1703	0,01	-973
S3D2	-835	9	533	1688	0,65	1695	0,65	-993
S4D2	-836	9	533	1689	0,33	1696	0,33	-996

A comparação das faixas de incerteza (e dos gráficos quantil-quantil correspondentes) obtidas para L1 e L5 reforçam os resultados obtidos no item 4.2.1: a utilização de um modelo para resíduos que considera que os resíduos são homoscedásticos (L1) resulta em uma faixa de incerteza superestimada para valores baixos (QQ plot do painel da esquerda nas Figura 39, Figura 40 e Figura 41) e superestimada para valores mais altos (QQ plot da direita nas Figura 39, Figura 40 e Figura 41). Comparando as diferentes formulações utilizadas para representar o processo de interceptação, verifica-se uma maior proximidade da linha 1:1 para os QQ plots de S3D1 e S4D1 (Figura 40) e de S2D2, S3D2 e S4D2 (Figura 41), indicando uma maior confiabilidade da faixa de incerteza obtida nestas situações.

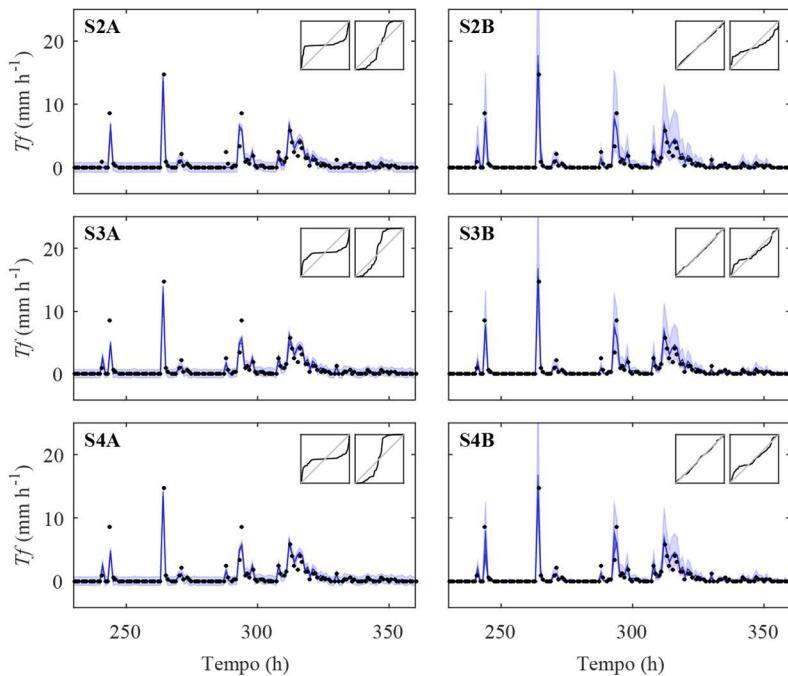
As mesmas conclusões foram obtidas a partir dos resultados da calibração dos modelos com valores chuva líquida (chuva interna + escoamento pelos troncos) ao invés de chuva interna (resultados no Apêndice C).



**Figura 39.** Resultado para a estrutura 1 (S1). Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).



**Figura 40.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 1. Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>, na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2$  mm h<sup>-1</sup> (esquerda) e  $Tf > 2$  mm h<sup>-1</sup> (direita).



**Figura 41.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 2. Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).

#### *Floresta nativa (na bacia do rio Araponga)*

Para a floresta nativa, semelhante ao resultado obtido para o reflorestamento de pinus, a regressão linear (S1) nem sempre resultou em piores valores para as métricas de desempenho (precisão, viés e confiabilidade) na calibração, porém teve desempenho inferior na validação (Figura 42). A estrutura S2 apresentou piores resultados quando comparado a S3 e S4, para as duas formulações de drenagem consideradas (Figura 42). Ao contrário do obtido para o reflorestamento de pinus, a utilização de uma formulação de drenagem mais complexa (D2) não resultou em uma melhoria de desempenho do modelo (em termos das métricas analisadas), tendo sido obtido um pior valor de viés e de confiabilidade (Figura 42).

	Calibração					Validação				
	P	V	C	$C^{y<2}$	$C^{y>2}$	P	V	C	$C^{y<2}$	$C^{y>2}$
S1	0,38	0,05	0,02	0,05	0,35	0,34	0,11	0,07	0,04	0,52
S2D1	0,57	0,28	0,04	0,04	0,37	0,53	0,21	0,06	0,07	0,30
S3D1	0,44	0,18	0,04	0,03	0,32	0,39	0,09	0,05	0,05	0,17
S4D1	0,45	0,20	0,06	0,04	0,34	0,40	0,11	0,05	0,06	0,20
S2D2	0,49	0,29	0,05	0,02	0,45	0,46	0,20	0,02	0,03	0,31
S3D2	0,42	0,22	0,06	0,04	0,44	0,38	0,13	0,03	0,05	0,24
S4D2	0,42	0,22	0,06	0,03	0,44	0,38	0,13	0,02	0,03	0,25

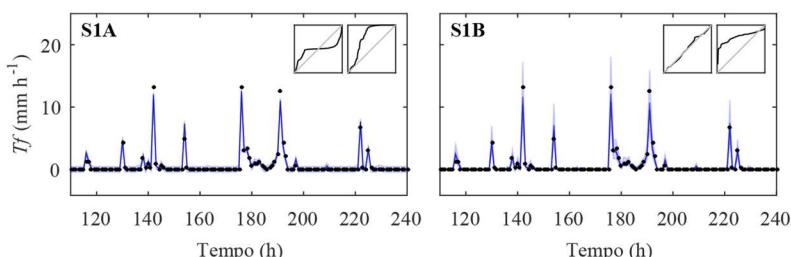
**Figura 42.** Métricas de desempenho para a floresta nativa obtidas para cada um dos modelos de interceptação (S1 a S4D2) utilizando a ZI-GL, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>. P é a precisão, V o viés, C a confiabilidade,  $C^{y<2}$  a confiabilidade para chuva interna < 2 mm h<sup>-1</sup>,  $C^{y>2}$  a confiabilidade para chuva interna > 2 mm h<sup>-1</sup>.

Considerando os valores dos critérios de informação ( $I_k$ ), o modelo S2D2 deveria ser escolhido (valores para L5 na Tabela 14). Este resultado diverge do obtido a partir da análise dos valores da função de verossimilhança do período de validação, em que melhores valores foram obtidos para os modelos S3D2 e S4D2. Além disso, verifica-se que o modelo S2D2 apresentou os piores valores para as métricas de desempenho apresentadas na Figura 42. Os critérios de informação considerados neste estudo utilizam em seu cálculo apenas o valor máximo da função de verossimilhança, sem consideração do desempenho geral em termos da faixa de incerteza. Este resultado sugere que seja considerado outros métodos de análise de complexidade, como a utilização da evidência – denominador do teorema de Bayes (e.g. Volpi et al., 2017), no processo de seleção de modelos de diferentes complexidades. Assim como os resultados obtidos para o reflorestamento de pinus, os critérios de informação de Akaike (AIC) e de Bayes (BIC) promoveram uma mesma classificação dos modelos e o uso do modelo para resíduos L1 na formulação GL resultou em uma classificação dos modelos diferente quando comparada à obtida com o modelo para resíduos L5 na formulação ZI-GL (Tabela 14).

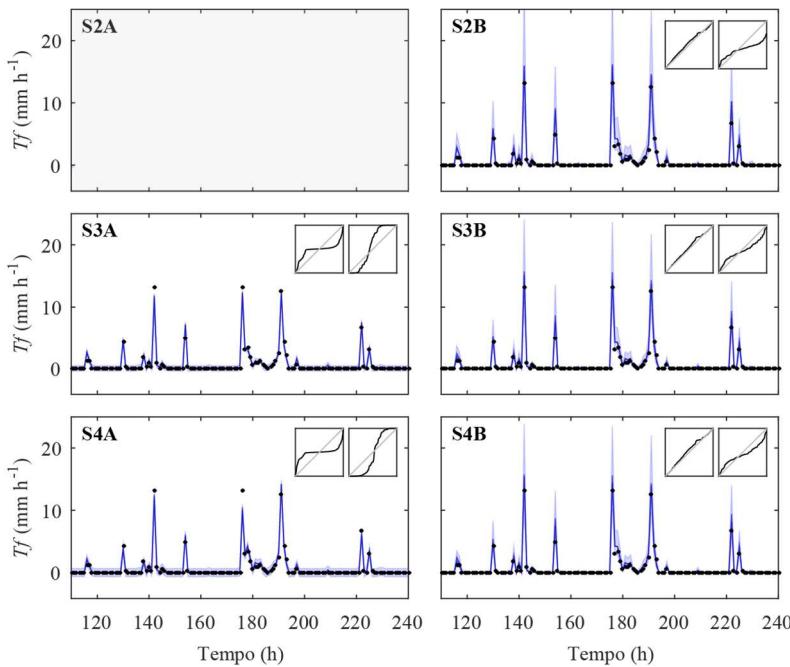
Quanto às faixas de incerteza obtidas para as diferentes formulações utilizadas para representar o processo de interceptação, verifica-se uma maior proximidade da linha 1:1 para os QQ plots de S3D2 e S4D2 (considerando os plots correspondentes a L5 na Figura 41), indicando uma maior confiabilidade da faixa de incerteza obtida nestas situações.

**Tabela 15.** Critérios de informação ( $I_k$ ) para as diferentes formulações do processo de interceptação. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes. Valores calculados para a vegetação nativa para o período de calibração.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado,  $w_i$  é o peso de cada modelo e  $L_{\text{val}}$  é o valor (máximo) da função de verossimilhança obtido na validação. A calibração com a estrutura S2D1 não convergiu quando o modelo de resíduos L1 foi utilizado, e desta maneira este resultado não é apresentado.

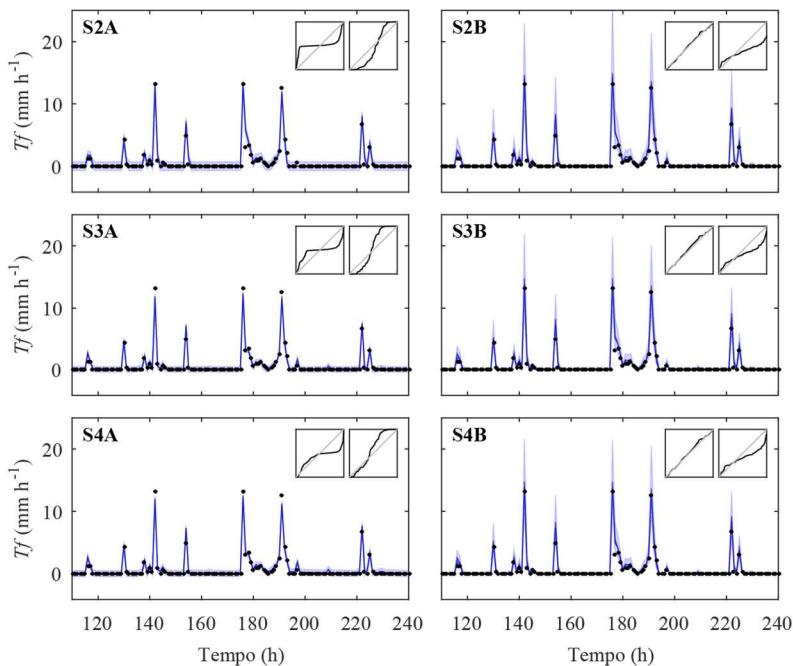
Formulação	$\ln L$	$k$	$n$	AIC		BIC		$\ln L_{\text{val}}$
				$I_k$	$w_i$	$I_k$	$w_i$	
<b>L1 na formulação GL</b>								
S1	-2233	3	669	4472	0,00	4475	0,00	-3029
S2D1								
S3D1	-2188	5	669	4385	0,98	4390	0,98	-3004
S4D1	-2462	5	669	4934	0,00	4938	0,00	-3078
S2D2	-2502	4	669	5012	0,00	5015	0,00	-3053
S3D2	-2191	5	669	4393	0,02	4397	0,02	-2940
S4D2	-2255	5	669	4521	0,00	4525	0,00	-2946
<b>L5 na formulação ZI-GL</b>								
S1	-1145	7	669	2304	0,00	2310	0,00	-1675
S2D1	-1130	8	669	2275	0,00	2282	0,00	-1644
S3D1	-1091	9	669	2199	0,00	2207	0,00	-1594
S4D1	-1090	9	669	2199	0,00	2206	0,00	-1593
S2D2	-1006	8	669	2028	1,00	2034	1,00	-1526
S3D2	-1021	9	669	2060	0,00	2067	0,00	-1522
S4D2	-1021	9	669	2060	0,00	2068	0,00	-1525



**Figura 43.** Resultado para a estrutura 1 (S1). Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita).



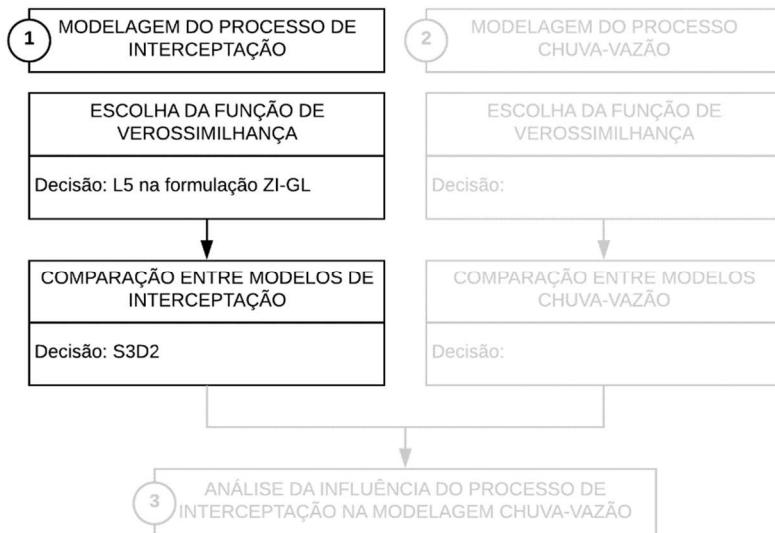
**Figura 44.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 1. Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>, na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita). A calibração com a estrutura S2D1 não convergiu quando o modelo de resíduos L1 foi utilizado, e desta maneira este resultado não é apresentado.



**Figura 45.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 2. Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita).

*Conclusão – comparação entre diferentes formulações*

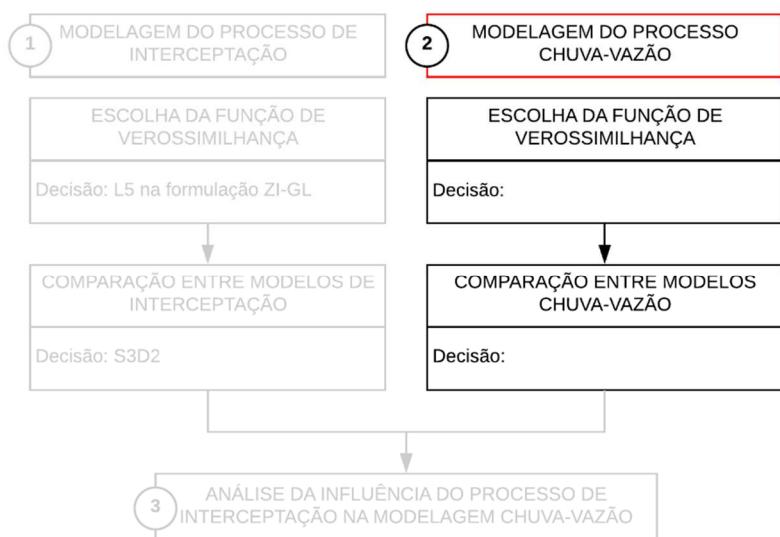
Com base nos resultados apresentados neste item, optou-se por utilizar o modelo de interceptação S3D2 nas etapas subsequentes deste trabalho (Figura 46).



**Figura 46.** Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo de interceptação – e o resultado correspondente à escolha do modelo de interceptação.

### 4.3. MODELAGEM DO PROCESSO CHUVA-VAZÃO

A Figura 47 mostra a sequência das etapas apresentadas neste item do trabalho, referente à modelagem do chuva-vazão. A primeira etapa consiste na escolha da função de verossimilhança a ser utilizada para representar os resíduos do modelo. Nesta etapa, foi utilizado o modelo M09. Em seguida, a função de verossimilhança escolhida é utilizada na inferência dos parâmetros de todos os modelos considerados, e os modelos são comparados em termos da qualidade da faixa de incerteza estimada e dos valores de critérios de informação.



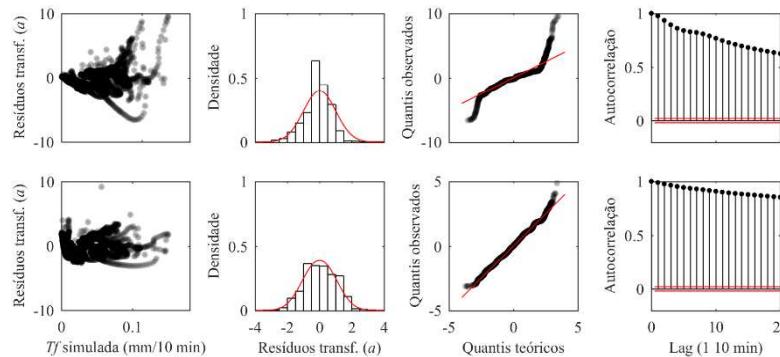
**Figura 47.** Fluxograma geral do trabalho, com destaque para as etapas da segunda parte – modelagem do processo chuva-vazão.

#### 4.3.1. Escolha da função de verossimilhança

*Bacia do rio Saci*

Para a bacia do rio Saci, os resíduos violaram a hipótese de homoscedasticidade, como pode ser observado a partir do diagnóstico dos resíduos para L1 (painedel superior da Figura 48). A utilização de um modelo para resíduos que considera heteroscedasticidade e curtose da distribuição (L3) melhorou o ajuste dos resíduos à distribuição assumida

(painel inferior da Figura 48). A utilização de um modelo AR(1) (modelo para resíduos L5) não foi suficiente para remoção da autocorrelação dos resíduos (resultado não apresentado). A consideração da autocorrelação dos resíduos do modelo chuva-vazão aplicado a esta bacia será discutida mais adiante.

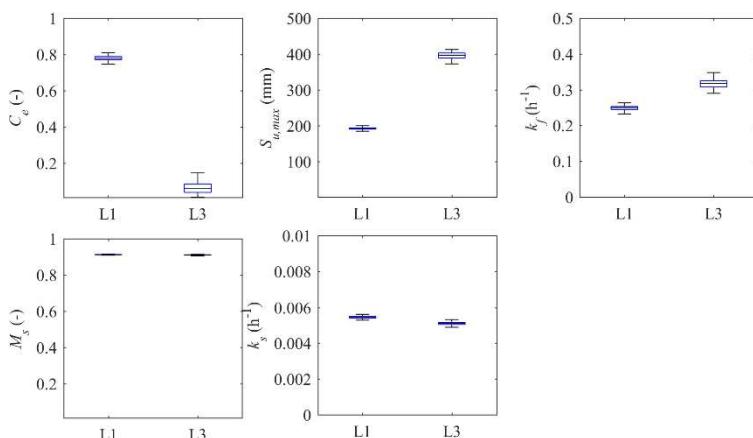


**Figura 48.** Diagnóstico dos resíduos para a bacia do rio Saci. Calibração realizada com a L1 (painel superior) e L3 (painel inferior) utilizando dados de vazão da série completa com 10 min de resolução temporal.

A escolha do modelo para resíduos influenciou a distribuição *a posteriori* obtida para os parâmetros (Figura 49) e a qualidade da faixa de incerteza obtida (Tabela 16). A utilização do modelo para resíduos L3 resultou em uma faixa de incerteza associada aos resultados das simulações mais representativa para os diferentes valores de vazão, tendo sido evitada a superestimativa da faixa de incerteza para valores baixos, evidente no caso da utilização da L1 (Figura 57).

Como mencionado anteriormente, a utilização de um modelo autoregressivo de primeira ordem não foi suficiente para remover a autocorrelação dos resíduos. Utilizando o modelo para resíduos L3, a elevada autocorrelação dos resíduos é desconsiderada (Figura 48). Visando reduzir esta autocorrelação dos resíduos, a calibração para a bacia do rio Saci foi realizada novamente com uma decimação da série de dados variando de 6 (um dado por hora) a 72 (um dado a cada 12 horas). As métricas de desempenho considerando uma decimação de até 18 (um dado a cada 3 horas) não divergiram significativamente dos valores obtidos com a calibração realizada utilizando todos os dados (Tabela 17). A consideração de decimação da série de dados de até 6 teve um efeito de aumentar a incerteza da distribuição *a posteriori* dos parâmetros, sem

modificar significativamente os valores obtidos (Figura 50). A utilização de um valor mais elevado de decimação resultou em uma maior divergência das distribuições *a posteriori* dos parâmetros (Figura 50). A utilização de uma decimação igual a 72 também prejudicou o ajuste dos resíduos à distribuição assumida (Figura 51). Desta maneira, nas próximas análises realizadas neste trabalho, foi considerado uma decimação de 6, visando reduzir o efeito de convergência excessiva da distribuição *a posteriori* dos parâmetros (como consequência da autocorrelação dos resíduos), e sem prejudicar os resultados da simulação (o que ocorreria caso fosse considerado uma decimação mais grosseiro).



**Figura 49.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.

**Tabela 16.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada. Células em cinza indicam melhor desempenho.

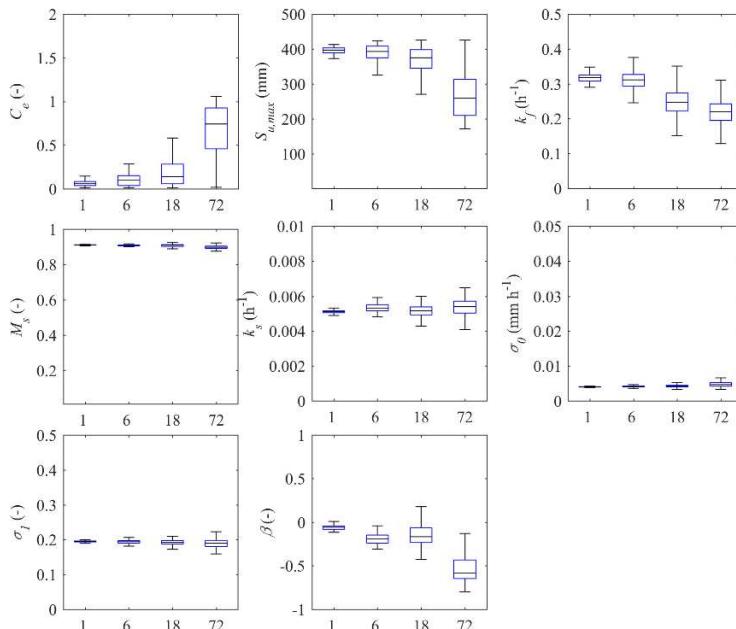
Métrica	Série toda		Série A		Série B		Série C	
	L1	L3	L1	L3	L1	L3	L1	L3
Precisão	0,30	0,21	1,96	0,39	0,37	0,24	0,17	0,19
Viés	0,03	0,04	0,52	0,21	0,29	0,09	0,06	0,08
Confiabilidade	0,13	0,03	0,39	0,21	0,51	0,32	0,29	0,36
$Q < 0,2 \text{ mm h}^{-1}$	0,31	0,25	0,39	0,21	0,56	0,41	0,26	0,23
$Q > 0,2 \text{ mm h}^{-1}$	0,30	0,41	0,43	0,61	0,14	0,30	0,33	0,42

**Tabela 17.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação variando de 1 (um dado a cada 10 min) a 72 (um dado a cada 12 horas) e chuva total como entrada.

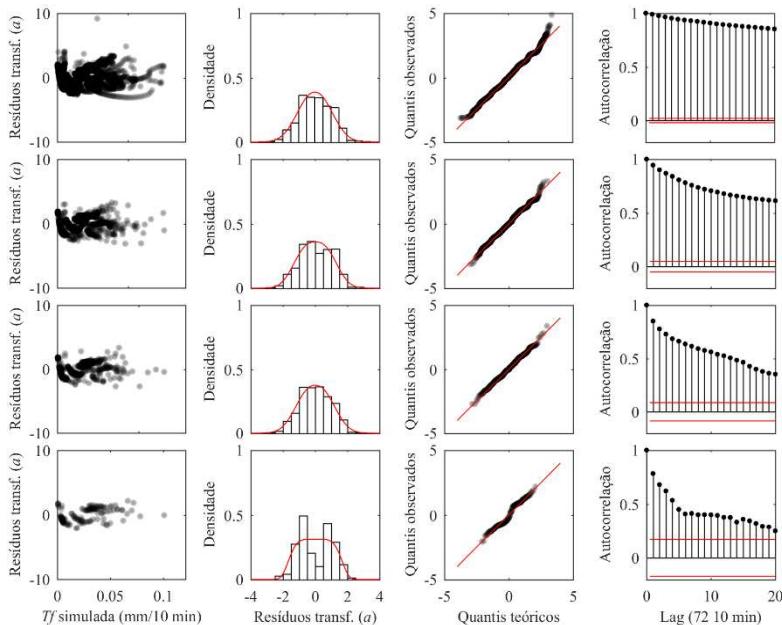
<b>Métrica</b>	<b>Série toda</b>				<b>Série A</b>			
	1	6	18	72	1	6	18	72
Precisão	0,21	0,21	0,21	0,21	0,39	0,40	0,40	0,44
Viés	0,04	0,04	0,04	0,06	0,21	0,21	0,21	0,27
Confiabilidade	0,03	0,04	0,03	0,07	0,21	0,21	0,21	0,27
$Q < 0,2 \text{ mm h}^{-1}$	0,25	0,23	0,24	0,26	0,21	0,21	0,21	0,27
$Q > 0,2 \text{ mm h}^{-1}$	0,41	0,41	0,42	0,48	0,61	0,58	0,65	0,64

<b>Métrica</b>	<b>Série B</b>				<b>Série C</b>			
	1	6	18	72	1	6	18	72
Precisão	0,24	0,24	0,24	0,25	0,19	0,19	0,19	0,19
Viés	0,09	0,10	0,10	0,12	0,08	0,08	0,09	0,12
Confiabilidade	0,32	0,31	0,33	0,34	0,36	0,37	0,37	0,45
$Q < 0,2 \text{ mm h}^{-1}$	0,41	0,39	0,41	0,40	0,23	0,24	0,23	0,24
$Q > 0,2 \text{ mm h}^{-1}$	0,30	0,27	0,27	0,16	0,42	0,43	0,43	0,50



**Figura 50.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) e do modelo para resíduos ( $\sigma_0$ ,  $\sigma_1$ ,  $\beta$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L3. Calibração realizada com dados de vazão da série completa com decimação de 1, 6, 18 e 72 (10 min) e chuva total como entrada.

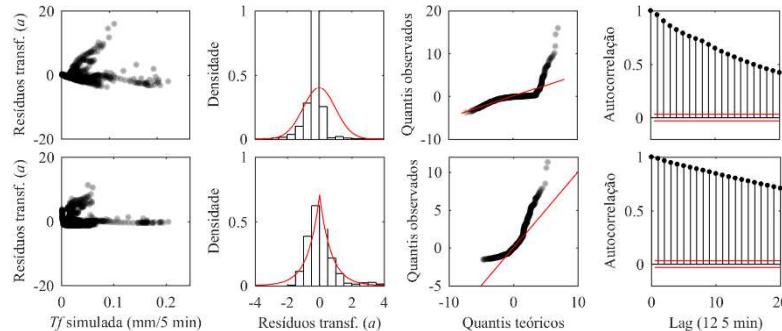


**Figura 51.** Diagnóstico dos resíduos para a bacia do rio Saci. Calibração realizada com a L3 utilizando dados de vazão da série completa com decimação de 1, 6, 18 e 72.

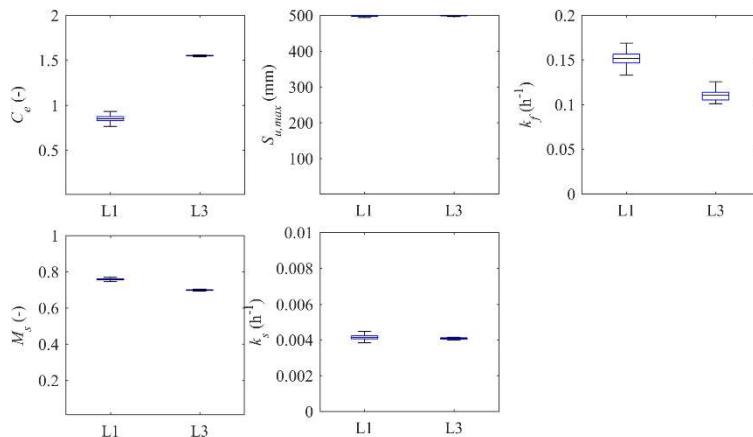
### Bacia do rio Araponga

A consideração de homoscedasticidade dos resíduos foi claramente violada para a bacia do rio Araponga (painedel superior da Figura 52). A utilização do modelo para resíduos L3 promoveu um melhor ajuste dos resíduos à distribuição assumida (painedel inferior da Figura 52), apesar do ajuste não ser perfeito.

Assim como verificado para a bacia do rio Saci, a escolha do modelo para resíduos influenciou a distribuição *a posteriori* dos parâmetros (Figura 53) e a qualidade da faixa de incerteza obtida (Tabela 18). A faixa de incerteza obtida com o modelo para resíduos L1 foi superestimada para valores baixos e subestimada para valores mais elevados (Figura 58).



**Figura 52.** Diagnóstico dos resíduos para a bacia do rio Araponga. Calibração realizada com a L1 (paineel superior) e L3 (paineel inferior) utilizando dados de vazão da série completa com decimação de 12 (um dado a cada hora).



**Figura 53.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e decimação de 12 (1 dado a cada hora), com chuva total como entrada.

Assim como o realizado para a bacia do rio Saci, a calibração para a bacia do rio Araponga foi refeita variando o valor de decimação da série de dados, com o objetivo de reduzir a alta autocorrelação dos resíduos. Para a bacia do rio Araponga, os resultados obtidos com uma decimação de 288 (que equivale à utilização na calibração de um dado por dia) foram similares aos valores obtidos considerando uma decimação de 12 (um

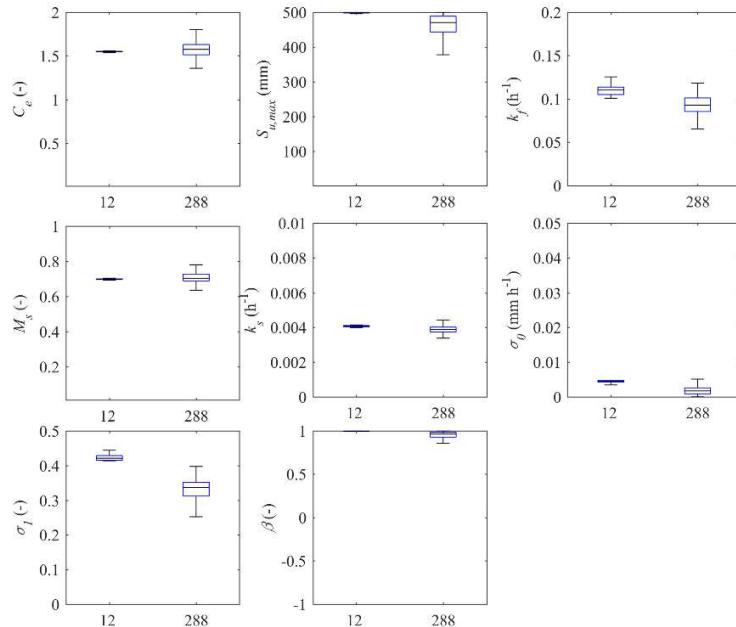
dado por hora) (Tabela 19). A utilização de uma decimação de 288 e a consideração de um modelo AR(1) reduziu significativamente a autocorrelação dos resíduos (Figura 55). O valor do parâmetro do modelo autorregressivo  $\phi$  foi fixado uma vez constatada a correlação deste parâmetro com os demais na inferência conjunta dos parâmetros do modelo chuva-vazão e do modelo para resíduos. O valor de  $\phi$  foi fixado em 0,40, após ter sido testado diferentes valores para este parâmetro. Assim como o verificado no caso da bacia do rio Saci, a redução da autocorrelação dos resíduos evitou a convergência excessiva da distribuição *a posteriori* dos parâmetros (Figura 54). Desta forma, nas análises seguintes realizadas neste estudo, a calibração do modelo chuva-vazão aplicado à bacia do rio Araponga foi realizada considerando uma decimação de 288 aliado a um modelo AR(1) com  $\phi$  fixado em 0,40.

**Tabela 18.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 e L3. Calibração realizada com dados de vazão da série completa com dados de 10 min e decimação de 12 (1 dado a cada hora), com chuva total como entrada. Células em cinza indicam melhor desempenho.

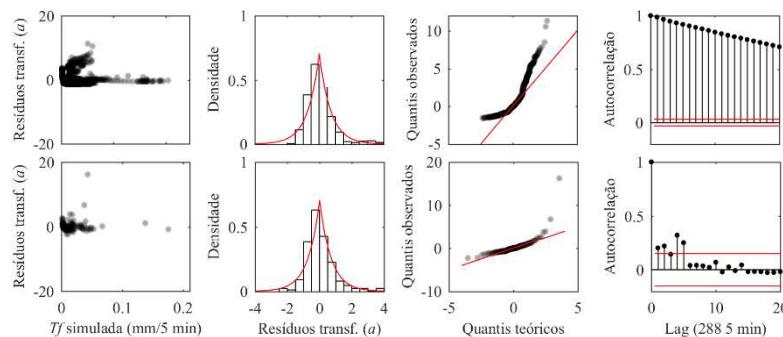
<b>Métrica</b>	<b>Série toda</b>		<b>Série A</b>		<b>Série B</b>	
	L1	L3	L1	L3	L1	L3
Precisão	1,07	0,45	1,02	0,32	1,03	0,52
Viés	0,22	0,05	0,03	0,32	0,37	0,16
Confiabilidade	0,30	0,08	0,31	0,10	0,29	0,16
$Q < 0,2 \text{ mm h}^{-1}$	0,37	0,11	0,39	0,09	0,36	0,17
$Q > 0,2 \text{ mm h}^{-1}$	0,22	0,18	0,20	0,67	0,43	0,16

**Tabela 19.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação variando de 12 (um dado a cada hora) a 288 (um dado a cada 24 horas) e chuva total como entrada.

<b>Métrica</b>	<b>Série toda</b>		<b>Série A</b>		<b>Série B</b>	
	12	288	12	288	12	288
Precisão	0,45	0,36	0,32	0,26	0,52	0,45
Viés	0,05	0,05	0,32	0,33	0,16	0,18
Confiabilidade	0,08	0,09	0,10	0,09	0,16	0,22
$Q < 0,2 \text{ mm h}^{-1}$	0,11	0,15	0,09	0,08	0,17	0,24
$Q > 0,2 \text{ mm h}^{-1}$	0,18	0,17	0,67	0,70	0,16	0,18



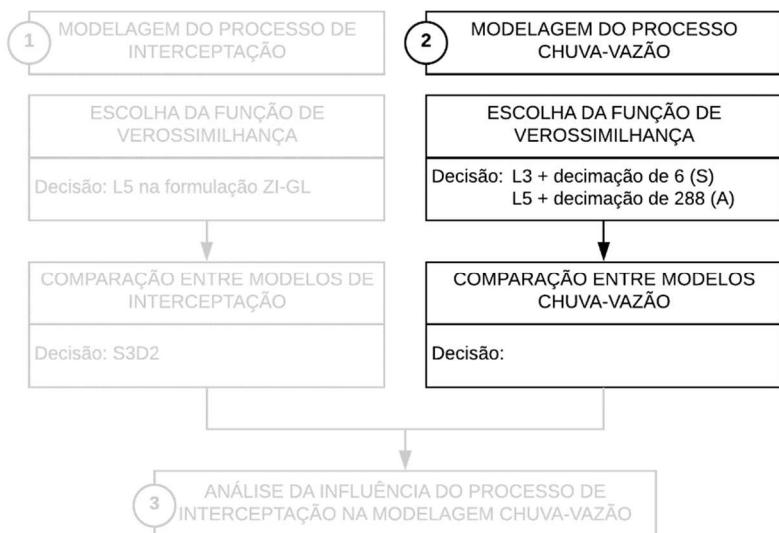
**Figura 54.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) e do modelo para resíduos ( $\sigma_0$ ,  $\sigma_1$ ,  $\beta$ ) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação de 12 e 288 (5 min) e chuva total como entrada. Para decimação = 12, foi utilizado o modelo para resíduos L3. Para decimação = 288, foi utilizado o modelo para resíduos L5, com o parâmetro  $\phi$  fixo em 0,40.



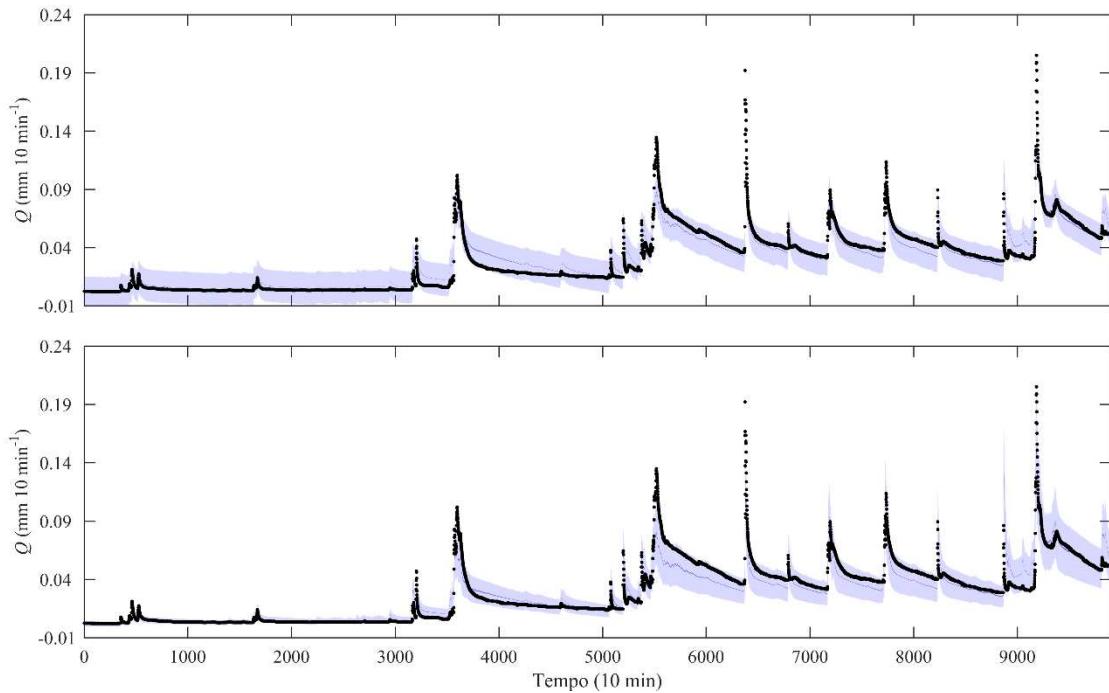
**Figura 55.** Diagnóstico dos resíduos para a bacia do rio Araponga. Calibração realizada utilizando dados de vazão da série completa com decimação de 12 (painele superior) e de 288 (painele inferior). Para decimação = 12, foi utilizado o modelo para resíduos L3. Para decimação = 288, foi utilizado o modelo para resíduos L5, com o parâmetro  $\phi$  fixo em 0,40.

### *Conclusão – escolha da função de verossimilhança*

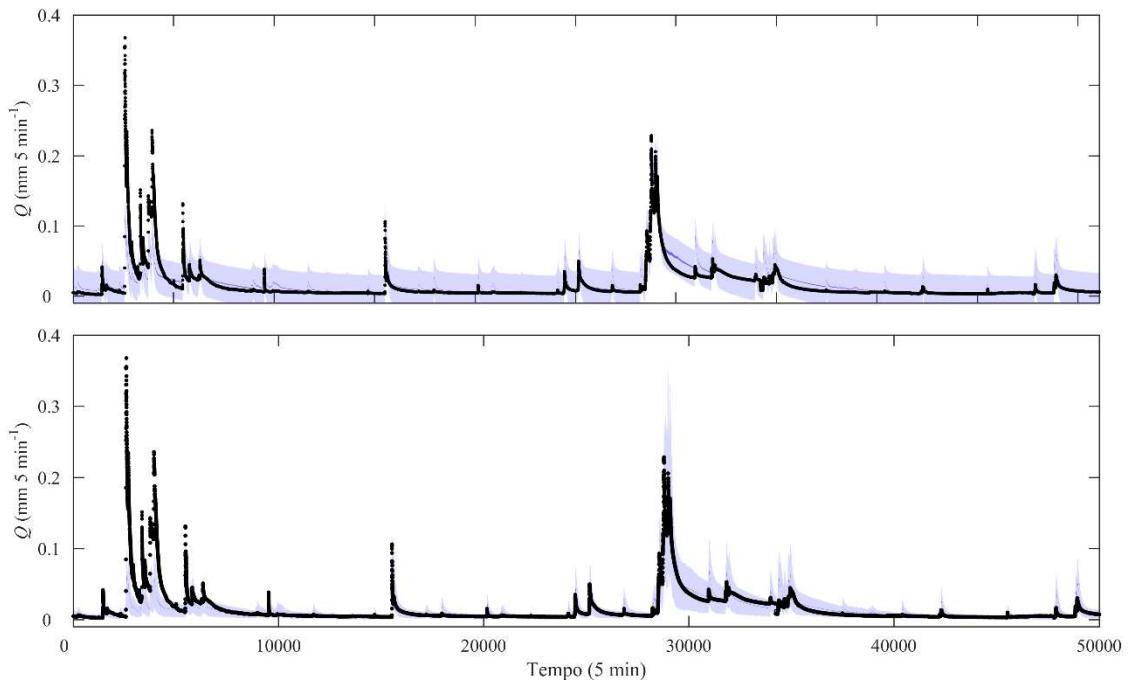
Com base nos resultados apresentados neste item, nas próximas análises realizadas neste trabalho foi considerado para a bacia do rio Saci o modelo para resíduos L3 e uma decimação de 6 (um dado por hora) e para a bacia do rio Araponga o modelo para resíduos L5, com o parâmetro  $\phi$  do modelo AR(1) fixado em 0,40, e uma decimação de 288 (um dado por dia) (Figura 56).



**Figura 56.** Fluxograma geral do trabalho, com destaque para as etapas da primeira parte – modelagem do processo chuva-vazão – e o resultado correspondente à escolha da função de verossimilhança. S: bacia do rio Saci. A: bacia do rio Araponga.



**Figura 57.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci, utilizando o modelo para resíduos L1 (paineel superior) e L3 (paineel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.



**Figura 58.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 (paineel superior) e L3 (paineel inferior). Calibração realizada com dados de vazão da série completa com dados de 5 min, decimação igual a 12 e chuva total como entrada.

### 4.3.2.Comparação entre modelos chuva-vazão

#### *Bacia do rio Saci*

Comparando as diferentes formulações utilizadas para simular o processo chuva-vazão na bacia do rio Saci, verifica-se que as estruturas em paralelo tiveram um melhor desempenho (Apêndice E).

Considerando os valores dos critérios de informação, o modelo M07 (o mais complexo em termos de números de parâmetros) foi o que resultou em um menor valor de  $I_k$ , tanto para o critério de informação de Akaike (AIC) quanto para o critério de informação de Bayes (BIC) (Tabela 20). O valor de peso para este modelo foi muito próximo a 1, indicando que a probabilidade da escolha dos demais modelos em um período diferente do utilizado na calibração é praticamente zero. A utilização dos valores de AIC e BIC para a seleção do modelo mais adequado é prejudicada devido à (entre outros) elevada autocorrelação dos resíduos, o que leva a uma superestimativa da informação fornecida pelos dados. Verifica-se que a variação no termo relacionado ao valor da função de verossimilhança foi muito maior do que a variação no termo que penaliza complexidade. Portanto, o modelo que produziu um maior valor para a função de verossomilhança acabou sendo priorizado. Porém, analisando o desempenho do modelo M07 em termos da faixa de incerteza obtida, constata-se que este modelo não conseguiu representar os picos de vazão. Este resultado indica a necessidade de se utilizar um critério de informação que considere o desempenho da faixa de incerteza como um todo, e não só o valor máximo da função de verossimilhança. Um exemplo seria utilizar a evidência, o denominador do teorema de Bayes, conforme sugerido em Volpi et al. (2017). Desta forma, nas etapas subsequentes deste trabalho, optou-se por utilizar o modelo M11, que apresentou o segundo melhor desempenho em termos dos critérios de informação analisados.

O modelo M08 foi o que resultou em um pior desempenho, resultando em uma faixa de incerteza de baixa qualidade e um valor mais elevado para os critérios de informação (Tabela 20). Dentre os modelos em paralelo testados (que apresentaram melhor desempenho), este modelo é o único sem um reservatório para a zona não saturada. Este resultado indica a relevância deste tipo de reservatório na simulação do processo chuva-vazão na bacia do rio Saci.

**Tabela 20.** Critérios de informação ( $I_k$ ) para as diferentes modelos chuva-vazão considerados. Valores calculados para a bacia do rio Saci. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado e  $w_i$  é o peso de cada modelo.

Modelo	$\ln L$	$k$	$n$	AIC			BIC		
				$I_k$	$\Delta A_i$	$w_i$	$I_k$	$\Delta B_i$	$w_i$
Estrutura com único reservatório									
M01	3617	6	1650	-7223	546	0,00	-7190	519	0,00
Estruturas em série									
M03	3419	7	1650	-6825	944	0,00	-6787	923	0,00
M04	3625	8	1650	-7234	535	0,00	-7191	518	0,00
Estruturas em paralelo									
M07	3896	11	1650	-7769	0	1,00	-7710	0	1,00
M08	3022	7	1650	-6029	1740	0,00	-5991	1718	0,00
M09	3687	8	1650	-7358	411	0,00	-7315	395	0,00
M10	3691	9	1650	-7363	406	0,00	-7314	395	0,00
M11	3835	10	1650	-7650	119	0,00	-7596	114	0,00

### Bacia do rio Araponga

Assim como para a bacia do rio Saci, os modelos com estrutura em paralelo representaram melhor o processo chuva-vazão na bacia do rio Araponga (Apêndice E). Este resultado indica que as duas bacias possuem um movimento vertical importante.

Os valores de critério de informação  $I_k$  foram parecidos para todas as estruturas em paralelo, exceto para o M08 (Tabela 21). Conforme discutido no caso da bacia do rio Saci, a baixa performance do modelo M08 sugere a importância do reservatório da zona não saturada para simular o processo chuva-vazão nestas bacias florestais. Este resultado vai ao encontro ao obtido por Mota (2017) para a bacia do rio Araponga, que verificou que a água da chuva atua inicialmente umedecendo o solo, com posterior movimento lateral para o rio.

Considerando os valores dos critérios de informação, o melhor modelo foi o M11 (Tabela 21). Assim como para a bacia do rio Saci, o peso do modelo com maior valor de AIC é muito superior aos demais, apesar de ter sido verificada uma pequena redução do peso do modelo selecionado (de 1,00 para 0,97). Isso indica que autocorrelação dos resíduos é apenas um dos fatores que prejudica a utilização deste critério de informação na seleção de modelos, já que no caso da bacia do rio Araponga a autocorrelação dos resíduos foi praticamente retirada. Quando o critério de informação de Bayes (BIC) foi utilizado, o peso

atribuído ao modelo M09 foi parecido com o peso atribuído ao modelo M11. Seguindo o critério da parcimônia, o modelo M09 foi escolhido por ser o mais simples dentre os dois (SCHONIGER et al., 2014). A formulação base destes dois modelos é muito similar, sendo compostos por um reservatório da zona não saturada cujo fluxo de saída é dividido entre um reservatório rápido e um lento. A diferença é que o modelo M11 considera que a saída do reservatório da zona não saturada é uma função não linear do armazenamento.

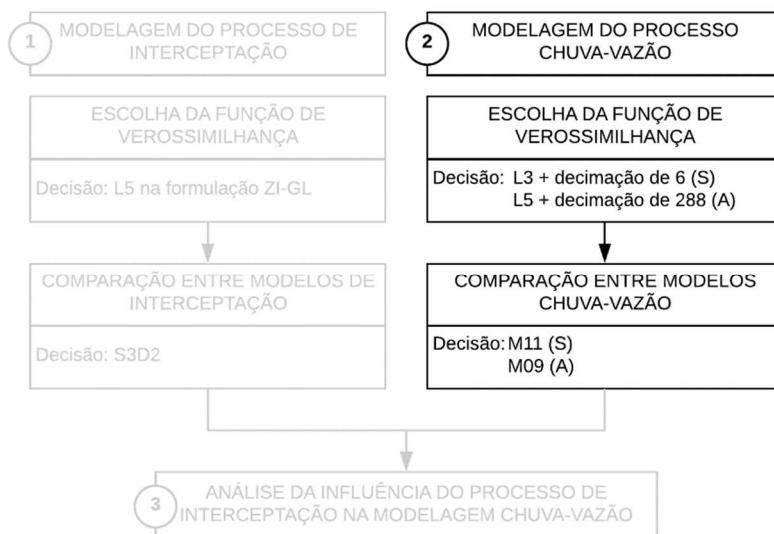
**Tabela 21.** Critérios de informação ( $I_k$ ) para as diferentes modelos chuva-vazão considerados. Valores calculados para a bacia do rio Araponga. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado e  $w_i$  é o peso de cada modelo.

Modelo	$\ln L$	$k$	$n$	AIC			BIC		
				$I_k$	$\Delta A_i$	$w_i$	$I_k$	$\Delta B_i$	$w_i$
Estrutura com único reservatório									
M01	291	6	178	-570	105	0,00	-551	92	0,00
Estruturas em série									
M03	303	7	178	-591	84	0,00	-569	74	0,00
M04	317	8	178	-618	57	0,00	-592	51	0,00
Estruturas em paralelo									
M07	342	11	178	-662	13	0,00	-627	16	0,00
M08	289	7	178	-564	110	0,00	-542	101	0,00
M09	342	8	178	-668	7	0,03	-642	1	0,39
M10	341	9	178	-665	10	0,01	-636	7	0,02
M11	347	10	178	-675	0	0,97	-643	0	0,59

### *Conclusão – comparação entre modelos chuva-vazão*

Apesar das limitações relacionadas à utilização dos critérios de informação na seleção de modelos, a variação relativa de seus valores nos possibilita verificar quais mudanças promoveram uma melhora mais significativa no desempenho, como indicado por Westra et al. (2014). Verifica-se, por exemplo, que menores valores de  $\Delta A_i$  foram obtidos para as estruturas em paralelo, ou seja, a consideração de modelos com reservatórios conectados em paralelo promoveu uma melhoria significativa na simulação do processo chuva-vazão.

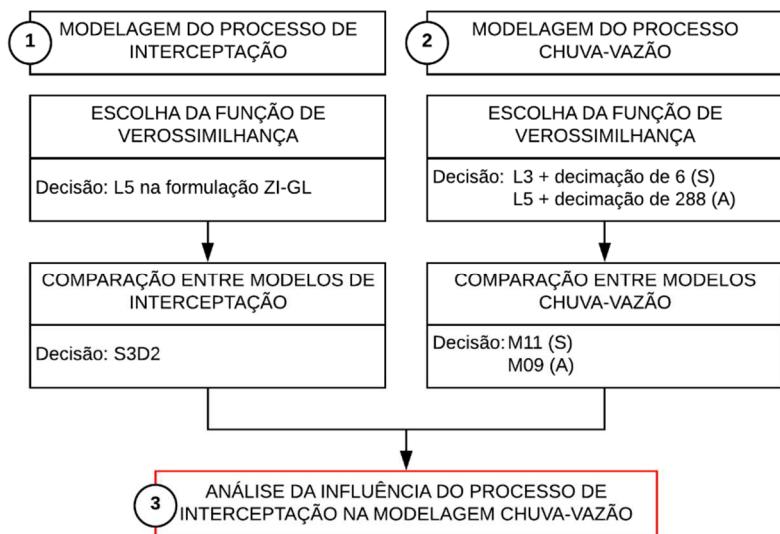
Para a bacia do rio Saci, o modelo M11 foi selecionado ser utilizado na última parte deste trabalho, e para a bacia do rio Araponga, o modelo M09 foi selecionado (Figura 59).



**Figura 59.** Fluxograma geral do trabalho, com destaque para as etapas da segunda parte – modelagem do processo chuva-vazão – e o resultado correspondente à escolha do modelo chuva-vazão para cada bacia estudada. S: bacia do rio Saci. A: bacia do rio Araponga.

### 4.3.3. Influência do processo de interceptação na modelagem do processo chuva-vazão

A análise da influência do processo de interceptação na modelagem do processo chuva-vazão foi conduzida a partir dos resultados obtidos na parte 1 – modelagem do processo de interceptação – e na parte 2 – modelagem do processo chuva-vazão (Figura 60).



**Figura 60.** Fluxograma geral do trabalho, com destaque para a terceira parte – análise da influência do processo de interceptação na modelagem chuva-vazão.

#### Bacia do rio Saci

Para a bacia do rio Saci, a qualidade da faixa de incerteza estimada (avaliada em termos das métricas de precisão, viés e confiabilidade) foi muito similar entre as formulações M11 sem reservatório de interceptação e com chuva total como entrada (M11-*P*), M11 sem reservatório de interceptação e com chuva líquida como entrada (M11-*Pn*), M11 com parâmetros de interceptação fixos e com chuva total como entrada (M11-IR<sub>fix</sub>) e M11 com parâmetros de interceptação calibrados e com chuva total como entrada (M11-IR<sub>cal</sub>) (Tabela 22 e Figura 63 para M11-*P*, Figura 64 para M11-*Pn*, Figura 65 para M11-IR<sub>fix</sub> e Figura 66 para M11-IR<sub>cal</sub>).

**Tabela 22.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e M11 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M11 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M11 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M11 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).

<b>Métrica</b>	<b>Série toda</b>				<b>Série A</b>			
	$P$	$Pn$	$IR_{fix}$	$IR_{cal}$	$P$	$Pn$	$IR_{fix}$	$IR_{cal}$
Precisão	0,18	0,18	0,19	0,20	0,44	0,40	0,38	0,37
Viés	0,02	0,03	0,02	0,01	0,10	0,08	0,05	0,01
Confiabilidade	0,09	0,11	0,10	0,06	0,20	0,22	0,19	0,11
$Q < 0,2 \text{ mm h}^{-1}$	0,08	0,08	0,11	0,17	0,20	0,22	0,19	0,11
$Q > 0,2 \text{ mm h}^{-1}$	0,31	0,33	0,36	0,26	0,78	0,69	0,66	0,78

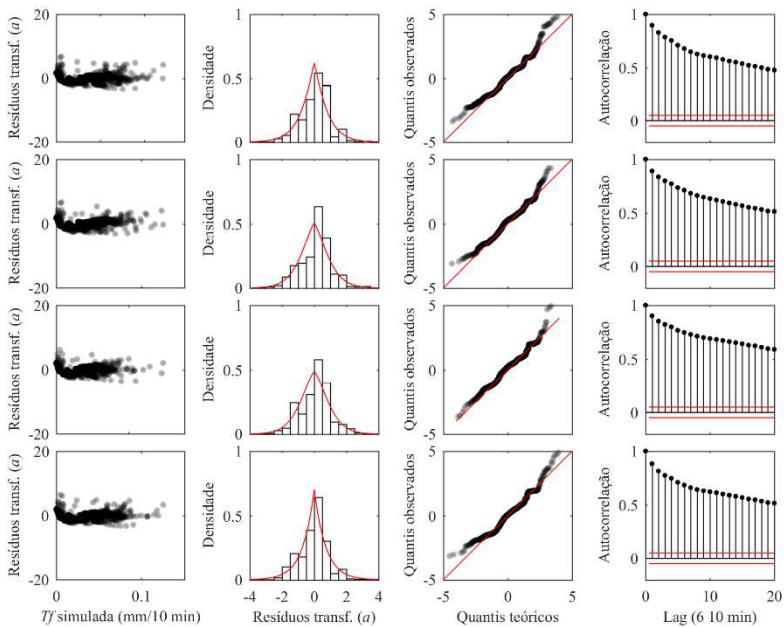
<b>Métrica</b>	<b>Série B</b>				<b>Série C</b>			
	$P$	$Pn$	$IR_{fix}$	$IR_{cal}$	$P$	$Pn$	$IR_{fix}$	$IR_{cal}$
Precisão	0,23	0,22	0,22	0,24	0,18	0,15	0,16	0,18
Viés	0,13	0,18	0,17	0,18	0,04	0,07	0,06	0,03
Confiabilidade	0,49	0,56	0,57	0,57	0,25	0,32	0,32	0,22
$Q < 0,2 \text{ mm h}^{-1}$	0,59	0,65	0,67	0,66	0,26	0,15	0,26	0,27
$Q > 0,2 \text{ mm h}^{-1}$	0,24	0,18	0,15	0,18	0,30	0,36	0,38	0,28

Em todos os casos, as premissas sobre os resíduos obtidos na calibração foram razoavelmente satisfeitas, exceto pela premissa de independência dos resíduos (Figura 61).

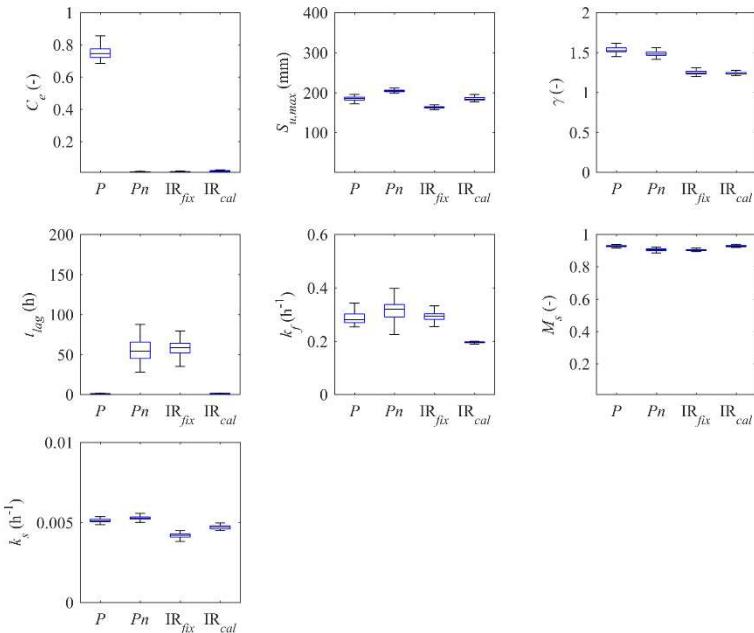
Com relação à distribuição *a posteriori* dos parâmetros, a consideração explícita do processo de interceptação na modelagem do processo chuva-vazão (M11- $Pn$ , M11- $IR_{fix}$ , M11- $IR_{cal}$ ) resultou em menores valores para o parâmetro de eficiência de evaporação  $C_e$  (Figura 62). Este resultado era esperado uma vez que ao se utilizar como entrada dados de chuva líquida, a parte da evaporação correspondente às perdas por interceptação é considerada separadamente, antes da simulação dos demais processos hidrológicos com o modelo chuva-vazão. Desta forma, o modelo não precisa compensar a ausência de um reservatório representando a interceptação com um aumento da evaporação do reservatório da zona não saturada.

A consideração explícita do processo de interceptação sempre resultou em maiores valores máximos para a função de verossimilhança (Tabela 23). A utilização do modelo M11 com parâmetros de interceptação calibrados resultou em menores (melhores) valores de critério de informação (Tabela 23). Esta formulação é a mais complexa, ou seja, a que apresenta um maior valor para o termo que penaliza a

complexidade. Porém, o aumento no valor da função de verossimilhança compensou este aumento de complexidade. O melhor desempenho desta formulação com relação a considerar diretamente o valor da chuva líquida como entrada no modelo chuva-vazão (dado real) indica que a adição de novos parâmetros permite que o modelo compense alguma deficiência em sua capacidade de representação dos demais processos a partir da variação dos valores dos parâmetros de interceptação. Este resultado indica que a adição de complexidade aos modelos, de forma a representarem mais fielmente o nosso conhecimento sobre os processos envolvidos, precisa ser acompanhada da adição de mais informação ao processo de calibração.



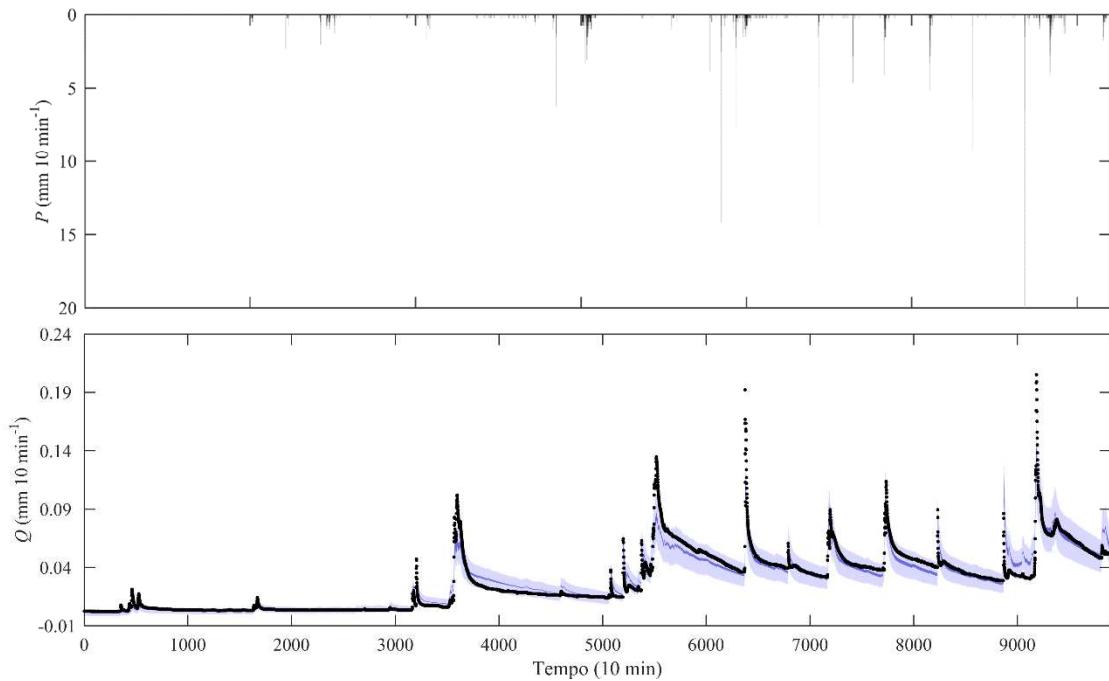
**Figura 61.** Diagnóstico dos resíduos para a bacia do rio Saci. Calibração realizada utilizando o modelo para resíduos L5, com o parâmetro  $\phi$  fixo em 0,40, dados de vazão da série completa com decimação de 6 e M11 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M11 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M11 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M11 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).



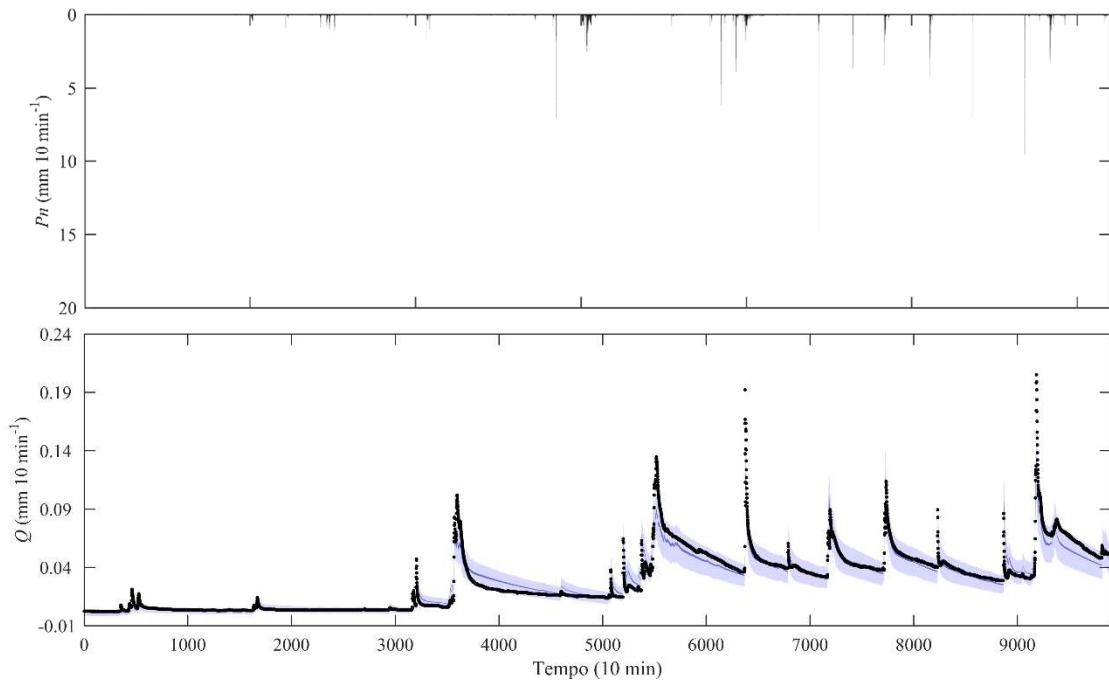
**Figura 62.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,max}$ ,  $\gamma$ ,  $t_{lag}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Saci, utilizando o modelo para resíduos L3. Calibração realizada com dados de vazão da série completa com decimação de 6 (um dado por hora) e M11 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M11 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M11 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M11 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).

**Tabela 23.** Critérios de informação ( $I_k$ ) para as diferentes considerações do processo de interceptação na modelagem chuva-vazão. Valores calculados para a bacia do rio Saci. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizado e  $w_i$  é o peso de cada modelo.

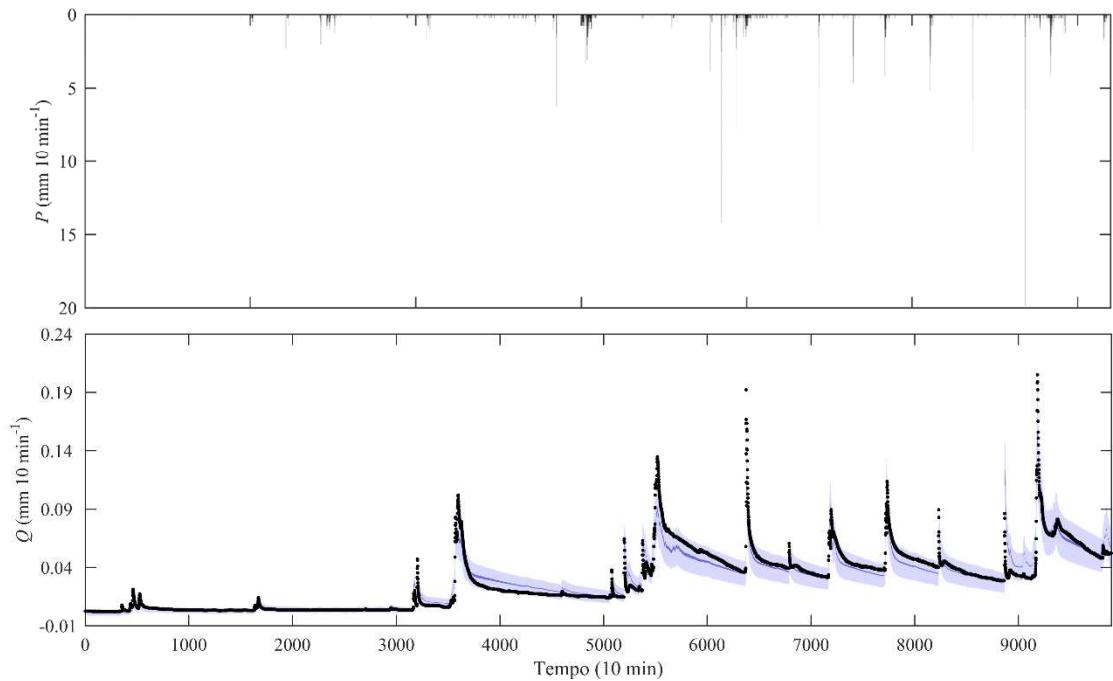
Modelo	$\ln L$	$k$	$n$	AIC			BIC		
				$I_k$	$\Delta A_i$	$w_i$	$I_k$	$\Delta B_i$	$w_i$
M11- $P$	3836	10	1650	-7652	78	0,00	-7598	56	0,00
M11- $Pn$	3864	10	1650	-7707	22	0,00	-7653	1	0,42
M11- $IR_{fix}$	3846	10	2183	-7673	57	0,00	-7616	38	0,00
M11- $IR_{cal}$	3879	14	1650	-7730	0	1,00	-7654	0	0,58



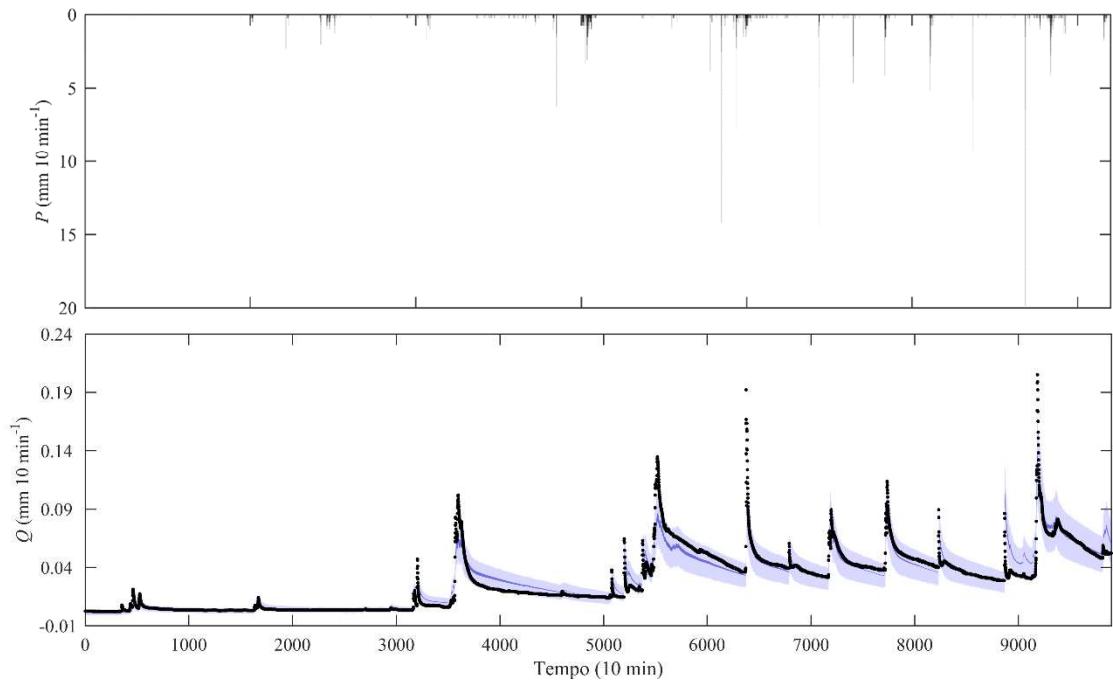
**Figura 63.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, M11 (sem reservatório de interceptação) e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva total como entrada.



**Figura 64.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, M11 (sem reservatório de interceptação) e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva líquida como entrada.



**Figura 65.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, M11 (**parâmetros de interceptação fixos**) e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.



**Figura 66.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, M11 (**parâmetros de interceptação calibrados**) e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.

### Bacia do rio Araponga

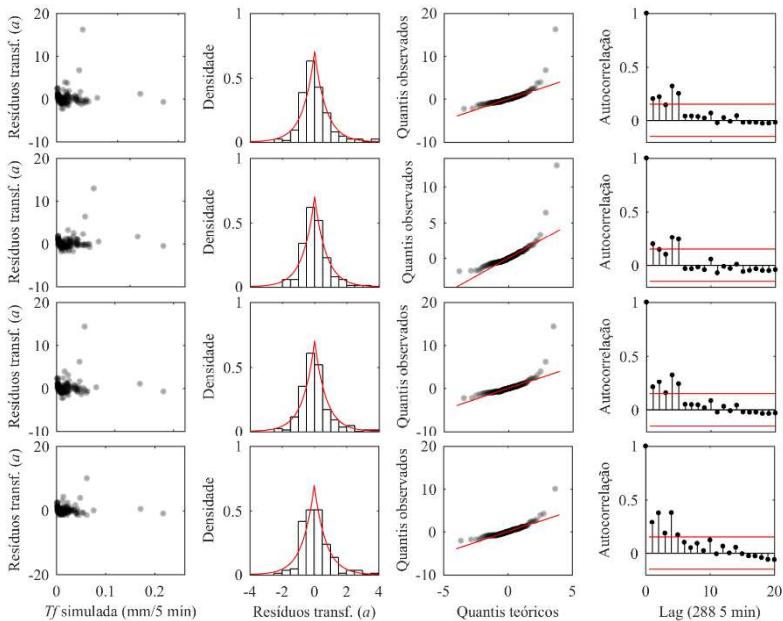
Assim como para a bacia do rio Saci, para a bacia do rio Araponga, a qualidade da faixa de incerteza estimada (avaliada em termos das métricas de precisão, viés e confiabilidade) foi muito similar entre as formulações M09 sem reservatório de interceptação e com chuva total como entrada ( $M09-P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $M09-P_n$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $M09-IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $M09-IR_{cal}$ ) (Tabela 26 e Figura 69 para  $M09-P$ , Figura 70 para  $M09-P_n$ , Figura 71 para  $M09-IR_{fix}$  e Figura 72 para  $M09-IR_{cal}$ ).

**Tabela 24.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia) e M09 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $P_n$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).

Métrica	Série toda			
	$P$	$P_n$	$IR_{fix}$	$IR_{cal}$
Precisão	0,36	0,33	0,35	0,35
Viés	0,05	0,15	0,09	0,06
Confiabilidade	0,09	0,03	0,10	0,06
$Q < 0,2 \text{ mm h}^{-1}$	0,15	0,09	0,17	0,12
$Q > 0,2 \text{ mm h}^{-1}$	0,17	0,33	0,16	0,17

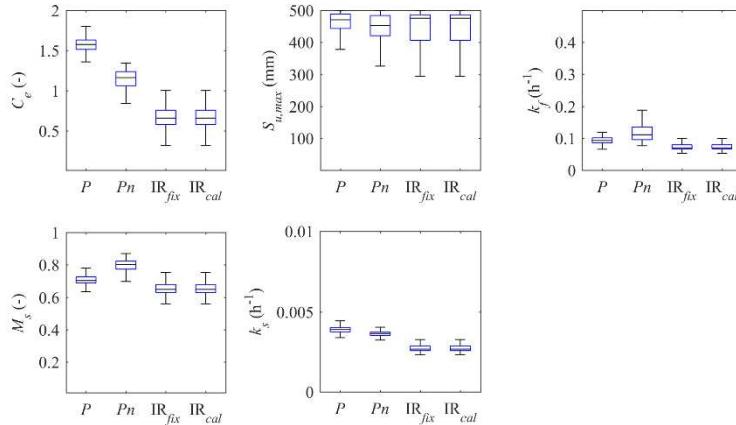
Em todos os casos, as premissas sobre os resíduos foram razoavelmente satisfeitas, exceto pela premissa de independência dos resíduos (Figura 67).

Assim como no caso da bacia do rio Saci, quando o processo de interceptação foi considerado explicitamente no modelo chuva-vazão menores valores para o parâmetro de eficiência de evaporação  $C_e$  foram obtidos (Figura 68). Não foi verificada uma variação significativa na distribuição *a posteriori* dos demais parâmetros (Figura 68).



**Figura 67.** Diagnóstico dos resíduos para a bacia do rio Araponga. Calibração realizada utilizando o modelo para resíduos L5, com o parâmetro  $\phi$  fixo em 0,40, dados de vazão da série completa com decimação de 288 e M09 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).

A consideração explícita do processo de interceptação sempre resultou em maiores valores máximos para a função de verossimilhança (Tabela 25). Porém, apenas considerando diretamente o valor da chuva líquida como entrada no modelo chuva-vazão resultou em melhores valores de critério de informação (Tabela 25). A adição de complexidade a partir da utilização do modelo M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) – através de um maior número de dados necessários para calibração do modelo de interceptação – e do modelo M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ) – com a adição de novos parâmetros na inferência – não foi justificada pela melhoria de desempenho promovida.



**Figura 68.** Distribuição *a posteriori* para os parâmetros do modelo hidrológico ( $C_e$ ,  $S_{u,\max}$ ,  $k_f$ ,  $M_s$ ,  $k_s$ ) para a bacia do rio Araponga, utilizando o modelo para resíduos L3. Calibração realizada com dados de vazão da série completa com decimação de 288 (um dado a cada dia) e M09 sem reservatório de interceptação e com chuva total como entrada ( $P$ ), M09 sem reservatório de interceptação e com chuva líquida como entrada ( $Pn$ ), M09 com parâmetros de interceptação fixos e com chuva total como entrada ( $IR_{fix}$ ) e M09 com parâmetros de interceptação calibrados e com chuva total como entrada ( $IR_{cal}$ ).

**Tabela 25.** Critérios de informação ( $I_k$ ) para as diferentes considerações do processo de interceptação na modelagem chuva-vazão. Valores calculados para a bacia do rio Araponga. AIC é o critério de informação de Akaike e BIC é o critério de informação de Bayes.  $L$  indica o valor (máximo) da função de verossimilhança obtido na calibração,  $k$  é o número de parâmetros,  $n$  é o número de dados utilizados e  $w_i$  é o peso de cada modelo.

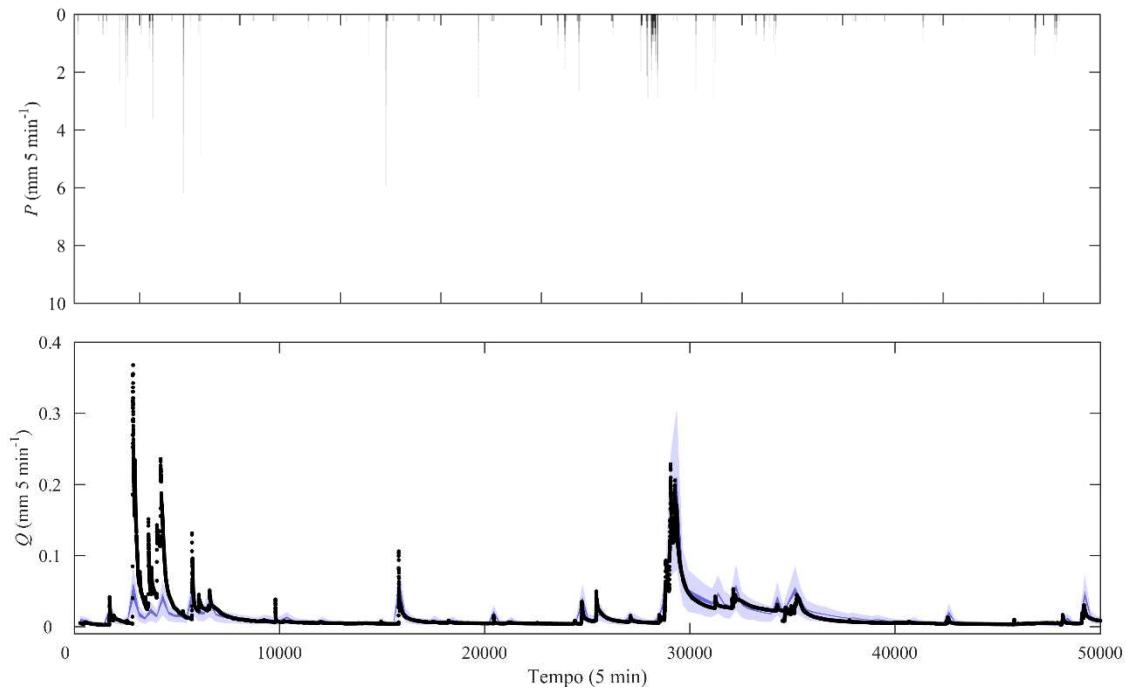
Modelo	$\ln L$	$k$	$n$	AIC			BIC		
				$I_k$	$\Delta A_i$	$w_i$	$I_k$	$\Delta B_i$	$w_i$
M09- $P$	342	8	178	-668	38	0,00	-642	38	0,00
M09- $Pn$	361	8	178	-705	0	1,00	-680	0	1,00
M09- $IR_{fix}$	342	8	1011	-667	38	0,00	-628	51	0,00
M09- $IR_{cal}$	353	12	178	-681	24	0,00	-643	37	0,00

Quando a calibração foi realizada separadamente para a série A (B) e validada na série B (A), a utilização de dados de chuva líquida como entrada no modelo chuva-vazão melhorou os valores de todas as métricas de desempenho considerando o período de validação (Tabela 26), confirmando os resultados obtidos anteriormente a partir dos critérios de informação. Os resultados desta análise são apresentadas na Figura 73

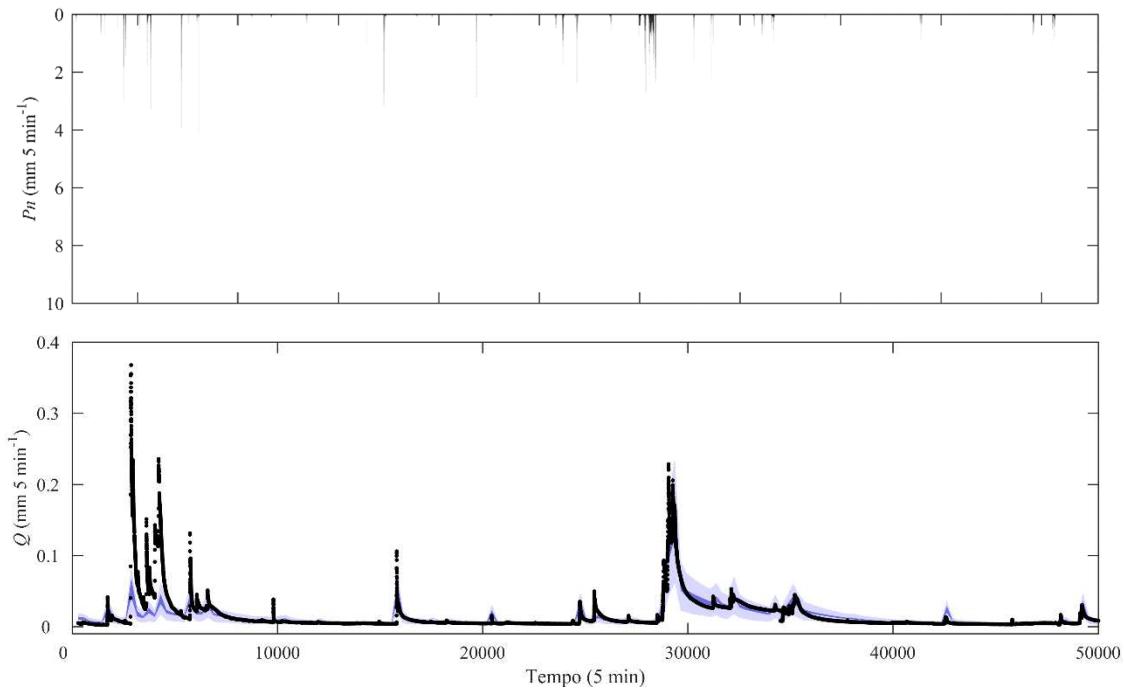
(M09-*P*, série A para calibração e série B para validação), Figura 74 (M09-*Pn*, série A para calibração e série B para validação), Figura 75 (M09-*P*, série B para calibração e série A para validação) e Figura 76 (M09-*Pn*, série B para calibração e série A para validação).

**Tabela 26.** Métricas para a simulação de vazão ( $Q$ ) para a bacia do rio Araponga. Calibração realizada com dados da série A e da série B com decimação igual a 288 (um dado a cada dia) e chuva total ( $P$ ) e chuva líquida ( $Pn$ ) como entrada. Células em cinza indicam melhor desempenho.

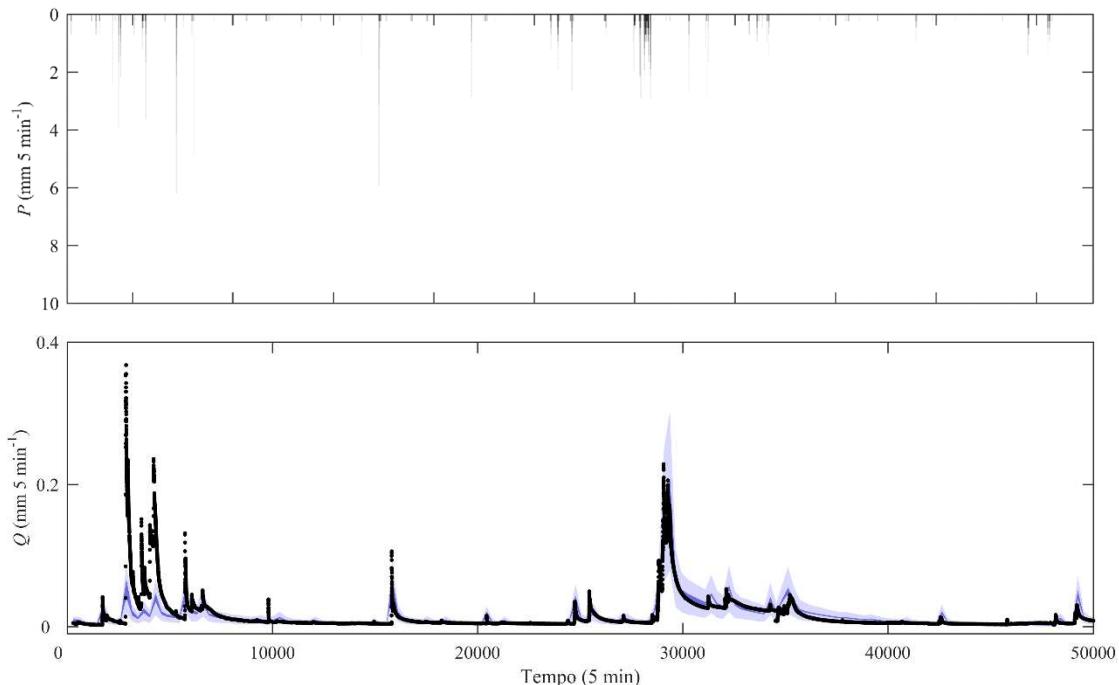
Métrica	Calibração com série A				Calibração com série B			
	Calibração		Validação		Calibração		Validação	
	$P$	$Pn$	$P$	$Pn$	$P$	$Pn$	$P$	$Pn$
Precisão	0,34	0,34	0,53	0,50	0,28	0,26	0,17	0,18
Viés	0,11	0,20	0,40	0,19	0,06	0,03	0,50	0,39
Confiabilidade	0,06	0,05	0,29	0,19	0,19	0,08	0,43	0,19
$Q < 0,2 \text{ mm h}^{-1}$	0,17	0,13	0,40	0,29	0,23	0,17	0,32	0,05
$Q > 0,2 \text{ mm h}^{-1}$	0,48	0,63	0,23	0,21	0,13	0,16	0,94	0,86



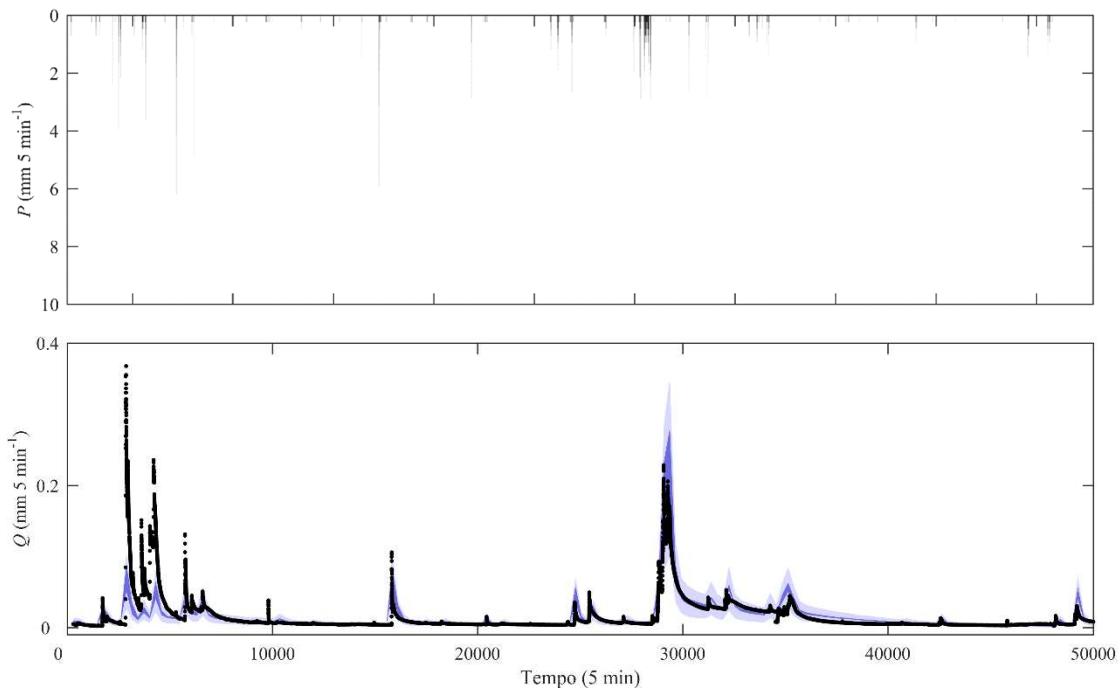
**Figura 69.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 sem reservatório de interceptação e chuva total como entrada**.



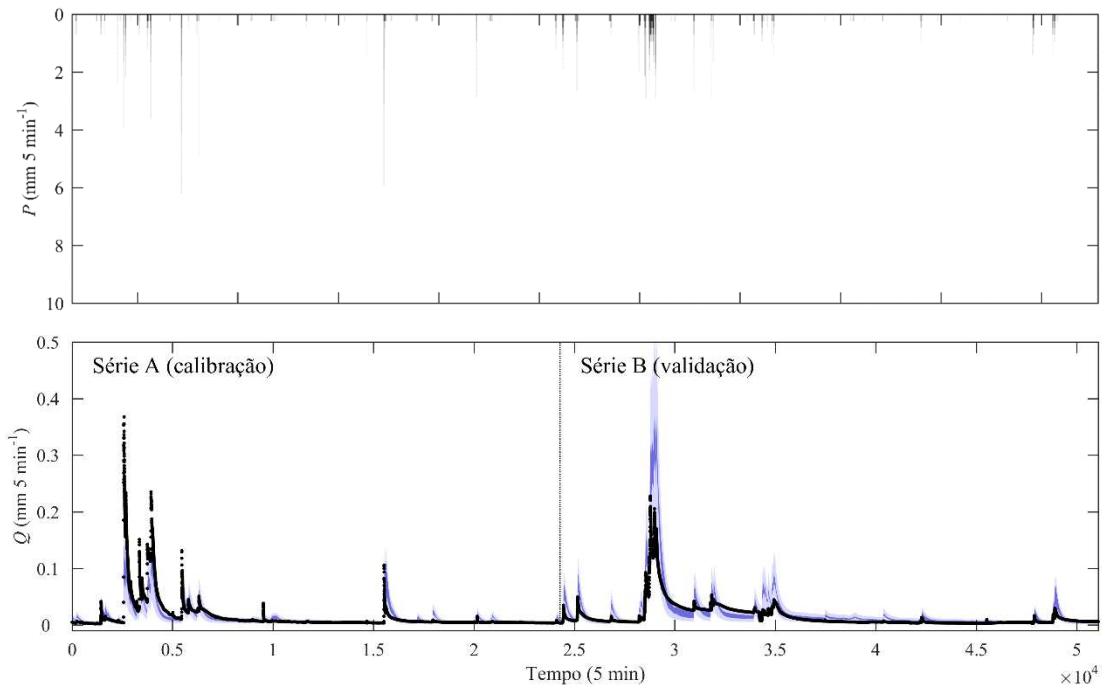
**Figura 70.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 sem reservatório de interceptação e chuva líquida como entrada**.



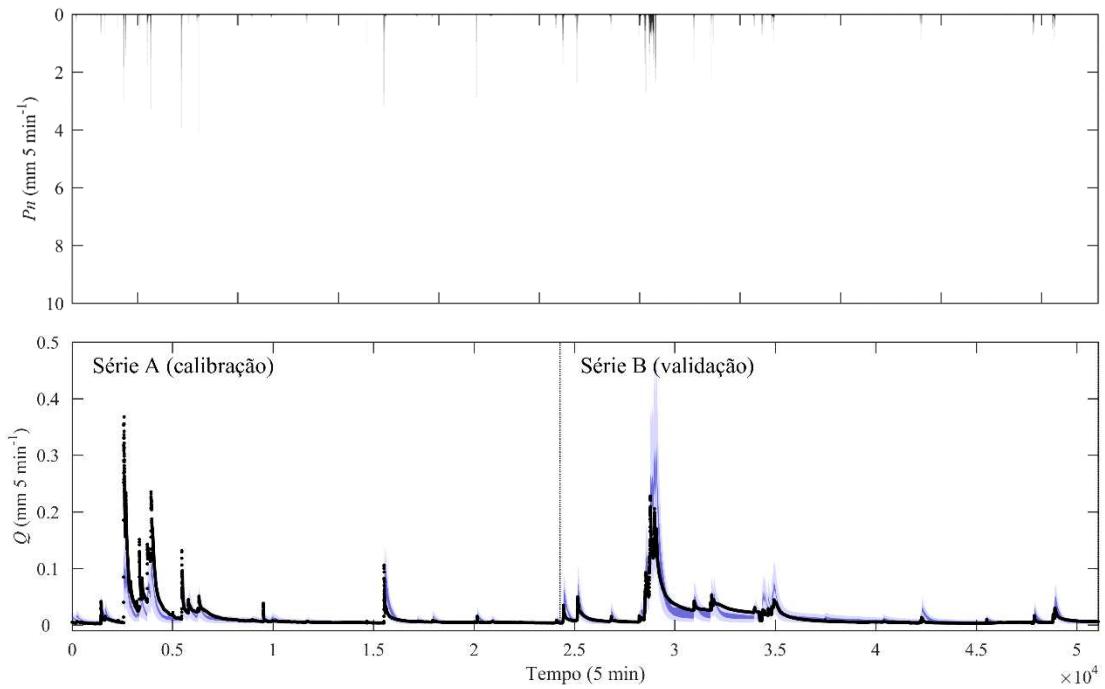
**Figura 71.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 com reservatório de interceptação (parâmetros fixos) e chuva total como entrada**.



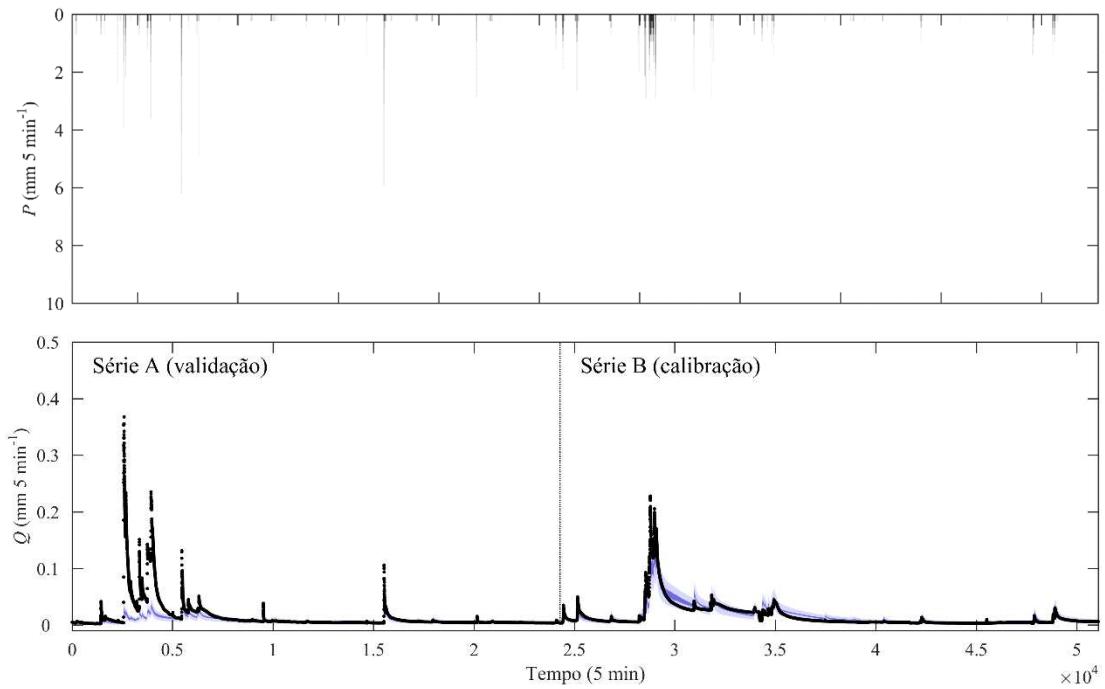
**Figura 72.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia), **M09 com reservatório de interceptação (parâmetros fixos) e chuva total como entrada..**



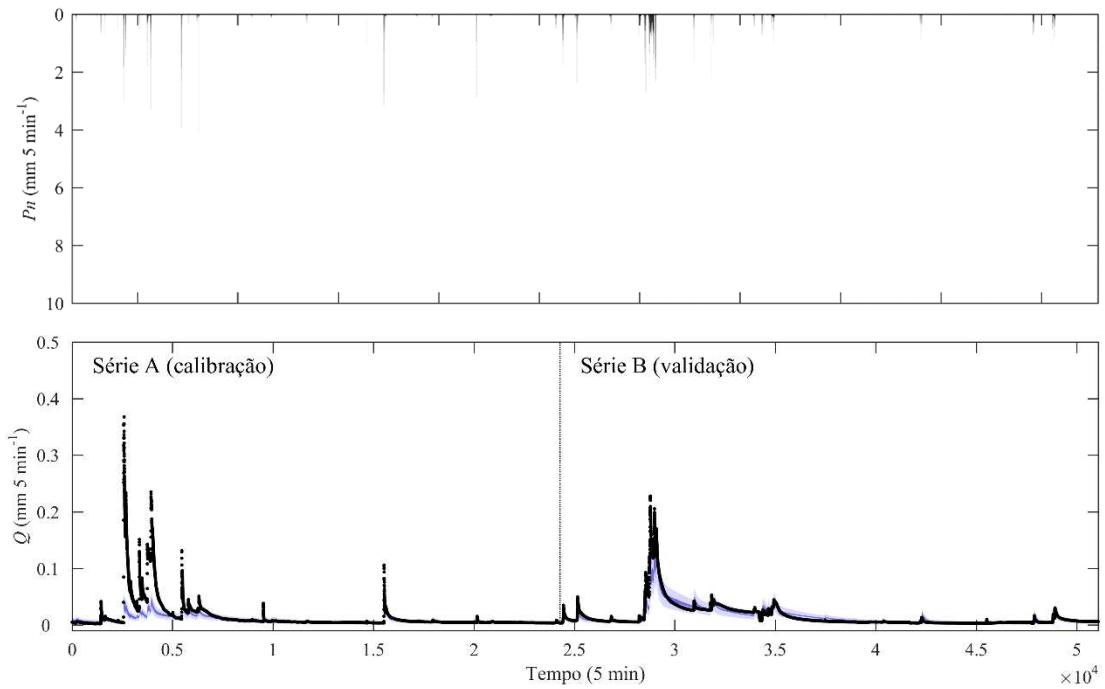
**Figura 73.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série A com decimação igual a 288 (um dado a cada dia) e chuva total como entrada.



**Figura 74.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série A com decimação igual a 288 (um dado a cada dia) e chuva líquida como entrada.



**Figura 75.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série B com decimação igual a 288 (um dado a cada dia) e chuva total como entrada.



**Figura 76.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série B com decimação igual a 288 (um dado a cada dia) e chuva líquida como entrada.



## 5. CONCLUSÕES

Neste trabalho, a inferência Bayesiana foi utilizada para a calibração de modelos de interceptação e chuva-vazão aplicados a duas bacias florestais: a bacia do rio Saci, coberta majoritariamente por reflorestamento de pinus; e a bacia do rio Araponga, com vegetação nativa. A utilização da inferência Bayesiana na calibração dos modelos permitiu a obtenção dos valores dos parâmetros e da faixa de incerteza associada aos resultados das simulações. Desta maneira, as diferentes representações (modelos) dos processos de interceptação e chuva-vazão puderam ser comparadas em termos da faixa de incerteza como um todo, e não apenas em relação a uma única simulação “ótima”. O método empregado para análise de incerteza neste trabalho permite a separação da incerteza associada aos valores dos parâmetros e a incerteza total. Tanto na modelagem do processo de interceptação quanto na modelagem do processo chuva-vazão, a incerteza associada aos valores dos parâmetros foi muito pequena com relação à incerteza total. Isso indica uma dominância das demais fontes de incerteza (e.g., incerteza devido à estrutura do modelo, incerteza devido às forçantes e aos dados utilizados na calibração) na modelagem dos processos de interceptação e chuva-vazão das duas bacias estudadas.

Este trabalho foi dividido em três partes principais: (1) a modelagem do processo de interceptação; (2) a modelagem do processo chuva-vazão; e (3) a análise da influência do processo de interceptação na modelagem chuva-vazão. Na modelagem dos processos de interceptação e chuva-vazão, o seguinte procedimento foi adotado: (1) escolha da função de verossimilhança; e (2) comparação entre diferentes modelos utilizados para representar o processo em questão. Tanto na modelagem do processo de interceptação quanto na modelagem do processo chuva-vazão, complexidade foi acrescentada de maneira incremental aos modelos, permitindo identificar a influência de cada componente em seu desempenho. Os resultados das simulações foram avaliados em termos da qualidade da faixa de incerteza estimada. Além disso, os critérios de informação de Akaike (AIC) e de Bayes (BIC) foram utilizados para verificar se a adição de complexidade aos modelos de interceptação e chuva-vazão era justificada pela melhoria de desempenho promovida.

A escolha da função de verossimilhança impactou diretamente a qualidade da faixa de incerteza, os valores dos parâmetros obtidos na inferência e o modelo selecionado a partir dos critérios de informação de Akaike (AIC) e de Bayes (BIC). Estes resultados indicam a importância da escolha de uma função de verossimilhança que represente

adequadamente os resíduos dos modelos. Tanto na modelagem do processo de interceptação quanto na modelagem do processo chuva-vazão foi necessária a consideração de um modelo heteroscedástico para os resíduos. Além disso, em todos os casos foi verificada correlação temporal dos resíduos, sendo que os métodos utilizados neste trabalho para tentar mitigar essa característica nem sempre foram suficientes. Desta maneira, outras formas de se lidar com a autocorrelação dos resíduos deve ser investigada em trabalhos futuros.

Na modelagem do processo de interceptação, a presença de muitos zeros na série observada fez com que fosse necessária uma adaptação da função de verossimilhança utilizada. A consideração de inflação da distribuição dos resíduos com zeros, com a omissão dos resíduos de observações iguais a zero do cálculo da função de verossimilhança ou com a utilização de uma versão modificada que considera explicitamente a presença de zeros, melhorou a qualidade da faixa de incerteza estimada.

Em termos da qualidade da faixa de incerteza, as estruturas S3 e S4 apresentaram os melhores resultados, avaliados no período de validação. Estas duas estruturas consideram uma divisão do fluxo de água da chuva com base no fator de cobertura da vegetação, possibilitando a simulação da chegada de água no chão florestal desde o início do evento de precipitação. Quanto à formulação da equação de drenagem da copa, os valores de critério de informação tenderam a favorecer a equação de drenagem mais complexa (D2).

Na modelagem do processo chuva-vazão, a estrutura do modelo foi mais importante na representação do processo do que a adição de complexidade (em termos do número de parâmetros). Para as duas bacias experimentais, as estruturas em paralelo promoveram melhores simulações. Este resultado indica que a vazão nas duas bacias é governada por duas respostas distintas: uma rápida, que pode estar relacionada ao movimento da água por meio de caminhos preferenciais; e uma lenta, que pode estar relacionada ao movimento mais lento da água no solo. Das estruturas em paralelo, a única formulação sem a consideração de um reservatório para a zona não saturada foi a que apresentou pior desempenho, indicando que o armazenamento da água no solo é um componente importante nas duas bacias.

A consideração explícita do processo de interceptação na modelagem chuva-vazão resultou em melhores simulações (quando avaliada em termos do valor máximo da função de verossimilhança). Porém, a faixa de incerteza obtida no modelo chuva-vazão com chuva total como entrada, com chuva líquida como entrada e acoplado com um modelo de interceptação com parâmetros fixos ou calibrados foi muito

similar. Como era esperado, a consideração explícita do processo de interceptação no modelo chuva-vazão resultou em menores valores inferidos para o parâmetro relacionado à eficiência de evaporação, já que neste caso a parte da evaporação correspondente às perdas por interceptação é considerada separadamente, anterior à simulação dos processos subsequentes pelo modelo chuva-vazão.

Os critérios de informação (AIC e BIC), utilizados para auxiliar a seleção dos modelos neste trabalho, consideram em seu cálculo apenas o valor máximo da função de verossimilhança e um termo que penaliza pela complexidade. De maneira geral, a variação no valor máximo da função de verossimilhança entre os modelos foi superior à variação no valor do termo que penaliza a complexidade do modelo. Por este motivo, muitas vezes o modelo que resultou em um maior valor máximo para a função de verossimilhança também resultou em melhores valores de critérios de informação. Porém, os modelos que resultaram em um maior valor para a função de verossimilhança nem sempre foram aqueles que promoveram uma faixa de incerteza com melhor desempenho (medido em termos das métricas de precisão, viés e confiabilidade). Este fato sugere que outros métodos para seleção de modelos, que considerem o desempenho da simulação em termos da faixa de incerteza como um todo, sejam considerados em estudos futuros. Um exemplo é a utilização da evidência, o denominador do teorema de Bayes. Um método para estimativa da evidência é apresentado em Volpi et al. (2017).

O método utilizado neste trabalho para estimativa dos parâmetros e análise de incerteza agrupa todos os erros do modelo (de cada passo de tempo) em uma única métrica (a função de verossimilhança). Este método permite que a incerteza seja quantificada; porém, pouca informação é fornecida a respeito de como esta incerteza pode ser reduzida. A utilização de assinaturas da bacia (e.g., coeficiente de escoamento superficial, curva de permanência) na calibração dos modelos, como apresentado recentemente em alguns estudos (FENICIA et al., 2018; KAVETSKI et al., 2018; SADEGH; VRUGT, 2014; VRUGT; SADEGH, 2013b) pode ser uma alternativa ao método utilizado neste trabalho. A utilização de assinaturas da bacia permite que sejam identificadas partes/formulações específicas do modelo que não representam adequadamente as observações.



## REFERÊNCIAS BIBLIOGRÁFICAS

- ABOAL, J. R.; JIMÉNEZ, M. S.; MORALES, D.; HERNÁNDEZ, J. M. Rainfall interception in laurel forest in the Canary Islands. **Agricultural and Forest Meteorology**, v. 97, n. 2, p. 73–86, 1999.
- ASDAK, C.; JARVIS, P. G.; GARDINGEN, P. V. Modelling rainfall interception in unlogged and logged forest areas of Central Kalimantan, Indonesia. **Hydrology and Earth System Sciences**, v. 2, p. 211–220, 1998.
- BEVEN, K. A manifesto for the equifinality thesis. **Journal of Hydrology**, v. 320, n. 1–2, p. 18–36, 2006.
- BEVEN, K.; BINLEY, A. The Future of Distributed Models: Model Calibration and Uncertainty Prediction. **Hydrol. Process.**, v. 6, n. May 1991, p. 279–298, 1992.
- BEVEN, K.; BINLEY, A. GLUE: 20 years on. **Hydrological Processes**, v. 28, n. 24, p. 5897–5918, 2014.
- BEVEN, K.; SMITH, P.; WESTERBERG, I.; FREER, J. Comment on “Pursuing the method of multiple working hypotheses for hydrological modeling” by Clark et al. **Water Resources Research**, v. 48, n. W11801, 2012.
- BIGELOW, S. Evapotranspiration modelled from stands of three broad-leaved tropical trees in Costa Rica. **Hydrological Processes**, v. 15, n. 14, p. 2779–2796, 2001.
- CALDER, I. R. A model of transpiration and interception loss from a spruce forest in Plynlimon, central Wales. **Journal of Hydrology**, v. 33, p. 247–265, 1977.
- CALDER, I. R. A stochastic model of rainfall interception. **Journal of Hydrology**, v. 89, p. 65–71, 1986.
- CALDER, I. R. Dependence of rainfall interception on drop size: 1. Development of the two-layer stochastic model. **Journal of Hydrology**,

v. 185, p. 363–378, 1996.

CARLYLE-MOSES, D. E.; PRICE, A. G. Modelling canopy interception loss from a Madrean pine-oak stand, Northeastern Mexico. **Hydrological Processes**, v. 21, p. 2572–2580, 2007.

CHAFFE, P.L.B. **Monitoramento e modelagem do processo chuva-vazão de uma pequena bacia florestal com ênfase em interceptação.** 2009. 100 f. Dissertação (Mestrado em Engenharia Ambiental) – Universidade Federal de Santa Catarina, Florianópolis, 2009.

CHAFFE, P. L. B.; KOBIYAMA, M.; YAMASHIKI, Y.; TAKARA, K. Is Interception Information Important for Rainfall-Runoff Modeling? **Annual Journal of Hydraulic Engineering, JSCE**, v. 54, p. 73–78, 2010.

CHENG, Q. B.; CHEN, X.; XU, C. Y.; REINHARDT-IMJELA, C.; SCHULTE, A. Improvement and comparison of likelihood functions for model calibration and parameter uncertainty analysis within a Markov chain Monte Carlo scheme. **Journal of Hydrology**, v. 519, p. 2202–2214, 2014.

CLARK, M. P.; KAVETSKI, D.; FENICIA, F. Pursuing the method of multiple working hypotheses for hydrological modeling. **Water Resources Research**, v. 47, n. 9, p. 1–16, 2011.

CLARK, M. P.; KAVETSKI, D.; FENICIA, F. Reply to comment by K. Beven et al. on “pursuing the method of multiple working hypotheses for hydrological modeling”. **Water Resources Research**, v. 48, n. 11, p. 1–7, 2012.

CLARK, M. P.; SLATER, A. G.; RUPP, D. E.; WOODS, R. A.; VRUGT, J. A.; GUPTA, H. V.; WAGENER, T.; HAY, L. E. Framework for Understanding Structural Errors (FUSE): A modular framework to diagnose differences between hydrological models. **Water Resources Research**, v. 44, n. 12, p. n/a-n/a, 2008.

DAVID, J. S.; VALENTE, F.; GASH, J. H. C. 43 : Evaporation of Intercepted Rainfall. **Encyclopedia of Hydrological Sciences**, p. 1–8,

2005.

DAVID, P. C. **Influência da estrutura de modelos hidrológicos conceituais na simulação do processo chuva-vazão em duas bacias florestais**. 2017. 135p. Trabalho de Conclusão de Curso (Graduação em Engenharia Sanitária e Ambiental) - Universidade Federal de Santa Catarina, Florianópolis, 2017.

DE BOER-EUSER, T.; BOUAZIZ, L.; NIEL, J. DE; BRAUER, C.; DEWALS, B.; DROGUE, G.; FENICIA, F.; GRELIER, B.; NOSSENT, J.; PEREIRA, F.; SAVENIJE, H.; THIREL, G.; WILLEMS, P. Looking beyond general metrics for model evaluation: lessons from an international model intercomparison study. **Hydrology and Earth System Sciences**, v. 21, p. 423–440, 2017.

DOORENBOS, J.; PRUITT, W.O. **Crop water requirement**. Roma: FAO, 1977. 144p.

DUNKERLEY, D. Identifying individual rain events from pluviograph records: a review with analysis of data from an Australian dryland site. **Hydrological Processes**, v. 22, p. 5024–5036, 2008.

EUSER, T.; WINSEMIUS, H. C.; HRACHOWITZ, M.; FENICIA, F.; UHLENBROOK, S.; SAVENIJE, H. H. G. A framework to assess the realism of model structures using hydrological signatures. **Hydrology and Earth System Sciences**, v. 17, n. 5, p. 1893–1912, 2013.

EVIN, G.; KAVETSKI, D.; THYER, M.; KUCZERA, G. Pitfalls and improvements in the joint inference of heteroscedasticity and autocorrelation in hydrological model calibration. **Water Resources Research**, v. 49, n. 7, p. 4518–4524, 2013.

EVIN, G.; THYER, M.; KAVETSKI, D.; MCINERNEY, D.; KUCZERA, G. Comparison of joint versus postprocessor approaches for hydrological uncertainty estimation accounting for error autocorrelation and heteroscedasticity. **Water Resources Research**, v. 50, p. 2350–2375, 2014.

FENICIA, F.; KAVETSKI, D.; REICHERT, P.; ALBERT, C. Signature-Domain Calibration of Hydrological Models Using Approximate

Bayesian Computation: Empirical Analysis of Fundamental Properties. **Water Resources Research**, n. 1, p. 1–44, 2018.

FENICIA, F.; KAVETSKI, D.; SAVENIJE, H. H. G. Elements of a flexible approach for conceptual hydrological modeling: 1. Motivation and theoretical development. **Water Resources Research**, v. 47, n. 11, p. 1–13, 2011.

FENICIA, F.; KAVETSKI, D.; SAVENIJE, H. H. G.; CLARK, M. P.; SCHOUPS, G.; PFISTER, L.; FREER, J. Catchment properties, function, and conceptual model representation: Is there a correspondence? **Hydrological Processes**, v. 28, n. 4, p. 2451–2467, 2014.

FENICIA, F.; SAVENIJE, H. H. G.; MATGEN, P.; PFISTER, L. Is the groundwater reservoir linear? Learning from data in hydrological modelling. **Hydrology and Earth System Sciences Discussions**, v. 10, n. 1, p. 139–150, 2006.

FENICIA, F.; SAVENIJE, H. H. G.; MATGEN, P.; PFISTER, L. Understanding catchment behavior through stepwise model concept improvement. **Water Resources Research**, v. 44, n. 1, p. 1–13, 2008.

GAO, H.; HRACHOWITZ, M.; FENICIA, F.; GHARARI, S.; SAVENIJE, H. H. G. Testing the realism of a topography-driven model (FLEX-Topo) in the nested catchments of the Upper Heihe, China. **Hydrology and Earth System Sciences**, v. 18, n. 5, p. 1895–1915, 2014.

GASH, J. H. C. An analytical model of rainfall interception by forests. **Quarterly Journal of the Royal Meteorological Society**, v. 105, n. 443, p. 43–55, 1979.

GASH, J. H. C.; LLOYD, C. R.; LACHAUD, G. Estimating sparse forest rainfall interception with an analytical model. **Journal of Hydrology**, v. 170, n. 95, p. 79–86, 1995.

GASH, J. H. C.; MORTON, A. J. An application of the Rutter model to the estimation of the interception loss from Thetford Forest. **Journal of Hydrology**, v. 38, p. 49–58, 1978.

GERRITS, A. M. J.; PFISTER, L.; SAVENIJE, H. H. G. Spatial and temporal variability of canopy and forest floor interception in a beech forest. **Hydrological Processes**, v. 3025, n. 24, p. 3011–3025, 2010.

GHARARI, S.; HRACHOWITZ, M.; FENICIA, F.; GAO, H.; SAVENIJE, H. H. G. Using expert knowledge to increase realism in environmental system models can dramatically reduce the need for calibration. **Hydrology and Earth System Sciences**, v. 18, n. 12, p. 4839–4859, 2014.

GIGLIO, J.N. **Interceptação da chuva em pequena bacia experimental coberta por Floresta Ombrófila Mista.** 2013. 194 f. Dissertação (Mestrado em Engenharia Ambiental) – Universidade Federal de Santa Catarina, Florianópolis, 2013.

GRAYSON, R. B.; MOORE, I. D.; MCMAHON, T. A. Physically based hydrologic modeling 2. Is the concept realistic? **Water Resources Research**, v. 26, n. 10, p. 2659–2666, 1992.

HOLWERDA, F.; BRUIJNZEEL, L. A.; SCATENA, F. N.; VUGTS, H. F.; MEESTERS, A. G. C. A. Wet canopy evaporation from a Puerto Rican lower montane rain forest: The importance of realistically estimated aerodynamic conductance. **Journal of Hydrology**, v. 414–415, p. 1–15, 2012.

HÖRMANN, G.; BRANDING, A.; CLEMEN, T.; HERBST, M.; HINRICHES, A.; THAMM, F. Calculation and simulation of wind controlled canopy interception of a beech forest in Northern Germany. **Agricultural and Forest Meteorology**, v. 79, n. 3, p. 131–148, 1996.

HORTON, R. E. Rainfall interception. **Monthly Weather Review**, v. 47, n. 9, p. 608–623, 1919.

HRACHOWITZ, M.; SAVENIJE, H.; BOGAARD, T. A.; TETZLAFF, D.; SOULSBY, C. What can flux tracking teach us about water age distribution patterns and their temporal dynamics? **Hydrology and Earth System Sciences**, v. 17, n. 2, p. 533–564, 2013.

IIDA, S.; LEVIA, D. F.; SHIMIZU, A.; SHIMIZU, T.; TAMAI, K.;

NOBUHIRO, T.; KABEYA, N.; NOGUCHI, S.; SAWANO, S.; ARAKI, M. Intrastorm scale rainfall interception dynamics in a mature coniferous forest stand. **Journal of Hydrology**, 2017.

KAVETSKI, D.; FENICIA, F. Elements of a flexible approach for conceptual hydrological modeling: 2. Application and experimental insights. **Water Resources Research**, v. 47, n. 11, p. 1–19, 2011.

KAVETSKI, D.; FENICIA, F.; CLARK, M. P. Impact of temporal data resolution on parameter inference and model identification in conceptual hydrological modeling: Insights from an experimental catchment. **Water Resources Research**, v. 47, p. W05501, 2011.

KAVETSKI, D.; FENICIA, F.; REICHERT, P.; ALBERT, C. Signature-Domain Calibration of Hydrological Models Using Approximate Bayesian Computation: Theory and Comparison to Existing Applications. **Water Resources Research**, n. 1, p. 1–34, 2018.

KAVETSKI, D.; KUCZERA, G.; FRANKS, S. W. Bayesian analysis of input uncertainty in hydrological modeling: 2. Application. **Water Resources Research**, v. 42, n. 3, p. 1–10, 2006a.

KAVETSKI, D.; KUCZERA, G.; FRANKS, S. W. Bayesian analysis of input uncertainty in hydrological modeling: 1. Theory. **Water Resources Research**, v. 42, p. W03407, 2006b.

KLAASEN, W.; BOSVELD, F.; DE WATER, E. Water storage and evaporation as constituents of rainfall interception. **Journal of Hydrology**, v. 212–213, p. 36–50, 1998.

KOSKELA, J. J.; CROKE, B. W. F.; KOIVUSALO, H.; JAKEMAN, A. J.; KOKKONEN, T. Bayesian inference of uncertainties in precipitation-streamflow modeling in a snow affected catchment. **Water Resources Research**, v. 48, p. W11513, 2012.

LEVIA, D. F.; GERMER, S. A review of stemflow generation dynamics and stemflow-environment interactions in forests and shrublands. **Reviews of Geophysics**, v. 53, p. 673–714, 2015.

LI, M.; YANG, D.; CHEN, J.; HUBBARD, S. S. Calibration of a distributed flood forecasting model with input uncertainty using a Bayesian framework. **Water Resources Research**, v. 48, p. W08510, 2012.

LINK, T. E.; UNSWORTH, M.; MARKS, D. The dynamics of rainfall interception by a seasonal temperate rainforest. **Agricultural and Forest Meteorology**, v. 124, n. 3–4, p. 171–191, 2004.

LIU, S. A new model for the prediction of rainfall interception in forest canopies. **Ecological Modelling**, v. 99, n. 2–3, p. 151–159, 1997.

LIU, S. Evaluation of the Liu model for predicting rainfall interception in forests world-wide. **Hydrological Processes**, v. 15, n. 12, p. 2341–2360, 2001.

LLORENS, P.; DOMINGO, F.; GARCIA-ESTRINGANA, P.; MUZYLO, A.; GALLART, F. Canopy wetness patterns in a Mediterranean deciduous stand. **Journal of Hydrology**, v. 512, p. 254–262, 2014.

LLOYD, C. R.; GASH, J. H. C.; SHUTTLEWORTH, W. J.; MARQUES, F. A. DE O. The measurement and modelling of rainfall interception by amazonian rain forest. **Agricultural and Forest Meteorology**, v. 43, p. 277–294, 1988.

LLOYD, C. R.; MARQUES, F. A. DE O. Spatial variability of throughfall and stemflow measurements in amazonian rainforest. **Agricultural and Forest Meteorology**, v. 42, p. 63–73, 1988.

MASSMAN, W. J. The derivation and validation of a new model for the interception of rainfall by forest. **Agricultural Meteorology**, v. 28, p. 261–286, 1983.

MASSOUD, E. C. **Predictive Modeling of Environmental Systems: Applications of parameter estimation, data assimilation, sensitivity analysis, and model emulation**. [s.l.] University of California, Irvine, 2017.

MCINERNEY, D.; THYER, M.; KAVETSKI, D.; LERAT, J.; KUCZERA, G. Improving probabilistic prediction of daily streamflow by identifying Pareto optimal approaches for modeling heteroscedastic residual errors. **Water Resources Research**, v. 53, p. 2199–2239, 2017.

MOTA, A. DE A. **Tempo de concentração em pequena bacia experimental**. [s.l.] Universidade Federal de Santa Catarina, 2012.

MOTA, A. DE A. **Tempo de concentração em pequena bacia experimental**. 2012. Dissertação (Mestrado em Engenharia Ambiental) – Universidade Federal de Santa Catarina, 2012.

MOTA, A. DE A. **Mecanismo de geração de vazão em pequena bacia experimental do bioma Mata Atlântica**. 2017. Tese (Doutorado em Recursos Hídricos e Saneamento) – Universidade Federal do Rio Grande do Sul, 2017.

MOTA, A. DE A.; GRISON, F.; GIGLIO, J. N.; KOBIYAMA, M. Instalação de uma pequena bacia experimental florestal: estudo de caso da bacia do Rio Araponga. **Revista Engenharia Sanitária e Ambiental**, v. 22, n. 1, p. 73–80, 2017.

MURAKAMI, S. A proposal for a new forest canopy interception mechanism: Splash droplet evaporation. **Journal of Hydrology**, v. 319, n. 1–4, p. 72–82, 2006.

MUZYLO, A.; LLORENS, P.; DOMINGO, F. Rainfall partitioning in a deciduous forest plot in leafed and leafless periods. **Ecohydrology**, v. 5, n. 6, p. 759–767, 2012.

MUZYLO, A.; LLORENS, P.; VALENTE, F.; KEIZER, J. J.; DOMINGO, F.; GASH, J. H. C. A review of rainfall interception modelling. **Journal of Hydrology**, v. 370, n. 1–4, p. 191–206, 2009.

MUZYLO, A.; VALENTE, F.; DOMINGO, F.; LLORENS, P. Modelling rainfall partitioning with sparse Gash and Rutter models in a downy oak stand in leafed and leafless periods. **Hydrological Processes**, 2011.

OLIVEIRA, D. Y. Identificação dos parâmetros de um modelo de interceptação utilizando um algoritmo de calibração automática. 2015. 96p. Trabalho de Conclusão de Curso (Graduação em Engenharia Sanitária e Ambiental) - Universidade Federal de Santa Catarina, Florianópolis, 2015.

PEARCE, A. J.; ROWE, L. K.; STEWART, J. B. Nighttime, wet canopy evaporation rates and the water balance of an evergreen mixed forest. **Water Resources Research**, v. 16, n. 5, p. 955–959, 1980.

REID, L. M.; LEWIS, J. Rates, timing, and mechanisms of rainfall interception loss in a coastal redwood forest. **Journal of Hydrology**, v. 375, n. 3–4, p. 459–470, 2009.

RENARD, B.; KAVETSKI, D.; KUCZERA, G.; THYER, M.; FRANKS, S. W. Understanding predictive uncertainty in hydrologic modeling: The challenge of identifying input and structural errors. **Water Resources Research**, v. 46, p. W05521, 2010.

RENARD, B.; KAVETSKI, D.; LEBLOIS, E.; THYER, M.; KUCZERA, G.; FRANKS, S. W. Toward a reliable decomposition of predictive uncertainty in hydrological modeling: Characterizing rainfall errors using conditional simulation. **Water Resources Research**, v. 47, p. W11516, 2011.

RUTTER, A. J.; KERSHAW, K. A.; ROBINS, R. C.; MORTON, A. J. A predictive model of rainfall interception in forests. 1. Derivation of the model from observations in a plantation of corsican pine. **Agricultural and Forest Meteorology**, v. 9, p. 367–384, 1971.

RUTTER, A. J.; MORTON, A. J. A Predictive Model of Rainfall Interception in Forests. III. Sensitivity of The Model to Stand Parameters and Meteorological Variables. **Journal of Applied Ecology**, v. 14, n. 2, p. 567–588, 1977.

RUTTER, A. J.; MORTON, A. J.; ROBINS, P. C. A predictive model of rainfall interception in forests. 2. Generalization of the model and comparison with observations in some coniferous and hardwood stands. **Journal of Applied Ecology**, v. 12, n. 1, p. 367–380, 1975.

SÁ, J.H.M. **Monitoramento e modelagem do processo de interceptação da chuva de uma bacia coberta por Floresta Ombrófila Mista.** 2015. 129 f. Dissertação (Mestrado em Engenharia Ambiental) – Universidade Federal de Santa Catarina, Florianópolis, 2015.

SADEGH, M.; VRUGT, J. A. Bridging the gap between GLUE and formal statistical approaches: Approximate Bayesian computation. **Hydrology and Earth System Sciences**, v. 17, n. 12, p. 4831–4850, 2013.

SADEGH, M.; VRUGT, J. A. Approximate Bayesian Computation using Markov Chain Monte Carlo simulation. **Water Resources Research**, v. 10, n. 2, p. 6767–6787, 2014.

SANTOS, I. **Monitoramento e modelagem de processos hidrogeomorfológicos: Mecanismos de geração de escoamento e conectividade hidrológica.** 2009. 167 f. Tese (Doutorado em Geografia) – Universidade Federal de Santa Catarina, Florianópolis, 2009.

SCATENA, F. N. Watershed scale rainfall interception on two forested watersheds in the Luquillo mountains of Puerto Rico. **Journal of Hydrology**, v. 113, p. 89–102, 1990.

SCHAEFLI, B.; TALAMBA, D. B.; MUSY, A. Quantifying hydrological modeling errors through a mixture of normal distributions. **Journal of Hydrology**, v. 332, n. 3–4, p. 303–315, 2007.

SCHELLEKENS, J.; BRUIJNZEEL, L. A.; SCATENA, F. N.; BINK, N. J.; HOLWERDA, F. Evaporation from a tropical rain forest, Luquillo Experimental Forest, eastern Puerto Rico. **Water Resources Research**, v. 36, n. 8, p. 2183–2196, 2000.

SCHELLEKENS, J.; SCATENA, F. N.; BRUIJNZEEL, L. A.; WICKEL, A. J. Modelling rainfall interception by a lowland tropical rain forest in northeastern Puerto Rico. **Journal of Hydrology**, v. 225, n. 3–4, p. 168–184, 1999.

SCHONIGER, A.; WOHLING, T.; SAMANIEGO, L.; NOWAK, W. Model selection on solid ground: Rigorous comparison of nine ways to evaluate Bayesian model evidence. **Water Resources Research**, p.

9484–9513, 2014.

SCHOUPS, G.; VAN DE GIESSEN, N. C.; SAVENIJE, H. H. G. Model complexity control for hydrologic prediction. **Water Resources Research**, v. 44, n. 1, p. 1–14, 2008.

SCHOUPS, G.; VRUGT, J. A. A formal likelihood function for parameter and predictive inference of hydrologic models with correlated, heteroscedastic, and non-Gaussian errors. **Water Resources Research**, v. 46, p. W10531, 2010.

SILVA, R. V. DA. **Desenvolvimento de um modelo hidrológico distribuído por meio de células voronoi com consideração das profundidades do solo.** [s.l.] Universidade Federal de Santa Catarina, 2010.

SMITH, T.; MARSHALL, L.; SHARMA, A. Modeling residual hydrologic errors with Bayesian inference. **Journal of Hydrology**, v. 528, n. SEPTEMBER 2015, p. 29–37, 2015.

SMITH, T.; SHARMA, A.; MARSHALL, L.; MEHROTRA, R.; SISSON, S. Development of a formal likelihood function for improved Bayesian inference of ephemeral catchments. **Water Resources Research**, v. 46, p. W12551, 2010.

TER BRAAK, C. J. F. A Markov Chain Monte Carlo version of the genetic algorithm Differential Evolution: Easy Bayesian computing for real parameter spaces. **Statistics and Computing**, v. 16, n. 3, p. 239–249, 2006.

THYER, M.; RENARD, B.; KAVETSKI, D.; KUCZERA, G.; FRANKS, S. W.; SRIKANTHAN, S. Critical evaluation of parameter consistency and predictive uncertainty in hydrological modeling: A case study using Bayesian total error analysis. **Water Resources Research**, v. 45, p. W00B14, 2009.

VACHÉ, K. B.; McDONNELL, J. J. A process-based rejectionist framework for evaluating catchment runoff model structure. **Water Resources Research**, v. 42, n. 2, p. 1–15, 2006.

VALENTE, F.; DAVID, J. S.; GASH, J. H. Modelling interception loss for two spares eucalypt and pine forests in central Portugal unssing reformulated Rutter and Gash analytical models. **Journal of Hydrology**, v. 190, p. 141–162, 1997.

VOLPI, E.; SCHOUPS, G.; FIRMANI, G.; VRUGT, J. A. Sworn testimony of themodel evidence: GaussianMixture Importance (GAME) sampling. **Water Resources Research**, v. 53, p. 5469–5494, 2017.

VRUGT, J. A. Markov chain Monte Carlo simulation using the DREAM software package: Theory, concepts, and MATLAB implementation. **Environmental Modelling and Software**, v. 75, p. 273–316, 2016.

VRUGT, J. A.; DEKKER, S. C.; BOUTEN, W. Identification of rainfall interception model parameters from measurements of throughfall and forest canopy storage. **Water Resources Research**, v. 39, n. 9, p. 1251, 2003.

VRUGT, J. A.; SADEGH, M. Toward diagnostic model calibration and evaluation: Approximate Bayesian computation. **Water Resources Research**, v. 49, n. 7, p. 4335–4345, 2013a.

VRUGT, J. A.; SADEGH, M. Toward diagnostic model calibration and evaluation: Approximate Bayesian computation. **Water Resources Research**, v. 49, n. 7, p. 4335–4345, 2013b.

VRUGT, J. A.; TER BRAAK, C. J. F.; CLARK, M. P.; HYMAN, J. M.; ROBINSON, B. A. Treatment of input uncertainty in hydrologic modeling: Doing hydrology backward with Markov chain Monte Carlo simulation. **Water Resources Research**, v. 44, p. W00B09, 2008.

WESTRA, S.; THYER, M.; LEONARD, M.; KAVETSKI, D.; LAMBERT, M. A strategy for diagnosing and interpreting hydrologicalmodel nonstationarity. **Water Resources Research**, v. 50, p. 5090–5113, 2014.

## APÊNDICE A

**Tabela A1.** Totais de chuva total ( $P$ ), chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) de cada um dos 35 eventos monitorados na bacia do rio Saci (reflorestamento de pinus).

Evento	Início DOY	Duração h	$P$ mm	$T_f$ mm	% $P$	$S_f$ mm	% $P$	PSA h
1	0,01	1	5,1	2,3	44	0,0	0	-
2	1,88	0	0,3	0,1	20	0,0	0	44
3	3,78	4	0,5	0,3	59	0,0	0	46
4	13,78	14	9,7	8,9	92	0,1	1	17
5	16,86	7	16,2	10,1	62	0,3	2	60
6	18,27	0	0,3	0,2	78	0,0	0	27
7	19,63	50	49,3	40,2	82	4,6	9	19
8	23,90	2	0,5	0,3	49	0,0	0	53
9	26,89	52	24,6	21,1	86	1,0	4	70
10	32,85	106	19,2	5,0	26	0,0	0	92
11	37,76	9	6,1	4,5	73	0,1	1	12
12	39,28	14	35,8	29,6	83	2,5	7	28
13	41,72	31	84,9	66,2	78	10,9	13	45
14	43,79	0	0,3	0,1	20	0,0	0	19
15	44,39	0	0,3	0,0	0	0,0	0	14
16	46,07	0	0,3	0,1	39	0,0	0	40
17	46,79	5	1,5	0,0	0	0,0	0	17
18	47,58	9	1,0	0,5	49	0,0	0	14
19	49,25	17	7,2	6,0	84	0,1	1	31
20	50,93	0	0,3	0,1	39	0,0	0	23
21	52,51	159	131,2	93,1	71	15,9	12	38
22	61,60	10	29,9	26,2	88	1,0	3	44
23	62,76	7	0,5	0,2	39	0,0	0	17
24	63,63	34	11,6	7,2	62	0,4	3	14
25	66,78	30	37,3	31,8	85	2,5	7	42
26	69,75	2	0,5	0,1	20	0,0	0	41
27	70,74	19	35,5	28,8	81	1,5	4	22
28	72,79	5	0,8	0,5	65	0,0	0	31
29	73,99	0	0,3	0,0	0	0,0	0	24
30	74,53	11	16,0	8,3	52	0,2	1	13
31	75,66	0	0,3	0,0	0	0,0	0	16
32	76,77	7	1,0	0,2	20	0,0	0	27
33	77,76	8	1,0	0,4	34	0,0	0	16
34	78,83	86	116,7	67,0	57	7,5	6	18
35	83,33	0	0,3	0,0	0	0,0	0	22

**Tabela A2.** Totais de chuva total ( $P$ ), chuva interna ( $Tf$ ), escoamento pelos troncos ( $Sf$ ) de cada um dos 59 eventos monitorados na bacia do rio Araponga (floresta nativa secundária) (continua).

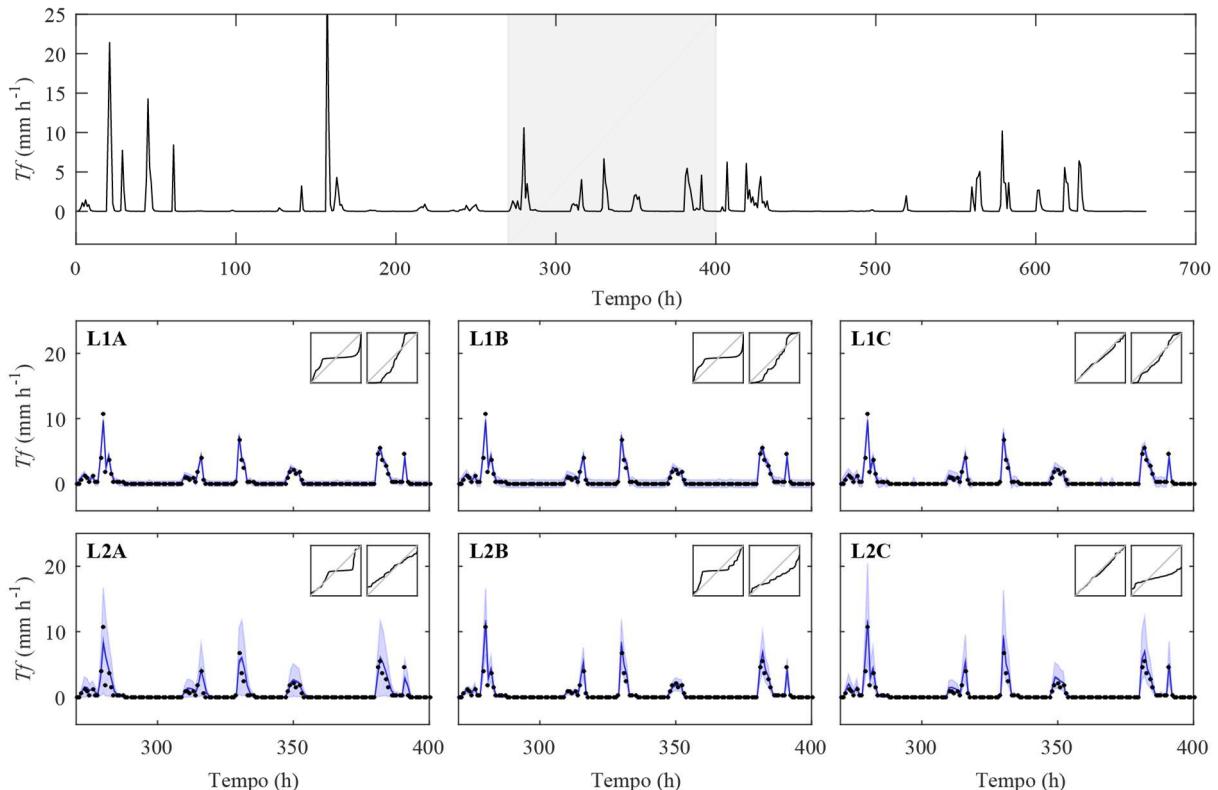
Evento	Início DOY	Duração h	$P$ mm	$Tf$ mm	%P	$Sf$ mm	%P	PSA h
1	57,68	24	19,4	15,6	81	0,6	7	13
2	59,24	7	7,4	5,4	73	0,2	7	14
3	62,88	4	2,6	1,1	43	0,0	0	18
4	63,62	30	32,4	23,9	74	1,5	9	14
5	66,64	10	5,7	1,5	27	0,0	1	43
6	67,58	12	72,6	53,1	73	7,5	13	12
7	68,78	2	5,4	2,5	46	0,0	2	17
8	69,82	33	40,1	28,3	70	1,7	7	23
9	71,71	22	65,1	50,6	78	6,3	13	13
10	75,70	0	0,7	0,0	7	0,0	9	74
11	77,63	6	42,2	28,0	67	1,6	7	19
12	78,79	8	16,0	10,6	66	0,7	10	22
13	86,17	7	0,5	0,0	0	0,0	0	49
14	89,47	30	10,8	5,4	50	0,1	3	73
15	91,76	2	11,3	8,6	76	0,4	9	25
16	92,78	35	12,5	5,9	47	0,1	2	23
17	99,17	5	7,4	5,0	67	0,0	1	118
18	100,26	3	0,5	0,2	36	0,0	0	21
19	102,18	9	1,4	0,2	15	0,0	0	43
20	105,19	19	2,4	0,9	38	0,0	1	64
21	108,21	0	0,5	0,0	0	0,0	0	53
22	109,65	4	5,3	3,5	66	0,0	1	34
23	112,60	12	65,1	52,8	81	1,3	3	37
24	113,88	17	1,7	0,6	37	0,0	0	18
25	118,06	11	5,5	3,5	63	0,0	0	84
26	120,85	8	10,5	6,4	61	0,0	0	56
27	130,63	20	10,6	5,1	49	0,1	1	46
28	136,08	3	2,1	1,3	61	0,0	0	80
29	143,43	12	33,7	29,1	86	0,5	3	20
30	145,43	32	35,0	27,2	78	0,3	2	37
31	151,58	8	16,2	10,1	63	0,1	1	91
32	156,63	87	352,4	297,7	84	28,9	3	114
33	161,94	9	1,0	0,4	41	0,0	1	41
34	162,83	8	1,2	0,6	46	0,0	0	12
35	166,15	6	20,0	14,1	71	0,1	1	72
36	168,98	16	30,8	23,1	75	0,3	2	49
37	176,49	7	14,5	9,0	62	0,0	1	25
38	177,33	41	39,9	31,8	80	0,3	1	14
39	179,59	14	32,1	27,5	86	0,3	2	13
40	188,86	1	3,4	2,4	72	0,0	0	108
41	190,19	6	0,5	0,1	21	0,0	0	31
42	191,08	4	0,5	0,2	36	0,0	0	15
43	191,77	6	0,7	0,0	7	0,0	0	12
44	193,17	24	3,4	0,7	21	0,0	0	28
45	198,83	16	6,2	3,0	48	0,0	0	60
46	210,97	3	0,5	0,0	8	0,0	0	13
47	213,96	2	0,5	0,0	8	0,0	0	42

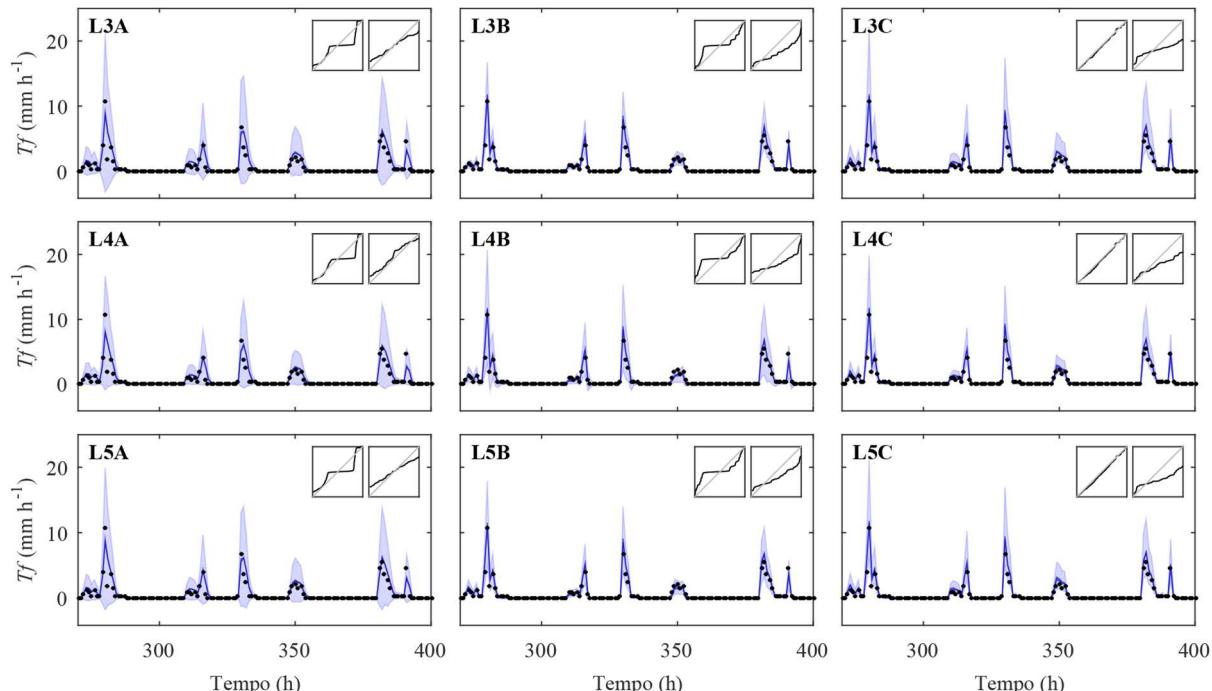
**Tabela A2.** Totais de chuva total ( $P$ ), chuva interna ( $T_f$ ), escoamento pelos troncos ( $S_f$ ) de cada um dos 59 eventos monitorados na bacia do rio Araponga (floresta nativa secundária) (continuação).

Evento	Início DOY	Duração h	$P$ mm	$T_f$ mm	% $P$	$S_f$ mm	% $P$	PSA h
48	224,75	6	23,5	18,9	80	0,1	1	104
49	228,04	23	39,8	28,5	72	0,2	1	73
50	237,89	6	30,2	22,7	75	0,2	2	213
51	261,63	21	49,1	41,6	85	0,7	2	32
52	263,79	1	6,7	4,5	67	0,0	0	31
53	267,31	7	23,0	19,0	82	0,0	0	83
54	268,83	9	9,6	7,0	73	0,0	0	29
55	270,40	55	29,3	23,5	80	0,1	0	28
56	273,64	12	32,5	28,0	86	0,1	1	23
57	275,84	2	0,5	0,0	0	0,0	0	16
58	277,15	4	1,0	0,1	8	0,0	0	30
59	277,95	5	1,4	0,4	31	0,0	0	15

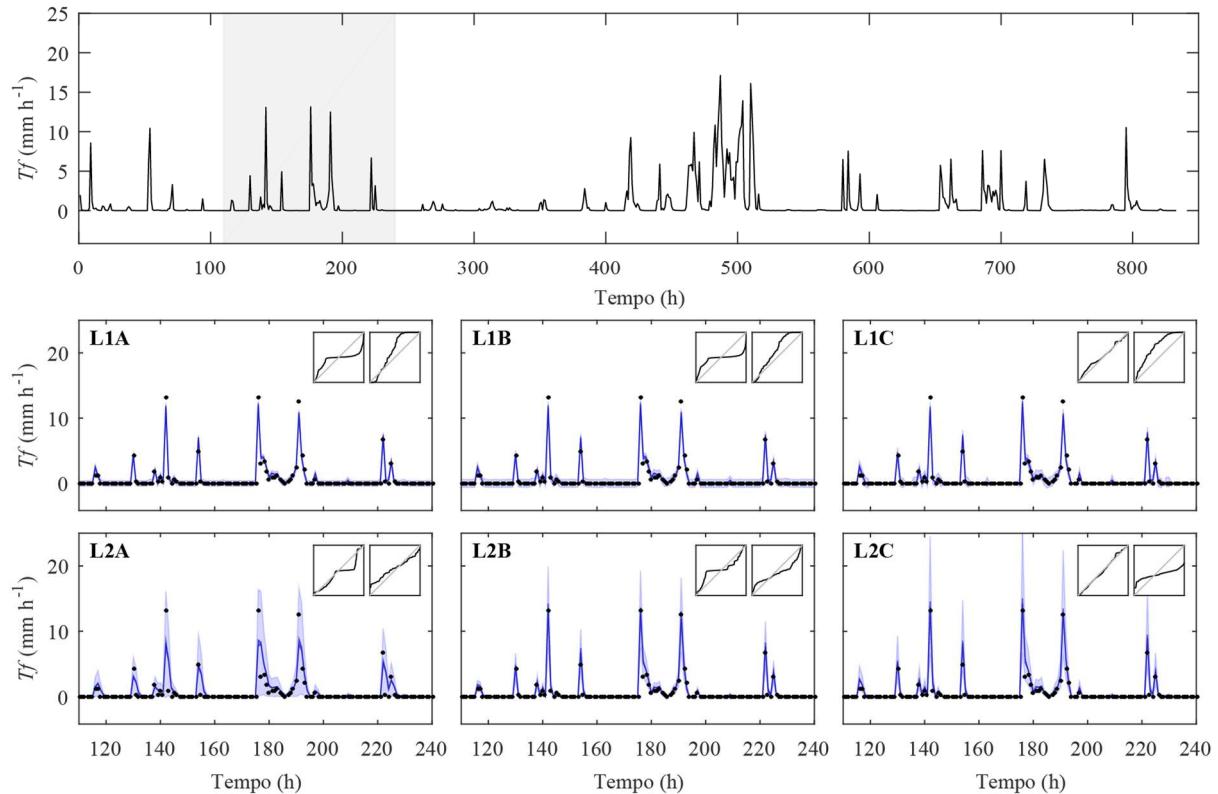


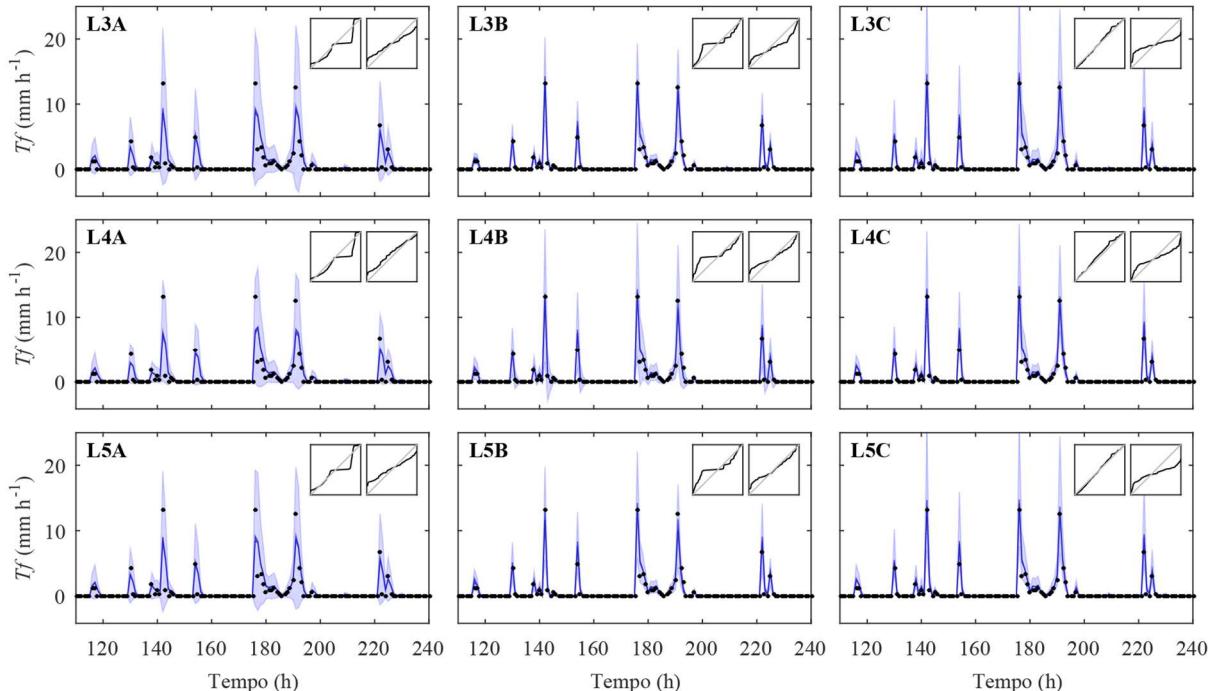
**APÊNDICE B****ESCOLHA DA FUNÇÃO DE VEROSSIMILHANÇA NA  
MODELAGEM DO PROCESSO DE INTERCEPTAÇÃO**



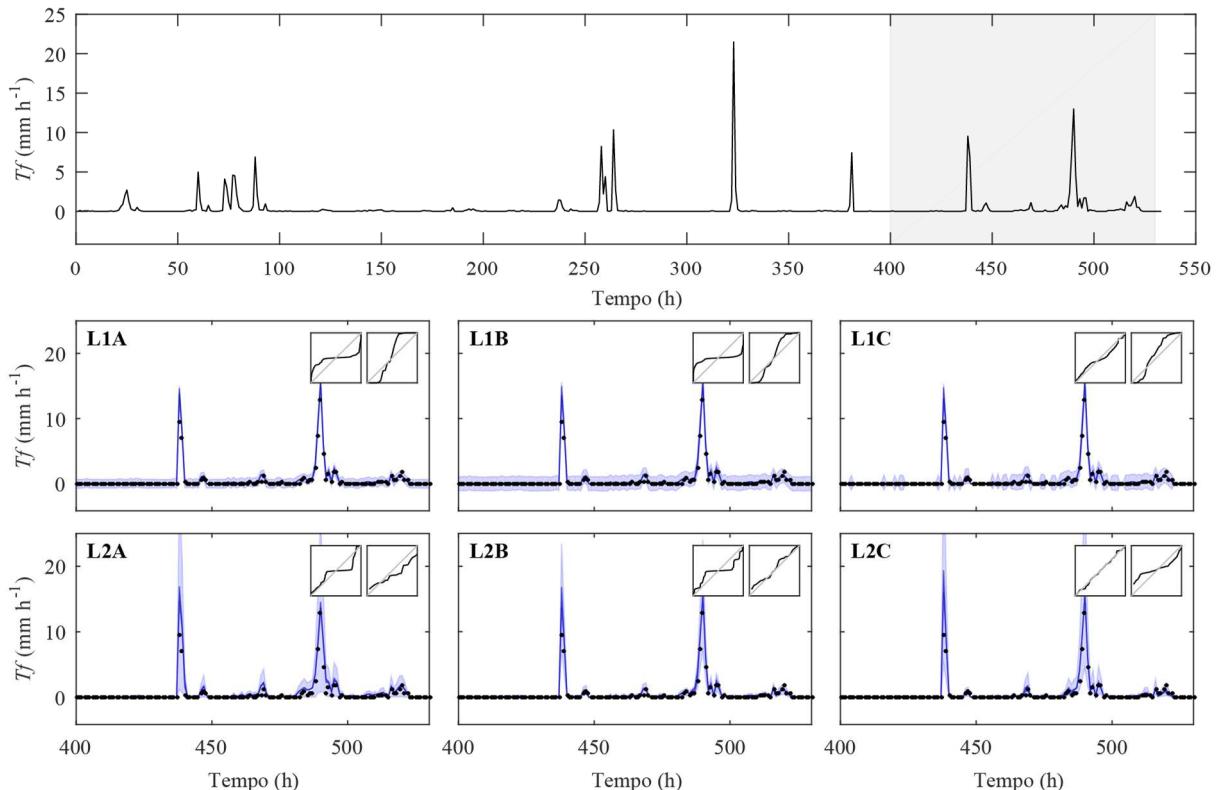


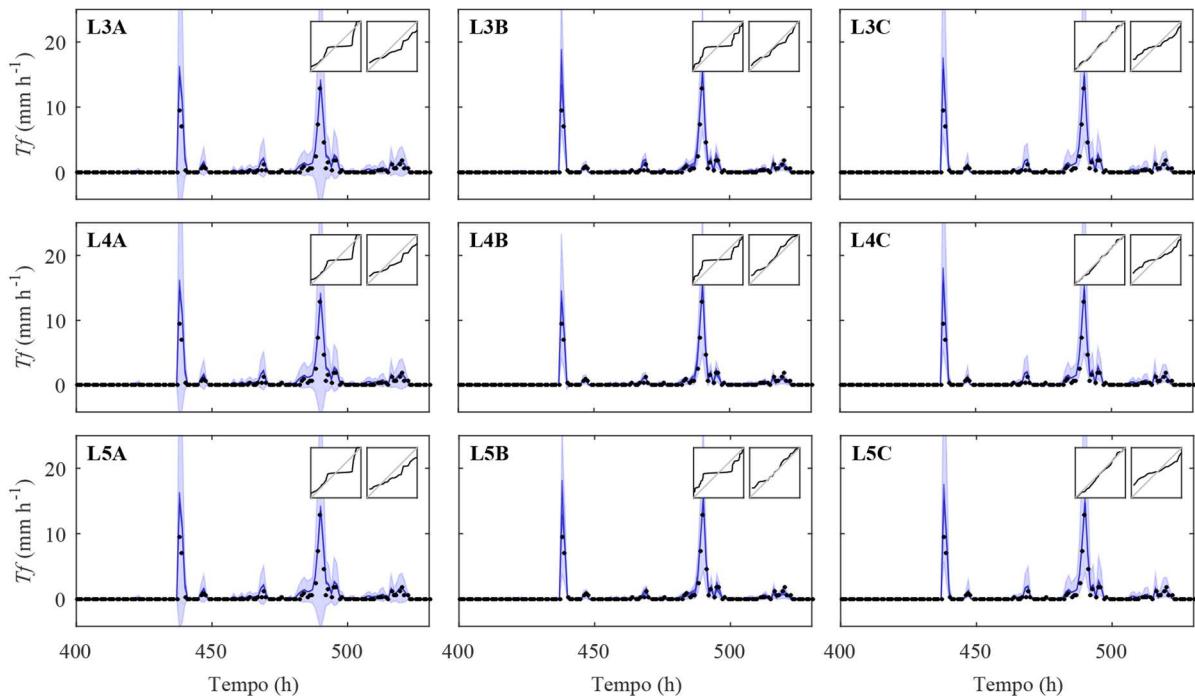
**Figura B1.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A), GL<sup>>0</sup> (B) e ZI-GL (C). No painel superior: todo período de calibração. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2$  mm h<sup>-1</sup> (esquerda) e  $T_f > 2$  mm h<sup>-1</sup> (direita).



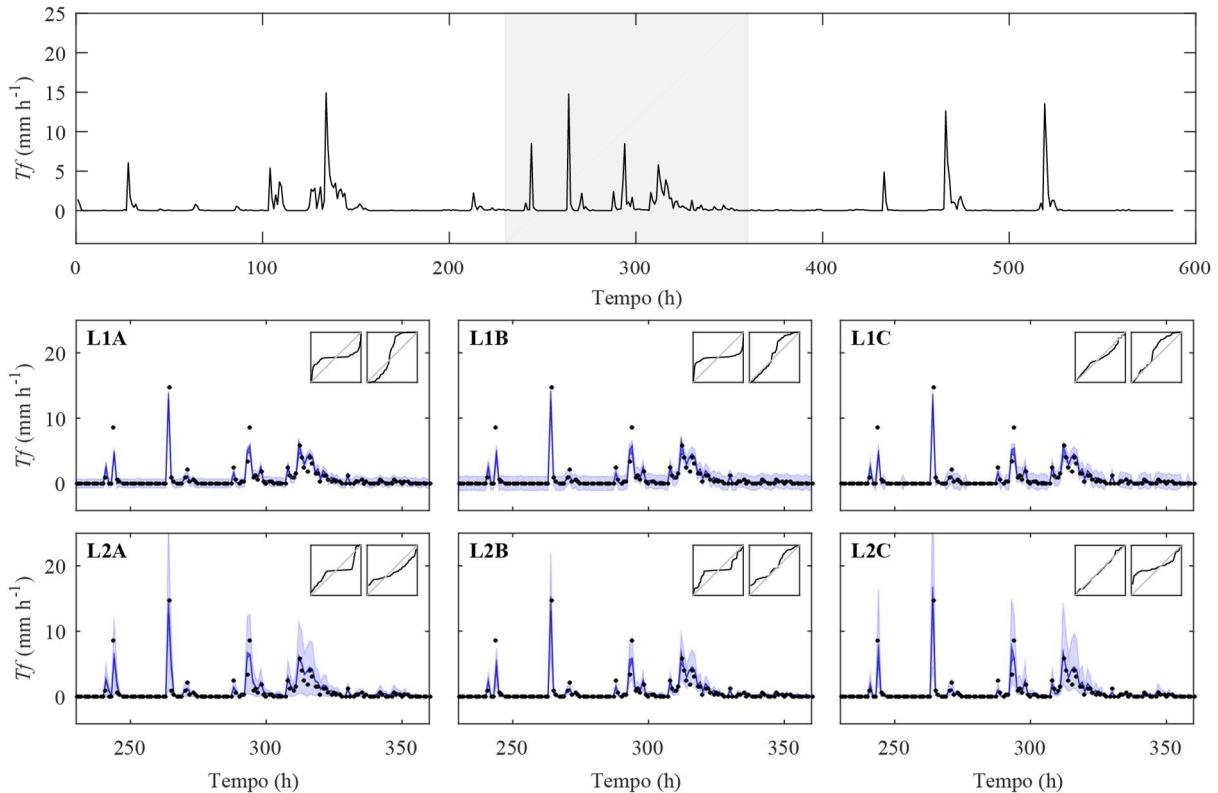


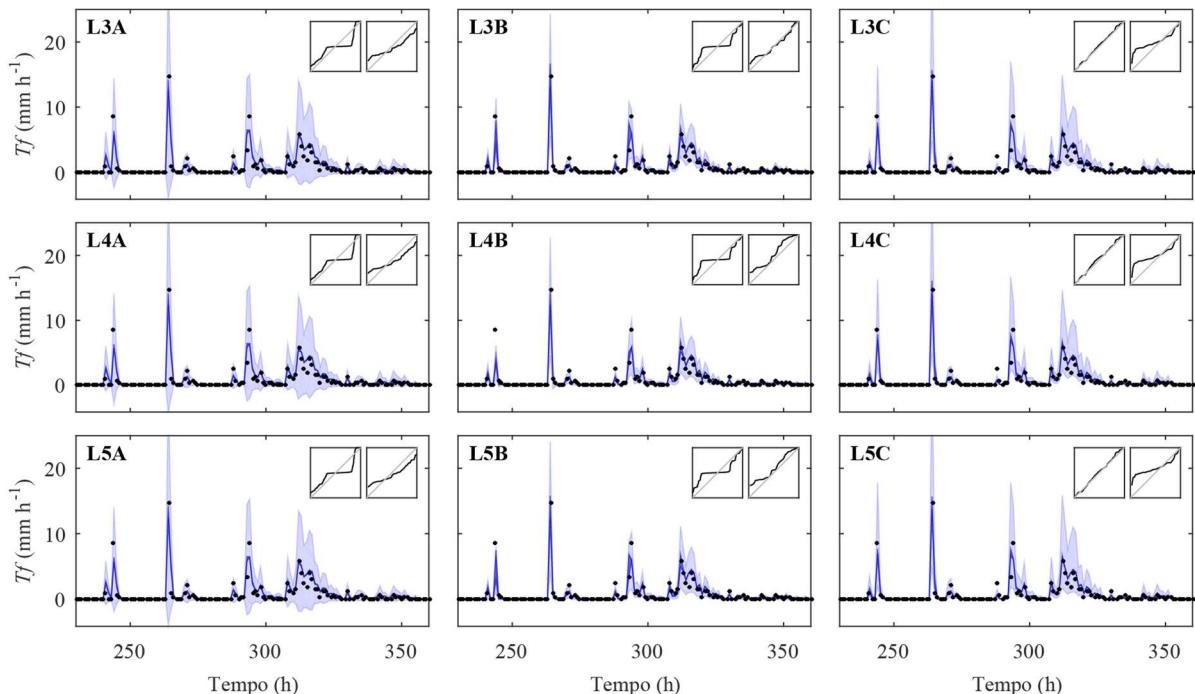
**Figura B2.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A), GL<sup>>0</sup> (B) e ZI-GL (C). No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2$  mm h<sup>-1</sup> (esquerda) e  $T_f > 2$  mm h<sup>-1</sup> (direita).



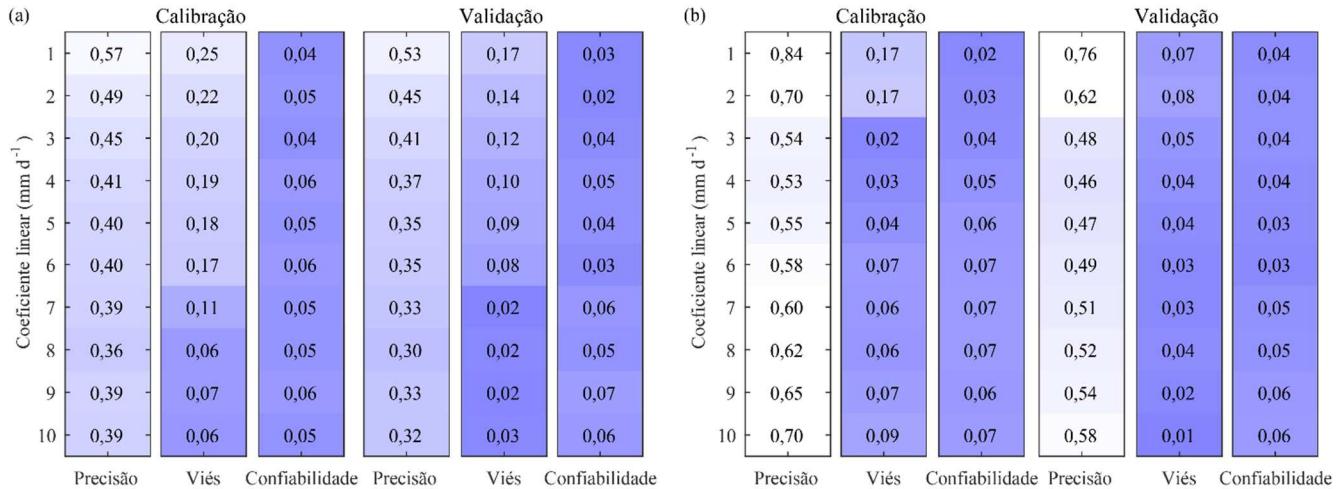


**Figura B3.** Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A), GL<sup>y0</sup> (B) e ZI-GL (C). No painel superior: todo período de calibração. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).

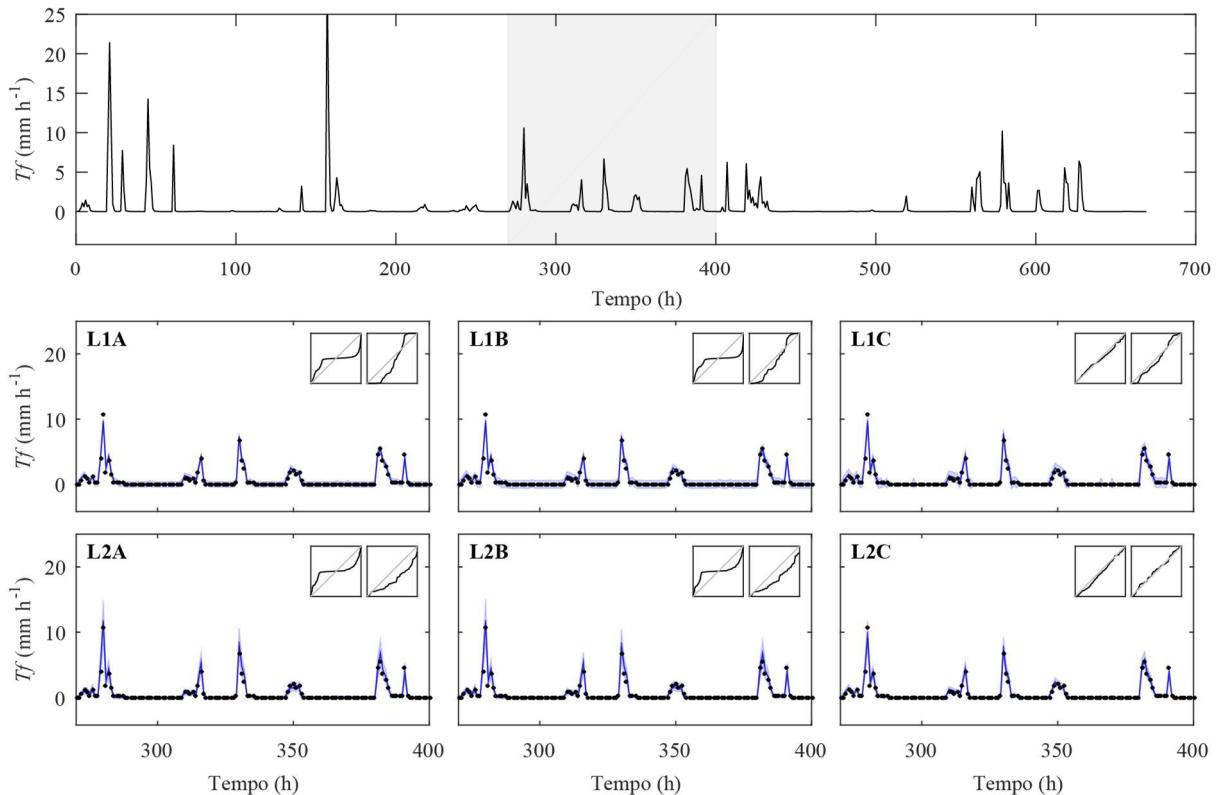


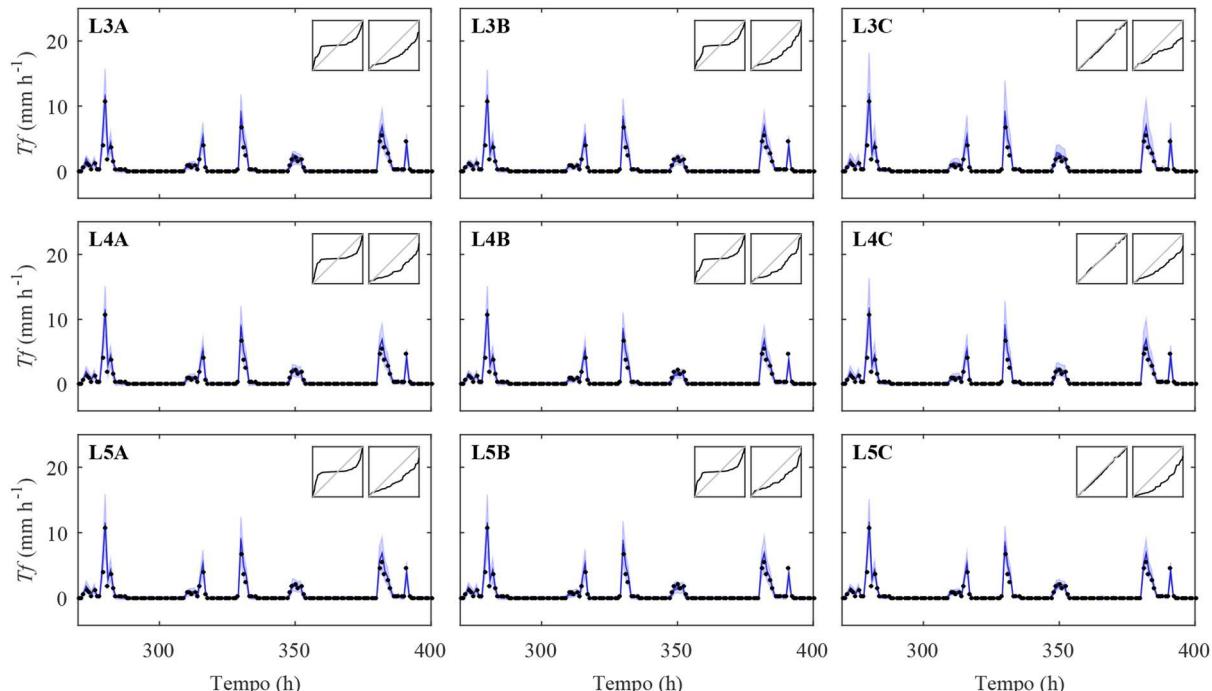


**Figura B4.** Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C). No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).

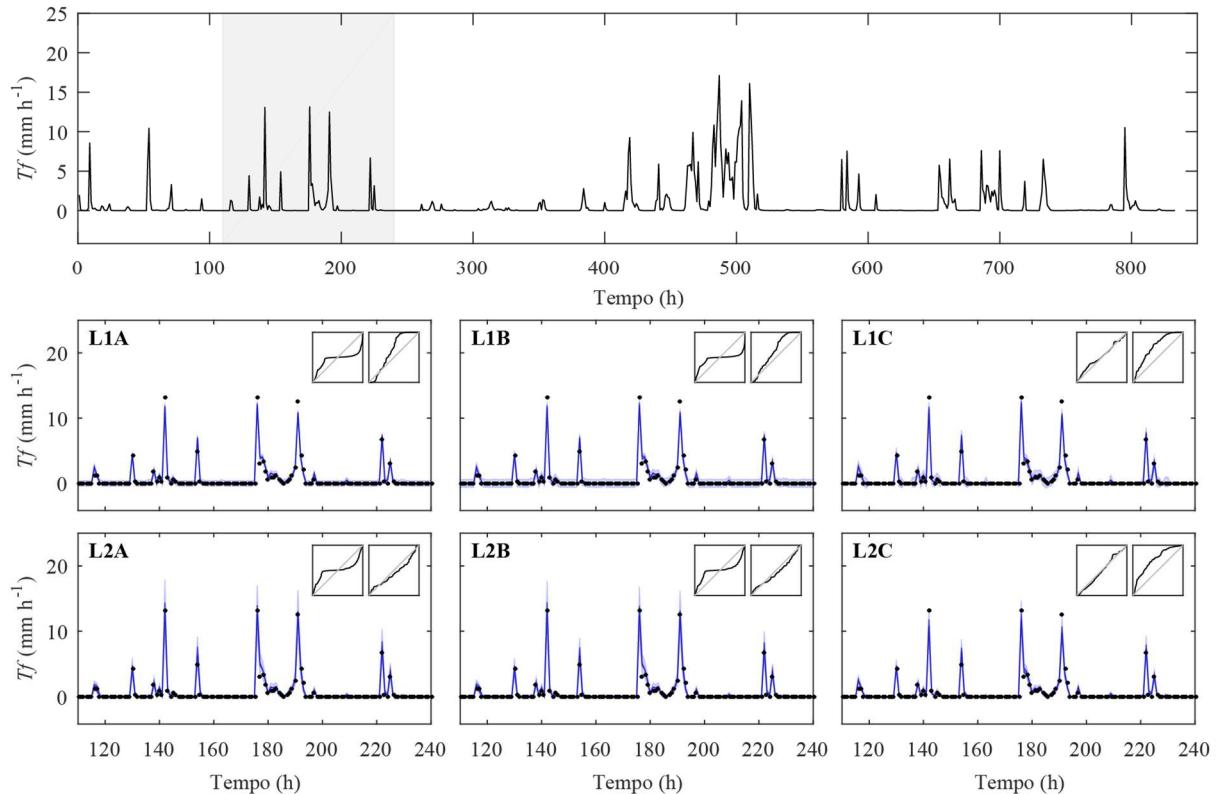


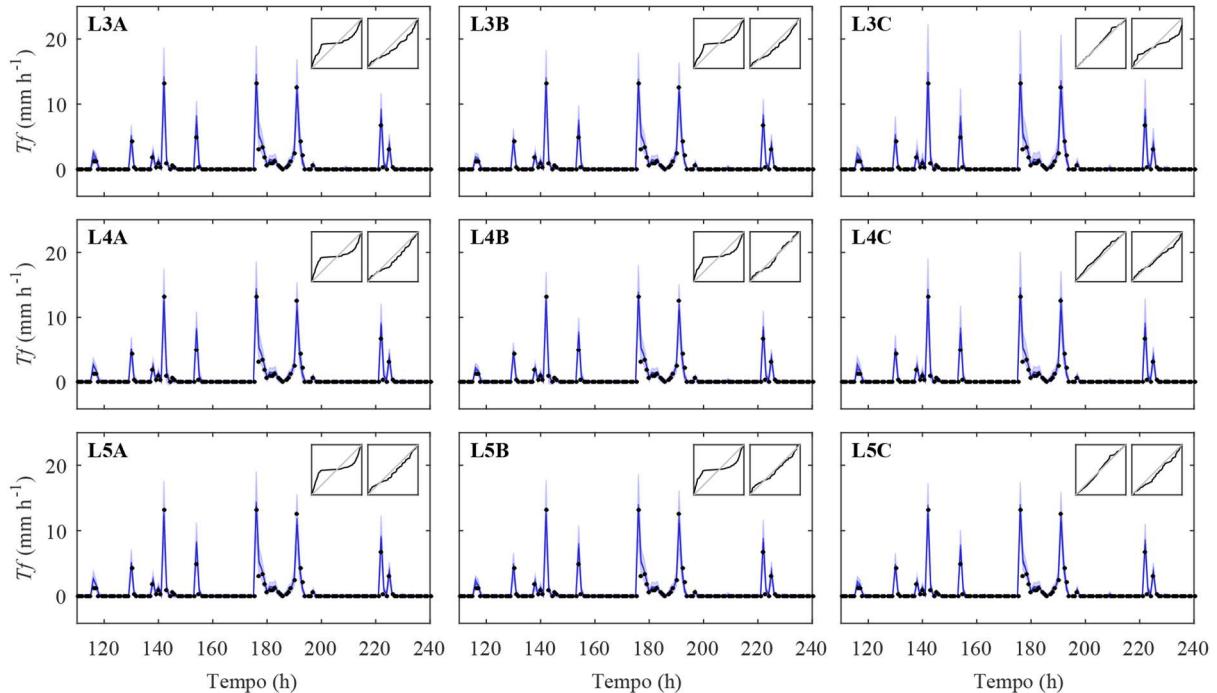
**Figura B5.** Variação dos valores das métricas de precisão, viés e confiabilidade de acordo com o valor do coeficiente linear do modelo heteroscedástico para (a) floresta nativa e (b) reflorestamento de pinus. Na sequência deste trabalho, o valor para o coeficiente linear do modelo heteroscedástico foi fixado como sendo igual a 3 mm d<sup>-1</sup> (= 0,12 mm h<sup>-1</sup>).



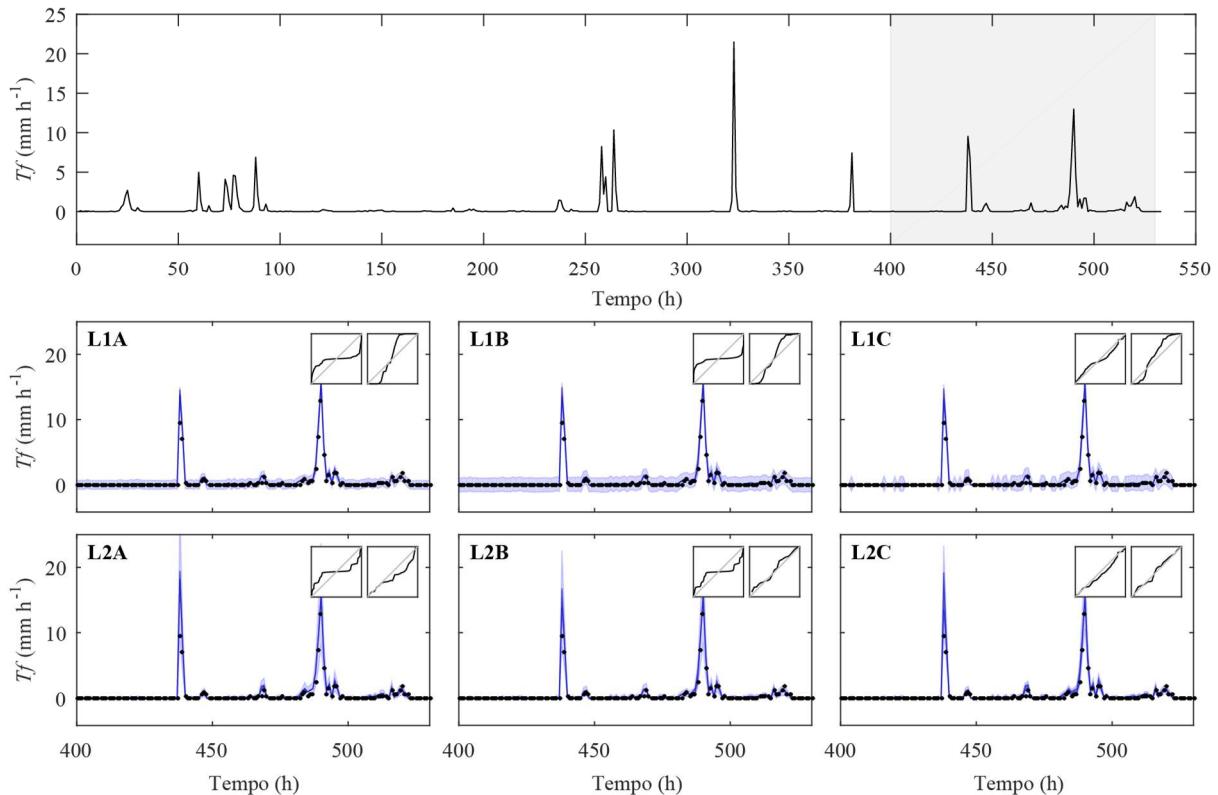


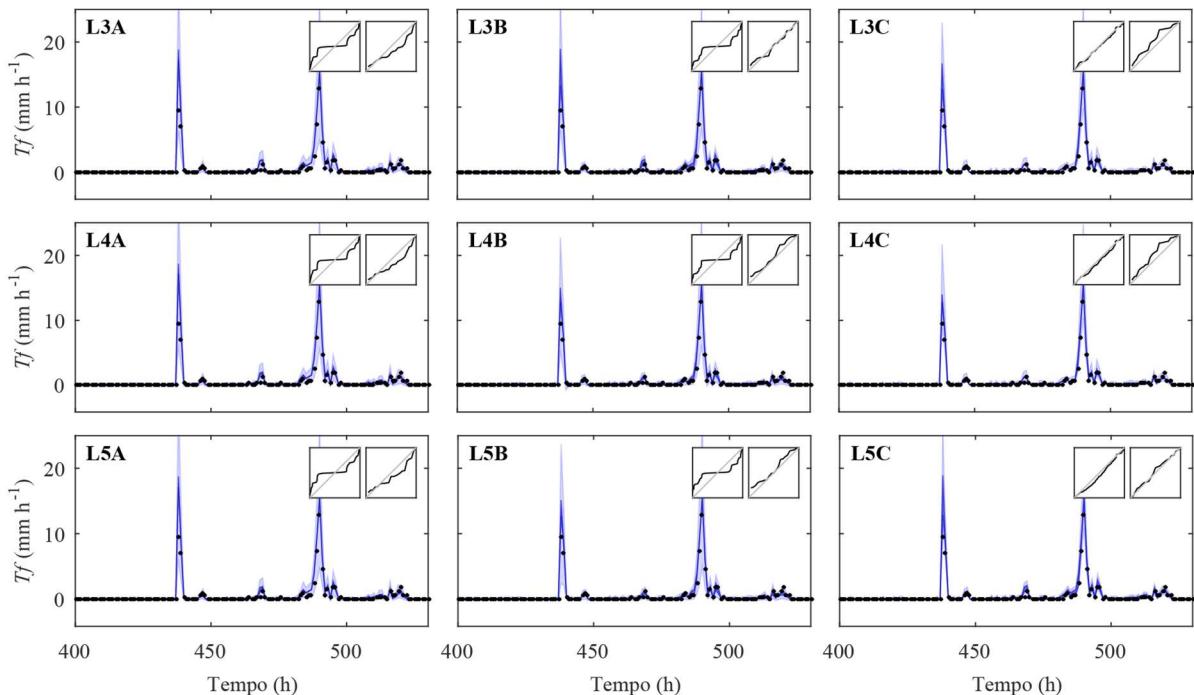
**Figura B6.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $GL^{y=0}$  (B) e ZI-GL (C).  $\sigma_0$  fixo em  $3 \text{ mm } d^{-1}$ . No painel superior: todo período de calibração. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm } h^{-1}$  (esquerda) e  $T_f > 2 \text{ mm } h^{-1}$  (direita).



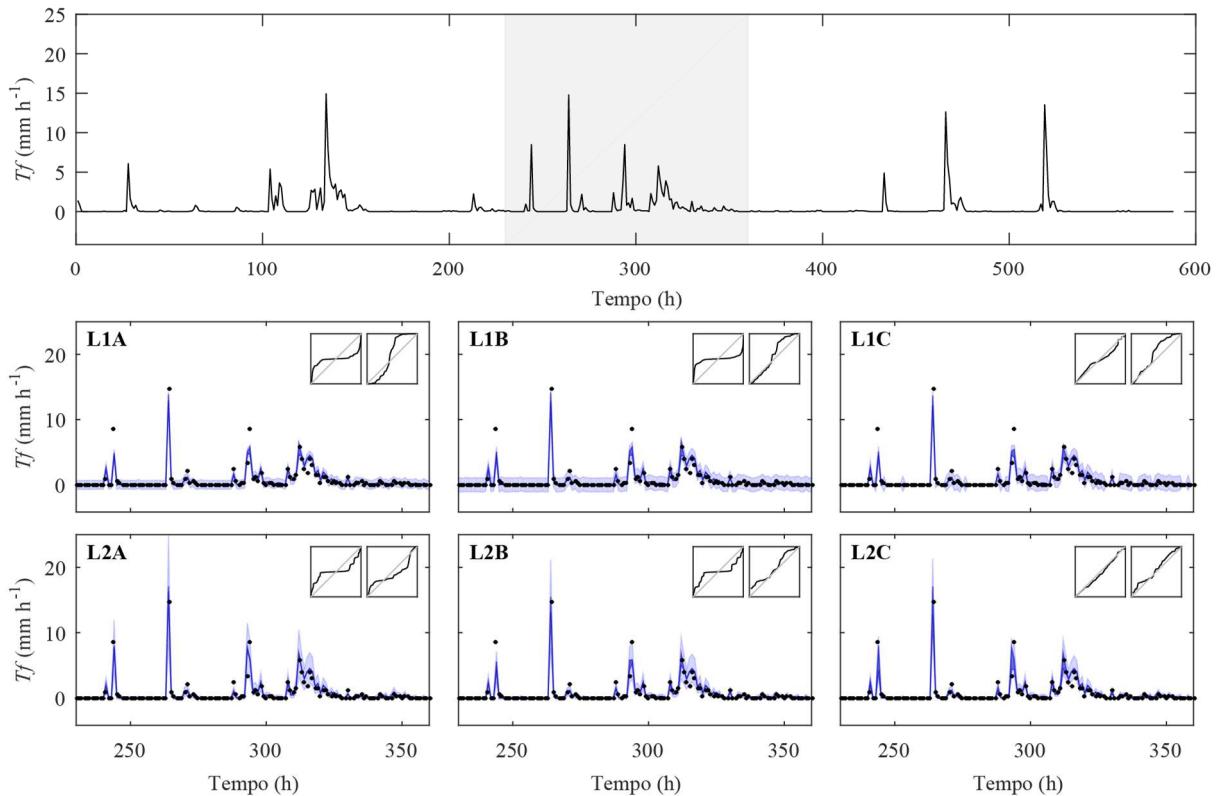


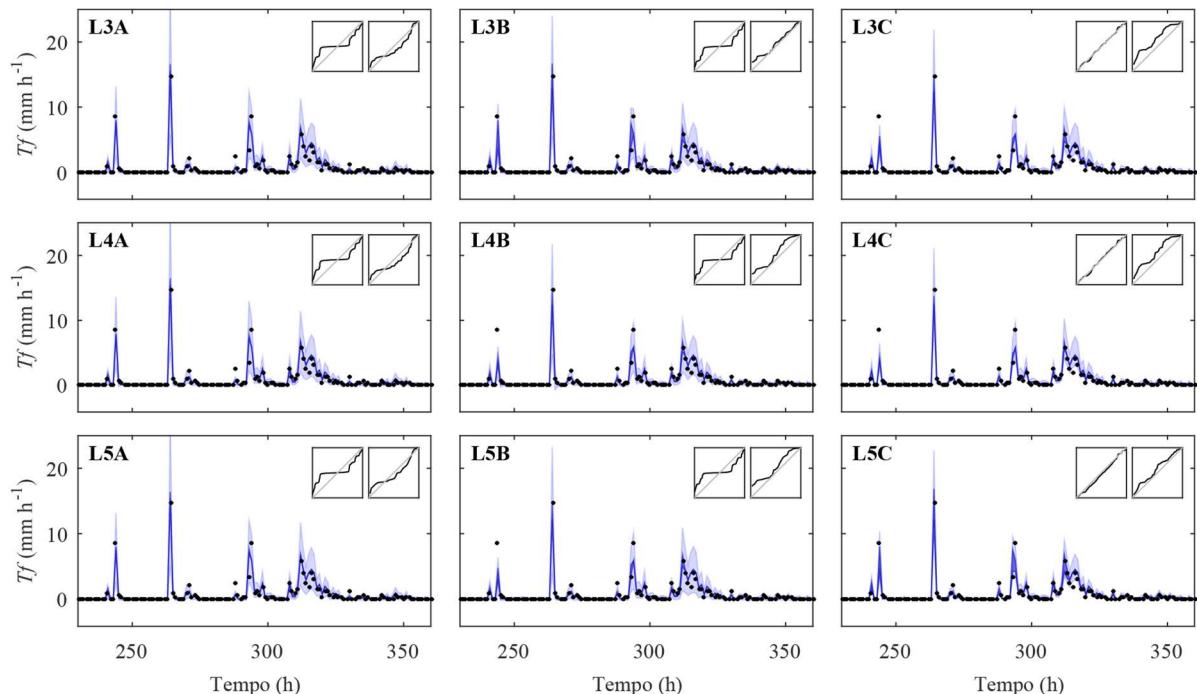
**Figura B7.** Série de chuva interna observada (círculos pretos) para a floresta nativa (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C).  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).





**Figura B8.** Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $\text{GL}^{y^0}$  (B) e ZI-GL (C).  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . No painel superior: todo período de calibração. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).



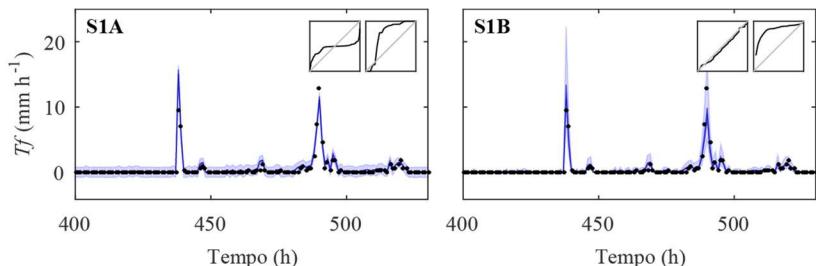


**Figura B9.** Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de validação), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) considerando os diferentes modelos para os resíduos (L1 a L5) utilizando GL (A),  $GL^{y>0}$  (B) e ZI-GL (C).  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ . No painel superior: todo período de validação. Dentro de cada plot são apresentados os gráficos quantil-quantil para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).

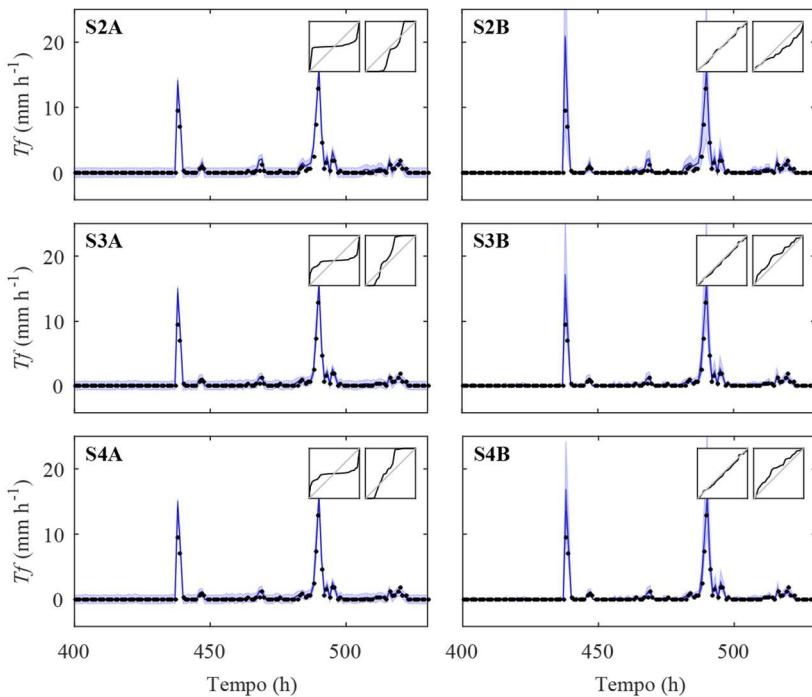
## APÊNDICE C

### COMPARAÇÃO ENTRE FORMULAÇÕES DE INTERCEPTAÇÃO

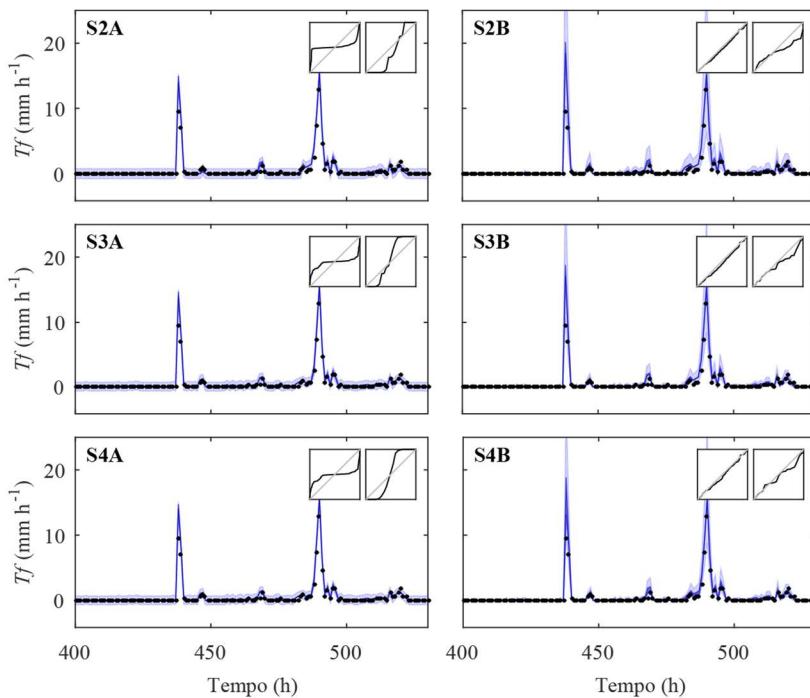
*Reflorestamento de pinus – chuva interna*



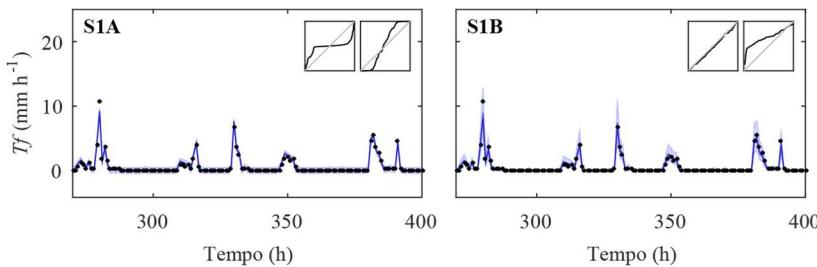
**Figura C1.** Resultado para a estrutura 1 (S1). Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>, na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $T_f < 2$  mm h<sup>-1</sup> (esquerda) e  $T_f > 2$  mm h<sup>-1</sup> (direita).



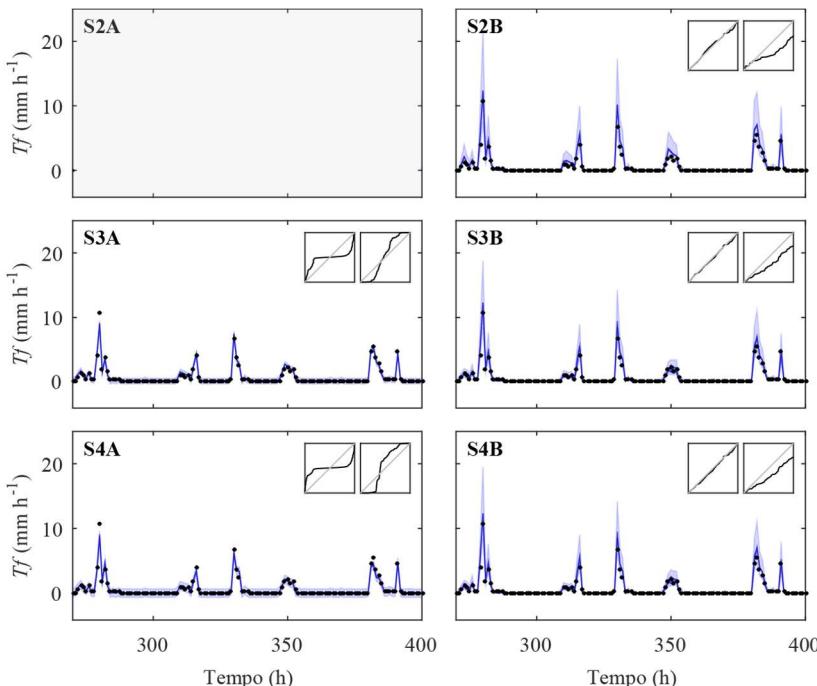
**Figura C2.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 1. Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>, na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $T_f < 2$  mm h<sup>-1</sup> (esquerda) e  $T_f > 2$  mm h<sup>-1</sup> (direita).



**Figura C3.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 2. Série de chuva interna observada (círculos pretos) para o reflorestamento de pinus (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita).

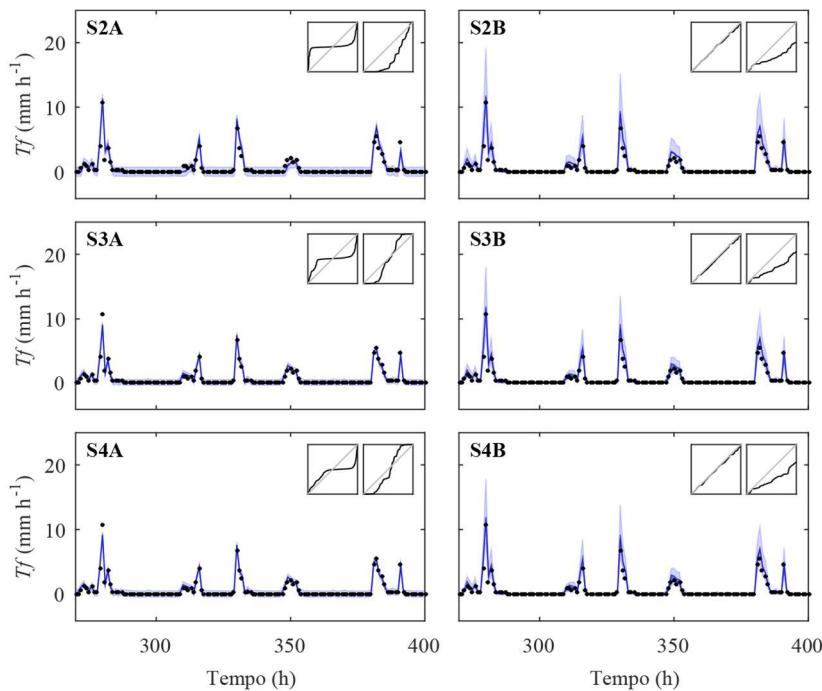
*Floresta nativa – chuva interna*

**Figura C4.** Resultado para a estrutura 1 (S1). Série de chuva interna observada (círculos pretos) para a floresta nativa (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $T_f < 2 \text{ mm h}^{-1}$  (esquerda) e  $T_f > 2 \text{ mm h}^{-1}$  (direita).



**Figura C5.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 1. Série de chuva interna observada (círculos pretos) para a floresta nativa (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza

associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita).



**Figura C6.** Resultado para as estruturas 2 a 4 (S2 a S4) com a formulação de drenagem 2. Série de chuva interna observada (círculos pretos) para a floresta nativa (período de calibração), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) utilizando L1 na formulação GL (A) e L5, com  $\sigma_0$  fixo em  $3 \text{ mm d}^{-1}$ , na formulação ZI-GL (B). Dentro de cada plot, QQ plot para  $Tf < 2 \text{ mm h}^{-1}$  (esquerda) e  $Tf > 2 \text{ mm h}^{-1}$  (direita).

### Reflorestamento de pinus – chuva líquida

	Calibração					Validação				
	P	V	C	$C^{y<2}$	$C^{y>2}$	P	V	C	$C^{y<2}$	$C^{y>2}$
S1	0,61	0,05	0,06	0,09	0,54	0,52	0,16	0,06	0,03	0,55
S2D1	0,98	0,37	0,05	0,06	0,24	0,87	0,23	0,07	0,06	0,29
S3D1	0,57	0,10	0,07	0,07	0,11	0,50	0,01	0,04	0,03	0,18
S4D1	0,57	0,10	0,07	0,08	0,13	0,51	0,01	0,04	0,04	0,19
S2D2	0,89	0,33	0,04	0,03	0,22	0,78	0,19	0,07	0,06	0,26
S3D2	0,61	0,19	0,06	0,06	0,13	0,54	0,10	0,05	0,05	0,11
S4D2	0,63	0,20	0,06	0,06	0,14	0,55	0,09	0,05	0,05	0,11

**Figura C7.** Métricas de desempenho para o reflorestamento de pinus obtidas para cada um dos modelos de interceptação (S1 a S4D2) utilizando a ZI-GL, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>. P é a precisão, V o viés, C a confiabilidade,  $C^{y<2}$  a confiabilidade para chuva interna < 2 mm h<sup>-1</sup>,  $C^{y>2}$  a confiabilidade para chuva interna > 2 mm h<sup>-1</sup>.

**Tabela C1.** Critérios de informação ( $I_k$ ) para as diferentes formulações do processo de interceptação. Valores calculados para o reflorestamento de pinus para o período de calibração. L indica o valor (máximo) da função de verossimilhança, k é a dimensão do problema, n é o número de dados utilizado,  $\psi$  é o termo que penaliza a complexidade, BIC é o critério de informação de Bayes e AIC é o critério de informação de Akaike.

Formulação	$\ln L$	k	n	BIC		AIC	
				$\psi(k \ln n)$	BIC	$\psi(2k)$	AIC
<b>L1 na formulação GL</b>							
S1	-2091	3	533		8 4189	6	4187
S2D1	-2003	4	533		11 4018	8	4015
S3D1	-1957	5	533		14 3929	10	3925
S4D1	-1958	5	533		14 3929	10	3925
S2D2	-2035	4	533		11 4081	8	4078
S3D2	-1976	5	533		14 3966	10	3963
S4D2	-1977	5	533		14 3967	10	3964
<b>L5 na formulação ZI-GL</b>							
S1	-996	7	533		19 2011	14	2006
S2D1	-1015	8	533		22 2053	16	2047
S3D1	-971	9	533		25 1966	18	1959
S4D1	-971	9	533		25 1966	18	1960
S2D2	-951	8	533		22 1923	16	1918
S3D2	-945	9	533		25 1916	18	1909
S4D2	-945	9	533		25 1914	18	1908

### Floresta nativa – chuva líquida

	Calibração					Validação				
	P	V	C	$C^{y<2}$	$C^{y>2}$	P	V	C	$C^{y<2}$	$C^{y>2}$
S1	0,39	0,04	0,04	0,07	0,33	0,34	0,10	0,07	0,03	0,49
S2D1	0,56	0,28	0,04	0,05	0,39	0,51	0,21	0,04	0,05	0,30
S3D1	0,43	0,19	0,05	0,03	0,35	0,38	0,10	0,05	0,06	0,18
S4D1	0,43	0,19	0,04	0,03	0,34	0,38	0,10	0,05	0,06	0,19
S2D2	0,45	0,29	0,07	0,04	0,51	0,42	0,20	0,02	0,03	0,34
S3D2	0,38	0,23	0,07	0,04	0,52	0,34	0,14	0,02	0,04	0,29
S4D2	0,39	0,22	0,08	0,05	0,51	0,35	0,13	0,03	0,04	0,27

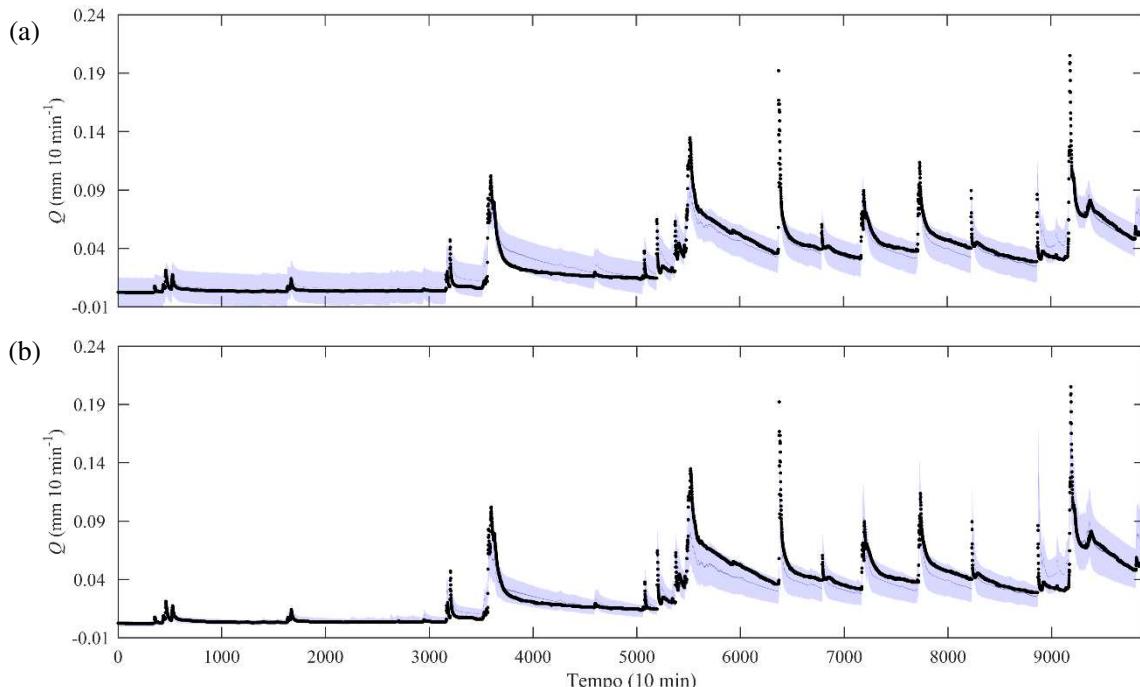
**Figura C8.** Métricas de desempenho para a floresta nativa obtidas para cada um dos modelos de interceptação (S1 a S4D2) utilizando a ZI-GL, com  $\sigma_0$  fixo em 3 mm d<sup>-1</sup>. P é a precisão, V o viés, C a confiabilidade,  $C^{y<2}$  a confiabilidade para chuva interna < 2 mm h<sup>-1</sup>,  $C^{y>2}$  a confiabilidade para chuva interna > 2 mm h<sup>-1</sup>.

**Tabela C2.** Critérios de informação ( $I_k$ ) para as diferentes formulações do processo de interceptação. Valores calculados para a vegetação nativa para o período de calibração. L indica o valor (máximo) da função de verossimilhança, k é a dimensão do problema, n é o número de dados utilizado,  $\psi$  é o termo que penaliza a complexidade, BIC é o critério de informação de Bayes e AIC é o critério de informação de Akaike.

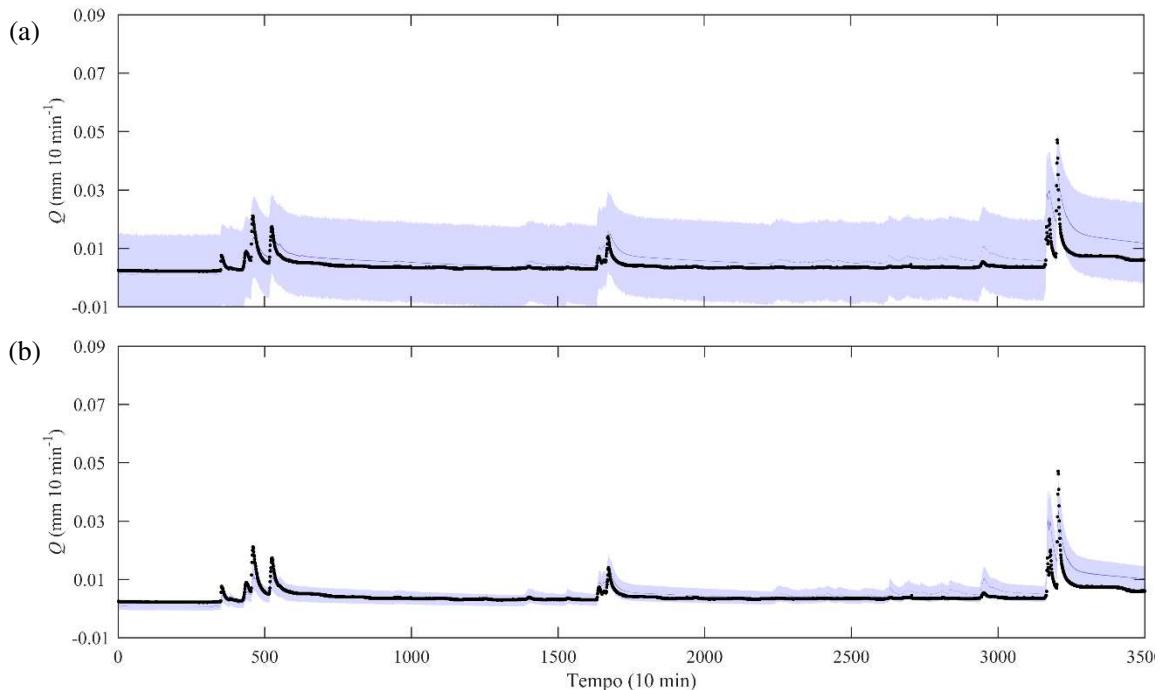
Formulação	$\ln L$	k	n	BIC		AIC	
				$\psi(k \ln n)$	BIC	$\psi(2k)$	AIC
<b>L1 na formulação GL</b>							
S1	-2274	3	669	8	4557	6	4555
S2D1	-2536	4	669	11	5083	8	5080
S3D1	-2195	5	669	14	4404	10	4400
S4D1	-2333	5	669	14	4680	10	4676
S2D2	-2367	4	669	11	4744	8	4741
S3D2	-2136	5	669	14	4286	10	4281
S4D2	-2265	5	669	14	4543	10	4539
<b>L5 na formulação ZI-GL</b>							
S1	-1192	7	669	20	2404	14	2398
S2D1	-1171	8	669	23	2365	16	2358
S3D1	-1133	9	669	25	2291	18	2283
S4D1	-1132	9	669	25	2290	18	2283
S2D2	-1030	8	669	23	2083	16	2077
S3D2	-1044	9	669	25	2113	18	2106
S4D2	-1043	9	669	25	2112	18	2104



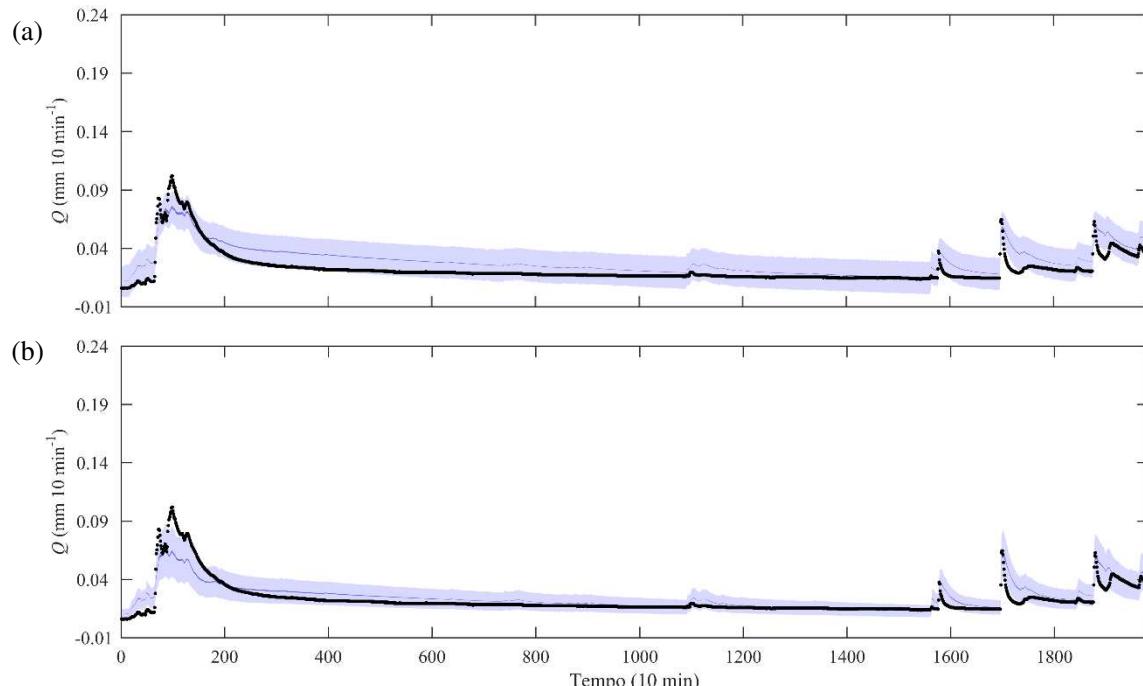
**APÊNDICE D****ESCOLHA DA FUNÇÃO DE VEROSSIMILHANÇA NA  
MODELAGEM DO PROCESSO CHUVA-VAZÃO**



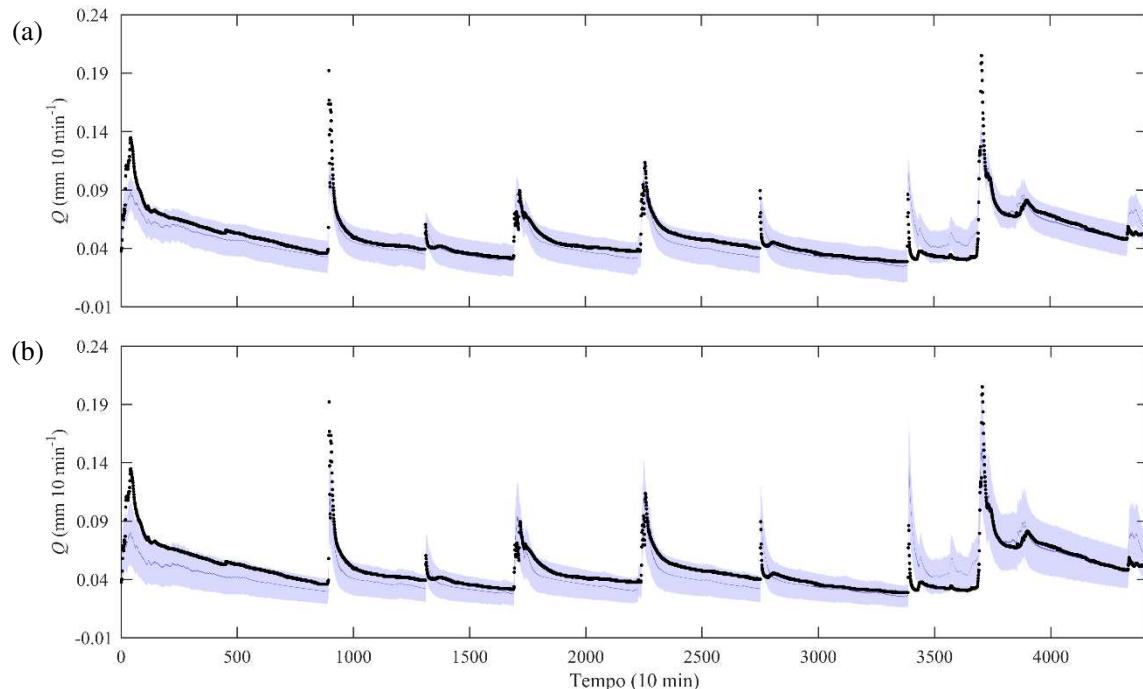
**Figura D1.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci, utilizando o modelo para resíduos L1 (paineel superior) e L3 (paineel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.



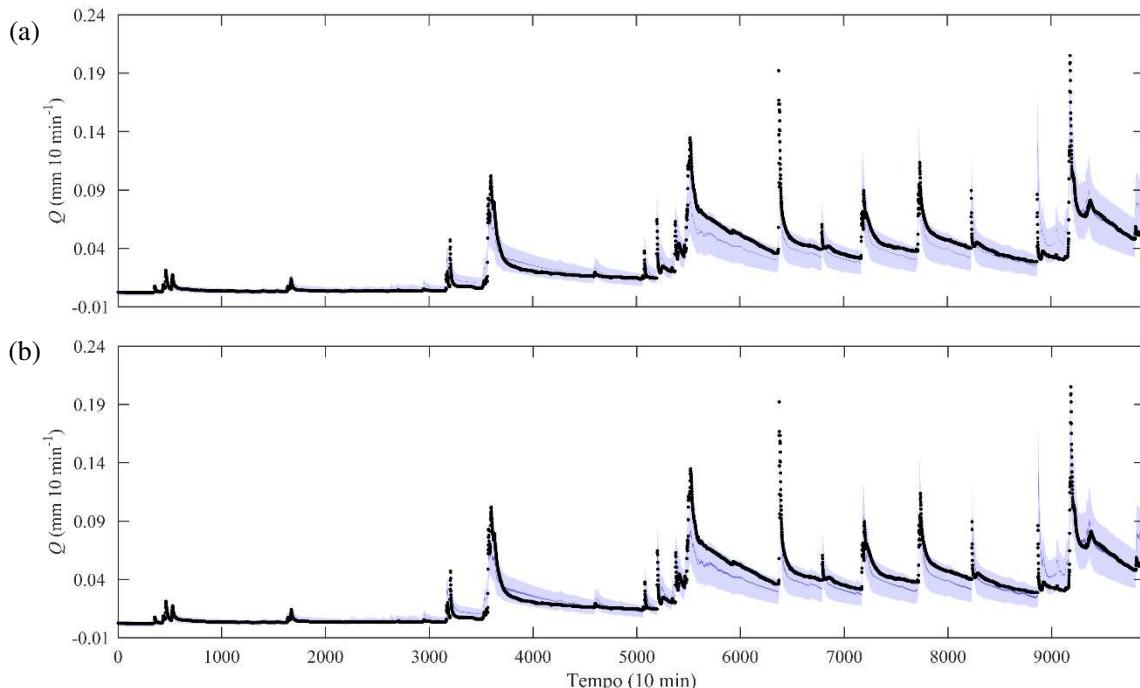
**Figura D2.** Série A. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.



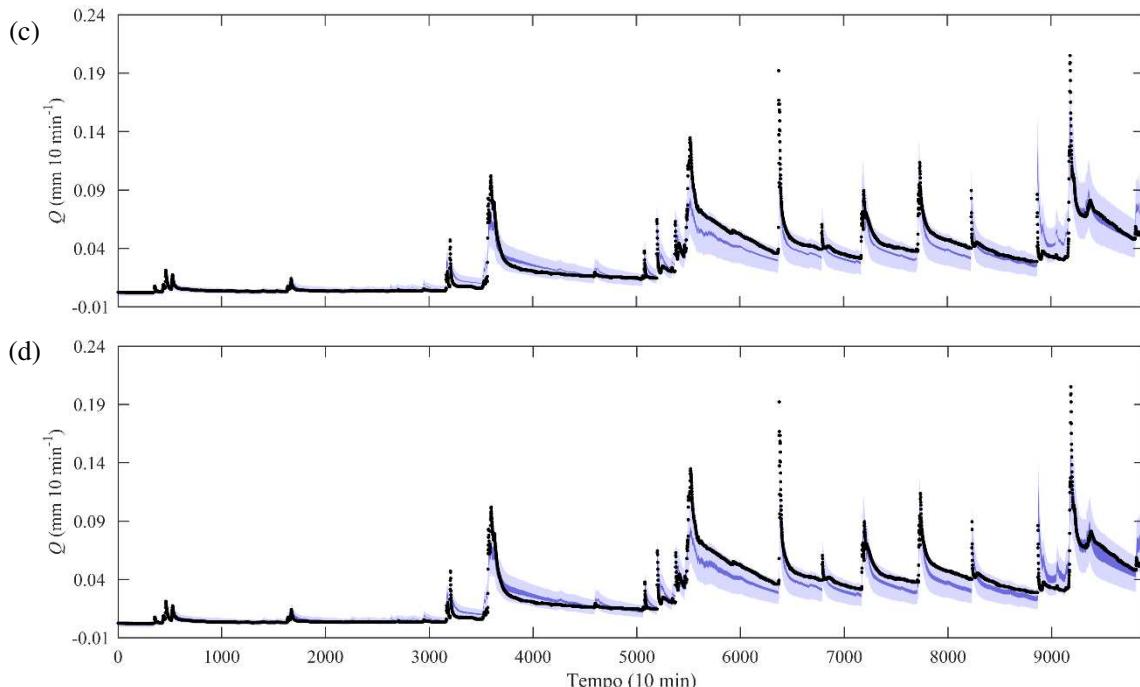
**Figura D3.** Série B. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.



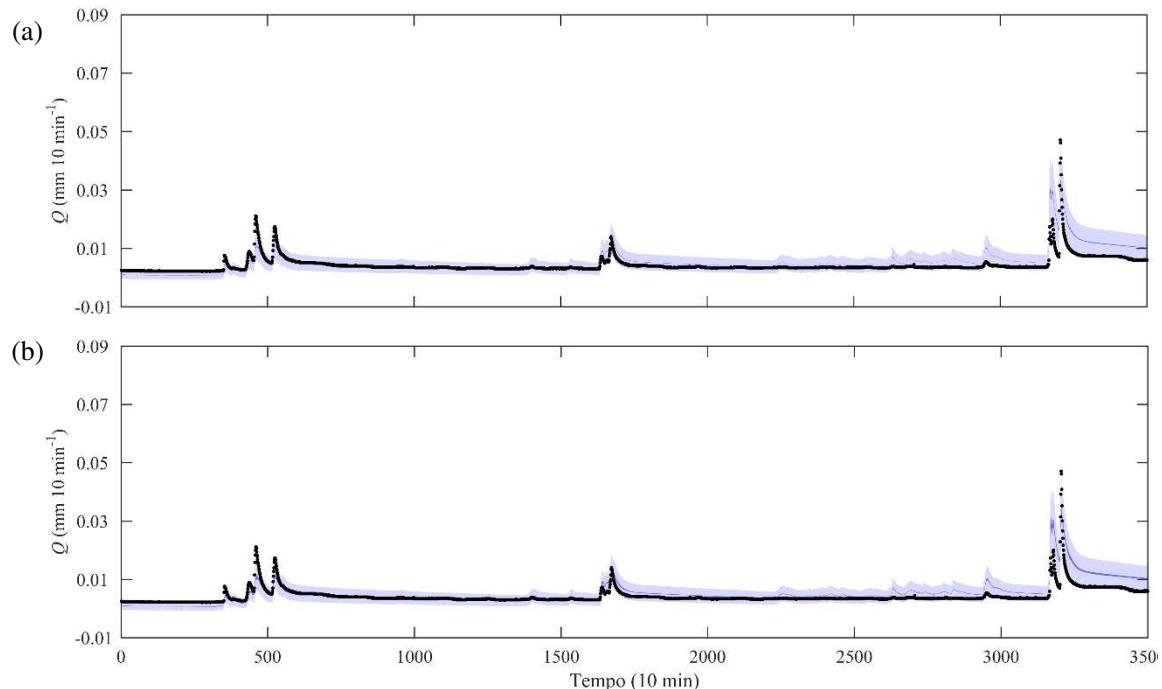
**Figura D4.** Série C. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e chuva total como entrada.



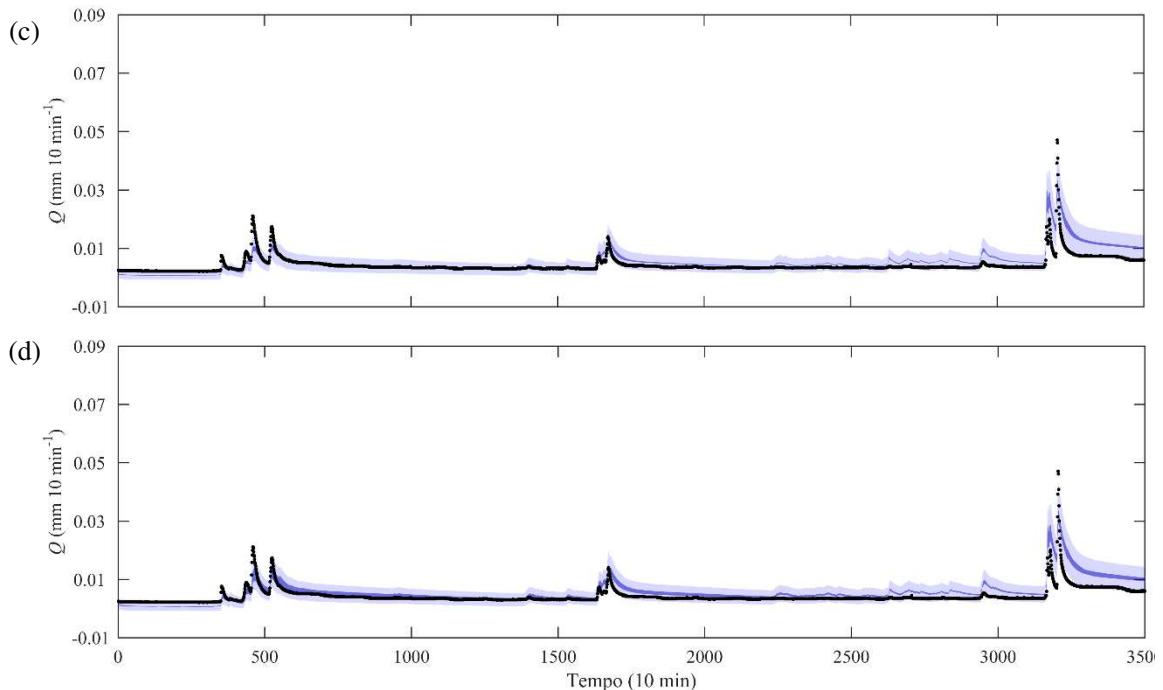
**Figura D5.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continua).



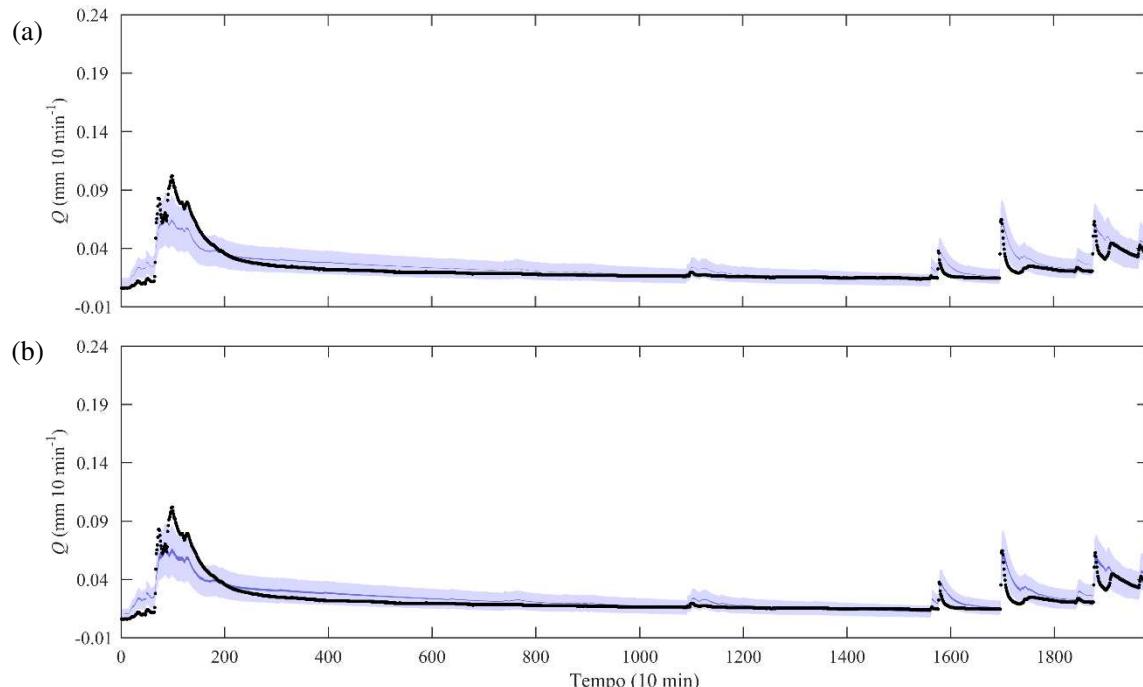
**Figura D5.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continuação).



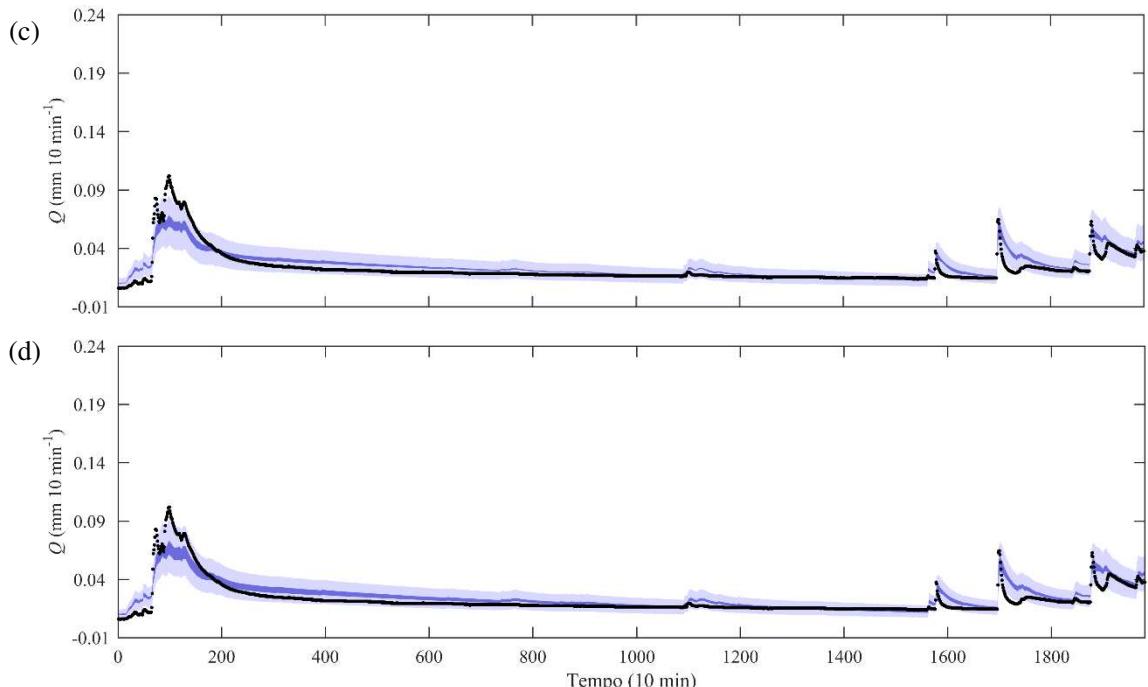
**Figura D6.** Série A. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continua).



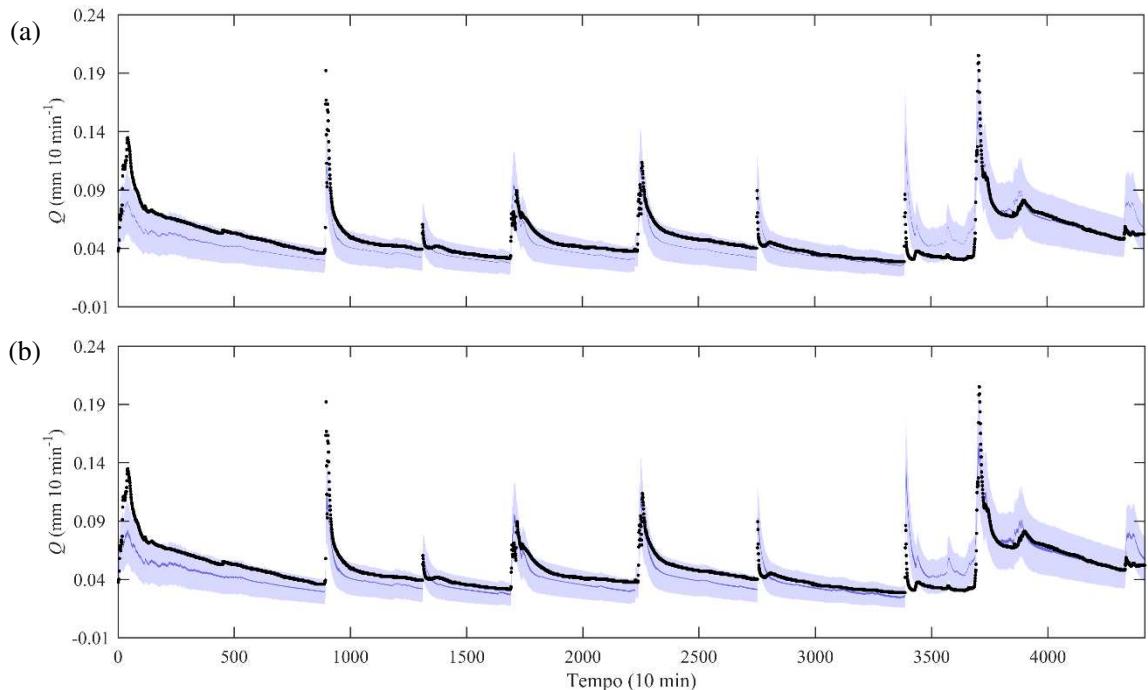
**Figura D6.** Série A. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continuação).



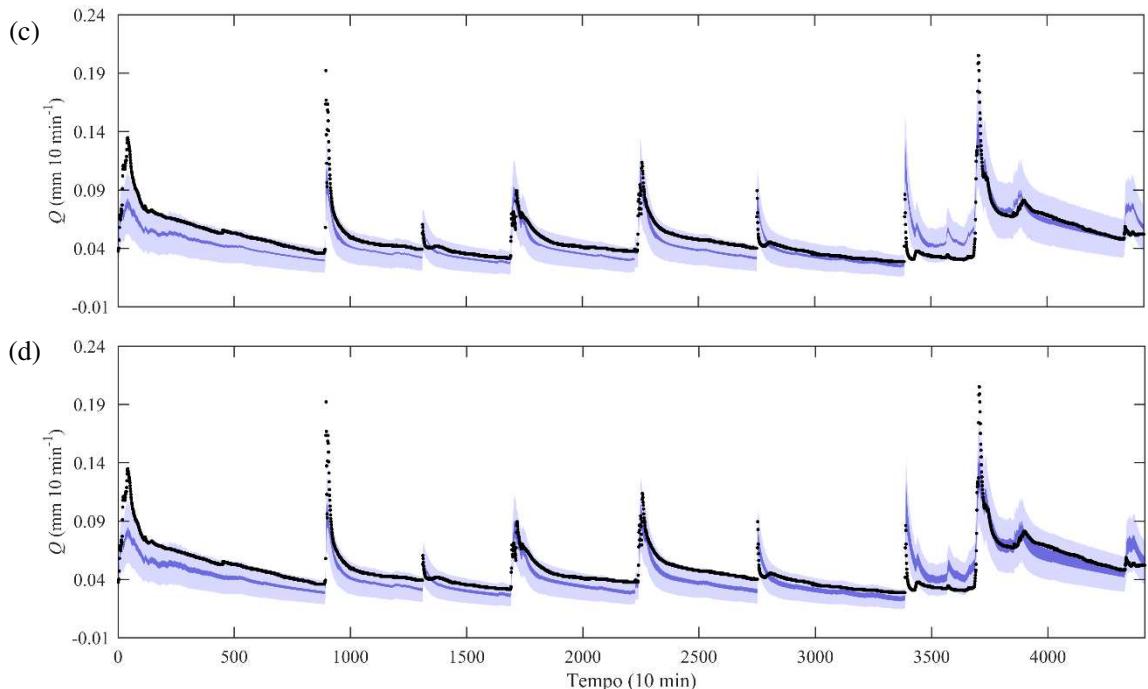
**Figura D7.** Série B. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continua).



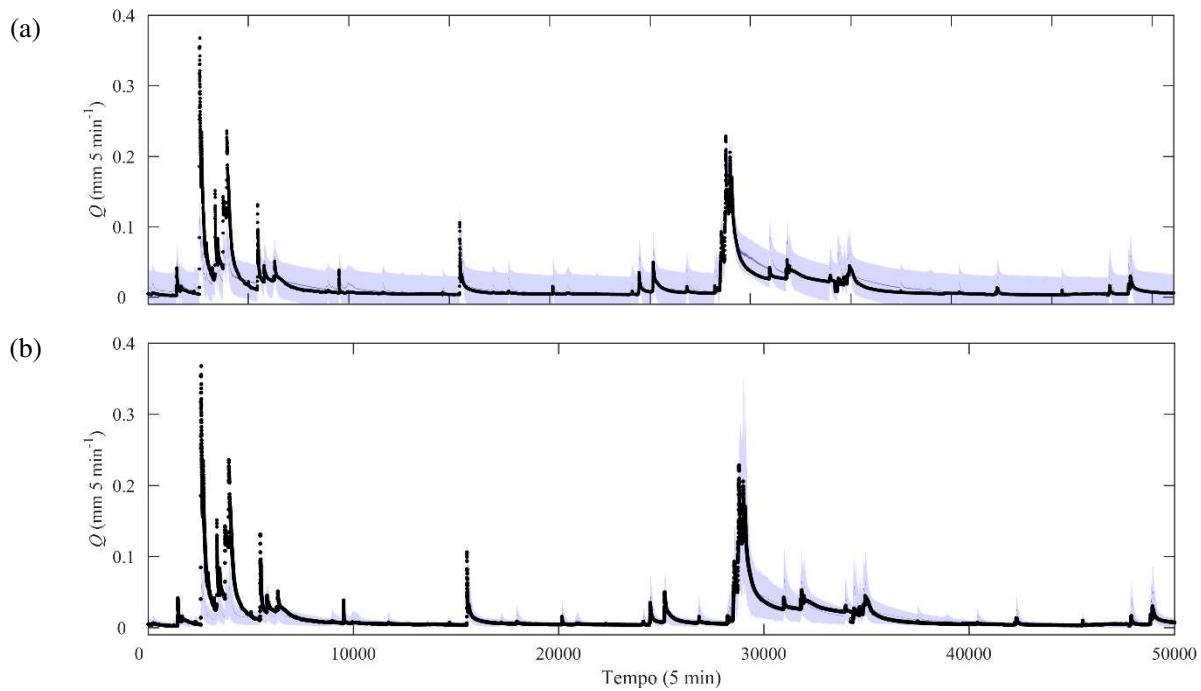
**Figura D7.** Série B. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimização igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continuação).



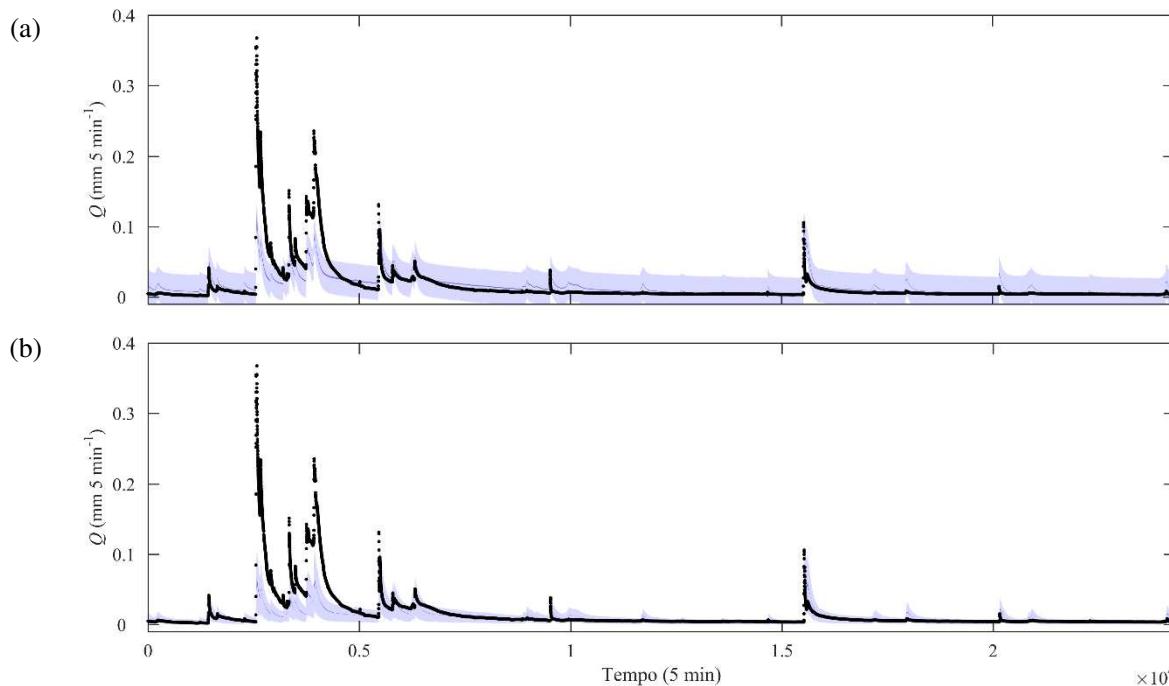
**Figura D8.** Série C. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continua).



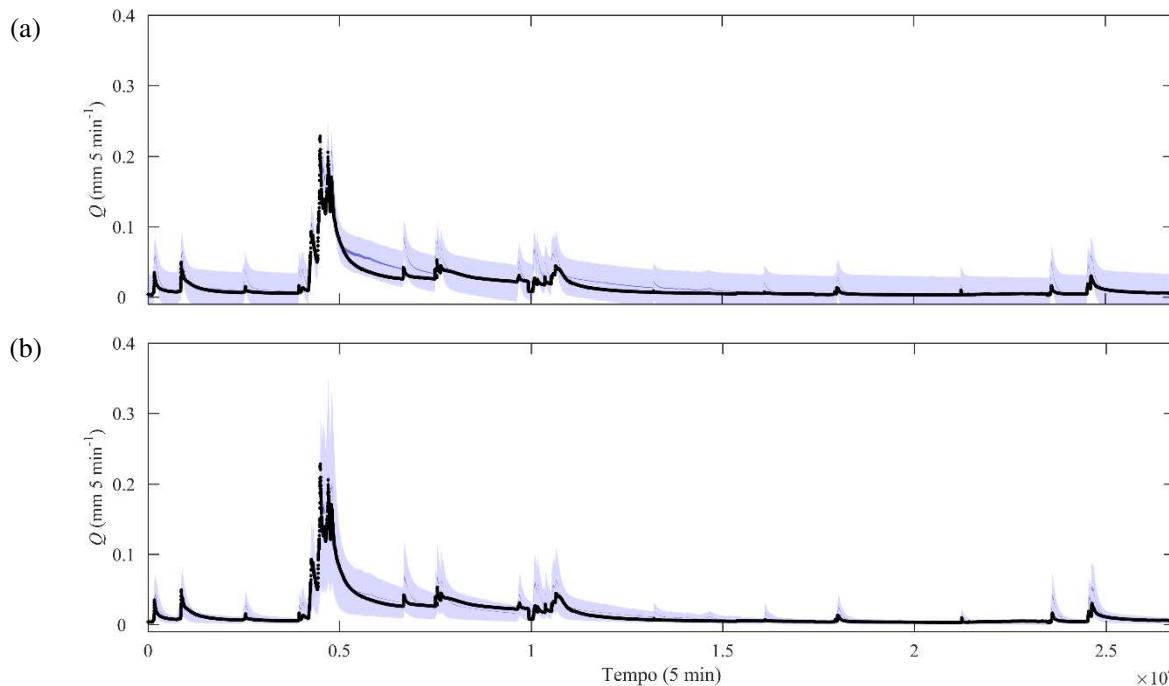
**Figura D8.** Série C. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 1 (um dado a cada 10 min), (b) 6 (um dado a cada hora), (c) 18 (um dado a cada 3 horas) e (d) 72 (um dado a cada 12 horas) e chuva total como entrada (continuação).



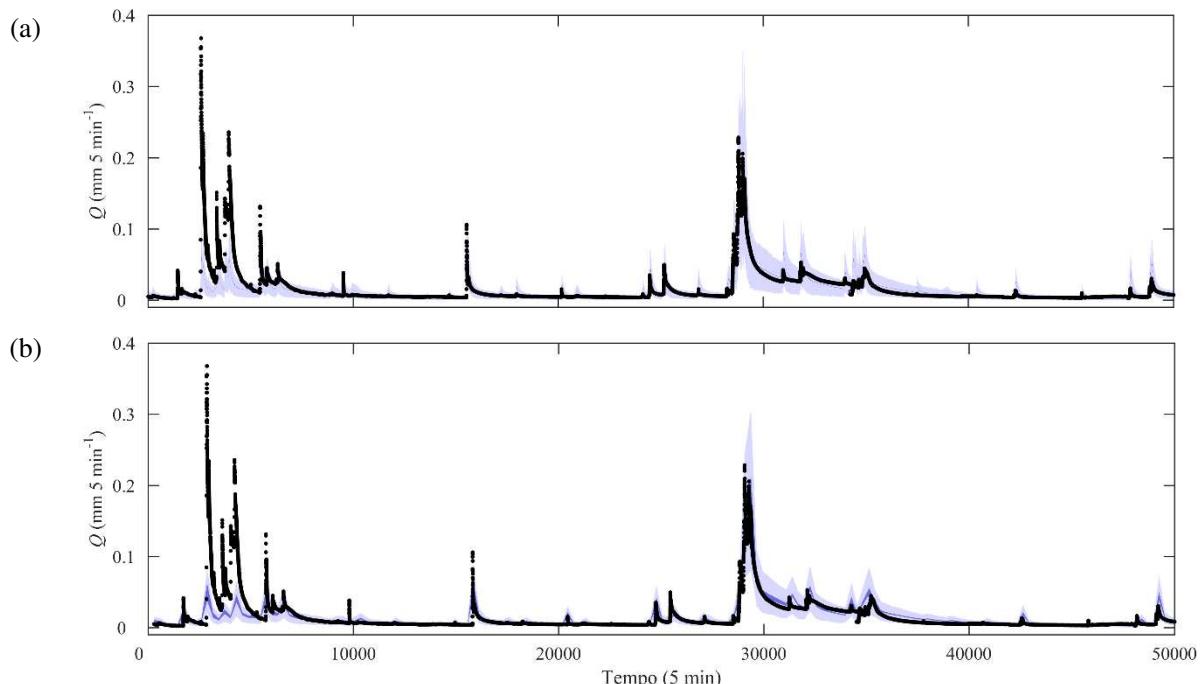
**Figura D9.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e decimação de 12 (um dado por hora) e chuva total como entrada.



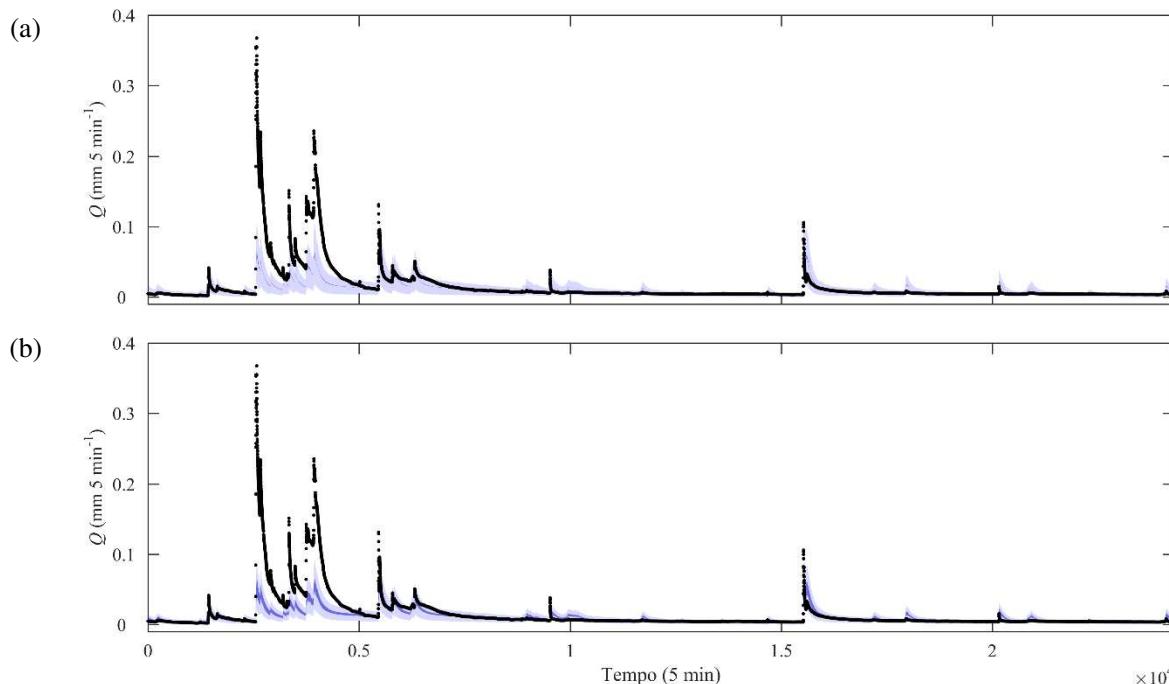
**Figura D10.** Série A. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e decimação de 12 (um dado por hora) e chuva total como entrada.



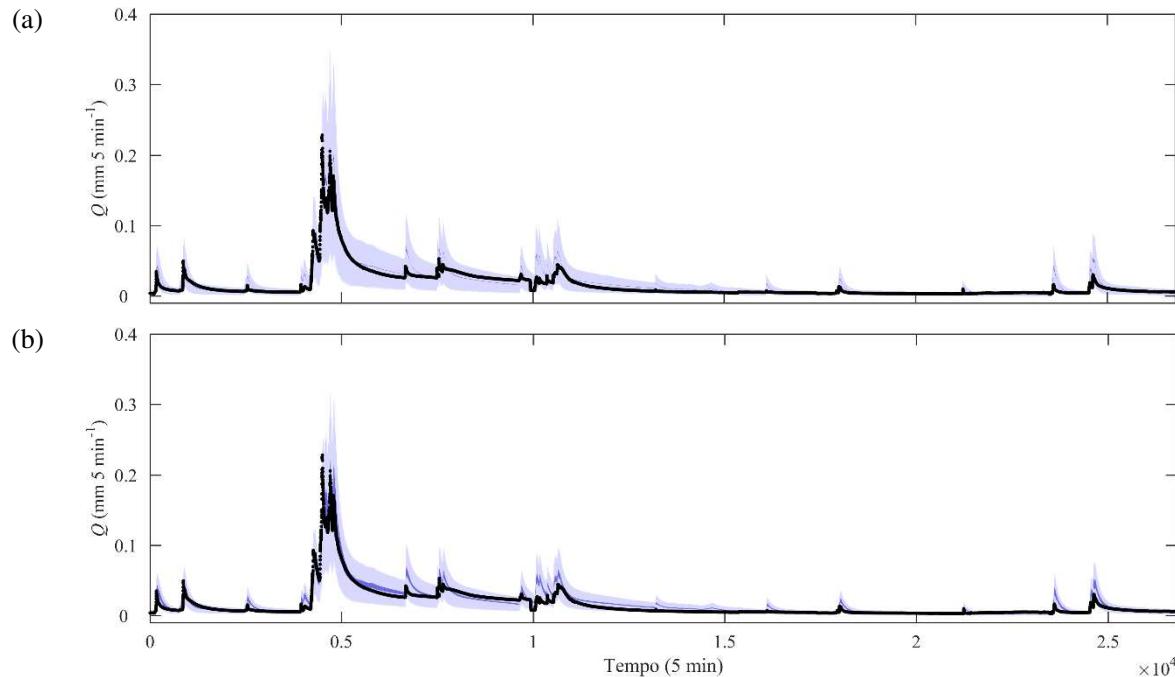
**Figura D11.** Série B. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga, utilizando o modelo para resíduos L1 (painel superior) e L3 (painel inferior). Calibração realizada com dados de vazão da série completa com dados de 10 min e decimação de 12 (um dado por hora) e chuva total como entrada.



**Figura D12.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 12 (um dado a cada hora) e (b) 288 (um dado a cada dia) e chuva total como entrada.



**Figura D13.** Série A. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 12 (um dado a cada hora) e (b) 288 (um dado a cada dia) e chuva total como entrada.

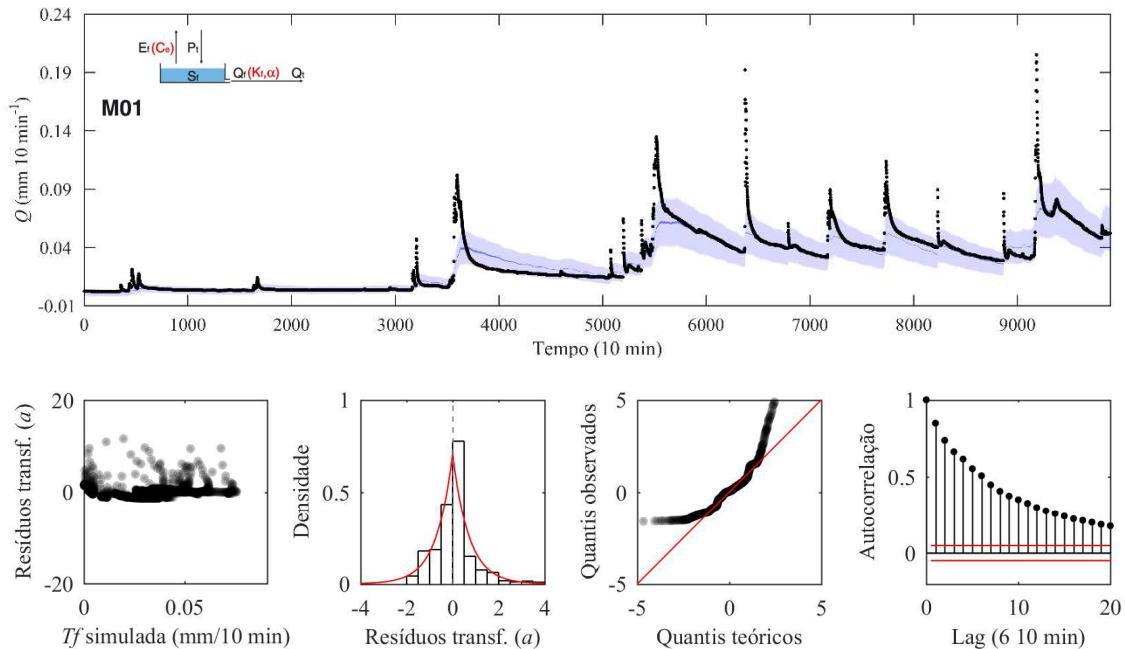


**Figura D14.** Série B. Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a (a) 12 (um dado a cada hora) e (b) 288 (um dado a cada dia) e chuva total como entrada.

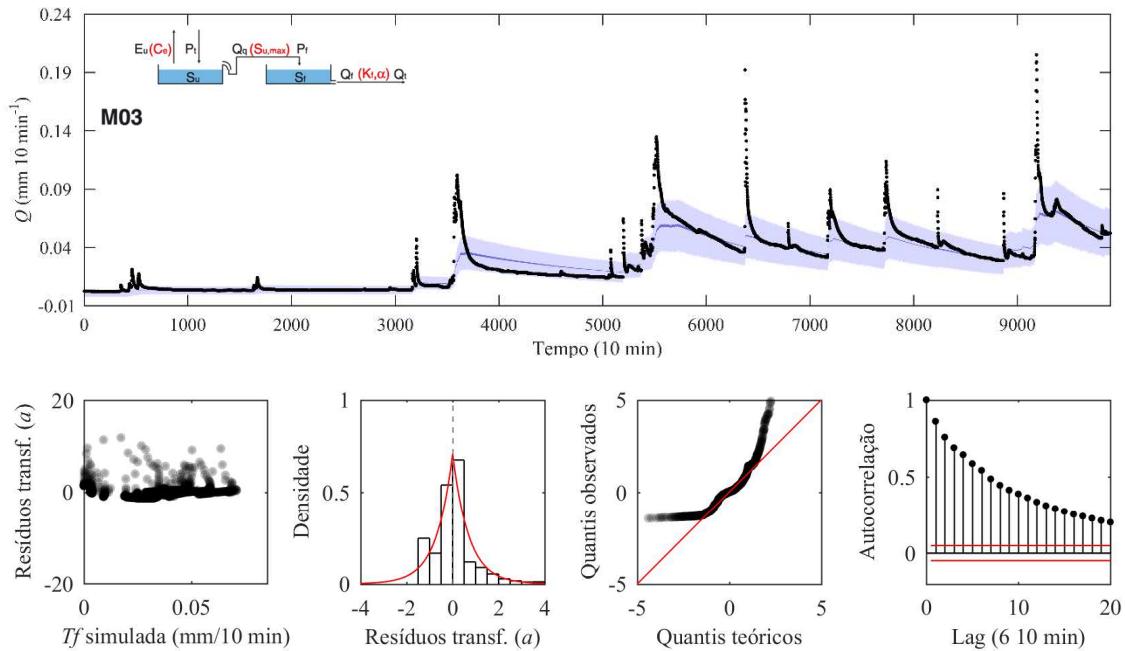


**APÊNDICE E**

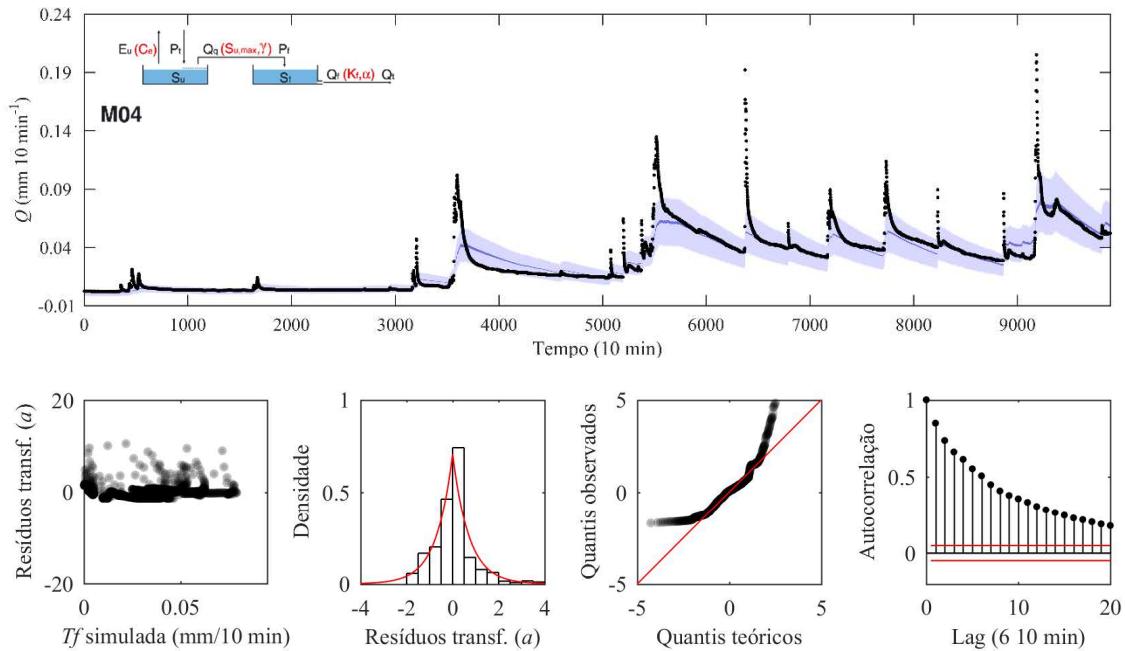
**COMPARAÇÃO ENTRE MODELOS CHUVA-VAZÃO**



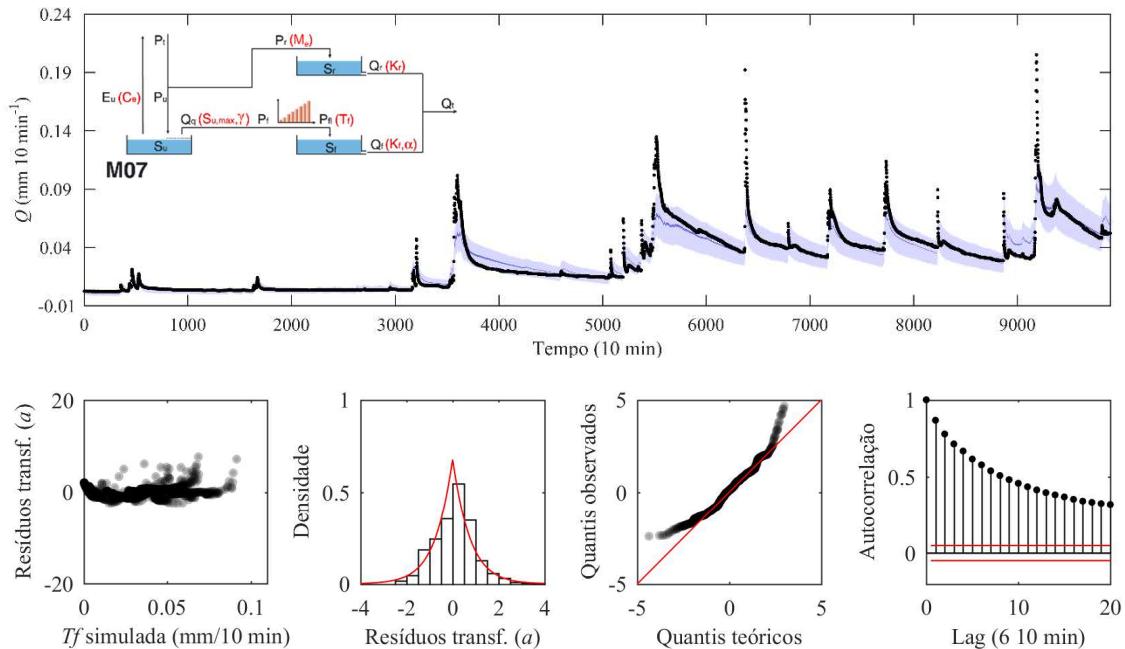
**Figura E1.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M01** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



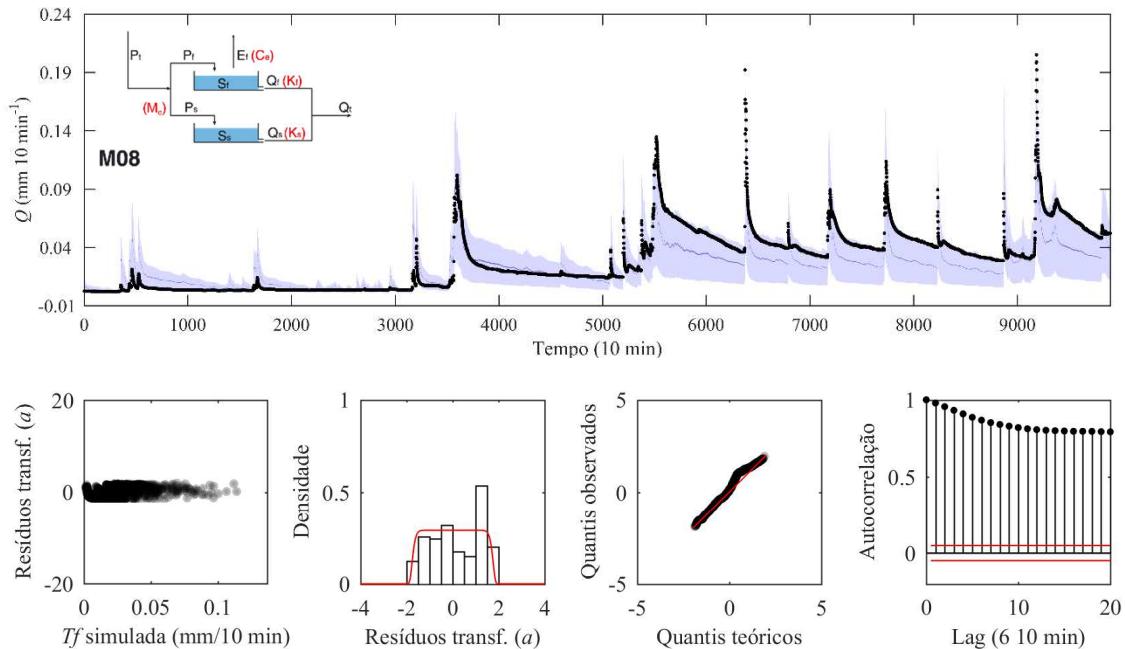
**Figura E2.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M03** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



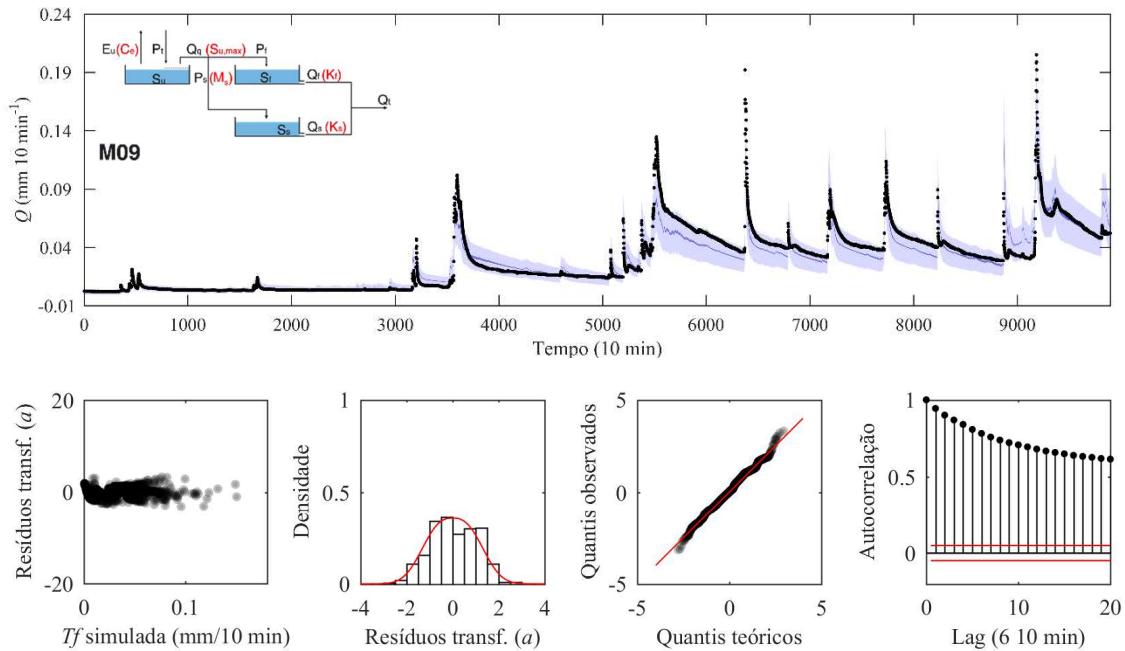
**Figura E3.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M04** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



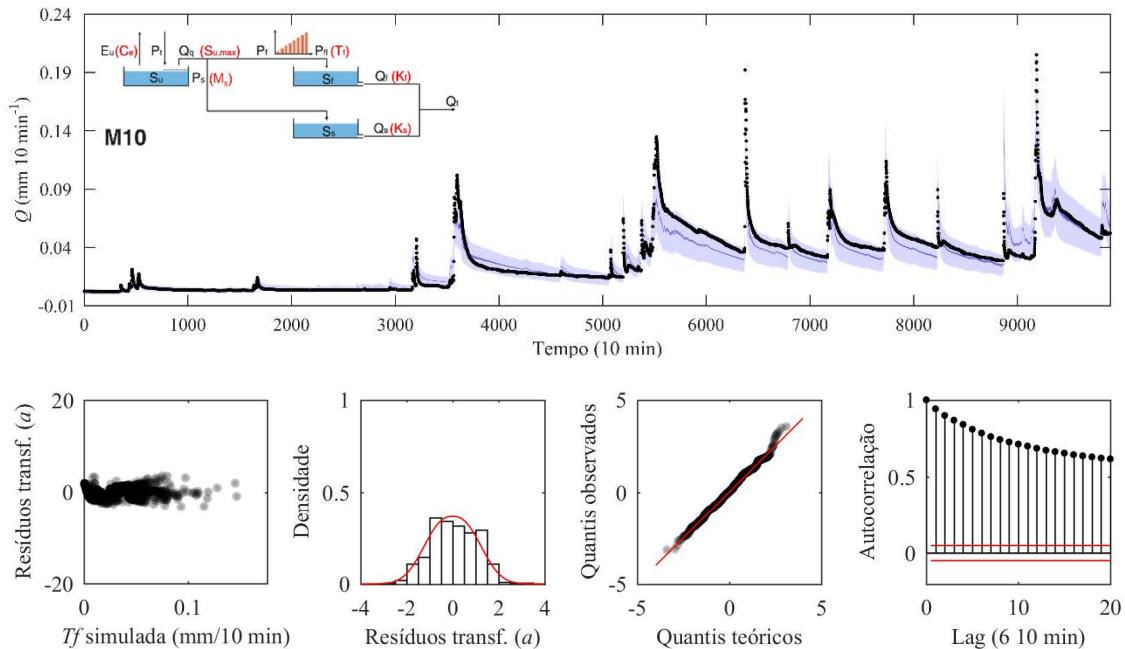
**Figura E4.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M07** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



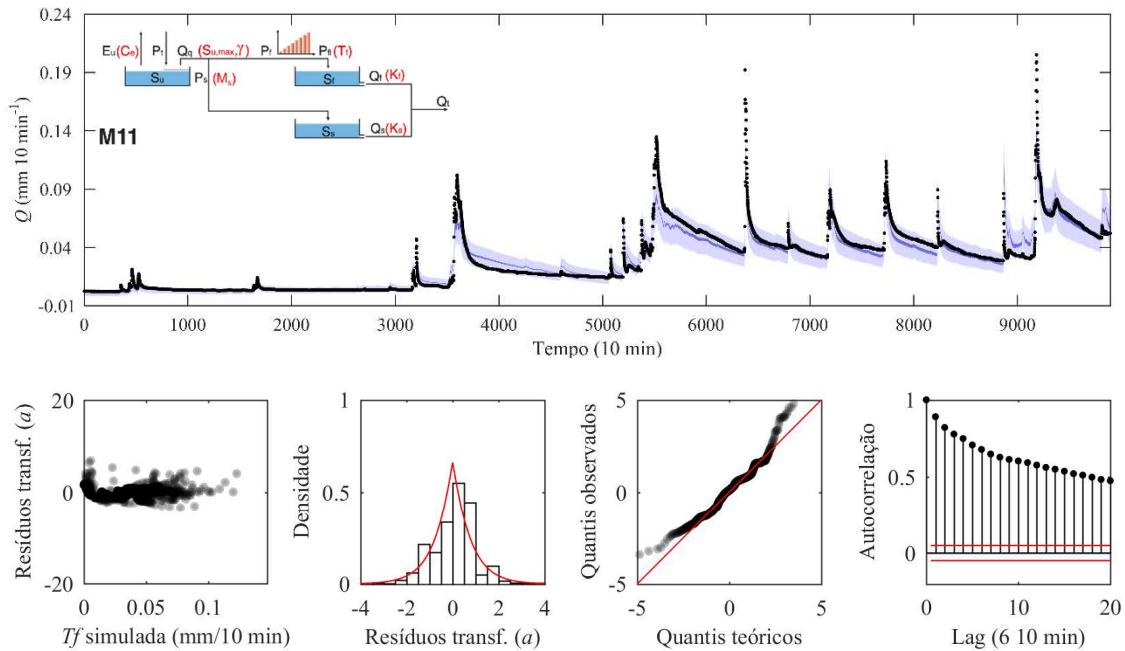
**Figura E5.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M08** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



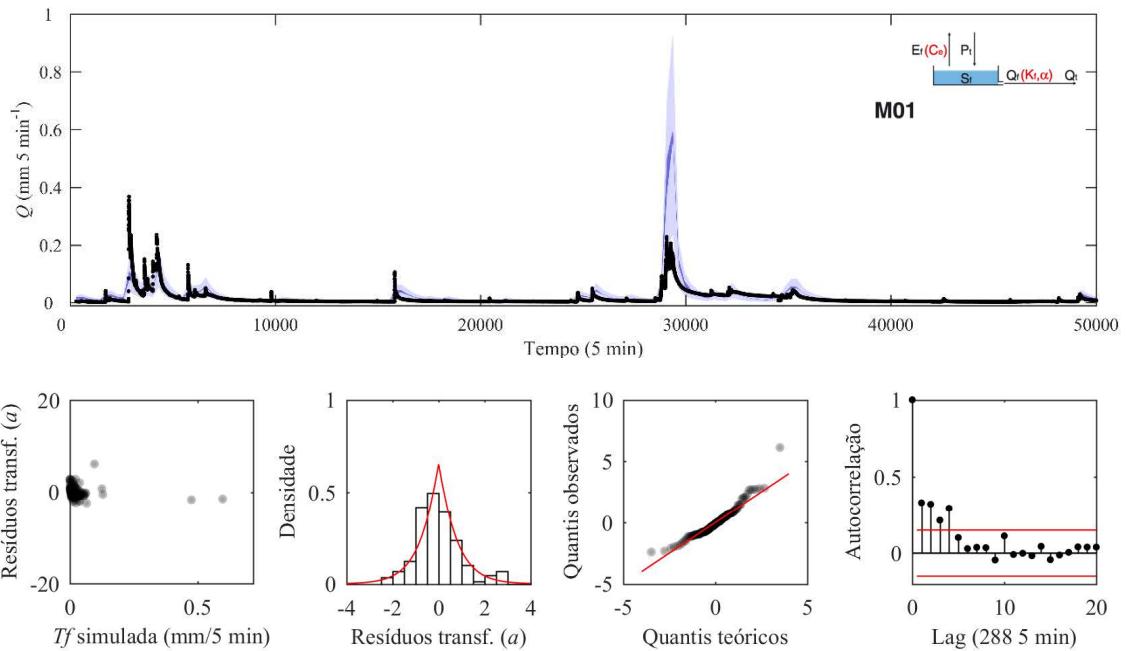
**Figura E6.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M09** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



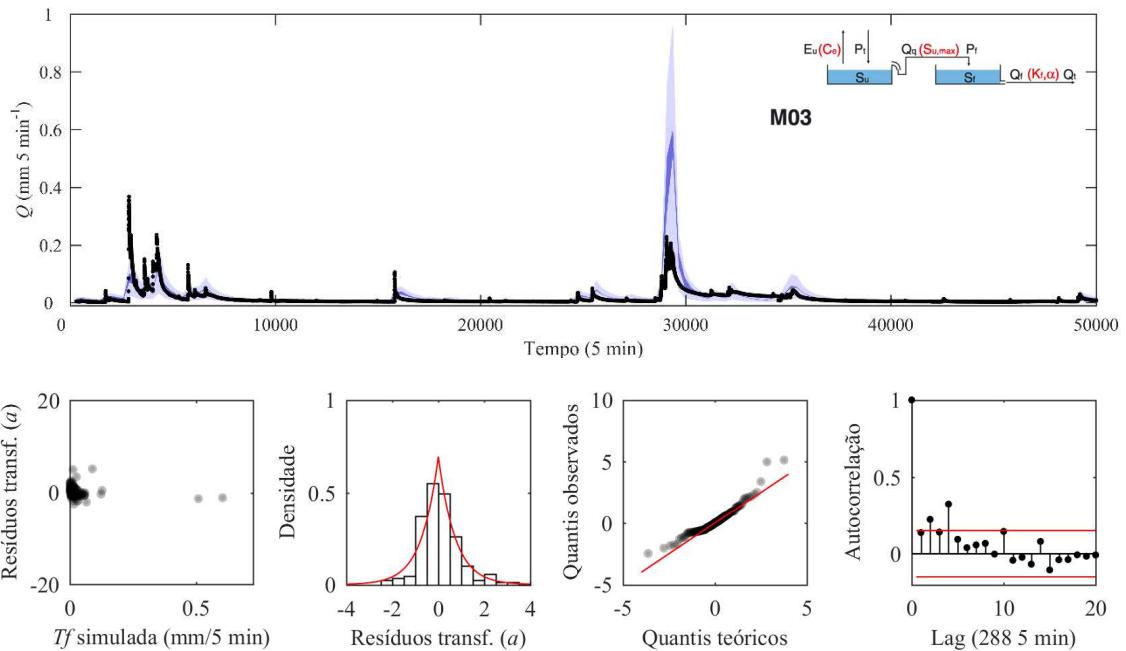
**Figura E7.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M10** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



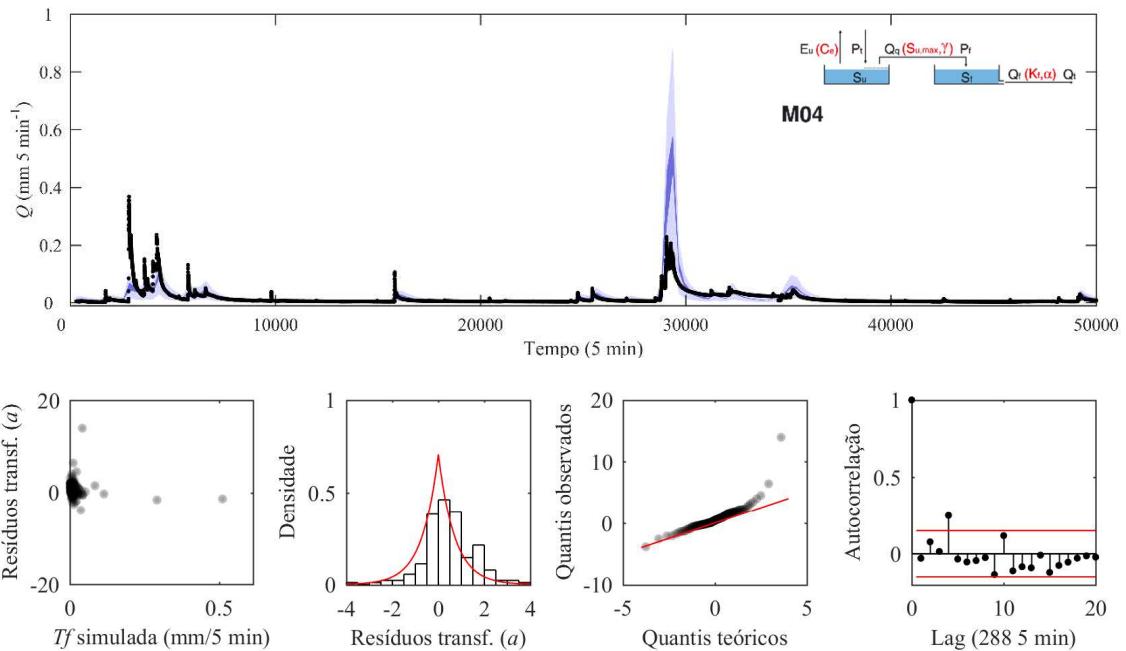
**Figura E8.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Saci**. Calibração realizada com o modelo **M11** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



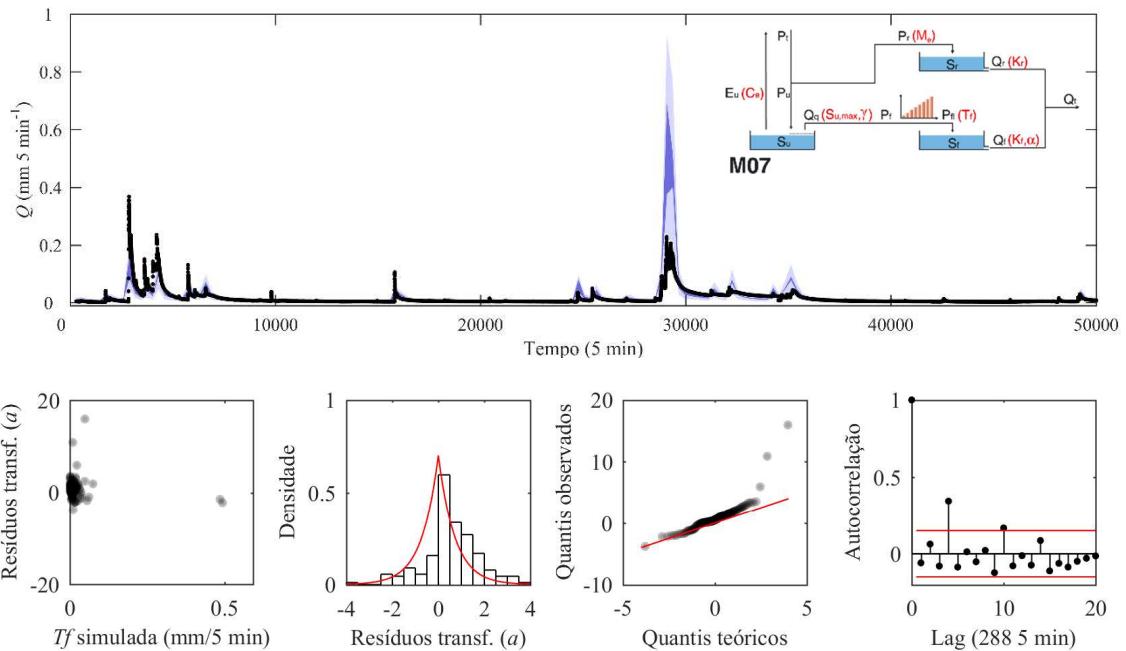
**Figura E9.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M01** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



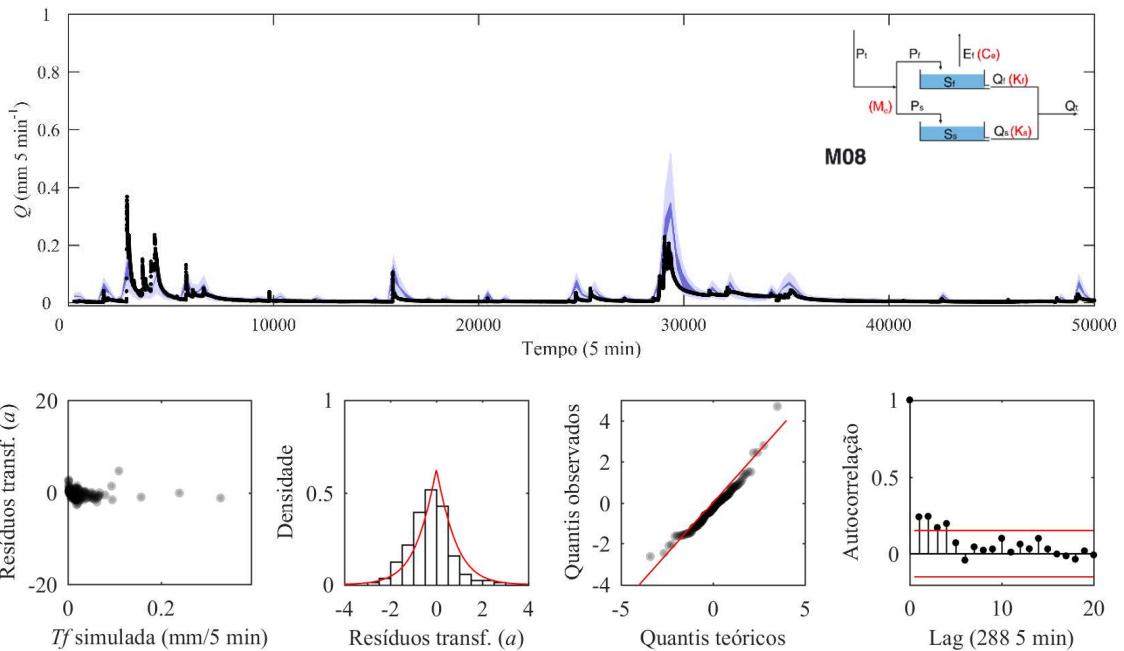
**Figura E10.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M03** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



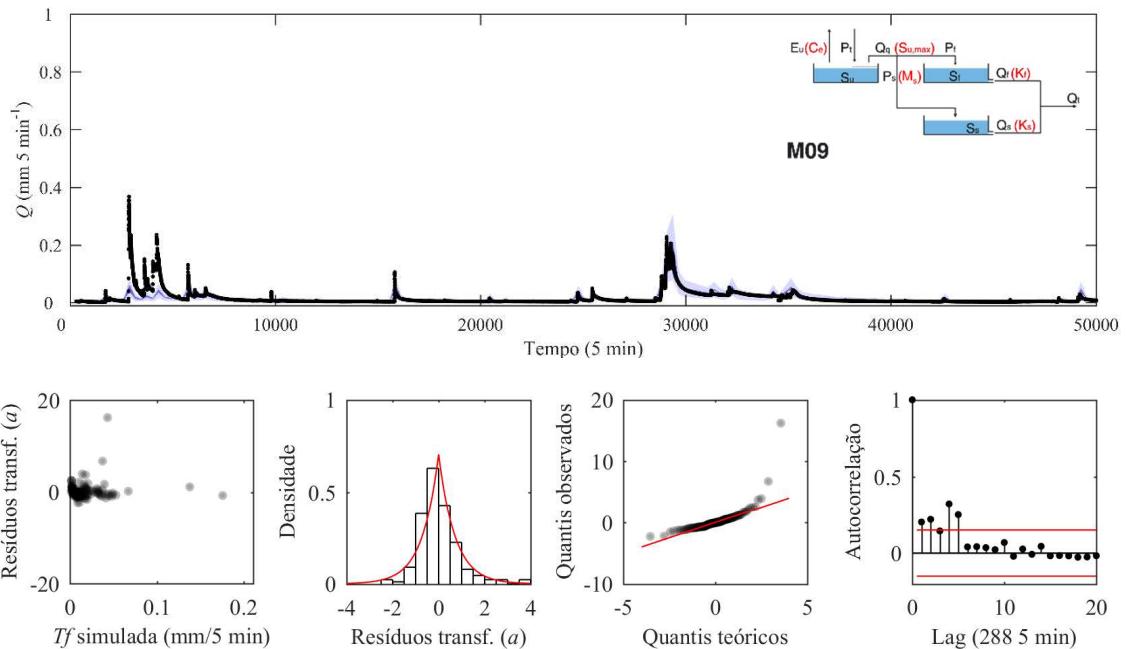
**Figura E11.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M04** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



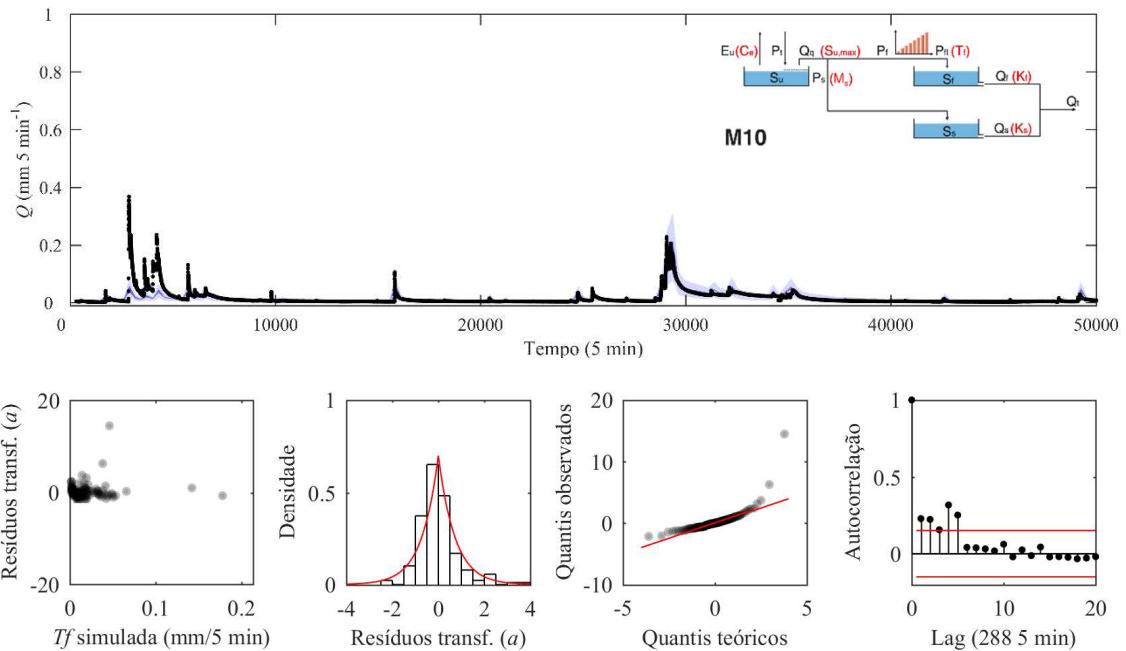
**Figura E12.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M07** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).

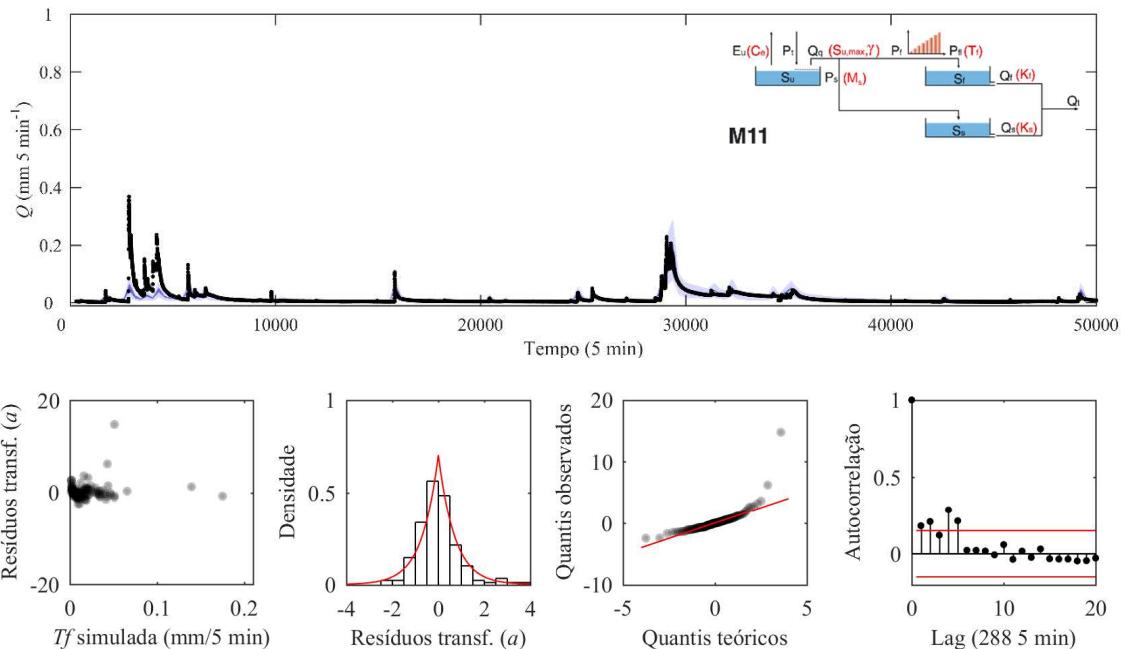


**Figura E13.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M08** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



**Figura E14.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M09** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).

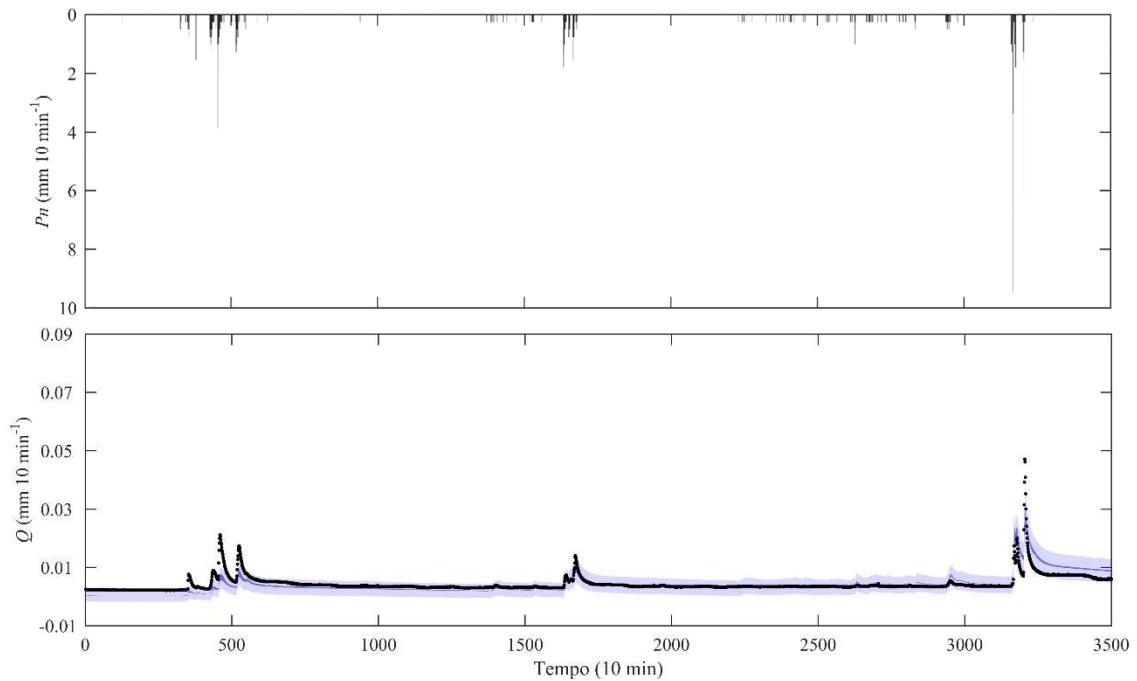




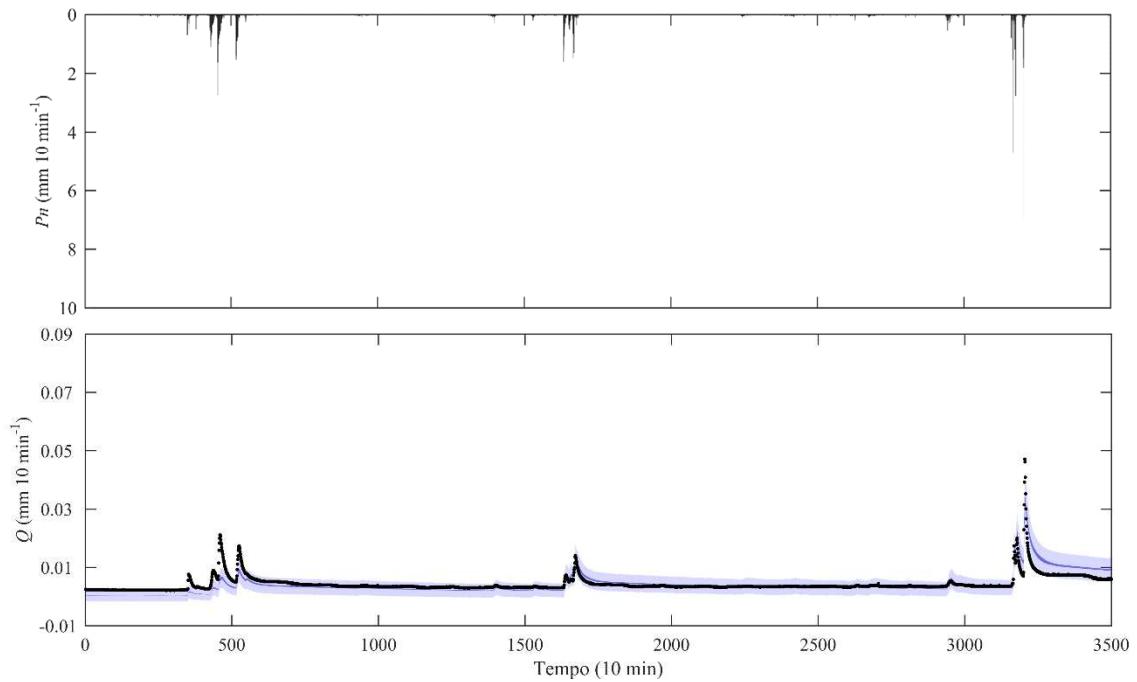
**Figura E16.** Série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a **bacia do rio Araponga**. Calibração realizada com o modelo **M11** e dados de vazão da série completa com decimação igual a 288 (um dado por dia).



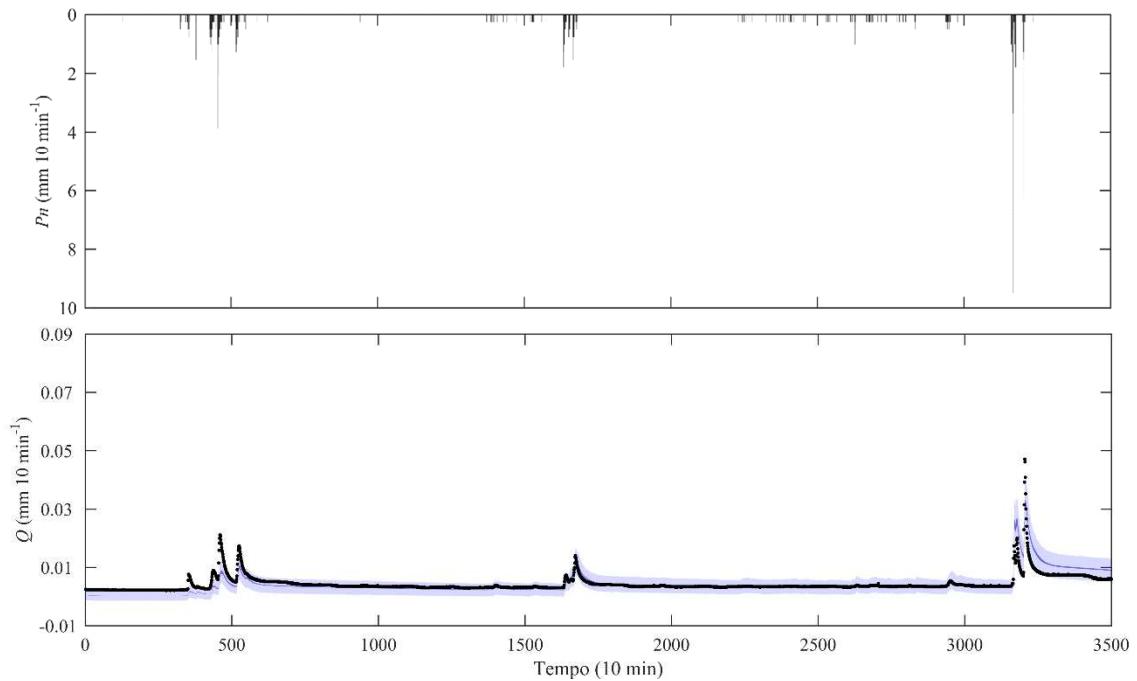
**APÊNDICE F****INFLUÊNCIA DO PROCESSO DE INTERCEPTAÇÃO NA  
MODELAGEM CHUVA-VAZÃO**



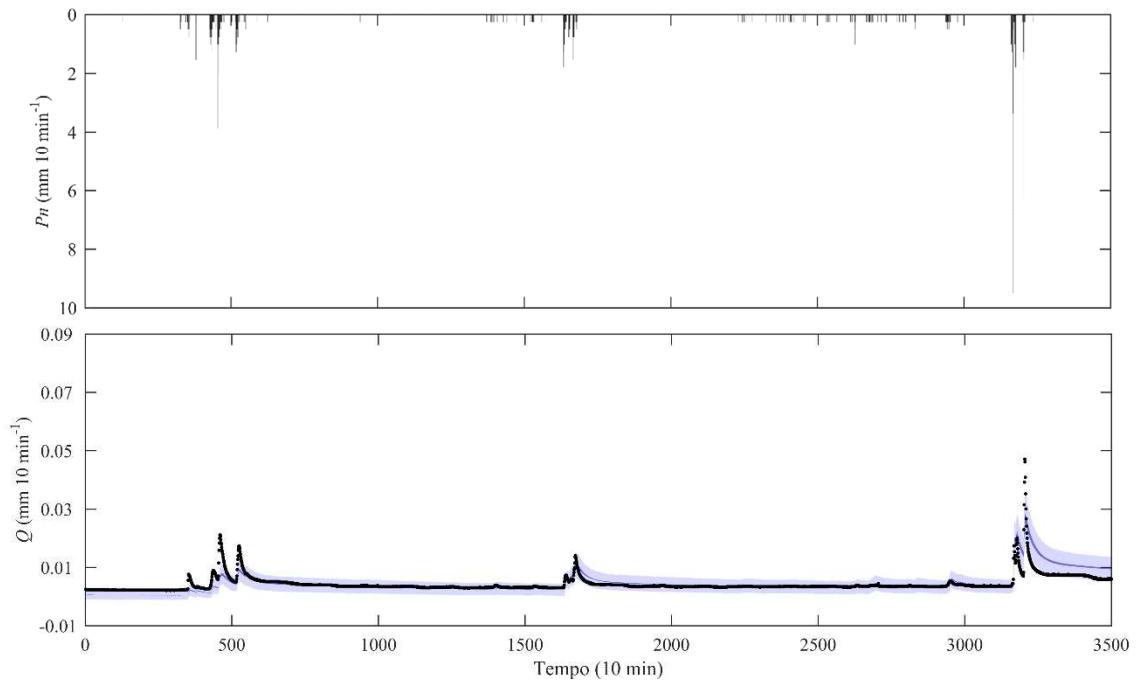
**Figura F1.** Série A. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva total como entrada.



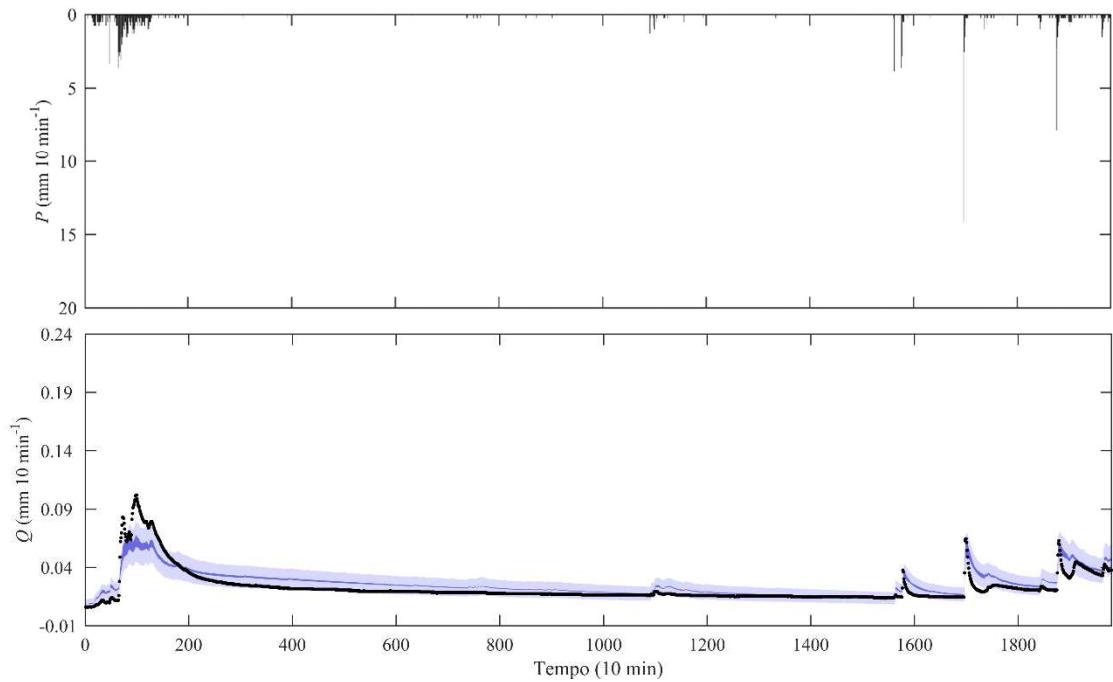
**Figura F2.** Série A. Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva líquida como entrada.



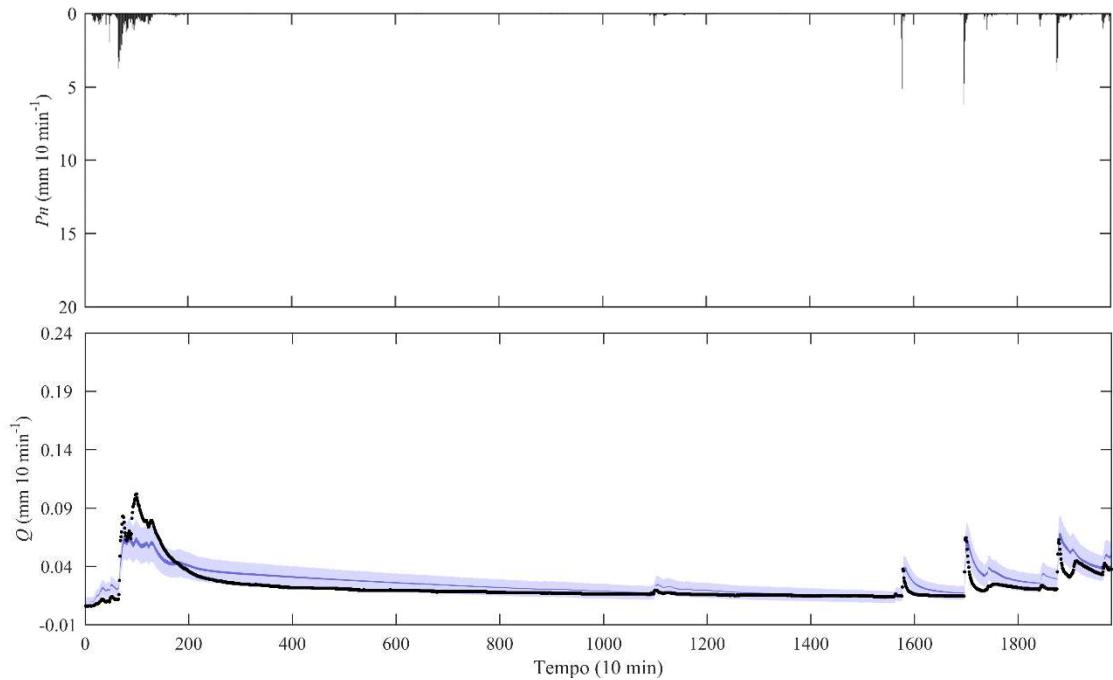
**Figura F3.** Série A. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (parâmetros de interceptação fixos)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva total como entrada.



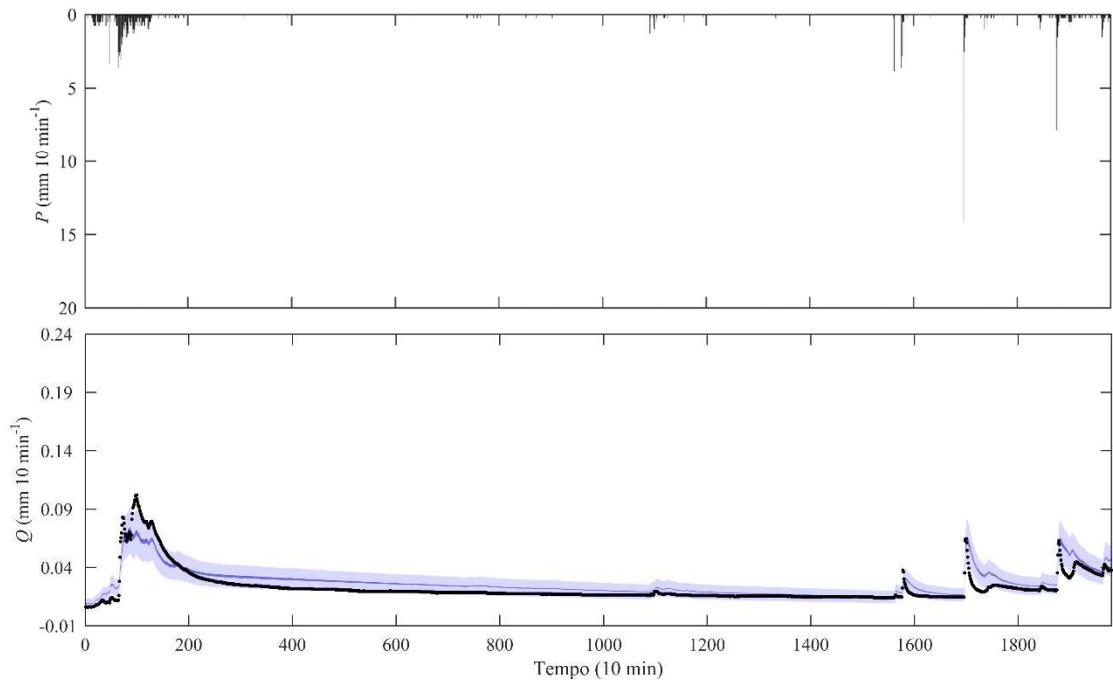
**Figura F4.** Série A. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, M11 (**parâmetros de interceptação calibrados**) e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.



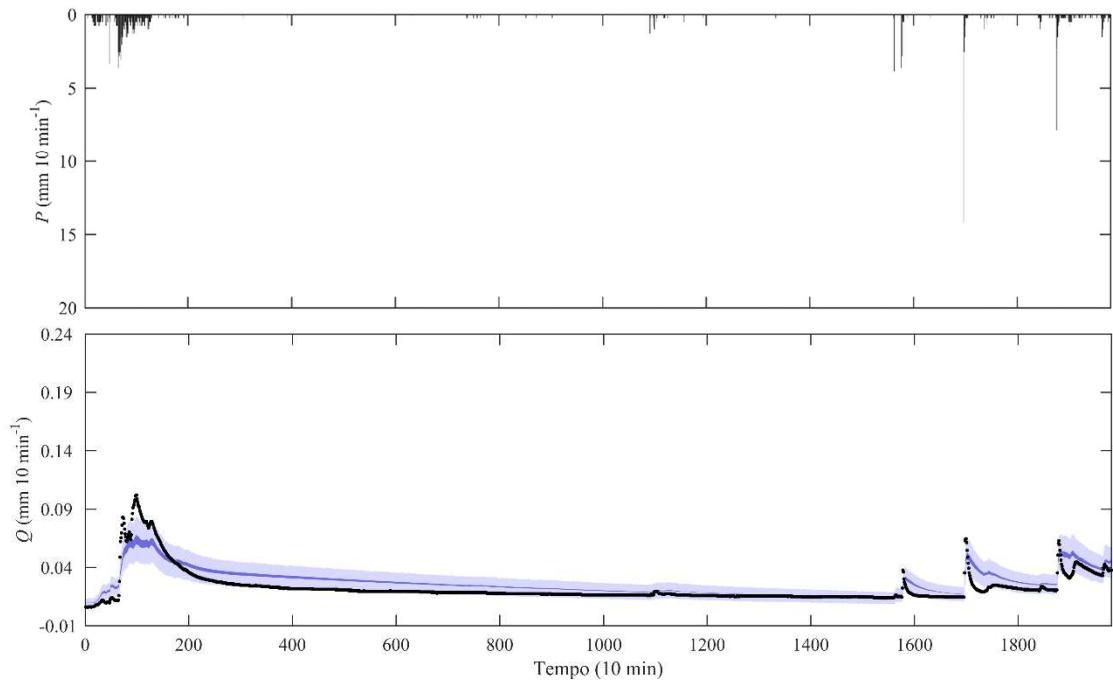
**Figura F5.** Série B. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva total como entrada.



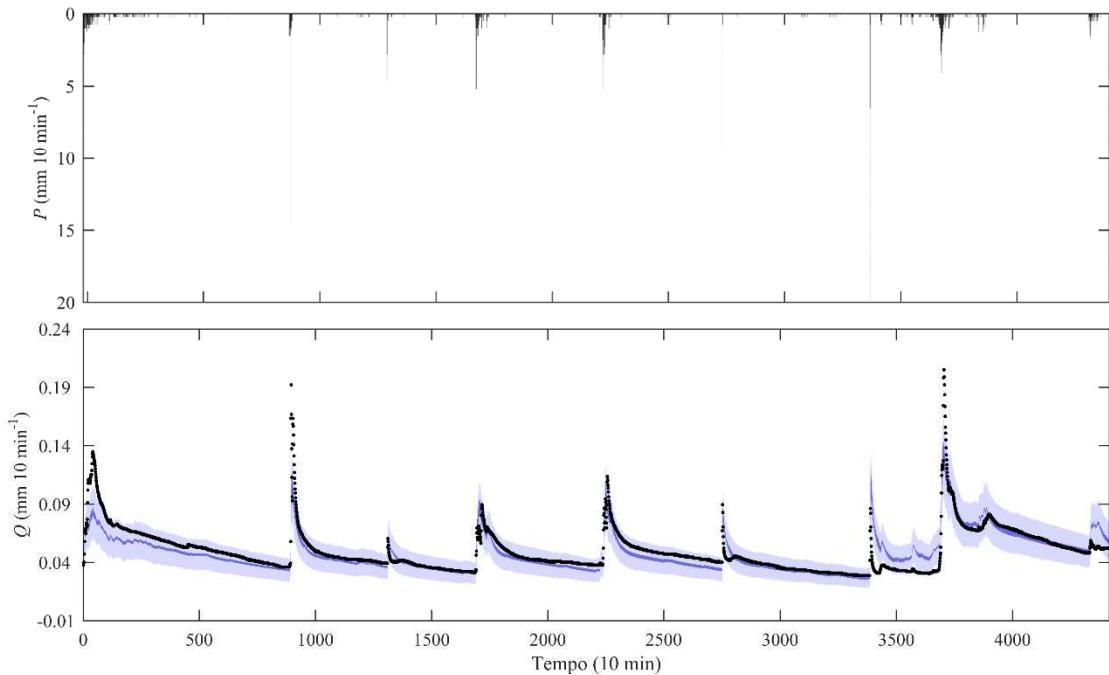
**Figura F6.** Série B. Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva líquida como entrada.



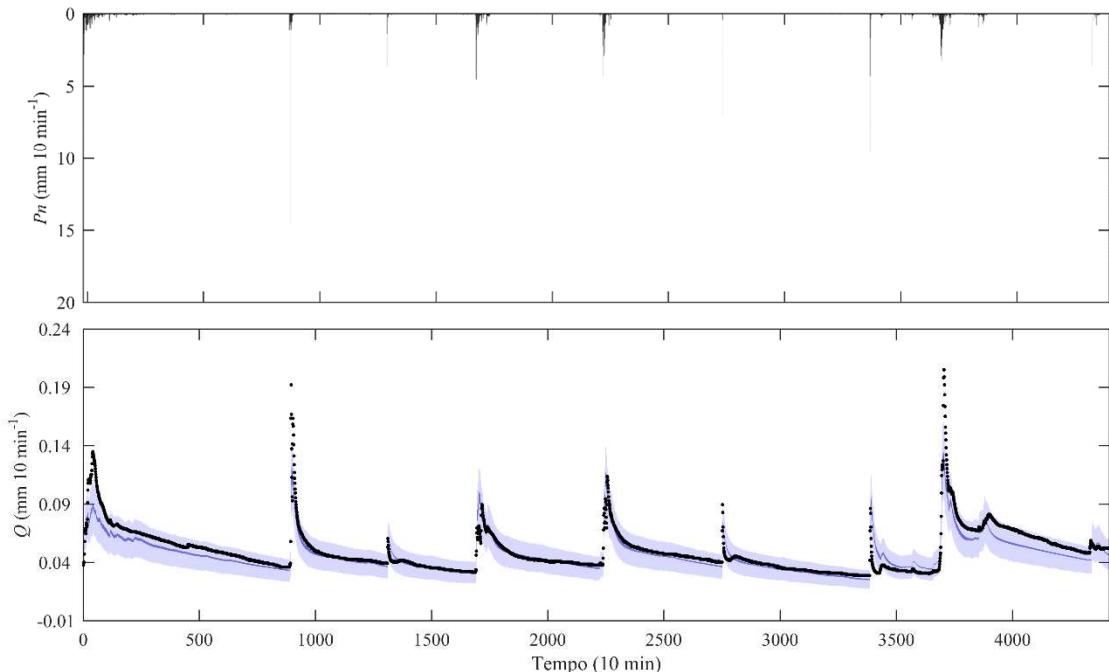
**Figura F7.** Série B. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, M11 (**parâmetros de interceptação fixos**) e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e chuva total como entrada.



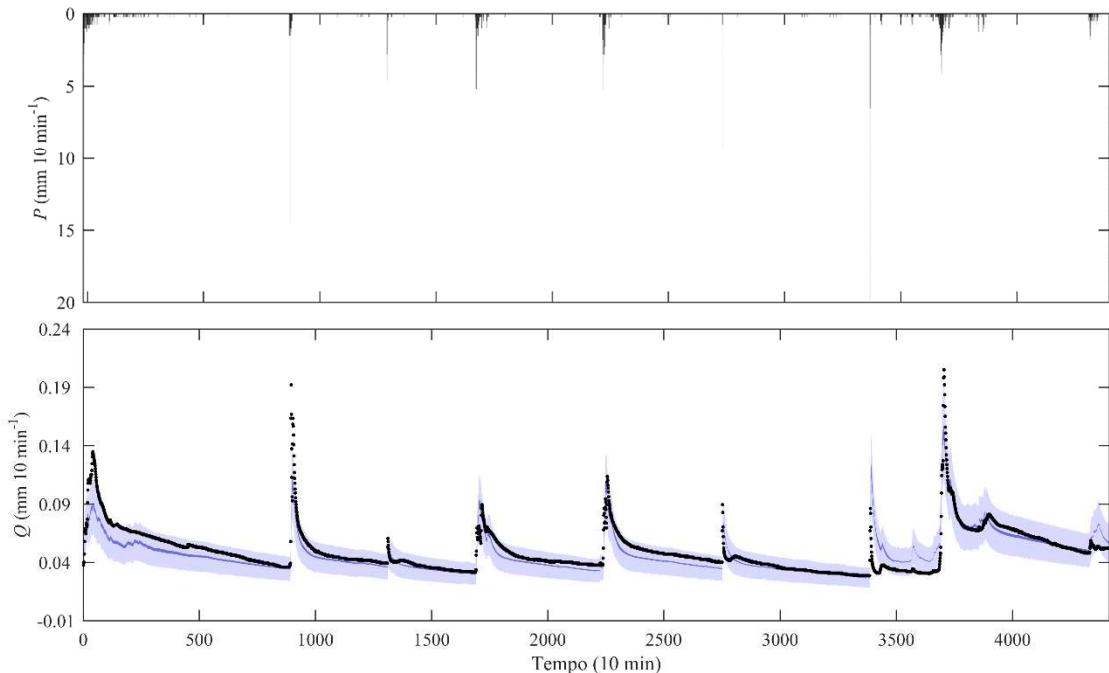
**Figura F8.** Série B. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (parâmetros de interceptação calibrados)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.



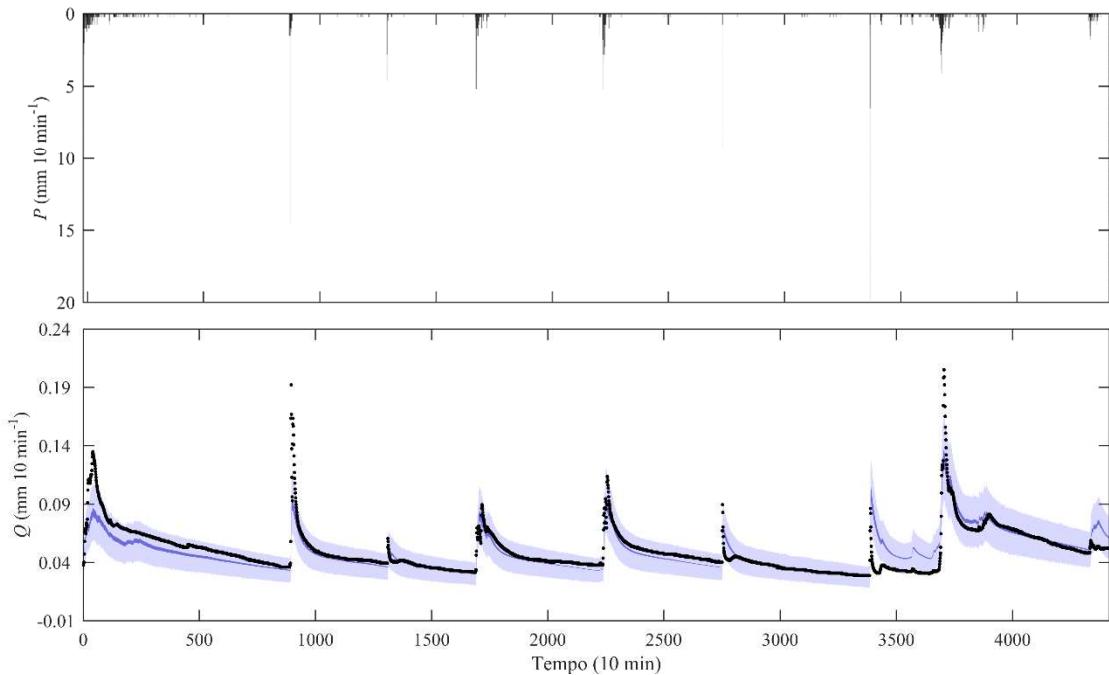
**Figura F9.** Série C. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.



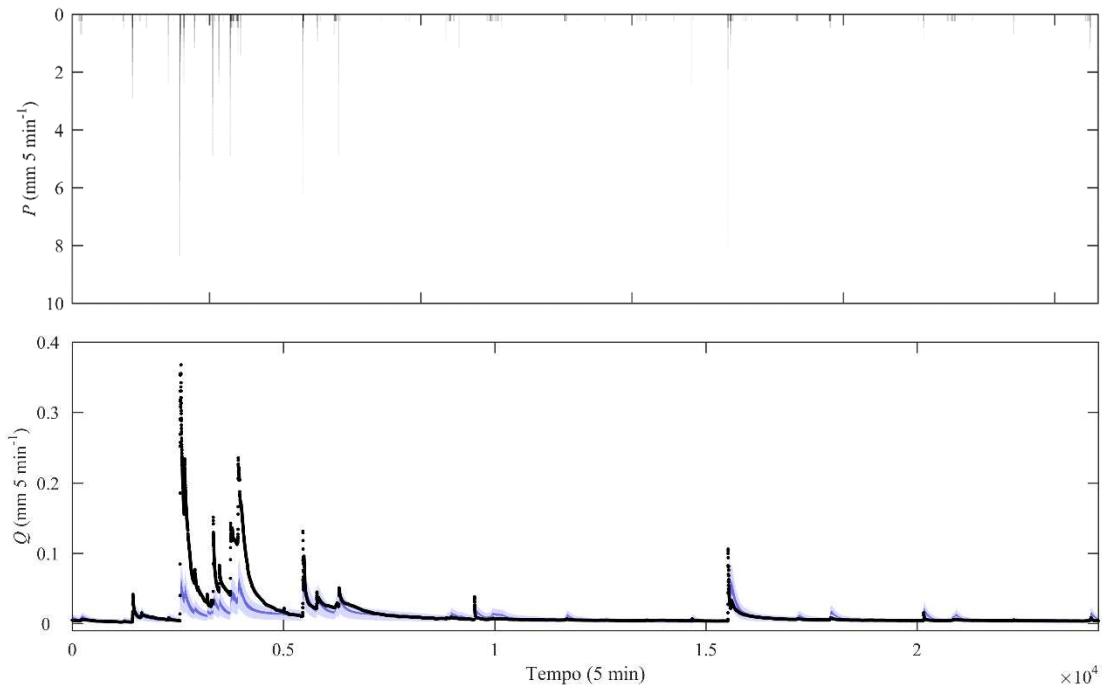
**Figura F10.** Série C. Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (sem reservatório de interceptação)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva líquida** como entrada.



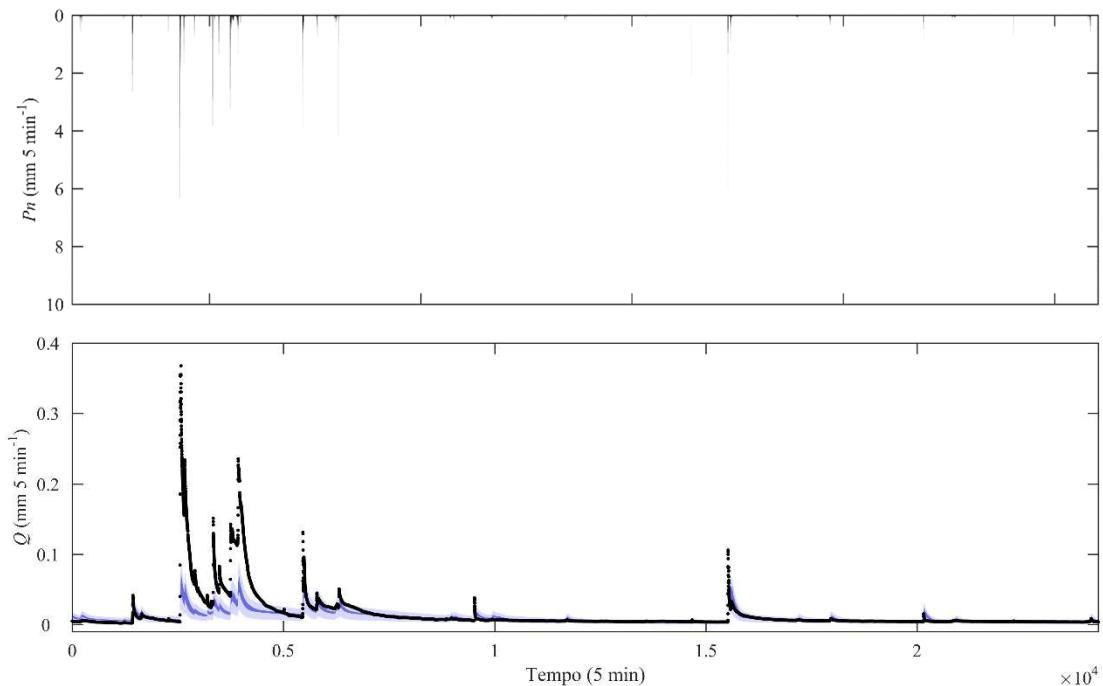
**Figura F11.** Série C. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (parâmetros de calibração fixos)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.



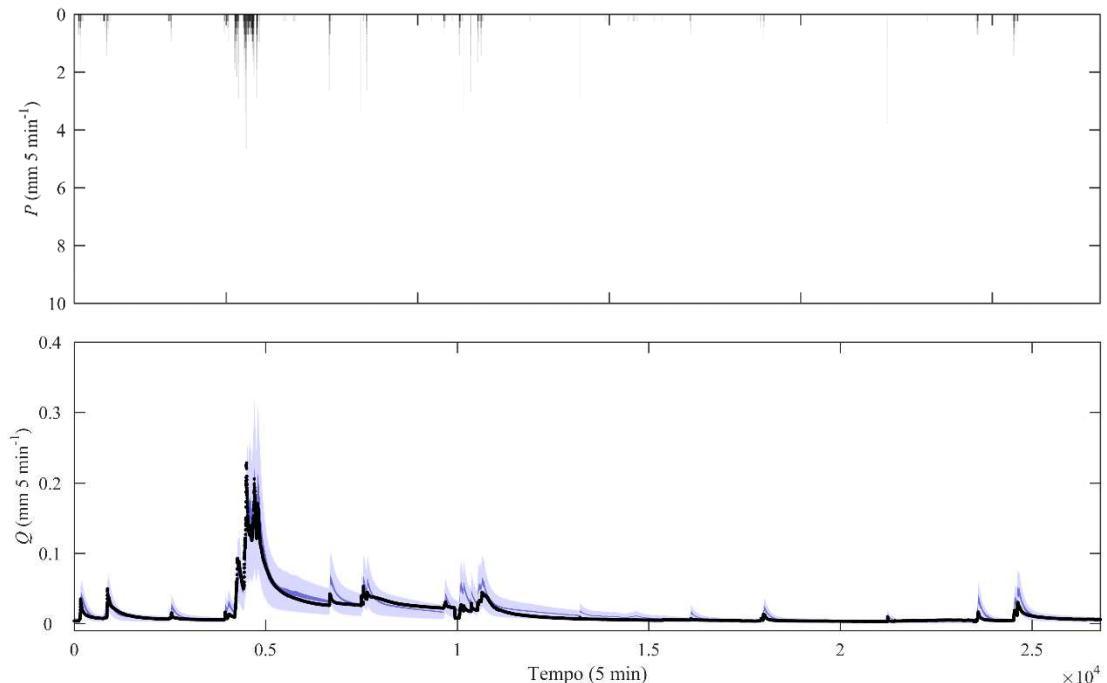
**Figura F12.** Série C. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Saci. Calibração realizada com L3, **M11 (parâmetros de interceptação calibrados)** e dados de vazão da série completa com decimação igual a 6 (um dado a cada hora) e **chuva total** como entrada.



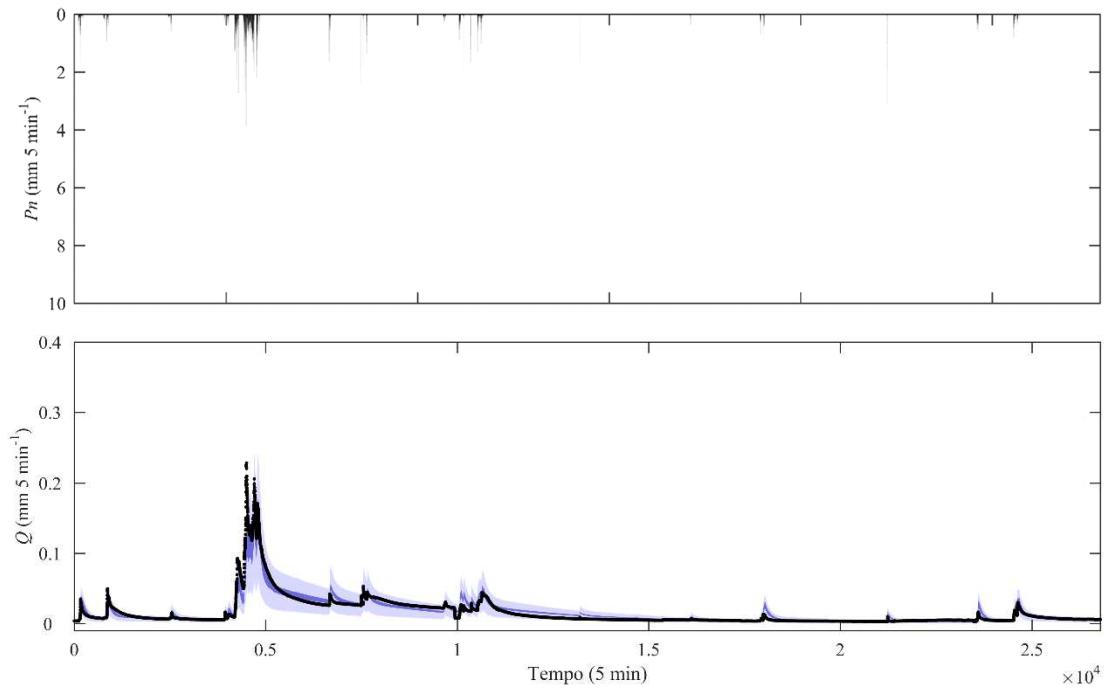
**Figura F13.** Série A. Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia) e chuva total como entrada.



**Figura F14.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia) e chuva líquida como entrada.



**Figura F15.** Painel superior: série de chuva total ( $P$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia) e chuva total como entrada.



**Figura F16.** Painel superior: série de chuva líquida ( $P_n$ ). Painel inferior: série de vazão observada (círculos pretos), faixa de 90% de incerteza (azul claro) e incerteza associada aos valores dos parâmetros (azul escuro) para a bacia do rio Araponga. Calibração realizada com dados de vazão da série completa com decimação igual a 288 (um dado a cada dia) e chuva líquida como entrada.



## APÊNDICE G

### IMPLEMENTAÇÃO DOS MODELOS DE INTERCEPTAÇÃO

S01



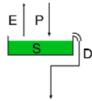
**S01**

```
function [TFsim] = MI01(x)

config

% Atribuição dos valores dos parâmetros
a = x(1);

TFsim = a.*P;
```

S02D01**S02**

```

function [TFsim,Si] = MI02_D01_EE(x)

config

% Atribuição dos valores dos parâmetros
Simax = x(1); Ce = x(2);

% Pré-alocação de espaço
Si = zeros(tmax,1);
Qi = zeros(tmax,1); q = zeros(dt_in/dt,1);

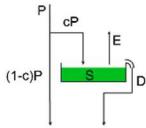
% Inicialização dos reservatórios
Si_Dt = S0;

% Reservatório de interceptação
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Si_Dt,q(kk)] =
    IR_D01_EE(Si_Dt,P(t),Ep(t),Simax,Ce,m,Dt);
    end
    Qi(t) = mean(q); % total do passo de tempo
    Si(t) = Si_Dt;    % armazenamento no final do passo de tempo

end
D = Qi;

TFsim = D;
  
```

S03D01**S03**

```

function [TFsim, Si] = MI03_D01_EE(x)

config

% Atribuição dos valores dos parâmetros
c = x(1); Simax = x(2); Ce = x(3);

% Pré-alocação de espaço
Si = zeros(tmax,1);
Qi = zeros(tmax,1); q = zeros(dt_in/dt,1);

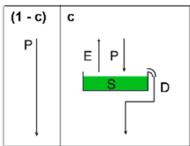
% Inicialização dos reservatórios
Si_Dt = S0;

% Reservatório de interceptação
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Si_Dt,q(kk)] =
IR_D01_EE(Si_Dt,c*P(t),Ep(t),Simax,Ce,m,Dt);
    end
    Qi(t) = mean(q); % total do passo de tempo
    Si(t) = Si_Dt;    % armazenamento no final do passo de tempo
end
D = Qi;

TFsim = (1-c).*P + D;

```

S04D01**S04**

```

function [TFsim, Si] = MI04_D01_EE(x)

config

% Atribuição dos valores dos parâmetros
c = x(1); Simax = x(2); Ce = x(3);

% Pré-alocação de espaço
Si = zeros(tmax,1);
Qi = zeros(tmax,1); q = zeros(dt_in/dt,1);

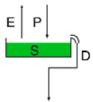
% Inicialização dos reservatórios
Si_Dt = S0;

% Reservatório de interceptação
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Si_Dt,q(kk)] =
IR_D01_EE(Si_Dt,P(t),Ep(t),Simax,Ce,m,Dt);
        End
        Qi(t) = mean(q); % total do passo de tempo
        Si(t) = Si_Dt;    % armazenamento no final do passo de tempo
    end
D = Qi;

TFsim = (1-c).*P + c.*D;

```

S02D02**S02**

```

function [TFsim, Si] = MI02_D02_EE(x)

config

% Atribuição dos valores dos parâmetros
Simax = x(1); Ce = x(2); b = x(3);

% Pré-alocação de espaço
Si = zeros(tmax,1);
Qi = zeros(tmax,1); q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Si_Dt = S0;

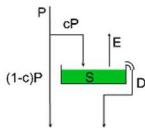
% Reservatório de interceptação
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Si_Dt,q(kk)] =
IR_D02_EE(Si_Dt,P(t),Ep(t),Simax,Ce,b,m,Dt);
    end
    Qi(t) = mean(q); % total do passo de tempo
    Si(t) = Si_Dt;    % armazenamento no final do passo de tempo

end
D = Qi;

TFsim = D;

```

S03D02**S03**

```

function [TFsim, Si] = MI03_D02_EE(x)

config

% Atribuição dos valores dos parâmetros
c = x(1); Simax = x(2); Ce = x(3); b = x(4);

% Pré-alocação de espaço
Si = zeros(tmax,1);
Qi = zeros(tmax,1); q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Si_Dt = S0;

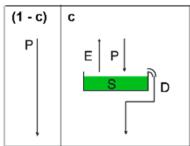
% Reservatório de interceptação
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Si_Dt,q(kk)] =
IR_D02_EE(Si_Dt,c*P(t),Ep(t),Simax,Ce,b,m,Dt);
    end
    Qi(t) = mean(q); % total do passo de tempo
    Si(t) = Si_Dt;    % armazenamento no final do passo de tempo

end
D = Qi;

TFsim = (1-c).*P + D;

```

S04D02**S04**

```

function [TFsim, Si] = MI04_D02_EE(x)

config

% Atribuição dos valores dos parâmetros
c = x(1); Simax = x(2); Ce = x(3); b = x(4);

% Pré-alocação de espaço
Si = zeros(tmax,1);
Qi = zeros(tmax,1); q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Si_Dt = S0;

% Reservatório de interceptação
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Si_Dt,q(kk)] =
IR_D02_EE(Si_Dt,P(t),Ep(t),Simax,Ce,b,m,Dt);
    end
    Qi(t) = mean(q); % total do passo de tempo
    Si(t) = Si_Dt;    % armazenamento no final do passo de tempo
end
D = Qi;

TFsim = (1-c).*P + c.*D;

```

## RESERVATÓRIO COM DRENAGEM D01

```
function [S_Dt,Q,E] = IR_D01_EE(S0,P,Ep,Smax,Ce,m,Dt)
% IR - Euler explícito

Sx = min(S0/Smax,1);
Q = P*fh(Sx,m);
E = Ce*Ep*fm(Sx,m);

S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
if S_Dt < 0
    E = 0;
    S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
end
```

## RESERVATÓRIO COM DRENAGEM D02

```
function [S_Dt,D,E] = IR_D02_EE(S0,P,Ep,Smax,Ce,b,m,Dt)
% IR - Euler explícito

Sx = min(S0/Smax,1);
E = Ce*Ep*fm(Sx,m);

D = max(b*(S0 - Smax),0);

S_Dt = S0 + Dt*P - Dt*D - Dt*E;
if S_Dt < Smax
    D = 0;
    S_Dt = S0 + Dt*P - Dt*D - Dt*E;
    if S_Dt < 0
        E = 0;
        S_Dt = S0 + Dt*P - Dt*D - Dt*E;
    end
end
```

## FUNÇÕES AUXILIARES

```
function f = fh(x,m)
f = 1 - (1-x).* (1+m) ./ (1-x+m);

function f = fm(x,m)
f = x.* (1+m) ./ (x+m);
```



## APÊNDICE H

### IMPLEMENTAÇÃO DOS MODELOS CHUVA-VAZÃO

#### MODELO M01



#### M01

```

function [Qt] = M01(x)
% M01

% Atribuição dos valores dos parâmetros
Ce = x(1); Kf = x(2); alpha = x(3);

config

% Pré-alocação de espaço
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Sf_Dt = S0;

% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] =
    end
    R01(Sf_Dt,Pt(t),Ep(t),Kf,alpha,Ce,m,Dt);
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt; % armazenamento no final do passo de tempo
end
Qt = Qf;

```

## MODELO M03



### M03

```

function [Qt] = M03(x)
% M03

% Atribuição dos valores dos parâmetros
Ce = x(1); Sumax = x(2); Kf = x(3); alpha = x(4);

config

% Pré-alocação de espaço
Su = zeros(tmax,1); Qu = zeros(tmax,1);
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Su_Dt = S0; Sf_Dt = S0;

% Reservatório da zona não-saturada (UR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Su_Dt,q(kk)] = R02(Su_Dt,Pt(t),Ep(t),Sumax,Ce,m,Dt);
    end
    Qu(t) = mean(q); % vazão total do passo de tempo
    Su(t) = Su_Dt;    % armazenamento no final do passo de tempo

end
Pf = Qu;

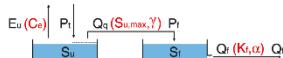
% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R03(Sf_Dt,Pf(t),Kf,alpha,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt;    % armazenamento no final do passo de tempo

end
Qt = Qf;

```

## MODELO M04



### M04

```

function [Qt] = M04(x)
% M04

% Atribuição dos valores dos parâmetros
Ce = x(1); Sumax = x(2); gamma = x(3); Kf = x(4); alpha = x(5);

config

% Pré-alocação de espaço
Su = zeros(tmax,1); Qu = zeros(tmax,1);
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Su_Dt = S0; Sf_Dt = S0;

% Reservatório da zona não-saturada (UR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Su_Dt,q(kk)] =
    R04(Su_Dt,Pt(t),Ep(t),Sumax,gamma,Ce,m,Dt);
    end
    Qu(t) = mean(q); % vazão total do passo de tempo
    Su(t) = Su_Dt;    % armazenamento no final do passo de tempo

end
Pf = Qu;

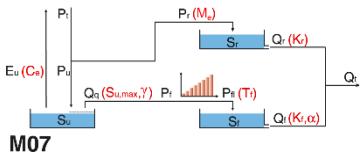
% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R03(Sf_Dt,Pf(t),Kf,alpha,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt;    % armazenamento no final do passo de tempo

end
Qt = Qf;

```

## MODELO M07



M07

```

function [Qt] = M07(x)
% M07

% Atribuição dos valores dos parâmetros
Ce = x(1); Sumax = x(2); gamma = x(3); Me = x(4); Kr = x(5); Tf
= x(6); Kf = x(7); alpha = x(8);

config

% Pré-alocação de espaço
Su = zeros(tmax,1); Qu = zeros(tmax,1);
Sr = zeros(tmax,1); Qr = zeros(tmax,1);
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Su_Dt = S0; Sr_Dt = S0; Sf_Dt = S0;

Pr = Me*Pt;
Pu = (1-Me)*Pt;

% Reservatório da zona ripária (RR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sr_Dt,q(kk)] = R03(Sr_Dt,Pr(t),Kr,1,Dt);
    end
    Qr(t) = mean(q); % vazão total do passo de tempo
    Sr(t) = Sr_Dt;    % armazenamento no final do passo de tempo
end

% Reservatório da zona não-saturada (UR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Su_Dt,q(kk)] =
R04(Su_Dt,Pu(t),Ep(t),Sumax,gamma,Ce,m,Dt);
    end
    Qu(t) = mean(q); % vazão total do passo de tempo
    Su(t) = Su_Dt;    % armazenamento no final do passo de tempo
end
Pf = Qu;

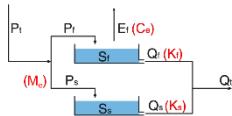
```

```
% Função de propagação
Weigths = Weigfun(Tf);
Pfl = conv(Pf,Weigths);
Pfl = Pfl(1:tmax);

% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R03(Sf_Dt,Pfl(t),Kf,alpha,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt; % armazenamento no final do passo de tempo

end
Qt = Qr + Qf;
```

MODELO M08**M08**

```

function [Qt] = M08(x)
% M08

% Atribuição dos valores dos parâmetros
Ce = x(1); Kf = x(2); Ms = x(3); Ks = x(4);

config

% Pré-alocação de espaço
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
Ss = zeros(tmax,1); Qs = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Sf_Dt = S0; Ss_Dt = S0;

Pf = (1-Ms)*Pt;
Ps = Ms*Pt;

% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R01(Sf_Dt,Pf(t),Ep(t),Kf,1,Ce,m,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt; % armazenamento no final do passo de tempo

end

% Reservatório lento (SR)
for t=1:tmax

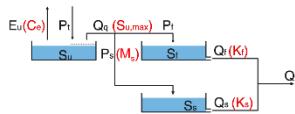
    for kk = 1:(dt_in/dt)
        [Ss_Dt,q(kk)] = R04(Ss_Dt,Ps(t),Ks,1,Dt);
    end
    Qs(t) = mean(q); % vazão total do passo de tempo
    Ss(t) = Ss_Dt; % armazenamento no final do passo de tempo

end

Qt = Qf + Qs;

```

## MODELO M09



**M09**

```

function [Qt] = M09(x)
% M09

% Atribuição dos valores dos parâmetros
Ce = x(1); Sumax = x(2); Kf = x(3); Ms = x(4); Ks = x(5);

config

% Pré-alocação de espaço
Su = zeros(tmax,1); Qu = zeros(tmax,1);
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
Ss = zeros(tmax,1); Qs = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Su_Dt = S0; Sf_Dt = S0; Ss_Dt = S0;

% Reservatório da zona não-saturada
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Su_Dt,q(kk)] = R05(Su_Dt,Pt(t),Ep(t),Sumax,1,Ce,m,Dt);
    end
    Qu(t) = mean(q); % vazão total do passo de tempo
    Su(t) = Su_Dt;    % armazenamento no final do passo de tempo

end
Pf = (1-Ms)*Qu;
Ps = Ms*Qu;

% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R04(Sf_Dt,Pf(t),Kf,1,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt;    % armazenamento no final do passo de tempo

end

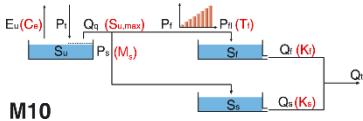
% Reservatório lento (SR)
for t=1:tmax

    for kk = 1:(dt_in/dt)

```

```
[Ss_Dt,q(kk)] = R04(Ss_Dt,Ps(t),Ks,1,Dt);  
end  
Qs(t) = mean(q); % vazão total do passo de tempo  
Ss(t) = Ss_Dt;    % armazenamento no final do passo de tempo  
  
end  
Qt = Qf + Qs;
```

## MODELO M10



```

function [Qt] = M10(x)
% M10

% Atribuição dos valores dos parâmetros
Ce = x(1); Sumax = x(2); Tf = x(3); Kf = x(4); Ms = x(5); Ks =
x(6);

config

% Pré-alocação de espaço
Su = zeros(tmax,1); Qu = zeros(tmax,1);
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
Ss = zeros(tmax,1); Qs = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Su_Dt = S0; Sf_Dt = S0; Ss_Dt = S0;

% Reservatório da zona não-saturada (UR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Su_Dt,q(kk)] = R05(Su_Dt,Pt(t),Ep(t),Sumax,1,Ce,m,Dt);
    end
    Qu(t) = mean(q); % vazão total do passo de tempo
    Su(t) = Su_Dt; % armazenamento no final do passo de tempo

end
Pf = (1-Ms)*Qu;
Ps = Ms*Qu;

% Função de propagação
Weigths = Weigfun(Tf);
Pfl = conv(Pf,Weigths);
Pfl = Pfl(1:tmax);

% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R04(Sf_Dt,Pfl(t),Kf,1,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt; % armazenamento no final do passo de tempo

end

```

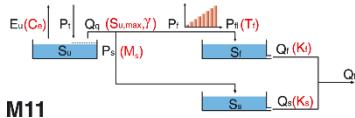
```
end

% Reservatório lento (SR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Ss_Dt,q(kk)] = R04(Ss_Dt,Ps(t),Ks,1,Dt);
    end
    Qs(t) = mean(q); % vazão total do passo de tempo
    Ss(t) = Ss_Dt;    % armazenamento no final do passo de tempo

end
Qt = Qf + Qs;
```

## MODELO M11



```

function [Qt] = M11(x)
% M11

% Atribuição dos valores dos parâmetros
Ce = x(1); Sumax = x(2); gamma = x(3); Tf = x(4); Kf = x(5); Ms
= x(6); Ks = x(7);

config

% Pré-alocação de espaço
Su = zeros(tmax,1); Qu = zeros(tmax,1);
Sf = zeros(tmax,1); Qf = zeros(tmax,1);
Ss = zeros(tmax,1); Qs = zeros(tmax,1);
q = zeros(dt_in/dt,1);

% Inicialização dos reservatórios
Su_Dt = S0; Sf_Dt = S0; Ss_Dt = S0;

% Reservatório da zona não-saturada (UR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Su_Dt,q(kk)] =
R05(Su_Dt,Pt(t),Ep(t),Sumax,gamma,Ce,m,Dt);
    end
    Qu(t) = mean(q); % vazão total do passo de tempo
    Su(t) = Su_Dt; % armazenamento no final do passo de tempo
end
Pf = (1-Ms)*Qu;
Ps = Ms*Qu;

% Função de propagação
Weigths = Weigfun(Tf);
Pfl = conv(Pf,Weigths);
Pfl = Pfl(1:tmax);

% Reservatório rápido (FR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Sf_Dt,q(kk)] = R04(Sf_Dt,Pfl(t),Kf,1,Dt);
    end
    Qf(t) = mean(q); % vazão total do passo de tempo
    Sf(t) = Sf_Dt; % armazenamento no final do passo de tempo
end
  
```

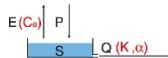
```
end

% Reservatório lento (SR)
for t=1:tmax

    for kk = 1:(dt_in/dt)
        [Ss_Dt,q(kk)] = R04(Ss_Dt,Ps(t),Ks,1,Dt);
    end
    Qs(t) = mean(q); % vazão total do passo de tempo
    Ss(t) = Ss_Dt;    % armazenamento no final do passo de tempo

end
Qt = Qf + Qs;
```

## RESERVATÓRIO R01



**R01**

```
function [S_Dt,Q] = R01(S0,P,Ep,K,alpha,Ce,m,Dt)
% R01 - Euler explícito

Q = K*S0^alpha;
E = Ce*Ep*fe(S0,m);

S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
if S_Dt < 0
    Q = 0;
    S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
    if S_Dt < 0
        E = 0;
        S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
    end
end
```

## RESERVATÓRIO R02



**R02**

```
function [S_Dt,Q,E] = R02(S0,P,Ep,Smax,Ce,m,Dt)
% R02 - Euler explícito

Sx = min(S0/Smax,1);
Q = P*fh(Sx,m);
E = Ce*Ep*fm(Sx,m);

S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
if S_Dt < 0
    Q = 0;
    S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
    if S_Dt < 0
        E = 0;
        S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
    end
end
```

## RESERVATÓRIO R03



R03

```
function [S_Dt,Q] = R03(S0,P,K,alpha,Dt)
% R03 - Euler explicito

Q = K*S0^alpha;

S_Dt = S0 + Dt*P - Dt*Q;
if S_Dt < 0
    Q = 0;
    S_Dt = S0 + Dt*P - Dt*Q;
end
```

## RESERVATÓRIO R04



R04

```
function [S_Dt,Q] = R04(S0,P,Ep,Sumax,gamma,Ce,m,Dt)
% R04 - Euler explicito

Sx = S0/Sumax;
Q = P*Sx^gamma;
E = Ce*Ep*fm(Sx,m);

S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
if S_Dt < 0
    Q = 0;
    S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
    if S_Dt < 0
        E = 0;
        S_Dt = S0 + Dt*P - Dt*Q - Dt*E;
    end
end
```

## FUNÇÕES AUXILIARES

```
function f = fe(x,m)
f = 1 - exp(-x/m);

function f = fh(x,m)
f = 1 - (1-x).* (1+m)./(1-x+m);

function f = fm(x,m)
f = x.* (1+m)./(x+m);
```